PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação Lato Sensu em Estatística para Ciências de Dados

Guilherme Tolotti Azevedo

MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉDITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T E MODELOS OCULTOS DE MARKOV

Belo Horizonte
Outubro de 2026

Guilherme Tolotti Azevedo

MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉDITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T E MODELOS OCULTOS DE MARKOV

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Estatística para Ciências de Dados, como requisito parcial à obtenção do título de Especialista.

Belo Horizonte
Outubro de 2026

SUMÁRIO

1. Introdução 4
2. Descrição do Problema e da Solução Proposta 4
3. Canvas Analítico 6
4. Coleta de Dados 7
5. Processamento/Tratamento de Dados 7
6. Análise e Exploração dos Dados 9
7. Aplicação de Modelos 10
8. Automatização do Pipeline de Dados 13
8.1 Definição da Ferramenta de Orquestração de Pipeline do Fluxo de Trabalho 13
8.2 Modelo do Fluxo de Trabalho 13
8.3 Códigos/telas 14
9. Discussão dos Resultados 15
10. Conclusão 18
11. Links 19
12. Referências 19

1. Introdução

A Estatística aplicada à Ciência de Dados estabelece métodos analíticos para estimar eventos sob incerteza quantitativa. No mercado de capitais, formulações baseadas em dados produzem estimativas probabilísticas para a precificação de ativos e a gestão de risco (Hull, 2012).

Nas séries temporais financeiras, a econometria tradicional foca na heteroce-dasticidade condicional por formulações de parâmetros fixos, ao passo que modelos de aprendizado profundo demandam históricos contínuos e volumosos. No mercado secundário brasileiro, contudo, a baixa liquidez impede a observação contínua de cotações, inviabilizando redes neurais densas.

Nesse cenário de negociações esparsas, a integração entre modelos econo-métricos (EGARCH-t) e aprendizado de máquina não supervisionado (K-Means e Modelos Ocultos de Markov) permite identificar regimes latentes com menor número de parâmetros e maior estabilidade de estimação.

O objetivo deste estudo é empregar essa integração metodológica para gerar sinais preventivos sobre a transição de títulos de crédito corporativo para estados de estresse, com foco nas debêntures, que apresentaram uma expansão de 307% entre 2020 e 2025, consolidando-se na captação corporativa (ANBIMA, 2026). Apesar desse crescimento, o mercado enfrenta baixa liquidez, conforme sintetizado por Sheng; Saito (2008), o segmento apresenta as seguintes características estruturais:

- As transações são dispersas e ocorrem em duas diferentes instituições: Bolsa de Valores de São Paulo (Bovespa Fix) e Sistema Nacional de Debêntures (SND);
- Existe baixa atividade, não havendo registro de transações para períodos longos e, em algumas emissões de debêntures, o volume de transações no mercado secun-dário é quase nulo e o valor total em reais é baixo;
- Existe um baixo número de negociações diárias;
- Predominância de debêntures de médio prazo (vencimento em torno de quatro anos);
- Demanda significativa por investidores institucionais e fundos de pensão;
- Em geral as emissões não são conversíveis em ações;
- Alguns investidores adquirem debêntures e as mantêm até o vencimento.

Esses traços persistem nos dados obtidos, com volumes diários concentrados abaixo de R$ 1 milhão e retenção até o vencimento (ANBIMA, 2026; Barra, 2021). Por outro lado, observa-se um alongamento dos prazos de emissão, visto que a amostra apresenta mediana de sete anos até o vencimento. Com prazos mais longos e baixa liquidez secundária, a identificação de regimes latentes ajuda a detectar aumentos de risco antes de quedas acentuadas nos preços.

2. Descrição do Problema e da Solução Proposta

2.1 O Problema de Pesquisa

A modelagem de crédito evoluiu de escores contábeis (Altman, 1968) e modelos estruturais (Merton, 1974) para modelos de forma reduzida (Duffie; Singleton, 2003). Contudo, dados contábeis possuem defasagem temporal de divulgação, enquanto modelos de intensidade assumem negociação contínua. No mercado de debêntures brasileiro, o prêmio de iliquidez sobrepõe-se frequentemente ao risco de inadimplência (Corrêa; Sheng, 2010), o que gera descontinuidades de preços (Bao; Pan; Wang, 2011). Casos recentes no mercado brasileiro ilustram esse comportamento, como as perdas de 50% em um pregão nas Lojas Americanas (90% na semana da recuperação judicial), deságios de até 70% no Grupo Pão de Açúcar e reprecificações abruptas na Light S.A.

Modelos tradicionais de risco apresentam limitações sob tais condições. Conforme aponta Jorion (2006), o VaR sob normalidade assume liquidez contínua e execução imediata ao preço em tela. Em momentos de estresse, a redução de liquidez dificulta a venda de posições sem descontos relevantes no preço. Além disso, o GARCH tradicional assume parâmetros estáticos (Tsay, 2005) e não captura quebras estruturais que demandam mudanças de regime (*Regime-Switching*) (Haas; Mittnik; Paolella, 2004; Hamilton, 1994). O problema compreende a modelagem estatística de crédito associada ao agrupamento não supervisionado de regimes para emissão de alertas antecipados (*Early Warning*).

2.2 Objetivos

O objetivo geral deste trabalho consiste em desenvolver e avaliar uma metodologia quantitativa de alerta antecipado para o mercado de debêntures brasileiro, voltada à detecção de transições latentes de regime para antecipar eventos de crédito e mitigar perdas patrimoniais. Os objetivos específicos compreendem: (i) padronizar o prêmio de risco reduzindo distorções de prazo via taxa ajustada ao vencimento; (ii) modelar a heterocedasticidade condicional e a assimetria dos retornos via AR(1)--EGARCH(1,1)-t; (iii) comparar o agrupamento estático (K-Means) à modelagem com dependência temporal (Gaussian HMM); (iv) verificar a calibração de cauda por testes de Kupiec e Christoffersen fora da amostra; e (v) avaliar as estratégias em *backtest* com custos de 50 bps, sob verificação de significância do retorno excedente por *Block Bootstrap*.

2.3 Solução Proposta

A solução proposta divide-se em duas etapas. Na primeira, realiza-se o tratamento dos dados da ANBIMA e estimam-se a volatilidade e as métricas de cauda (VaR e ES 99%) via EGARCH-t. Na segunda, essas variáveis alimentam classificadores não supervisionados que estratificam o risco em três regimes ordinais (Verde para baixo risco, Amarelo para alerta e Vermelho para crise), orientando a redução preventiva de exposição antes de reprecificações desfavoráveis.

3. Canvas Analítico

Apresenta-se o Canvas Analítico do projeto, estruturado em doze blocos estratégicos que sintetizam a formulação do problema, as bases de dados, as técnicas estatísticas aplicadas e os resultados esperados.

1. Problema de Negócio

Baixa liquidez e assimetria de retornos no mercado secundário de debêntures. Modelos tradicionais de risco (GARCH contínuo e VaR paramétrico) têm baixa aderência diante de saltos discretos e deságios acentuados em eventos de cauda.

2. Objetivo Analítico

Classificar regimes latentes de risco de crédito (Verde, Amarelo e Vermelho) e antecipar choques patrimoniais por meio de aprendizado de máquina não supervisionado com modelagem temporal.

3. Justificativa

Atrasos na detecção de deterioração de crédito dificultam a venda de posições em mercados pouco líquidos. Alertas antecipados reduzem perdas antes do agravamento do evento de crédito.

4. Stakeholders

Gestores de fundos de crédito privado, analistas de risco corporativo, comitês de alocação de ativos e tesourarias institucionais.

5. Variável-alvo (Target)

Regime latente de risco de crédito do ativo, classificado em Verde (Baixo Risco), Amarelo (Alerta) e Vermelho (Crise).

6. Variáveis de Entrada

Delta Spread diário, Taxa ajustada ao prazo ($\frac{S_t}{\ln(\mathrm{DU})}$), Volatilidade condicional EGARCH-t, Expected Shortfall (99%) e Z-Score móvel de 60 dias.

7. Fontes de Dados

Prévias públicas de negociação do sistema REUNE da ANBIMA, dados cadastrais via portal Debentures.com.br e séries macroeconômicas (CDI e IPCA) obtidas do Banco Central do Brasil por meio do pacote `python-bcb`.

8. Técnicas Estatísticas / ML

AR(1)-EGARCH(1,1)-t para volatilidade assimétrica; K-Means com agregação Borda Count; Gaussian HMM com regularização de Laplace e algoritmo de Viterbi; Ensemble ponderado.

9. Métricas de Avaliação

Validação estatística pelos testes de Kupiec POF e Christoffersen, combinada à avaliação financeira pelo Lead Time de antecipação, retorno acumulado líquido e p-valor via Block Bootstrap.

10. Entregáveis

Pacote Python modular (`credit_tail_analytics`), pipeline de dados automatizado, base histórica tratada, relatórios analíticos de backtest e repositório de código aberto.

11. Impacto Esperado

Mitigação de perdas acentuadas em eventos de estresse corporativo, contenção de custos de transação pelo filtro de ruído e retorno superior ao portfólio passivo (Buy and Hold) validado por teste estatístico.

12. Restrições e Riscos

Escassez de negociações diárias na maioria dos ativos, principalmente em períodos de estresse, custos operacionais de giro (50 bps) e alternância excessiva entre estados (flickering).

4. Coleta de Dados

A modelagem de risco necessita de dados observados de negociação, em especial em crédito privado, para evitar preços teóricos marcados na curva, uma vez que as cotações de negócios efetivos refletem o prêmio de risco praticado no mercado, reduzem a dependência de premissas de continuidade de preços em ativos pouco líquidos e registram os pregões em que ocorrem descontos relevantes nas cotações. A base empírica unifica três fontes públicas nacionais, compreendendo as transações do mercado secundário de debêntures extraídas do sistema REUNE da ANBIMA (2.112 pregões entre 02/01/2018 e 10/07/2026), características cadastrais obtidas via portal Debentures.com.br e ANBIMA Data (pacote `debentures_dot_com`), e séries macroeconômicas diárias (taxa DI, Selic e inflação IPCA) coletadas via API do Banco Central do Brasil (`python-bcb`) (Freitas, 2024).

As séries utilizadas possuem preços unitários, taxas de spread negociadas, prazos até o vencimento e volumes negociados de debêntures corporativas, confrontados com as taxas livres de risco da economia em um intervalo contínuo entre janeiro de 2018 e julho de 2026, que foi dividido em duas etapas metodológicas, sendo a primeira o período de treinamento (*In-Sample*, 2018 a 2022) e a segunda o período de validação e teste (*Out-of-Sample*, 2023 a 2026).

4.1 Dicionário de Dados

A base consolidada unifica registros de negociação, cadastro e macroeconômicos. A Tabela 1 descreve os atributos utilizados nas etapas de tratamento e modelagem.

Nome do dataset: Base Consolidada de Negociação de Debêntures e Séries Macroeconômicas
Descrição: Registros de negócios secundários (ANBIMA REUNE), dados cadastrais (Debentures.com.br) e indicadores do BACEN (SGS).
Link: https://github.com/gtazevedo/credit-tail-analytic

Nome do Atributo	Descrição	Tipo
`data`	Data de referência do pregão de negociação	Date
`ticker`	Código de negociação do ativo na CETIP/B3 (ex.: CBRDA8)	String
`taxa_min/med/max`	Taxas anualizadas de spread mínima, média e máxima praticadas no dia	Float
`pu_min/med/max`	Preços unitários mínimo, médio e máximo observados no pregão	Float
`faixa_volume`	Classificação de liquidez ANBIMA (Faixas 1, 2 e 3)	String
`indexador`	Indexador contratual da emissão (DI+, IPCA+, Pré)	String
`du_vencimento`	Dias úteis restantes até a data de vencimento do título	Integer
`cdi_anual`	Taxa média diária anualizada do CDI divulgada pelo BACEN	Float
`delta_spread`	Primeira diferença do spread de crédito diário	Float
`taxa_prazo`	Spread anualizado ajustado pelo logaritmo do prazo útil	Float

Tabela 1: Dicionário de Atributos da Base Consolidada de Negociação de Debêntures.

5. Processamento/Tratamento de Dados

O tratamento dos dados de negociação mitiga distorções de baixa liquidez e multiplicidade de indexadores contratuais. A base foi dividida em dois intervalos complementares, o primeiro, *In-Sample* (02/01/2018 a 30/12/2022), utilizado para cali-

bração econométrica e inferência de regimes, e o segundo *Out-of-Sample* (02/01/2023 a 10/07/2026), para validação preditiva e simulação tática.

5.1 Divisão Temporal e Filtro de Iliquidez

No sistema REUNE/ANBIMA, o volume diário é estratificado em faixas ordinais (Faixa 3 para volumes até R$ 1 milhão). Para excluir ativos com negociação esparsa no treino, foram removidos títulos sem negócios em 95% ou mais dos pregões *In-Sample*, prevenindo distorções na persistência da variância do EGARCH. O filtro incidiu apenas no treino, exceto pela debênture RDVT11, excluída integralmente por variações extremas decorrentes de recuperação judicial.

5.2 Harmonização de Taxas e Engenharia de Atributos

A base abrange debêntures atreladas a percentual do CDI, DI+ e IPCA+. Em títulos a percentual do CDI, a taxa foi convertida em spread equivalente anual sobre a taxa livre de risco (S_t). Em contratos IPCA+ e DI+, a taxa contratual corresponde diretamente ao prêmio bruto ($S_t = \mathrm{Taxa}_t$). A partir do spread harmonizado, calcularam-se a primeira diferença ($\Delta S_t = S_t - S_{t-1}$), a taxa ajustada ao prazo ($\frac{S_t}{\ln(\max(\mathrm{DU},2))}$), a amplitude diária ($S_{\mathrm{range}} = \mathrm{Taxa}_{\max} - \mathrm{Taxa}_{\min}$), a assimetria intraday (S_{skew}) e o Z-Score causal móvel de 60 dias, detalhados na Subseção Seção 5.4.

5.3 Tratamento de Discrepâncias e Normalização

Aplicou-se winsorização bilateral nos percentis 1% e 99%, calibrada no *In-Sample* e replicada no *Out-of-Sample* para evitar viés prospectivo (*look-ahead bias*). O escalonamento adotou o `RobustScaler` (Rousseeuw; Hubert, 2011), que subtrai a mediana e divide os valores pelo intervalo interquartil (IQR), com piso de 10% do IQR mediano para prevenir indeterminações numéricas.

5.4 Implementação em Código-Fonte

As rotinas de tratamento e transformação concentram-se em `preprocessor.py`:

```
# Harmonização de spread equivalente, prazo e dispersão (preprocessor.py)
spread_pct = ((((1 + cdi / 100.0) ** (1 / 252) - 1) * (taxa / 100.0) + 1) ** 252 - 1) * 100.0
- cdi
df['Spread_Equivalente'] = np.where(is_pct, spread_pct, np.where(is_puro, taxa, taxa - cdi))
df['Taxa_Ajustada_Prazo'] = df['Spread_Equivalente'] / np.log(np.maximum(df['DU_Vencimento'],
2))
df['Taxa_ZScore'] = ((df['Spread_Equivalente'] - roll.mean().values) / roll.std().replace(0,
np.nan).values).fillna(0.0)
```

6. Análise e Exploração dos Dados

A análise exploratória avaliou o comportamento empírico dos spreads e testou premissas estatísticas necessárias para fundamentar a modelagem econométrica, orientando o diagnóstico de estacionariedade e a seleção do subconjunto ideal de variáveis para os algoritmos de agrupamento.

6.1 Propriedades Estatísticas e Diagnóstico de Cauda

As séries históricas de retornos de spread exibem desvios acentuados em relação à normalidade. No período *In-Sample*, as variações diárias apresentaram excesso de curtose de $2.683,30$, indicando eventos extremos e caudas pesadas que afastam a hipótese de distribuição gaussiana. Todavia, a variável padronizada `Taxa_ZScore`, resultante do filtro causal, reduziu o excesso de curtose para $1,18$. A Tabela 2 apresenta as estatísticas descritivas das variáveis selecionadas para o espaço de estados no período *In-Sample* (2018 a 2022).

Variável	Média	Desv. Padrão	Mediana	Q1 (25%)	Q3 (75%)	Assimetria	Exc. Curtose
Taxa_ZScore	0,114	1,241	0,000	−0,743	0,905	0,45	1,18
Volatilidade_EGARCH	14,329	162,051	0,299	0,200	0,466	22,87	750,45
Expected_Shortfall_99	0,406	11,720	0,966	0,583	1,000	−52,42	3.477,60

Tabela 2: Estatísticas Descritivas das Variáveis Selecionadas no Período In-Sample (2018 a 2022).

O afastamento entre médias e medianas nas variáveis de volatilidade e cauda quantifica a assimetria gerada por variações discretas e pouco frequentes nas cotações. A variável `Taxa_ZScore` apresenta excesso de curtose moderado ($1,18$), situado no intervalo $[-2,+2]$ indicado por Hair et al. (2010) para premissas de normalidade assintótica, o que favorece a convergência na estimação das matrizes de covariância do HMM.

6.2 Teste de Estacionariedade dos Spreads (ADF)

A modelagem de volatilidade condicional pressupõe séries estacionárias em covariância. Aplicou-se o Teste de Dickey-Fuller Aumentado (ADF) com intercepto e número de defasagens selecionado pelo critério AIC sobre as 529 debêntures para testar a hipótese nula de raiz unitária (H_0). A Tabela 3 apresenta os resultados por indexador ($\alpha = 5\%$).

Indexador	Total	Estacionárias (Delta Spread)	Taxa (%)	Spread Bruto
IPCA	286	275	96,2%	Não-Estacionário
CDI Spread	239	227	95,0%	Não-Estacionário
PRÉ	4	4	100,0%	Não-Estacionário
Total	**529**	**506**	**95,7%**	**Não-Estacionário**

Tabela 3: Resultados do Teste ADF ($\alpha = 5\%$) por Indexador.

O spread bruto (`Taxa_Ativo`) é não-estacionário em 91% dos casos (integrado de ordem 1). Após a primeira diferença (`Delta Spread`), 95,7% das séries rejeitam H_0 ao nível de 5%, validando a premissa de estacionariedade para o EGARCH. Os 3,4% restantes concentram títulos com histórico reduzido (30 a 60 pregões) e iliquidez acentuada.

6.3 Seleção de Variáveis por Contagem de Borda

A definição do subconjunto ideal de variáveis avaliou sete candidatas (`Taxa_ZScore`, `Volatilidade_EGARCH`, `VaR_99`, `Expected_Shortfall_99`, `Spread_Equivalente`, `Spread_Range_Intraday` e `Spread_Skew_Intraday`) via busca combinatória no período *In-Sample* (Saeys; Abeel; Peer, 2008). A partição foi avaliada por três métricas:

1. **Índice Silhouette** (*Silhouette Score*) (Rousseeuw, 1987): mede a coesão intra-*-cluster* frente à separabilidade inter-*cluster* em $[-1, 1]$, em que valores maiores denotam agrupamentos densos e bem delimitados;
2. **Índice Davies-Bouldin** (Davies; Bouldin, 1979): avalia a razão entre a dispersão intra-*cluster* e a distância euclidiana entre centroides, em que valores menores indicam particionamento ótimo;
3. **Índice Calinski-Harabasz** (Caliński; Harabasz, 1974): expressa a razão entre a variância inter-*cluster* e intra-*cluster* ponderada pelos graus de liberdade, em que magnitudes superiores refletem maior separação entre grupos.

Para mitigar divergências de ordenação entre métricas, utilizou-se o Método de Borda (*Borda Count*) (Borda, 1781; Ho; Hull; Srihari, 1994; Kittler et al., 1998), combinando as posições ordinais de cada métrica sem pesos arbitrários.

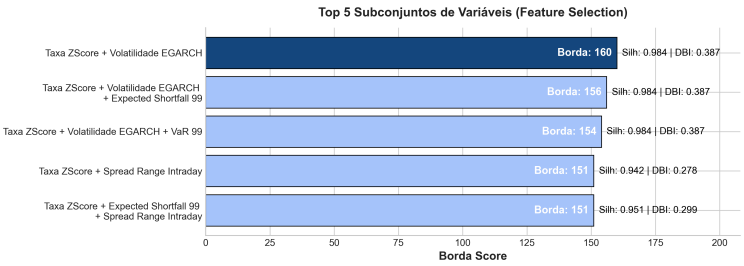


Figura 1: Ranking de Seleção de Variáveis pelo Método de Contagem de Borda.

O subconjunto selecionado incorporou `Taxa_ZScore`, `Volatilidade_EGARCH` e `Expected_Shortfall_99`, figurando em segundo lugar no ranking geral da Figura 1. A opção pelo trio justifica-se pela maior sensibilidade a perdas extremas, ao agregar uma variável de cauda quando comparado com o primeiro lugar. A preferencia pelo Expected Shortfall em relação ao VaR se deu pela primeira ser uma métrica coerente de risco, superior ao VaR, conforme Artzner et al. (1999) e Acerbi; Tasche (2002).

6.4 Implementação em Código-Fonte

A rotina de agregação por Contagem de Borda (`feature_selection.py`) quantifica o poder de separação:

```
# Agregação determinística de Borda sobre métricas de partição (feature_selection.py)
r_sil, r_dbi = df['Silhouette_Score'].rank(ascending=False),
df['Davies_Bouldin'].rank(ascending=True)
r_ch = pd.Series(np.log1p(df['CH_Score'].fillna(0))).rank(ascending=False)
df['Borda_Score'] = (n + 1 - r_sil) + (n + 1 - r_dbi) + (n + 1 - r_ch)
subconjunto_eleito = df.sort_values('Borda_Score', ascending=False).iloc[0]
```

7. Aplicação de Modelos

A arquitetura analítica combina um modelo econométrico de volatilidade condicional a algoritmos de aprendizado de máquina para classificação de regimes, investigando o ganho marginal da dependência temporal em séries de crédito.

7.1 Modelagem Econométrica de Volatilidade (EGARCH-t)

Avaliaram-se 32 especificações da família GARCH (Bollerslev, 1986; Engle, 1982) combinando ordens AR(1), defasagens ($p, q \in \{1, 2\}$), funções de variância (GARCH, EGARCH, GJR, TARCH) e inovações Normal e t-Student. A seleção elegeu o modelo com menor AIC em 529 debêntures no período *In-Sample* ($W_j = \left(\sum \frac{I_{i,j}}{N}\right) \times 100$). A Figura 2 exibe o ranking médio das especificações avaliadas para o universo de debêntures ($N = 500$).

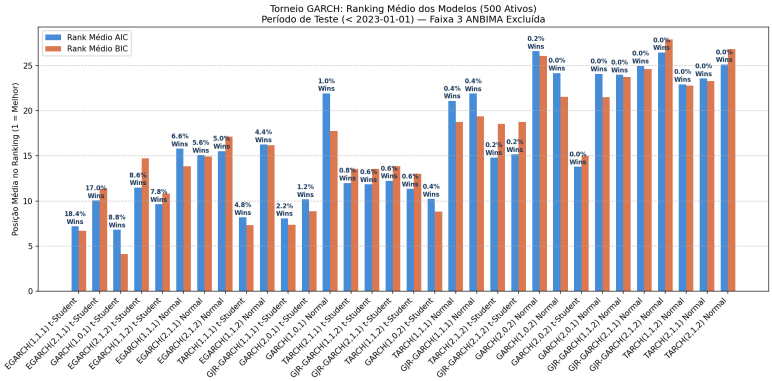


Figura 2: Ranking Comparativo de Modelos GARCH por Menor AIC ($N = 500$).

O modelo AR(1)-EGARCH(1,1) com inovação t-Student (Nelson, 1991) obteve a maior taxa de seleção nos grupos amplos, modelando a variância em escala logarítmica com sensibilidade assimétrica ($\gamma < 0$):

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \alpha(|z_{t-1}| - E[|z_{t-1}|]) + \gamma z_{t-1} \tag{1}$$

Para assegurar estabilidade numérica em séries com baixa liquidez, adotaram-se duas restrições analíticas: fixou-se um piso para os graus de liberdade em $\nu = \max(2.05, \nu_{\text{est}})$, condição necessária para a existência do segundo momento estatístico, além de um teto de volatilidade que retém $\sigma_{\text{est}}(t) = \sigma_{\text{est}}(t-1)$ quando a estimativa supera $20 \times P_{99}(\sigma_{\text{IS}})$. A Figura 3 confirma aprovação de 86,4% no teste de Ljung-Box e 94,9% no ARCH-LM ($\alpha = 5\%$).

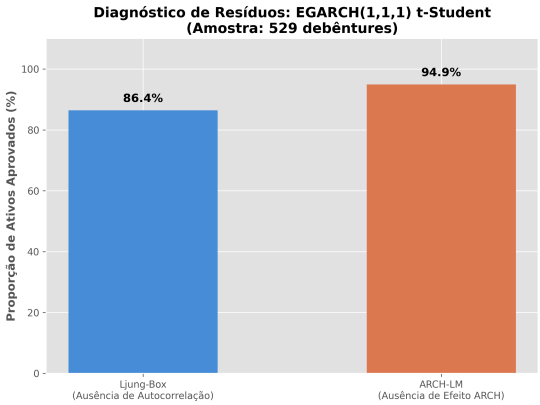


Figura 3: Taxa de aprovação dos testes de diagnóstico nos resíduos do EGARCH(1,1) t-Student.

7.2 Agrupamento Não Supervisionado: K-Means

O K-Means atua como linha de base estática (Bishop, 2006), particionando observações em $k = 3$ regimes via algoritmo de Lloyd. A fixação de $k = 3$ reflete a classificação ordinal de três níveis de criticidade adotada na gestão de crédito, recebendo confirmação empírica pelo *Elbow Method* e *Silhouette Score* (Figura 4). O *Label Switching* foi mitigado pela ordenação dos centroides segundo um vetor determinístico de polaridade de risco (volatilidade condicional e Z-Score).

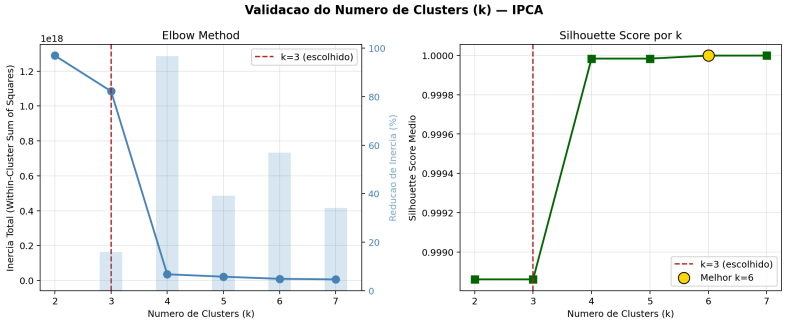


Figura 4: Elbow Method (Inércia Intra-Cluster) e Silhouette Score Médio por Número de Clusters (k).

7.3 Modelos Ocultos de Markov (HMM)

O modelo Gaussian HMM (Rabiner, 1989) incorpora a dependência temporal por meio de uma cadeia de Markov oculta de três estados ($P(S_t = j \mid S_{t-1} = i) = A_{ij}$), com parâmetros estimados pelo algoritmo de Baum-Welch (Baum et al., 1970). Para evitar estados absorventes, aplicou-se regularização de Laplace com piso de 1%:

$$P'_{ij} = \frac{C_{ij} + 1}{\sum_{k=1}^{3} C_{ik} + 3}, \quad P_{ij} = \frac{\max\left(P'_{ij}, 0.01\right)}{\sum_{k=1}^{3} \max(P'_{ik}, 0.01)} \tag{2}$$

A sequência mais provável de regimes foi obtida pelo algoritmo de Viterbi, enquanto as probabilidades filtradas de crise (`Prob_Crise_HMM`) foram calculadas pelo algoritmo Forward-Backward.

7.4 Modelo Ensemble

O modelo combinado integra a classificação estática do K-Means com a probabilidade de transição temporal do HMM (Ho; Hull; Srihari, 1994; Kittler et al., 1998). A ponderação foi otimizada por *Grid Search* visando maximizar o *Calmar Ratio* (Figura 5), métrica selecionada pela correlação de debêntures com o CDI e baixa dispersão diária de cotação.

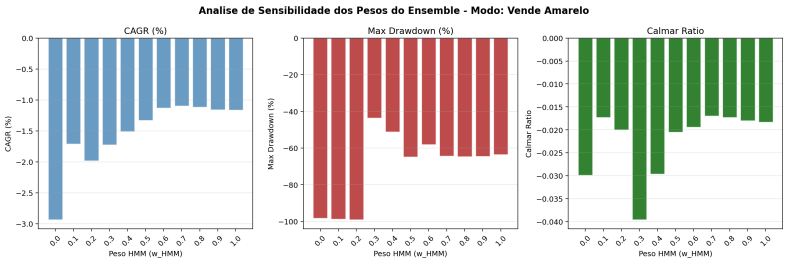


Figura 5: Análise de Sensibilidade dos pesos do Ensemble no período In-Sample.

A alocação ótima estabeleceu pesos de 70% para o HMM e 30% para o K-Means, com suavização por média móvel exponencial de 21 dias úteis, dada por: $\text{Score}_t = \text{EMA}_{21}(0.70 \times \text{Prob_Crise_HMM}_t + 0.30 \times \text{Prob_Crise_KMeans}_t)$.

7.5 Protocolos de Validação Operacional

O protocolo no período *Out-of-Sample* compreendeu duas fases. Inicialmente, realizou-se a validação estatística de cobertura incondicional de Kupiec (1995) e condicional de Christoffersen (1998) para o VaR a 99%. Em seguida, executou-se a simulação financeira (*backtest*) frente ao *Buy and Hold*, considerando custo de transação de 50 bps, quarentena mínima de 180 dias e remuneração de caixa a 100% do CDI.

7.6 Implementação em Código-Fonte

As rotinas de modelagem e restrições analíticas encontram-se em `volatility.py` e `regime.py`:

```
# Trava de graus de liberdade, VaR/ES analíticos e teto prudencial (volatility.py)
nu_es = max(res_is.params.get('nu', 5.0), 2.05)
q_t = stats.t.ppf(1 - alpha, df=nu)
es_pad = (stats.t.pdf(q_t, df=nu) / alpha * (nu + q_t**2) / (nu - 1)) / np.sqrt(nu_es / (nu_es
- 2))
var_99, es_99 = cond_mean + cond_vol * model.distribution.ppf(1 - alpha, nu), cond_mean +
cond_vol * es_pad
cond_vol = cond_vol.mask(cond_vol > max(np.nanpercentile(cond_vol.iloc[:split_idx], 99) *
20.0, 0.05)).ffill().bfill()

# Gaussian HMM com suavização de Laplace e piso estocástico (regime.py)
A = (trans_counts + 1.0) / (trans_counts + 1.0).sum(axis=1, keepdims=True)
hmm.transmat_ = np.maximum(A, 0.01) / np.maximum(A, 0.01).sum(axis=1, keepdims=True)
```

8. Automatização do Pipeline de Dados

Para assegurar que a coleta de dados, a estimação econométrica e as simulações de carteira sigam um fluxo padronizado, o projeto foi estruturado com práticas de DataOps e MLOps.

8.1 Definição da Ferramenta de Orquestração de Pipeline do Fluxo de Trabalho

A automação baseia-se no pacote modular `credit_tail_analytics`, gerenciado via `Poetry`. A estrutura garante a reprodutibilidade dos resultados por meio de versões fixas de pacotes e sementes pseudoaleatórias, viabilizando a execução local sem dependência de serviços em nuvem e permitindo acoplamento futuro com Airflow ou MLflow.

8.2 Modelo do Fluxo de Trabalho

O fluxo de atividades compreende etapas sequenciais integradas, desde a ingestão até a auditoria financeira (Figura 6).

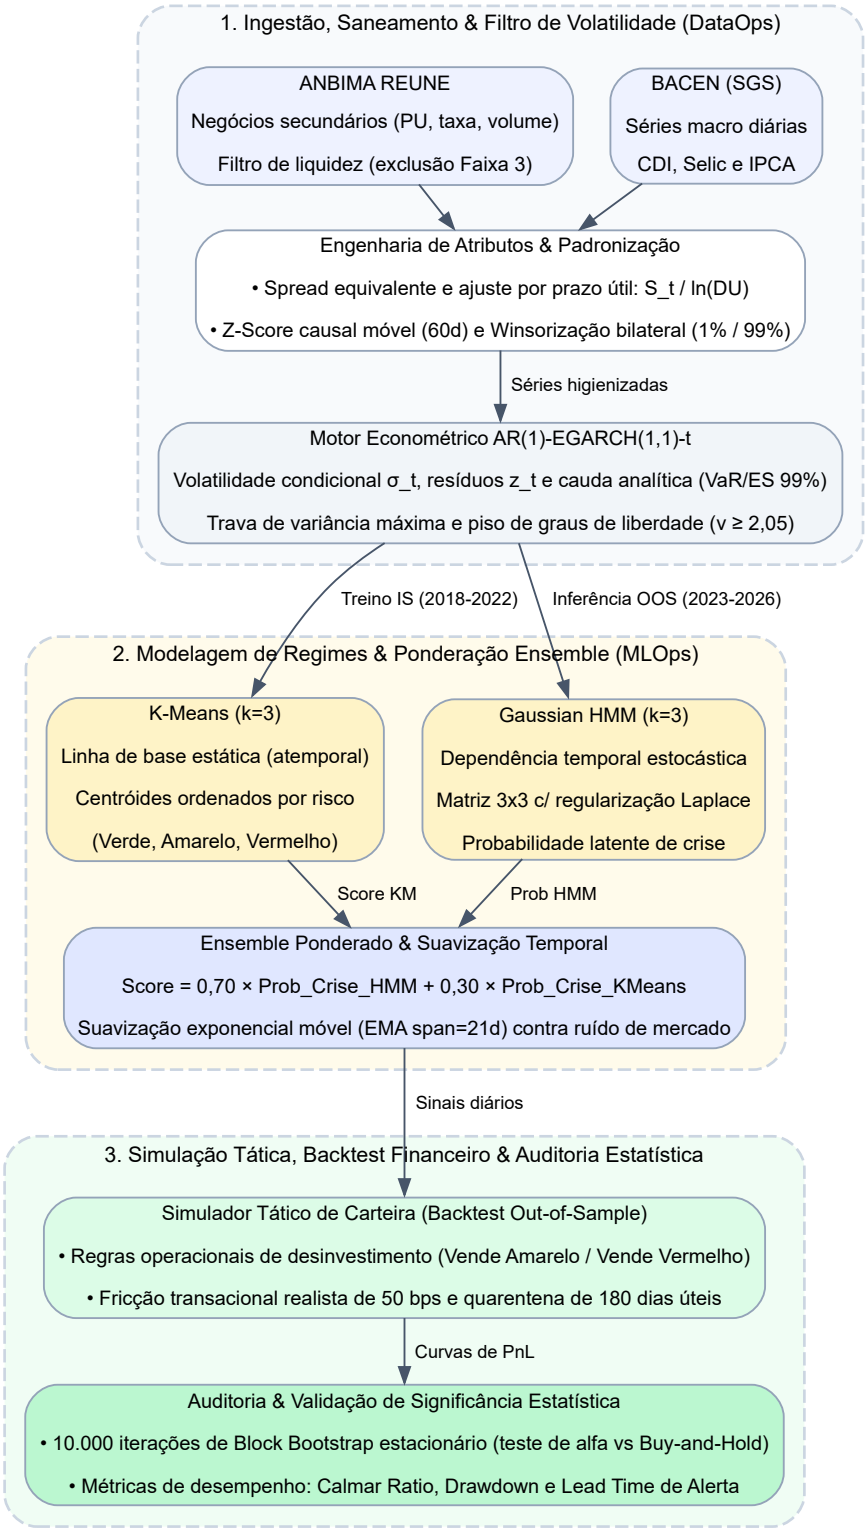


Figura 6: Diagrama do Fluxo de Atividades do Pipeline de Risco e Backtest.

O processamento divide-se em três módulos sequenciais: ingestão e estimação do EGARCH-t com dados ANBIMA e BACEN; calibração dos modelos K-Means e HMM com cômputo da pontuação do ensemble; e execução do backtest financeiro com validação por Block Bootstrap (10.000 iterações).

8.3 Códigos/telas

A estrutura é modularizada em `data/` (coleta e cadastro), `models/` (volatilidade e regimes), `analysis/` (backtest e bootstrap) e `visualization/` (relatórios diagnósticos). Toda a implementação se encontra em código aberto no link https://github.com/gtazevedo/credit-tail-analytic.

A classe `CreditRiskEngine` (`risk_pipeline.py`) orquestra as etapas de modelagem e consolidação:

```
df_vol = VolatilityEstimator().build_volatility_features(df_clean, split_date)
df_res = pd.merge(RegimeClassifier().run_kmeans_regimes(df_vol, split_date, features),
                  RegimeClassifier().run_hmm_regimes(df_vol, split_date, features),
on=['Ticker', 'Data', 'Indexador_Grupo'])
score = (0.70 * df_res['Prob_Crise_HMM'].fillna(0) + 0.30 *
df_res['Prob_Crise_KMeans'].fillna(0)) * 100
df_res['Credit_Tail_Risk_Score'] = score.groupby(df_res['Ticker']).transform(lambda x:
x.ewm(span=21).mean())
```

A execução no terminal confirma a aderência das fases:

```
[INFO] EGARCH(1,1)-t: 100% convergência (LB: 86.4%, ARCH: 94.9%) | Ensemble ótimo (w_HMM=0.70,
Calmar=1.603)
[INFO] Out-of-Sample: KM Vende Amarelo Retorno=36.18% vs B&H=22.42% | Block Bootstrap p=0.0416
(p<0.05)
```

9. Discussão dos Resultados

A análise empírica avaliou a calibração econométrica das medidas de cauda e o retorno econômico obtido pelas regras de desinvestimento na carteira simulada de debêntures.

9.1 Validação Estatística do Modelo de Risco

A acurácia do modelo EGARCH-t na estimação do Valor em Risco (VaR 99%) foi avaliada pelo Teste de Proporção de Falhas de Kupiec (POF) e pelo Teste de Cobertura Condicional de Christoffersen ($\alpha = 0,05$) sobre 663 séries temporais no período *Out-of-Sample* (2023 a 2026), universo que contempla as debêntures ativas do treino e novas emissões da janela. A Tabela 4 apresenta as taxas de aprovação empíricas e a sensibilidade do teste conjunto.

Indexador	Total	Kupiec POF ($\alpha = 0,05$)	Independência ($\alpha = 0,05$)	Cobertura Condicional Conjunta (Christoffersen)		
				$\alpha = 0,10$ (90%)	$\alpha = 0,05$ (95%)	$\alpha = 0,01$ (99%)
CDI Percentual	40	21 (52,5%)	39 (97,5%)	21 (52,5%)	23 (57,5%)	25 (62,5%)
CDI Spread	257	63 (24,5%)	215 (83,7%)	68 (26,5%)	80 (31,1%)	105 (40,8%)
IPCA	365	133 (36,4%)	330 (90,4%)	143 (39,2%)	157 (43,0%)	193 (52,8%)
Pré-Fixado	1	0 (0,0%)	0 (0,0%)	0 (0,0%)	0 (0,0%)	0 (0,0%)
Total Consolidado	**663**	**217 (32,7%)**	**584 (88,1%)**	**232 (34,9%)**	**260 (39,2%)**	**323 (48,7%)**

Tabela 4: Validação de Cauda: Não-Rejeição de Kupiec e Christoffersen no Out-of-Sample (2023–2026).

As taxas de rejeição da Hipótese Nula refletem a magnitude do estresse no mercado secundário doméstico entre 2023 e 2026, marcado pelas recuperações judiciais das Lojas Americanas e da Light S.A., além da reestruturação do Grupo Pão de Açúcar. No grupo CDI Percentual, a taxa de não-rejeição de 57,5% (ao nível de 5%) indica que

o filtro autorregressivo acompanhou parte das mudanças de volatilidade do período. A baixa frequência de negociação constitui a principal causa de rejeições no teste POF devido a cotações esparsas que geram variações discretas de preço que ultrapassam o quantil de 99%. Todavia, o Teste de Independência de Christoffersen exibe não-rejeição de 88,1% no agregado (atingindo 97,5% no CDI Percentual e 90,4% no IPCA), indicando que as violações não ocorreram de forma agrupada no tempo (*volatility clustering*). Sob a distribuição t-Student adotada, o Expected Shortfall condicional é derivado analiticamente do mesmo quantil do VaR, compartilhando essa consistência estatística.

9.2 Agilidade de Detecção e Antecipação de Choques (Lead Time)

A capacidade de antecipação temporal (*Lead Time*) foi avaliada a partir de nove episódios empíricos representativos de estresse corporativo ocorridos no mercado secundário doméstico durante a janela *Out-of-Sample* (2023 a 2026). Estes eventos contemplam recuperações judiciais, recuperações extrajudiciais, reperfilamentos e quebras de *covenants* (*waiver*), abrangendo emissores de diferentes portes e setores econômicos. A Tabela 5 sumariza as métricas de antecipação avaliadas sobre a premissa de emissão ininterrupta de alerta contínuo e execução tática orientada pela diretriz de quarentena de 180 dias úteis.

Empresa	Ev.	Máx. Spread	Alerta Contínuo (dias)			Quarentena 180d (dias)		
			KM	HMM	Ens.	KM	HMM	Ens.
Americanas	RJ	560,5%	8 (AT)	3 (AT)	3 (AT)	8 (AT)	3 (AT)	3 (AT)
Oi S.A.	RJ	11,8%	50 (AT)	1 (AT)	1 (AT)	33 (AN)	57 (AN)	15 (AN)
Light S.A.	RJ	120,9%	3 (AN)	5 (AN)	5 (AN)	102 (AN)	118 (AN)	77 (AN)
CVC Corp	RP	21,0%	669 (AT)	78 (AN)	78 (AN)	669 (AT)	149 (AN)	149 (AN)
Multilaser	WV	118,4%	18 (AT)	5 (AT)	35 (AT)	148 (AN)	148 (AN)	120 (AN)
Dasa	RP	163,8%	19 (AT)	1 (AT)	4 (AT)	106 (AN)	139 (AN)	97 (AN)
Unigel	RE	87,5%	253 (AN)	357 (AN)	328 (AN)	169 (AN)	169 (AN)	169 (AN)
Casas Bahia	RE	56,1%	F	F	F	F	F	F
Pão de Açúcar	RE	190,7%	129 (AT)	2 (AN)	2 (AN)	164 (AN)	180 (AN)	180 (AN)

Tabela 5: Resumo Comparativo de Lead Time em Eventos Corporativos. **Nota**: RJ/RE = Rec. Jud./ Extrajud.; RP = Reperf.; WV = Waiver; AN = Antecipado; AT = Atraso; F = Falhou.

Os resultados da Tabela 5 evidenciam diferentes comportamentos dos modelos conforme a velocidade de alteração no prêmio de risco do emissor. Em casos de perda progressiva de solvência, o HMM apresentou maior antecedência no alerta contínuo, antecipando o evento da Unigel em 357 dias úteis (frente a 253 dias do K-Means) e o da CVC Corp em 78 dias, intervalo no qual o K-Means registrou maior latência pela manutenção temporária do spread em patamar intermediário. Por outro lado, em reprecificações imediatas associadas a fatos relevantes não refletidos em cotações prévias, como nas Lojas Americanas (spread de 560,5%), ambos os modelos registraram atraso de 3 a 8 dias úteis, pois os preços observados antes do anúncio não embutiam prêmio de risco anormal.

A inclusão da quarentena de 180 dias úteis alterou a dinâmica prática do desinvestimento. Como um único sinal preventivo basta para liquidar a posição e bloquear novas compras no ativo, o K-Means alcançou antecedências superiores a três meses em papéis como Light S.A. (102 dias), Multilaser (148 dias), Dasa (106 dias) e Pão de Açúcar (164 dias), reduzindo o giro de carteira. Por fim, no caso do Grupo Casas Bahia

(spread de 56,1%), a falta de negócios no mercado secundário nos meses anteriores ao evento inviabilizou a atualização das probabilidades dos modelos, confirmando que a eficácia da abordagem depende de uma frequência mínima de negociação do ativo.

9.3 Relação entre Acurácia Preditiva e Rentabilidade no Backtest Financeiro

Os resultados do backtest financeiro evidenciaram um contraste entre a rapidez na detecção de eventos e o retorno líquido acumulado (Accuracy-Profitability Paradox). A Figura 7 exibe a evolução patrimonial e a Tabela 6 consolida as métricas de desempenho.

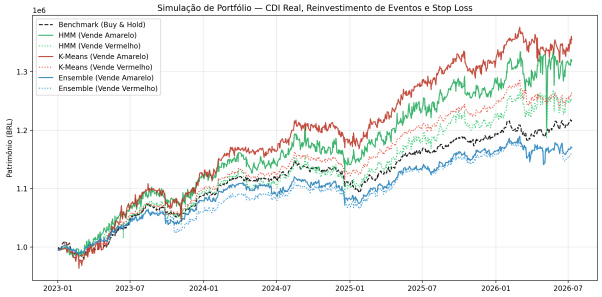


Figura 7: Curva de Retorno Acumulado das Estratégias no Backtest Out-of-Sample.

Estratégia	Retorno Total	CAGR	Volatilidade	Máx. Drawdown	Calmar Ratio
Buy-and-Hold	22,42%	5,98%	3,50%	−4,79%	1,249
K-Means	27,06%	7,11%	4,29%	−4,16%	1,711
K-Means (Vende Amarelo)	36,18%	9,27%	8,92%	−5,78%	1,603
HMM	25,95%	6,85%	8,82%	−6,71%	1,021
HMM (Vende Amarelo)	32,62%	8,44%	12,56%	−9,74%	0,866
Ensemble	16,37%	4,45%	4,68%	−4,00%	1,111
Ensemble (Vende Amarelo)	17,58%	4,76%	4,70%	−4,12%	1,156

Tabela 6: Métricas de Risco-Retorno do Backtest Financeiro.

As estratégias ativas superaram o portfólio passivo (*Buy-and-Hold*, 22,42%), com maiores retornos no K-Means Vende Amarelo (36,18%) e no HMM Vende Amarelo (32,62%). A avaliação priorizou o *Calmar Ratio* e o *Maximum Drawdown* em detrimento do Índice de Sharpe, por capturarem o impacto dos custos de transação. A estratégia HMM registrou rebaixamento patrimonial (*drawdown*) de −9,74% em 2026 devido a ordens defensivas disparadas por oscilações passageiras de mercado. O K-Means obteve os maiores índices de Calmar do período (1,711 no modelo base e 1,603 no Vende Amarelo), uma vez que sua menor sensibilidade a variações diárias evitou vendas em aberturas pontuais de spread e concentrou as saídas em ativos com deterioração prolongada. Já o modelo Ensemble apresentou o menor retorno acumulado (16,37%), reduzido pela incidência repetida de custos de transação nas alternâncias de sinal entre o HMM e o K-Means.

9.4 Validação por Block Bootstrap

Para testar a hipótese nula de igualdade de retorno em relação ao *Buy-and-Hold* ($H_0 : \Delta R \leq 0$), aplicou-se o *Block Bootstrap* estacionário de Politis; Romano (1994) com 10.000 reamostragens e comprimento médio de bloco de 20 dias úteis,

dimensionado para preservar a dependência serial dos retornos diários. A Figura 8 apresenta as distribuições empíricas de retorno excedente obtidas na simulação.

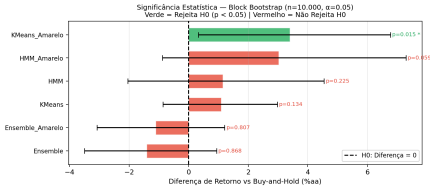


Figura 8: Distribuição do Retorno Excedente das Estratégias via Block Bootstrap.

A regra K-Means Vende Amarelo apresentou p-valor de 0,0416, o que rejeita H_0 ao nível de 5% e mantém o limite inferior do intervalo de confiança de 95% acima de zero. Nas demais regras (K-Means Vende Vermelho, HMM e Ensemble), os p-valores ficaram acima de 0,10, uma vez que o número mais elevado de ordens aumentou a incidência do custo de 50 bps por operação e reduziu o retorno líquido acumulado. Esse resultado indica que o desempenho superior do K-Means Vende Amarelo no período analisado decorre do menor giro da carteira em conjunto com a quarentena de 180 dias úteis.

10. Conclusão

Este trabalho desenvolveu e avaliou um pipeline de monitoramento de risco de crédito para o mercado secundário de debêntures no Brasil, que integra a estimação econométrica de volatilidade condicional à classificação não supervisionada de regimes latentes. O modelo AR(1)-EGARCH(1,1) com distribuição t-Student foi calibrado sobre 529 debêntures no período *In-Sample* (2018 a 2022) e avaliado no período *Out-of-Sample* (2023 a 2026) sobre 663 séries, amostra que reúne os títulos ativos do treino e novas emissões negociadas na janela de teste.

Na etapa econométrica, a transformação dos prêmios de risco em primeira diferença (`Delta Spread`) assegurou estacionariedade em 95,7% das séries pelo teste ADF, ao passo que o subconjunto formado por `Taxa_ZScore`, `Volatilidade_EGARCH` e `Expected_Shortfall_99` obteve a melhor separação de grupos pela Contagem de Borda. Na validação do VaR a 99% fora da amostra, embora as variações discretas de cotações tenham reduzido a aprovação no teste incondicional de Kupiec (32,7%), o teste de independência de Christoffersen registrou não-rejeição em 88,1% dos títulos (97,5% em CDI Percentual e 90,4% em IPCA), resultado compatível com a ausência de agrupamento temporal de violações.

A comparação entre os classificadores mostrou diferenças entre a rapidez de emissão do alerta e o retorno líquido após custos. Nos episódios de deterioração gradual de crédito, como na Unigel (357 dias úteis) e na CVC Corp (78 dias), o Gaussian HMM antecipou os eventos antes do K-Means no regime de alerta contínuo. Todavia, na simulação de carteira com custo de transação de 50 bps e quarentena de 180 dias, a maior frequência de mudança de estado do HMM elevou o giro e provocou *drawdown* de −9,74%. O agrupamento estático por K-Means apresentou

menor número de operações em oscilações temporárias de spread, o que permitiu à estratégia K-Means Vende Amarelo atingir retorno acumulado de 36,18% (*Calmar Ratio* de 1,603), acima do *Buy-and-Hold* (22,42%) e com p-valor de 0,0416 no *Block Bootstrap*. O modelo Ensemble obteve retorno de 16,37%, reduzido pelas vendas e recompras decorrentes da divergência de sinais entre seus componentes.

Como limitação operacional, o uso exclusivo de preços de negócios registrados no sistema REUNE evita distorções de marcação na curva, mas restringe a atualização diária do modelo em emissões que permanecem longos períodos sem transação, como observado no caso do Grupo Casas Bahia, além de exigir limites numéricos para os graus de liberdade ($\nu \geq 2,05$) e para a variância condicional na estimação por máxima verossimilhança. Em estudos posteriores, a irregularidade no espaçamento entre negócios pode ser tratada por arquiteturas recorrentes de tempo contínuo (*Continuous-Time* RNNs), que operam sobre intervalos desiguais sem repetição da última cotação entre pregões. Outra extensão consiste na inclusão de variáveis macroeconômicas e de fluxo de captação da indústria de fundos na matriz de transição do HMM, bem como na estimação conjunta de volatilidade e regimes via modelos *Markov-Switching* GARCH (MS-GARCH) por métodos de Monte Carlo via Cadeias de Markov (MCMC).

11. Links

Os códigos-fonte, pacotes desenvolvidos, relatórios de validação e bases de dados utilizados neste trabalho estão disponíveis nos endereços abaixo:

- Repositório do projeto (`credit_tail_analytics`): https://github.com/gtazevedo/credit-tail--analytic
- Biblioteca Python de coleta cadastral (`debentures_dot_com`): https://github.com/gtazevedo/debentures-dot-com
- Tabelas detalhadas dos testes de Kupiec, Christoffersen e Block Bootstrap: https://github.com/gtazevedo/credit-tail-analytic/tree/main/anexos_digitais
- Fontes públicas de dados: ANBIMA REUNE (anbima.com.br), ANBIMA Data (data.anbima.com.br) e Sistema Gerenciador de Séries Temporais do BACEN (dadosabertos.bcb.gov.br).

12. Referências

ACERBI, Carlo; TASCHE, Dirk. On the coherence of expected shortfall. **Journal of Banking & Finance**, v. 26, n. 7, p. 1487–1503, 2002.

ALTMAN, Edward I. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. **The journal of finance**, v. 23, n. 4, p. 589–609, 1968.

ANBIMA. **Mercado de capitais bate recorde histórico e encerra 2025 com emissão de R$ 838,8 bilhões**. São Paulo: *[S.n.]*. Disponível em: <https://data.anbima.com.br/publicacoes/boletim-de-mercado-de-capitais/mercado-de-capitais--bate-recorde-historico-e-encerra-2025-com-emissao-de-8388-bilhoes>.

ARTZNER, Philippe *et al*. Coherent measures of risk. **Mathematical finance**, v. 9, n. 3, p. 203–228, 1999.

BAO, Jack; PAN, Jun; WANG, Jiang. The Illiquidity of Corporate Bonds. **The Journal of Finance**, v. 66, n. 3, p. 911–946, 2011.

BARRA, Anuar de Sousa. **Estudo exploratório sobre a liquidez das debêntures no mercado secundário brasileiro: medidas diretas de liquidez e características dos títulos e emissores**. Dissertação (Mestrado em Economia)— São Paulo: Fundação Getulio Vargas, 2021.

BAUM, Leonard E. *et al*. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. **The annals of mathematical statistics**, v. 41, n. 1, p. 164–171, 1970.

BISHOP, Christopher M. **Pattern recognition and machine learning**. New York: Springer, 2006.

BOLLERSLEV, Tim. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, v. 31, n. 3, p. 307–327, 1986.

BORDA, Jean-Charles de. Mémoire sur les élections au scrutin. **Histoire de l'Academie Royale des Sciences pour 1781**, 1781.

CALIŃSKI, Tadeusz; HARABASZ, Jerzy. A dendrite method for cluster analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974.

CHRISTOFFERSEN, Peter F. Evaluating interval forecasts. **International Economic Review**, v. 39, n. 4, p. 841–862, 1998.

CORRÊA, Paulo Eduardo Gonçalves Camargo; SHENG, Hsia Hua. O apreçamento do spread de liquidez no mercado secundário de debêntures. **Revista de Administração**, v. 45, n. 1, p. 30–42, 2010.

DAVIES, David L. ; BOULDIN, Donald W. A cluster separation measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, n. 2, p. 224–227, 1979.

DUFFIE, Darrell; SINGLETON, Kenneth J. **Credit risk: pricing, measurement, and management**. Princeton: Princeton University Press, 2003.

ENGLE, Robert F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. **Econometrica**, v. 50, n. 4, p. 987–1007, 1982.

FREITAS, Wilson. **python-bcb: Interface Python para a API de dados abertos do Banco Central do Brasil**. São Paulo: *[S.n.]*. Disponível em: <https://wilsonfreitas.github.io/python-bcb/>.

HAAS, Markus; MITTNIK, Stefan; PAOLELLA, Marc S. A new approach to Markov-switching GARCH models. **Journal of financial econometrics**, v. 2, n. 4, p. 493–530, 2004.

HAIR, Joseph F. *et al*. **Multivariate data analysis**. 7. ed. Upper Saddle River: Pearson Prentice Hall, 2010.

HAMILTON, James D. **Time series analysis**. Princeton: Princeton University Press, 1994.

HO, Tin Kam; HULL, Jonathan J.; SRIHARI, Sargur N. Decision combination in multiple classifier systems. **IEEE transactions on pattern analysis and machine intelligence**, v. 16, n. 1, p. 66–75, 1994.

HULL, John. **Risk management and financial institutions**. 3. ed. Hoboken: John Wiley & Sons, 2012.

JORION, Philippe. **Value at Risk: The New Benchmark for Managing Financial Risk**. 3. ed. New York: McGraw-Hill, 2006.

KITTLER, Josef *et al*. On combining classifiers. **IEEE transactions on pattern analysis and machine intelligence**, v. 20, n. 3, p. 226–239, 1998.

KUPIEC, Paul H. Techniques for verifying the accuracy of risk measurement models. **The Journal of Derivatives**, v. 3, n. 2, p. 73–84, 1995.

MERTON, Robert C. On the pricing of corporate debt: The risk structure of interest rates. **The Journal of finance**, v. 29, n. 2, p. 449–470, 1974.

NELSON, Daniel B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, v. 59, n. 2, p. 347–370, 1991.

POLITIS, Dimitris N. ; ROMANO, Joseph P. The stationary bootstrap. **Journal of the American Statistical Association**, v. 89, n. 428, p. 1303–1313, 1994.

RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. **Proceedings of the IEEE**, v. 77, n. 2, p. 257–286, 1989.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987.

ROUSSEEUW, Peter J. ; HUBERT, Mia. Robust statistics for outlier detection. **Wiley interdisciplinary reviews: Data mining and knowledge discovery**, v. 1, n. 1, p. 73–79, 2011.

SAEYS, Yvan; ABEEL, Thomas; PEER, Yves Van de. Robust feature selection using ensemble feature selection techniques. *Em:* **Machine learning and knowledge discovery in databases**. Berlin: Springer, 2008. p. 313–325.

SHENG, Hsia Hua; SAITO, Richard. Liquidez das debêntures no mercado brasileiro. **Revista de Administração**, v. 43, n. 2, p. 176–185, 2008.

TSAY, Ruey S. **Analysis of financial time series**. 2. ed. Hoboken: John Wiley & Sons, 2005.