

Nome da Universidade / Instituição

Guilherme Tolotti Azevedo

**MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉ-
DITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T
E MODELOS OCULTOS DE MARKOV**

Dissertação apresentada como requisito parcial
para obtenção do grau de Especialista.
Orientador: Nome do Orientador

São Paulo, SP
2026

SUMÁRIO

Resumo	4
Abstract	5
Lista de Figuras	6
Lista de Tabelas	7
1 Introdução	8
1.1 O Problema de Pesquisa	8
1.2 Objetivos (Geral e Específicos)	9
2 Revisão da Literatura	11
2.1 Modelos de Early Warning de Crédito	11
2.2 Value-at-Risk e Modelos da Família GARCH	12
2.2.1 Expected Shortfall (ES) e Testes de Backtesting	13
2.3 A Hipótese de Mudança de Regimes (Regime-Switching)	14
2.4 Aprendizado de Máquina Não Supervisionado	15
2.4.1 K-Means	15
2.4.2 Hidden Markov Models (HMM)	16
2.5 Seleção de Atributos e Avaliação de Clusters	17
3 Metodologia e Dados	19
3.1 Coleta e Tratamento de Dados (ANBIMA)	19
3.2 O Pipeline de Risco (EGARCH, K-Means e HMM)	21
3.2.1 Pré-processamento de Dados e Filtros	23
3.2.2 EGARCH	24
3.2.3 Teste de Estacionariedade dos Spreads	28
3.2.4 Seleção de variáveis	29
3.2.5 K-Means	33
3.2.6 HMM	35
3.2.7 Modelo Misto (Ensemble)	37
3.3 Protocolos de Validação (Kupiec POF e Backtest)	39
4 Resultados e Discussões	42
4.1 Validação Estatística dos Motores	42
4.2 O Desempenho do HMM vs K-Means na Classificação	44
4.2.1 K-Means	45
4.2.2 HMM	47
4.2.3 Ensemble	48
4.2.4 Antecipação de Eventos Sistêmicos (Lead Time)	49
4.3 Simulação de Portfólio (Backtest Financeiro)	52

4.3.1	Significância Estatística das Estratégias — Block Bootstrap	54
4.3.2	Discussão sobre a Generalização dos Resultados	56
5	Conclusão	58
5.1	Principais Descobertas	58
5.2	Implicações Práticas	59
5.3	Limitações e Recomendações para Trabalhos Futuros	60
	Bibliografia	61

RESUMO

O mercado secundário de debêntures no Brasil impõe aos investidores diversos desafios como a assimetria de retornos, baixa liquidez e um histórico recente de eventos de crédito abruptos que os modelos tradicionais de risco costumam ter dificuldade para capturar. Diante desse cenário, esta dissertação propõe e valida um sistema de alerta precoce (*Early Warning System*), capaz de identificar e sinalizar este tipo de eventos, através da classificação de regimes de risco. A metodologia utiliza um motor EGARCH-t para absorver a volatilidade condicional e padronizar os ruídos dos spreads de crédito e, em seguida, aplica algoritmos de aprendizado de máquina não supervisionado (K-Means e Modelos Ocultos de Markov) para classificar os ativos em regimes de baixo risco, alerta e crise. Ao longo do estudo empírico, baseado em dados de negociação públicos disponibilizados pela plataforma REUNE da ANBIMA. Foi descoberta, no escopo das simulações realizadas, uma dicotomia entre a precisão teórica e o ganho prático, ilustrando o conhecido “Paradoxo da Acurácia-Rentabilidade” (*Accuracy-Profitability Paradox*). O HMM provou ser o modelo mais reativo, sendo capaz de antecipar diversos dos eventos de crédito observados. No entanto, sua alta sensibilidade temporal gerou falsos alarmes e custos excessivos no *trading*. Por outro lado, a inércia do K-Means funcionou como um filtro natural contra os ruídos do mercado, poupando a carteira dos custos de negociação relacionados a um elevado numero de transações, sendo a única estratégia a superar financeiramente o carregio passivo (*Buy and Hold*) de forma estatisticamente comprovada. Os resultados finais atestam que aliar ferramentas preditivas quantitativas a regras operacionais robustas (como as travas de quarentena temporal) é necessário para mitigar impactos adversos decorrentes do “Paradoxo da Acurácia-Rentabilidade” e da instabilidade em manutenção de estados (como problemas de *flickering*, que foi observado principalmente no modelo que utiliza K-means). Nesse aspecto, a união entre modelagem e tática se mostra como a melhor alternativa para proteger o capital de forma eficaz em mercados de crédito ilíquidos.

Palavras-chave: Risco de Crédito. Early Warning. Debêntures. EGARCH. Cadeias de Markov. K-Means.

ABSTRACT

The Brazilian secondary debenture market imposes several challenges on investors, such as return asymmetry, low liquidity, and a recent history of abrupt credit events that traditional risk models often struggle to capture. Given this scenario, this dissertation proposes and validates an Early Warning System capable of identifying and signaling these types of events through the classification of risk regimes. The methodology uses an EGARCH-t engine to absorb conditional volatility and standardize the noise of credit spreads, and then applies unsupervised machine learning algorithms (K-Means and Hidden Markov Models) to classify assets into low-risk, warning, and crisis regimes. Throughout the empirical study, based on public trading data provided by ANBIMA's REUNE platform, a dichotomy was discovered, within the scope of the performed simulations, between theoretical accuracy and practical gain, illustrating the well-known "Accuracy-Profitability Paradox". The HMM proved to be the most reactive model, capable of anticipating several of the observed credit events. However, its high temporal sensitivity generated false alarms and excessive trading costs. On the other hand, the inertia of the K-Means acted as a natural filter against market noise, sparing the portfolio from trading costs related to a high number of transactions, being the only strategy to financially outperform the passive carry (Buy and Hold) with proven statistical significance. The final results attest that combining predictive quantitative tools with robust operational rules (such as temporal quarantine locks) is necessary to mitigate adverse impacts arising from the "Accuracy-Profitability Paradox" and from state maintenance instability (such as flickering problems, which were observed mainly in the model using K-Means). In this regard, the union between modeling and tactics proves to be the best alternative to effectively protect capital in illiquid credit markets.

Keywords: Credit Risk. Early Warning. Debentures. EGARCH. Markov Chains. K-Means.

LISTA DE FIGURAS

Figura 1	Arquitetura do Pipeline de Risco e Backtest	22
Figura 2	Torneio GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.	25
Figura 3	Torneio GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.	25
Figura 4	Torneio GARCH: Ranking Médio para a amostra ampla de 500 ativos.	26
Figura 5	Taxa de aprovação dos testes de diagnóstico nos resíduos padronizados do EGARCH(1,1,1) t-Student para 529 debêntures. ...	27
Figura 6	Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.	31
Figura 7	Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).	32
Figura 8	Elbow Method e Silhouette Score por número de clusters k — Superior: IPCA, Inferior: CDI Spread	34
Figura 9	Análise de Sensibilidade (<i>Grid-Search</i>) dos pesos do modelo Ensemble no período <i>In-Sample</i>.	38
Figura 10	Sensibilidade da Não-Rejeição (Teste Conjunto) a Diferentes Níveis de Confiança	43
Figura 11	Resultados do K-Means para o Estudo de Caso do Grupo Pão de Açúcar (GPA)	47
Figura 12	Resultados do HMM para o Estudo de Caso do Grupo Pão de Açúcar (GPA)	48
Figura 13	Resultados do Ensemble para o Estudo de Caso do Grupo Pão de Açúcar (GPA)	49
Figura 14	Resultados do Backtest	52
Figura 15	Forest Plot — Diferença de Retorno vs. Buy-and-Hold com Intervalo de Confiança 95% (Block Bootstrap)	56

LISTA DE TABELAS

Tabela 1	Resultados do Teste ADF ($\alpha = 5\%$) — Estacionariedade por Indexador.	
	Nota: NE = Não-Estacionário.	29
Tabela 2	Métricas da grade de sensibilidade (<i>In-Sample</i>) por par de pesos. . .	38
Tabela 3	Resultados do Teste de Kupiec (Não-Rejeição de H_0) por Nível de Confiança	42
Tabela 4	Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDA8	45
Tabela 5	Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDB8	45
Tabela 6	Resumo Comparativo: Antecipação (Lead Time) do Alerta de Crise por Modelo.	
	Nota: Eventos: RJ = Rec. Judicial; RP = Reperfilamento; WV = Waiver; RE = Rec. Extrajudicial. Status: AN = Antecipado; AT = Atraso; F = Falhou.	50
Tabela 7	Resumo Comparativo: Antecipação (Lead Time) considerando Quarentena de 180 dias.	
	Nota: Eventos: RJ = Rec. Judicial; RP = Reperfilamento; WV = Waiver; RE = Rec. Extrajudicial. Status: AN = Antecipado; AT = Atraso; F = Falhou.	51
Tabela 8	Métricas de Risco-Retorno do Backtest Financeiro	53
Tabela 9	Resultados do Block Bootstrap ($n = 10.000$, $\alpha = 5\%$, bloco=20 dias) — Significância Estatística vs. Buy-and-Hold.	
	Nota: R = Rejeitada; NR = Não Rejeitada.	55

1 INTRODUÇÃO

O mercado de crédito privado brasileiro vem crescendo continuamente, e se consolidando como uma ferramenta de captação de recursos para as empresas, como se pode observar em ANBIMA (2026). Uma das principais ferramentas de crédito privado utilizadas são as debêntures, que tiveram um crescimento de 307% no volume de emissões, quando comparamos o volume observado em 2020 contra o volume observado em 2025. Porém, esse mercado enfrenta problemas de liquidez, e conforme Sheng; Saito (2008), apresenta as seguintes características:

- As transações são dispersas e ocorrem em duas diferentes instituições - Bolsa de Valores de São Paulo (Bovespa Fix) e Sistema Nacional de Debêntures (SND);
- Existe baixa atividade, não havendo registro de transações para períodos longos e, em algumas emissões de debêntures, o volume de transações no mercado secundário é quase nulo e o valor total em reais é baixo;
- Existe um baixo número de negociações diárias;
- Predominância de debêntures de médio prazo (vencimento em torno de quatro anos);
- Demanda significativa por investidores institucionais e fundos de pensão;
- Em geral as emissões não são conversíveis em ações;
- Alguns investidores adquirem debêntures e as mantêm até o vencimento;

Apesar de algumas dessas características estruturais se manterem verdadeiras, como:

- A baixa liquidez (onde mais da metade das marcações diárias do mercado giram volumes inferiores a R\$ 1 milhão);
- A exclusividade de emissões do tipo simples;

e outras características, como:

- A baixa presença de pessoas físicas e investidores estrangeiros;
- O fato de os intermediários manterem os papéis na carteira até o vencimento;

serem reforçadas por estudos mais recentes como Barra (2021) e ANBIMA (2026), houve algumas mudanças relevantes que sugerem um amadurecimento institucional. A amostra utilizada neste estudo indica que as empresas têm conseguido alongar o perfil de suas dívidas, com as debêntures apresentando uma mediana de sete anos de prazo até o vencimento.

1.1 O Problema de Pesquisa

Apesar do crescimento e amadurecimento do mercado de crédito privado brasileiro, a baixa liquidez no mercado secundário representa um desafio para a precificação e acompanhamento de risco do papel. Estudos como Corrêa; Sheng (2010) focam em problemas de apreçamento do *spread* de crédito, enquanto estudos como Sheng; Saito (2008) analisam os fatores que afetam o prêmio de liquidez em debêntures. Contudo, muitos modelos assumem situações normais de mercado, enquanto outros fazem suposições ainda mais fortes que não condizem com a realidade do mercado brasileiro. Bancos e assets muitas vezes controlam o risco de cauda de debêntures baseado em GARCH e VaR contínuos, que possuem suposições violadas quando ocorrem eventos extremos, e podem subestimar o risco observado.

Como demonstrado por Bao; Pan; Wang (2011), o mercado de crédito corporativo apresenta fricções de liquidez que impedem o ajuste contínuo dos preços, eventos recentes envolvendo o Grupo Pão de Açúcar e Americanas são exemplos dos saltos observados nos preços das debêntures desses emissores; No caso das Americanas, houve uma queda de 50% no valor das debêntures em um dia, acumulando perdas de cerca de 90% em uma semana; Já no caso do Grupo Pão de Açúcar, foram observados deságios de até cerca de 70%. Nessas situações, modelos GARCH e VaR tradicionais falham em capturar o risco de cauda, uma vez que segundo Jorion (2006), assumem que a liquidação será instantânea a preço de tela. Para corrigir essas suposições e capturar quebras estruturais, a literatura mais moderna defende a transição para modelos baseados em mudanças de regime (*Markov-Switching*), conforme proposto por Haas; Mittnik; Paoletta (2004) e Ardia et al. (2019).

1.2 Objetivos (Geral e Específicos)

A proposta desse trabalho é desenvolver e avaliar os resultados de uma modelagem de risco de crédito adaptada à realidade do mercado brasileiro de debêntures. Ao invés de tentarmos prever flutuações contínuas, o modelo busca identificar eventos de mudança de regime para disparar alertas de risco antes de que se observem grandes perdas, possibilitando ao detentor das debêntures, um tempo hábil para tentar vender o papel antes que as perdas se materializem.

Para isso, serão utilizadas duas abordagens de modelagem de risco, uma baseada em K-Means e outra em HMM, ambas utilizando as mesmas *features* de entrada, derivadas de variáveis como a volatilidade e o *spread* das debêntures, obtidas por meio de dados abertos divulgados pela Anbima. Além disso, toda a aplicação,

feita em python, será disponibilizada para consulta pública no GitHub, juntamente da sua documentação de uso, permitindo que qualquer interessado possa replicar os resultados, incluindo o *download* das informações utilizadas no trabalho, uma vez que os dados são públicos.

2 REVISÃO DA LITERATURA

A ideia central deste trabalho parte da modelagem de risco de crédito de debêntures. Mas, para entender esse conceito, é necessário entender primeiramente, “O que é risco?”. Existem várias definições, Jorion (2006) possui uma das mais simples e intuitivas, na qual afirma que risco é a volatilidade dos resultados inesperados, seja no valor de ativos, patrimônio ou resultados. E esse risco pode ser originado de várias formas, criados pelos humanos, por meio de ciclos de negócios, inflação, mudanças políticas, guerras, etc., ou pode ocorrer devido a fenômenos naturais como terremotos, tsunamis, etc. É na tentativa de combater e mitigar esses riscos que a economia cresce e as tecnologias se desenvolvem.

Parte significativa do mercado financeiro atual foi desenvolvida na tentativa de lidar ou compartilhar esses riscos. Ao mesmo tempo que o mercado se desenvolveu, foi gerada a necessidade de limitar as perdas potenciais das operações realizadas, sem deixar de tomar risco. Existem controles *ex post*, mas esses não conseguem garantir que as perdas sejam próximas ao limite desejado, ao depender da sorte, podem ser maiores. A solução é o uso de modelos quantitativos *ex ante* que limitam a exposição a determinados ativos ou fatores de risco baseados em distribuições de probabilidade, como por exemplo os modelos de *Value at Risk*.

2.1 Modelos de Early Warning de Crédito

Os primeiros sistemas formais de alerta de *distress* corporativo remontam ao modelo de Altman (1968), que utiliza combinações lineares de indicadores fundamentais (Altman Z-Score) para prever insolvência. Desde então, a literatura evoluiu para abordagens baseadas em modelos estruturais de crédito (Merton, 1974), contudo, as abordagens tradicionais baseadas em fundamentos, obtidos em balanços e informações contábeis, geralmente divulgados em frequência trimestral ou anual, são inadequados para sistemas de alerta em tempo real (ou com poucos dias de defasagem) devido à frequência de divulgação dessas informações.

Para superar a dependência de demonstrações financeiras, surgiram os modelos de forma reduzida, conforme consolidado por Duffie; Singleton (2003), que modelam o risco de crédito diretamente através de dados de mercado. Porém, apesar

de serem capazes de mitigar a defasagem da informação contábil, a modelagem contínua exige mercados líquidos, uma vez que é amplamente dependente dos dados observados. No mercado de debêntures brasileiro, onde se observa baixa liquidez e baixa atividade, essa abordagem se mostra frágil.

Na tentativa de mitigar este problema, este trabalho propõe uma abordagem alternativa. Ao invés de mensurar o risco dos papéis e estimar possíveis perdas, limita-se apenas a identificar momentos em que ocorrem mudanças de regime, através do uso de algoritmos de aprendizado de máquina, para gerar alertas antecipados sobre a possibilidade de grandes perdas, apesar de não ser capaz de estimá-las, como é feito por outros modelos, como o Value at Risk (VaR).

2.2 Value-at-Risk e Modelos da Família GARCH

O *Value at Risk* (VaR) pode ser definido de forma intuitiva como a maior perda esperada de uma carteira em um determinado período de tempo, com um determinado nível de confiança. Ou, de forma mais formal, é o quantil da distribuição de ganhos e perdas projetadas para um horizonte de tempo. Muitas vezes para séries temporais, essa projeção é feita por meio de modelos da família GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*), cuja formulação fundamental foi introduzida por Engle (1982) e posteriormente generalizada por Bollerslev (1986). Apesar de amplamente utilizado, o GARCH tradicional falha em choques assimétricos, como observamos nos eventos recentes envolvendo o Grupo Pão de Açúcar e Americanas. Para superar essa fraqueza, Nelson (1991) propõe o modelo EGARCH, que captura assimetrias na volatilidade dos ativos financeiros.

Matematicamente, a especificação da variância condicional do EGARCH(1,1) de Nelson (1991) é dada por:

$$\ln(\sigma_t^2) = \omega + \alpha \left[|z_{t-1}| - \sqrt{\frac{2}{\pi}} \right] + \gamma z_{t-1} + \beta \ln(\sigma_{t-1}^2) \quad (1)$$

Onde:

- σ_t^2 é a variância condicional no tempo t .
- z_t é o resíduo padronizado ($z_t = \varepsilon_t / \sigma_t$).
- α mensura o “efeito tamanho” (a magnitude do choque).
- γ captura o **efeito assimétrico** (o sinal do choque).
- β mede a persistência da volatilidade.

Se $\gamma < 0$, os choques negativos em $t - 1$ aumentam a variância em t mais do que choques positivos da mesma magnitude, adicionando a possibilidade de efeitos assimétricos, diferentemente do modelo GARCH tradicional.

Contudo, além da assimetria, os retornos de ativos de crédito exibem forte leptocurtose (caudas pesadas), onde perdas extremas ocorrem com frequência superior ao previsto pela distribuição normal. Para contornar este problema, a modelagem EGARCH pode ser combinada a uma distribuição T de Student condicional, que permite modelar as caudas da distribuição por meio dos graus de liberdade ν .

2.2.1 Expected Shortfall (ES) e Testes de Backtesting

Apesar de sua ampla adoção, o VaR apresenta uma limitação matemática: ele não é uma medida de risco subaditiva e, conseqüentemente, não é uma métrica “coerente” de risco, conforme Artzner et al. (1999). Em outras palavras, ele responde apenas à pergunta “Qual é a perda máxima esperada com 99% de confiança?”, sendo cego em relação ao que ocorre na cauda extrema, ou seja, ele desconsidera, no nosso exemplo (supondo um VaR a 99%), os 1% da distribuição e os impactos de um possível evento dessa cauda.

Para solucionar essa limitação, a literatura e regulações como Basileia III têm migrado para o *Expected Shortfall* (ES) (Acerbi; Tasche, 2002), que calcula a perda média esperada condicionada ao nível de confiança. Diferentemente do VaR, o ES é uma métrica de risco coerente e possibilita uma avaliação mais robusta da magnitude das perdas extremas, porque, enquanto o VaR nos diz qual a perda máxima esperada, por exemplo, para um dia com 99% de confiança, o ES nos informa qual a perda média esperada, caso ocorra um evento de quebra do VaR (ou seja, considerando os piores 1% dos cenários, para nosso exemplo de 99% de confiança).

Adicionalmente, modelos de estimação de risco requerem validação estatística (*Backtesting*). Os dois métodos tradicionalmente utilizados para a validação do VaR são:

- **Teste de Proporção de Falhas (POF) de Kupiec** (Kupiec, 1995): Avalia a “Cobertura Incondicional”, ou seja, verifica se a quantidade total de falhas (quebras do limite do VaR) é estatisticamente idêntica à proporção esperada.
- **Teste de Independência e Teste Conjunto de Christoffersen** (Christoffersen, 1998): Avalia a “Cobertura Condicional”. Testa se as violações do VaR ocorrem de forma agrupada no tempo (*volatility clustering*). Se as violações forem estatisticamente independentes, o modelo prova que capturou e exauriu corretamente

a dinâmica temporal da variância, resultando em um modelo validado no Teste Conjunto (que unifica e avalia simultaneamente a Cobertura Incondicional e a Independência).

Para formalizar a validação empírica do motor de volatilidade frente às anomalias discutidas, este estudo adota a seguinte hipótese:

- **H0₁**: O modelo EGARCH-t **não** produz uma taxa de falhas estatisticamente compatível com o nível de confiança de 99% estipulado, ou seja, a frequência empírica de violações

do VaR difere significativamente de 1%.

- **H1₁**: O modelo EGARCH-t produz uma taxa de falhas estatisticamente compatível com 1%, e as violações ocorrem de forma independente no tempo.

A rejeição generalizada de H0₁ no portfólio analisado indicaria inadequação estrutural do filtro de volatilidade para capturar as dinâmicas de cauda pesada no mercado secundário de debêntures.

2.3 A Hipótese de Mudança de Regimes (Regime-Switching)

Porém, mesmo o modelo EGARCH que possui o tratamento da assimetria dos retornos, possui limitações. A família GARCH, como explicado por Tsay (2005), assume que os parâmetros do modelo (ou seja, os pesos ω , α , γ e β da Equação 1) e a “variância incondicional” não mudam ao longo do tempo. Eles são constantes, baseados em uma única média do comportamento global da série.

Devido a essa constância, esses modelos têm dificuldade em se adaptarem quando existe uma quebra de regime, como os eventos de crédito que foram comentados acima, que uma vez divulgados, alteram a dinâmica de negociação e preço dos papéis. As informações observadas antes do evento deixam de possuir a mesma relevância para prever o comportamento futuro dos ativos afetados. Hamilton (1994) mostra que tais quebras estruturais ocorrem na maioria das séries macroeconômicas ou financeiras que possuem um período suficientemente longo. Como solução a esse problema, o autor propõe a hipótese de mudanças de regime (*Regime-Switching*). Segundo essa teoria, a economia e os mercados não têm um estado único, eles transitam entre diferentes estados, onde as equações que regem os preços mudam dependendo do regime atual, e devido a isso, foi proposta a utilização de Cadeias de Markov para modelar a transição entre diferentes estados da economia, uma vez que elas modelam o estado futuro como um estado dependente apenas do anterior.

2.4 Aprendizado de Máquina Não Supervisionado

Enquanto alguns autores na literatura propõem a integração direta (como os modelos MS-GARCH unificados), neste trabalho adotam-se algoritmos não supervisionados para agrupar e classificar os regimes de risco latentes.

Algoritmos de clusterização baseados em distância espacial euclidiana são extremamente sensíveis a valores discrepantes (*outliers*) e grandezas numéricas não uniformes. No mercado de debêntures, onde os ativos apresentam distorções bruscas, a padronização dos dados (pré-processamento) é indispensável. Ao invés da utilização de escalonadores tradicionais, a literatura, como em Rousseeuw; Hubert (2011) sugere o uso de padronizadores baseados em quantis, como o *RobustScaler*. Este algoritmo subtrai a mediana e divide os dados pelo intervalo interquartil (IQR, ou seja, a diferença entre o 3º e o 1º quartil), mitigando estatisticamente o peso das caudas anômalas (*outliers*) e permitindo que o agrupador avalie a matriz de características livre de distorções induzidas por anomalias momentâneas.

2.4.1 K-Means

Um algoritmo popular para problemas de clusterização é o *K-means* que particiona os dados em K grupos distintos, minimizando a variância intra-cluster. Para utilizá-lo no problema em questão, foram criados três clusters de acordo com o nível de risco do papel, de forma que o esperado é que, conforme um papel comece a apresentar, durante o seu período de negociação, uma variação mais errática do seu *spread*, ou seja, um aumento da volatilidade do *spread*, ele vá migrando do cluster de baixo ao cluster de alto risco.

Para entender melhor essa aplicação vamos tomar como base Bishop (2006), em nosso problema temos que identificar grupos ou *clusters* de dados em um espaço multidimensional. Suponha que esse espaço seja dado por $\{x_1, x_2, \dots, x_N\}$ onde cada um dos N pontos no espaço multidimensional é um vetor de dimensão D .

O objetivo do algoritmo de K-means é particionar os dados em K grupos distintos, de forma que a soma do quadrado das distâncias de cada ponto com o vetor μ_k mais próximo seja minimizada. Ou de forma mais formal:

$$J = \sum_{\{n=1\}}^N \sum_{\{k=1\}}^K r_{nk} \|x_n - \mu_k\|^2 \quad (2)$$

Onde $r_{nk} \in \{0, 1\}$ é uma variável indicadora binária, tal que $r_{nk} = 1$ se o ponto x_n foi alocado ao *cluster* k , e $r_{nj} = 0$, caso contrário (para $j \neq k$). Por sua vez, μ_k representa o vetor centroide do *cluster* k . O objetivo é encontrar os valores de r_{nk} e os centroides μ_k que minimizam a função J . Isso é comumente realizado por meio de um algoritmo iterativo dividido em duas etapas, conhecido como Algoritmo de Lloyd (ou, mais genericamente, algoritmo de maximização de expectativa (EM)).

O modelo, por vezes apresenta um problema conhecido como *Label Switching*, no qual os centroides gerados recebem rótulos arbitrários, isso ocorre porque o algoritmo inicializa os centroides (μ_k) de forma aleatória e busca minimizar a soma das distancias quadráticas (conforme a Equação 2), independentemente dos rótulos atribuídos aos centróides. Porém, existem muitas formas conhecidas de tratar esse problema. A forma adotada nesse trabalho será detalhada em Seção 3.2.5, mas envolve a aplicação de um vetor de polaridade de risco para fixar os rótulos nos regimes Verde (baixo risco), Amarelo (alerta) e Vermelho (crise).

Apesar de sua eficiência em separar os períodos de forma estática, minimizando J , o K-Means é cego para o tempo: ele ignora a probabilidade de transição de um dia para o outro. Como será analisado posteriormente, essa ausência de memória probabilística gera dois efeitos práticos, observados nessa pesquisa: por um lado, causa instabilidade na manutenção do regime (problemas de *flickering* nas fronteiras dos *clusters*); por outro, exige deslocamentos geométricos mais severos para confirmar uma mudança definitiva de estado. Isso torna seu tempo de reação mais lento (inércia geométrica), o que pode torná-lo insensível a quebras de regime abruptas, mas atua, paradoxalmente, como um filtro de ruídos nas simulações financeiras realizadas na etapa de Backtest.

2.4.2 Hidden Markov Models (HMM)

Para corrigir a imperfeição temporal do K-Means, utiliza-se o HMM (*Hidden Markov Model*), um modelo probabilístico estruturado classicamente por Rabiner (1989) e adotado para modelagem de dados sequenciais com estados latentes. Conforme detalhado por Bishop (2006), o HMM parte do princípio de que os dados observados (como o *spread* e a volatilidade) são reflexos de um estado (chamado de variável latente ou *hidden state*), que não pode ser observado diretamente e que é a causa do comportamento dos preços.

Seja z_n a variável latente que representa o regime oculto do mercado no tempo n . No HMM, a dinâmica temporal é regida por um processo de Markov onde a proba-

bilidade do estado atual z_n depende estritamente do estado imediatamente anterior $z_{\{n-1\}}$, denotado por $p(z_n | z_{\{n-1\}})$.

Como as variáveis latentes assumem K regimes categóricos (neste estudo, 3 regimes de risco, detalhados em Seção 3.2.5.1), essa distribuição corresponde matematicamente à matriz de transição de estados A . Adicionalmente, o modelo é governado pelas probabilidades de emissão B , que descrevem a distribuição contínua das observações x_n dado o estado z_n (modeladas aqui por distribuições Gaussianas), e pelo vetor de probabilidades iniciais π , logo, o modelo é parametrizado por $\theta = \{A, B, \pi\}$.

Segundo Rabiner (1989), a viabilidade do HMM depende da solução matemática de dois problemas presentes na arquitetura do motor de risco: a calibração dos parâmetros θ e a decodificação da sequência ótima de regimes.

Para calibração do HMM de forma não supervisionada, utiliza-se o algoritmo de **Baum-Welch**, um caso especial do algoritmo de *Expectation-Maximization* (EM). Na etapa de Expectativa (**E-Step**), estimam-se as probabilidades de cada estado usando o procedimento *Forward-Backward* formalizado por Baum et al. (1970), já a etapa *Forward* calcula as probabilidades observando o histórico até n , denotado por $\alpha(z_n)$, enquanto a etapa *Backward* condensa a probabilidade sob a ótica do futuro de n em diante, denotado por $\beta(z_n)$.

Na etapa de Maximização (**M-Step**), as matrizes A , B e o vetor π são iterativamente atualizados por Máxima Verossimilhança até a convergência. Uma vez calibrado o HMM, a identificação do nível de risco no tempo n é realizada filtrando a probabilidade condicional de cada regime, decodificando a trajetória oculta mais provável via **Algoritmo de Viterbi**, dessa forma, o HMM captura simultaneamente a topologia multivariada dos dados e a inércia estrutural das transições de crédito.

2.5 Seleção de Atributos e Avaliação de Clusters

Para que os algoritmos não-supervisionados (como o K-Means) convirjam para partições representativas, a escolha adequada das variáveis de entrada é crucial. Como, diferentemente de algoritmos supervisionados, não existem os rótulos esperados para guiar os modelos, a qualidade do agrupamento deve ser mensurada matematicamente por meio de métricas de validação interna da geometria dos grupos gerados:

1. **Silhouette Score** (Rousseeuw (1987)): Mede a coesão intra-*cluster* frente à separabilidade inter-*cluster*, variando no intervalo $[-1, 1]$. Nesta métrica, valores maiores indicam melhor adequação, ou seja, valores próximos a 1

sugerem clusters perfeitamente densos e bem separados, enquanto valores próximos a 0 ou negativos indicam forte sobreposição.

2. **Índice Davies-Bouldin** (Davies; Bouldin (1979)): Avalia a razão média da dispersão interna do *cluster* pela distância euclidiana entre os centroides, penalizando sobreposições. Diferente do Silhouette, nesta métrica valores menores indicam melhor adequação, pois

um índice menor (com limite inferior tendendo a zero) significa que os clusters são compactos internamente e distantes uns dos outros.

3. **Índice Calinski-Harabasz** (Caliński; Harabasz (1974)): Mensura a razão entre a variância inter-*cluster* e a variância intra-*cluster*, ponderada pelos graus de liberdade do sistema. Para este índice, valores maiores indicam melhor adequação,

denotando que a distância entre os centros dos clusters é expressivamente maior que a dispersão dos pontos dentro de cada regime.

Dado que não existe uma solução unificada no Aprendizado de Máquina, frequentemente estas três métricas fornecem orientações sobre qual o melhor particionamento, então, a solução matemática para este problema repousa sobre as heurísticas de consenso, combinando os resultados de cada métrica. O **Método de Borda (Borda Count)**, tradicionalmente um sistema de votação, foi introduzido por (Borda, 1781), contudo, sua adaptação computacional moderna o torna um mecanismo imparcial e poderoso para consolidar múltiplos sistemas de classificação e validação multivariada, sendo amplamente estendido na literatura moderna de Aprendizado de Máquina, e validado na construção de classificadores de consenso por Ho; Hull; Srihari (1994) e Kittler et al. (1998), bem como na seleção robusta de atributos (*ensembles*) por Saeys; Abeel; Peer (2008). No contexto deste trabalho, as *features* são pontuadas pela posição ordinal que alcançaram em cada métrica isolada, combinando os resultados pelo **Método de Borda**, mitiga-se o viés individual de cada métrica e se converge para o subconjunto dimensionalmente mais robusto.

3 METODOLOGIA E DADOS

A análise do risco de crédito das debêntures requer uma coleta extensa de dados e análise rigorosa de sua qualidade para que o modelo implementado seja acurado e capaz de capturar as nuances desejadas. Este capítulo detalha os procedimentos que foram adotados para a coleta, tratamento e análise dos dados, além dos modelos e validações aplicados neste estudo.

Uma vez que o estudo será disponibilizado juntamente dos códigos-fonte utilizados para sua elaboração (estarão disponíveis para consulta no no repositório do GitHub do autor, juntamente com a documentação de uso), todos os procedimentos detalhados abaixo podem ser replicados pelo leitor de forma independente.

3.1 Coleta e Tratamento de Dados (ANBIMA)

Os dados base de *spread* por debênture e dia de negociação, que alimentam essa pesquisa foram extraídos do site da ANBIMA, mais especificamente na seção de Prévias Públicas de Negociação de Instrumentos Financeiros, que pertence ao sistema REUNE. O período da amostra foi do segundo dia de janeiro de 2018 a 10 de julho de 2026, sendo que os dados diários extraídos possuem as seguintes colunas: Código Cetip, Tipo, Agrupamento, Taxa Mínima, Taxa Média, Taxa Máxima, Preço Mínimo, Preço Médio, Preço Máximo e Faixa de Volume. O leitor interessado em reproduzir esta coleta de dados pode consultar as rotinas de raspagem de dados (*web scraping*) e os *scripts* de unificação (pois a raspagem de dados gera um arquivo csv por dia de consulta) disponibilizados no repositório público desta pesquisa no GitHub.

Já as informações cadastrais foram obtidas na página Debentures.com.br (que será substituída pelo ANBIMA Data) por meio de consulta automatizada utilizando o pacote `debentures_dot_com` (mantido pelo autor desse trabalho). As informações obtidas são referentes à emissão das debêntures e incluem informações como: Ticker, Indexador, Data de Emissão, Data Vencimento, Empresa, CNPJ, Emissão, Situação, Classe, Garantia, Quantidade Emitida, Quantidade Mercado, Taxa Emissão, Motivo de Saida, entre outras; para mais informações sobre os campos citados ou campos disponíveis consultar a página do ANBIMA Data e/ou o pacote `debentures_dot_com`.

A rotina automatizada para o cruzamento destas informações cadastrais também encontra-se documentada no repositório do projeto.

As informações macroeconômicas (CDI, Selic, IPCA Mensal e 12M e IGPM Mensal) foram extraídas utilizando o pacote `python-bcb`. O leitor pode replicar esse download por meio da aplicação direta do pacote de Freitas (2024) para as variáveis de interesse, cujos *scripts* constam no repositório do projeto.

Na etapa de pré-processamento, mais detalhada na Seção 3.2.1, foi realizada a normalização e tratamento das variáveis. Como a base de dados extraída da ANBIMA abrange múltiplos indexadores (como IPCA+, DI+ e % do CDI), foi necessário separar esses grupos para treinar e aplicar o modelo de forma independente, criando uma instância de modelagem por indexador, conforme será detalhado nas sessões seguintes, uma vez que os papéis de diferentes indexadores possuem comportamento de risco distintos, assim como distinta sensibilidade à variação da taxa.

Como citado na Seção 1, um desafio inerente ao mercado secundário de crédito privado brasileiro é a baixa liquidez dos ativos, inclusive com alguns chegando a possuir dias sem negociação. A ANBIMA classifica o volume de negociação, no sistema de informações consultado, em faixas, sendo a faixa mais baixa dada por “Até 1MM”, e portanto, dado as informações possuídas na realização dessa pesquisa, esses são os ativos definidos como ilíquidos. Para lidar com essa característica, desenvolveu-se uma rotina algorítmica de tratamento, que, quando habilitada, remove da base de dados para treinamento (que será detalhada posteriormente em Seção 3.2.1), os ativos que permaneceram como ilíquidos durante um período igual ou superior a 95% da amostra. O propósito dessa funcionalidade é impedir que, caso sejam observados eventos de variação de *spread* espúrios, devido a baixa liquidez, eles não sejam propagados para o modelo EGARCH, o que poderia corromper a estimação da persistência e dos choques (parâmetros α e β) da variância condicional, sendo importante notar que esses ativos foram removidos apenas da amostra de teste, com a exceção de RDVT11, que foi removido manualmente da amostra devido aos seguintes fatores:

- O ativo não tinha dados de negociação durante a etapa de treinamento, então seria considerado posteriormente, mesmo ilíquido.
- A série de preços do ativo apresenta grandes variações, com um espaçamento elevado entre os dados, o que pode introduzir vieses na estimação.
 - Em 05/12/2023 o ativo foi negociado com PU de 1001.77, sendo negociado novamente apenas em 20/03/2024 com PU de 1.40 e posterior em 21/03/2024 com PU de 0.000014. Voltando a ser negociado em 26/07/2024 com PU de 38.04 e em 28/02/2025 com PU de 754.31.
- A empresa passou por eventos de reestruturação e recuperação judicial

A princípio, a empresa deveria ser um exemplo natural de evento de *tail risk* que o modelo deveria prever. Contudo, devido ao espaçamento temporal irregular de marcações a mercado e à extrema escassez de liquidez, as séries de retorno tornaram-se puramente espúrias, o que pode comprometer severamente a convergência do estimador de máxima verossimilhança do motor EGARCH, além disso, como o ativo permanece durante o período *Out-of-Sample*, ele seria considerado no *backtest*, gerando PnLs espúrios. Por esse motivo, a exclusão sumária deste ativo da amostra final foi necessária para preservar a integridade estatística da modelagem e coerência dos resultados observados.

3.2 O Pipeline de Risco (EGARCH, K-Means e HMM)

Para a implementação dos modelos, foi criado um *pipeline* de risco, que, através de um fluxo linear estima as variáveis de maior impacto para o modelo, realiza o cálculo do volatilidade, VaR e *Expected Shortfall* (ES) por papel e, por fim, aplica o algoritmo K-Means e o Modelo Oculto de Markov (HMM). Uma vez obtidos os resultados do K-Means e HMM, se gera um modelo *Ensemble*, ponderando os resultados de cada modelo. Abaixo será detalhada a metodologia aplicada em cada etapa. Para facilitar a compreensão sistêmica, a Figura 1 ilustra a arquitetura global do *pipeline*, desde a coleta de dados e divisão temporal até o processamento nos motores estocásticos e a simulação final (*Backtest*).




Figura 1: Arquitetura do Pipeline de Risco e Backtest

3.2.1 Pré-processamento de Dados e Filtros

Os dados coletados em Seção 3.1 foram divididos em dois períodos: *In-Sample* e *Out-of-Sample*. O período *In-Sample*, iniciado em janeiro de 2018 até dezembro de 2022 utilizado para a seleção e estimação dos parâmetros dos modelos e o período *Out-of-Sample*, iniciado em janeiro de 2023 até julho de 2026, utilizado para a implementação, observação e validação dos modelos, incluindo a avaliação do modelo em eventos de crédito realizado como o Grupo Pão de Açúcar, amplamente citado nessa pesquisa, devido a suas proporções e ao fato de ter sido o evento mais recente, dado o momento em que este trabalho foi escrito.

Além disso, as variáveis obtidas na etapa Seção 3.1 foram utilizadas como base para o cálculo de outras métricas. Para papéis indexados a um percentual do CDI (ex: 120% do DI), foi realizada uma conversão explícita baseada na taxa CDI anualizada (extraída via `python-bcb`, conforme a Seção 3.1). A transformação anualiza o fator diário do título e extrai o prêmio absoluto sobre a taxa livre de risco, conforme abaixo:

$$F_{\text{cdi}} = \left(1 + \frac{\text{CDI}_t}{100}\right)^{\frac{1}{252}} \quad (3)$$

$$F_{\text{título}} = (F_{\text{cdi}} - 1) \times \left(\frac{\text{Taxa do Ativo}_t}{100}\right) + 1 \quad (4)$$

$$S_t = ((F_{\text{título}})^{252} - 1) \times 100 - \text{CDI}_t \quad (5)$$

Para os títulos atrelados a índices de inflação (como IPCA, IGPM) ou por um prêmio direto sobre o DI (DI Spread), a própria taxa informada no secundário já reflete o prêmio de risco:

$$S_t = \text{Taxa do Ativo}_t \quad (6)$$

A partir dessa informação, foi calculado a variação diária do *spread* (**Delta Spread**), que atua como o principal input para o ajuste temporal do modelo EGARCH.

$$\Delta S_t = S_t - S_{t-1} \quad (7)$$

Devido a indisponibilidade de dados suficientes para o cálculo de duration se utilizou como base a quantidade de dias úteis para o vencimento do papel (limitado ao mínimo de dois dias), para calcular a taxa ajustada ao prazo, conforme abaixo:

$$\text{Taxa}_{\text{prazo}} = \frac{S_t}{\ln(\max(\text{DU}, 2))} \quad (8)$$

Foi também calculado o *z-score* do *spread*, utilizando uma janela móvel de 60 dias, além do *Spread Range Intraday* e *Spread Skew Intraday*, dados respectivamente por:

$$S_{\text{range}} = \text{Taxa do Ativo}_{\text{max}} - \text{Taxa do Ativo}_{\text{min}} \quad (9)$$

$$S_{\text{skew}} = \frac{\text{Taxa do Ativo} - \text{Taxa do Ativo}_{\text{min}}}{S_{\text{range}} + \varepsilon} \quad (10)$$

Sendo $\varepsilon = 1e - 6$ utilizado para evitar divisão por zero.

3.2.2 EGARCH

Apesar do viés teórico discutido em Seção 2, foram testados vários modelos da família GARCH em um modelo de torneio de *grid-search*, para diferentes tamanhos de amostra, o modelo EGARCH foi aquele que apresentou melhor desempenho. O torneio avaliou os dados a partir de 2018 até o fim de 2022, que foi o período utilizado para treinamento do modelo, sendo o período a partir de 2023 o período de validação dos resultados, conforme detalhado em Seção 3.2.1. O código listou todos os ativos e filtrou os n mais líquidos do período, sendo testado para diferentes valores de n .

Para cada um dos ativos selecionados, o otimizador testou um grid combinatório de 32 especificações da família GARCH (utilizando o pacote `arch`). Os hiperparâmetros iterados foram:

- Média Condicional: Fixada em um modelo Autorregressivo de ordem 1 (AR(1)).
- Famílias de Volatilidade: GARCH tradicional, EGARCH (exponencial), GJR-GARCH (assimétrico) e TARARCH.
- Defasagens (Lags) p : 1 e 2 (Impacto da variância passada).
- Defasagens (Lags) q : 1 e 2 (Impacto dos choques correntes).
- Distribuição dos Resíduos: Normal e t-Student.

A variável de entrada, conforme detalhado em Seção 3.2.1 foi o **Delta Spread**. Para cada combinação de modelo e ativo foi calculado o Critério de Informação de Akaike (AIC) e então para cada papel o modelo escolhido foi aquele que apresentou menor valor de AIC, cada vez que o modelo foi eleito foi considerado uma vitória e, ao final, foi calculado a taxa média de vitórias de cada modelo e eleito aquele que apresentou um maior percentual de vitórias. Matematicamente, a taxa de vitória W_j de um modelo j é dada por:

$$W_j = \frac{\sum_{\{i=1\}}^N I_{i,j}}{N} \times 100 \quad (11)$$

onde N é o número total de ativos avaliados e $I_{i,j}$ é uma função indicadora que assume valor 1 se o modelo j apresentar o menor AIC para o ativo i (ou seja, $AIC_{i,j} = \min_k AIC_{i,k}$), e 0 caso contrário.

Adotou-se o modelo que maximizou W_j , garantindo a escolha empírica do algoritmo que melhor se adapta à maior proporção do mercado de crédito. Para amostras pequenas o destaque foi o modelo EGARCH(2,1,1) utilizando a distribuição t-student, porém, a partir de 100 amostras ($n = 100$), o EGARCH(1,1,1) com a distribuição t-student passou a apresentar uma maior taxa de vitórias, como se pode observar nas figuras abaixo:




Figura 2: Torneio GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.




Figura 3: Torneio GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.




Figura 4: Torneio GARCH: Ranking Médio para a amostra ampla de 500 ativos.

Além disso, nas Figura 3, Figura 4 podemos observar que apesar do EGARCH(1,1,1) com a distribuição t-student apresentar maior taxa de vitórias, o GARCH(1,0,1) com a distribuição t-student apresentou melhor rank médio no teste. Esse resultado é, de certa forma, esperado, uma vez que para debentures liquidas que não possuem grandes choques, o GARCH, como visto em Seção 2 tem alto poder preditivo em condições de normalidade, enquanto o EGARCH pode ser penalizado pela tentativa de estimar assimetria (e parâmetros a mais quando comparamos apenas as versões supra citadas), uma vez que o AIC penaliza modelos que possuem parâmetros extras caso eles não tragam ganhos de aderência significativos. Contudo, nos papéis que passam por mais eventos de estresse, é esperado que o EGARCH performe melhor, por ser capaz de capturar assimetrias, além da heterocedasticidade condicional, o que poderia justificar os resultados observados.

Como o intuito dessa pesquisa é estudar justamente os casos de estresse, e não a dinâmica da normalidade, foi adotado o modelo que apresentou maior *Win Rate*, e não aquele que apresentou o melhor rank médio. Essa escolha é justificada pelo fato de que, desejamos possuir o modelo que possui maior taxa de acertos, em detrimento da otimização de parâmetros, o que também justifica a escolha do AIC como métrica principal em detrimento do BIC, que possui maior penalização por parâmetros extras, favorecendo modelos mais simples, além disso, o EGARCH modela a variancia em escala logarítmica, o que garante que a variancia seja sempre positiva, diferentemente do GARCH tradicional.

Após a eleição do EGARCH(1,1,1) com distribuição t-Student como o motor principal de volatilidade condicional, foram aplicados testes de diagnóstico aos resíduos gerados por este modelo para verificar sua qualidade estatística:

1. **Ljung-Box (Lag 10):** Para confirmar a ausência de autocorrelação serial remanescente, atestando que a média condicional AR(1) foi bem especificada.
2. **ARCH-LM (Lag 10):** O teste do multiplicador de Lagrange (Lagrange Multiplier) para verificar se toda a heterocedasticidade condicional foi devidamente absorvida pela variância EGARCH, impossibilitando a persistência do efeito ARCH nos resíduos.

Como a modelagem GARCH é realizada univariadamente (ativo a ativo), ajustou-se o modelo campeão para o universo viável de debêntures do período de teste, totalizando uma amostra de 529 debêntures. Este número representa a quantidade de debêntures na amostra utilizada para o período que preencheram simultaneamente os critérios de elegibilidade: alta liquidez (exclusão de dias com volume “Até 1MM”), convergência numérica no otimizador de máxima verossimilhança e um histórico contínuo mínimo de 50 observações válidas. Os testes de hipótese foram aplicados aos resíduos de cada um dos ativos, considerando um nível de significância de 5%.

Os resultados demonstram um excelente grau de aderência do modelo ao mercado de crédito secundário brasileiro, conforme ilustrado na Figura 5, onde 86,4% dos papéis modelados passaram no teste de Ljung-Box e 94,9% dos ativos passaram no teste ARCH-LM, o que evidencia que o modelo EGARCH é adequado para a maioria das debêntures analisadas.




Figura 5: Taxa de aprovação dos testes de diagnóstico nos resíduos padronizados do EGARCH(1,1,1) t-Student para 529 debêntures.

Uma vez definido e implementado o modelo EGARCH(1,1,1) com distribuição t-Student, a distribuição estimada para cada ativo foi utilizada também para o cálculo do Valor em Risco (VaR) e Expected Shortfall (ES) (com percentil de 99%, que foram atribuídos às variáveis VaR_{99} e $Expected_Shortfall_{99}$, respectivamente) como forma de precificar o risco das debêntures analisadas baseado na série de volatilidade estimada. Como a distribuição escolhida para os resíduos foi a t-student, se $\nu \leq 2$ então a variancia da distribuição se torna infinita, levando a erros numericos no python quando se tenta calcular o VaR e ES, para evitar tais erros, foi aplicado um limite nos graus de liberdade, de forma que ν sempre será maior que 2.05, matematicamente, temos que o tratamento aplicado foi:

$$\nu = \max(2.05, \nu_{est}) \quad (12)$$

Onde ν_{est} é o valor estimado pelo modelo EGARCH(1,1,1). Além disso, durante a estimação da volatilidade, foram encontrados alguns problemas de otimização devido a instabilidade de algumas séries, principalmente as que permanecem dias sem negociação e quando são negociadas apresentam “saltos” no *spread*. Como o intuito do modelo é uma classificação de *warning*, e não uma quantificação exata do risco, ou do valor esperado da perda, aplicou-se uma limitação na volatilidade calculada, de forma que caso o EGARCH estime um valor que seja 20 vezes maior que o percentil 99% da volatilidade observada do ativo, estimada pelo desvio padrão, o valor é removido da amostra e replica-se a volatilidade observada no dia anterior, matematicamente, temos que o tratamento aplicado foi:

$$\sigma_{est}(t) = \sigma_{est}(t-1) \quad \text{se} \quad \sigma_{est}(t) > v_{teto} \quad (13)$$

onde $\sigma_{est}(t)$ é a volatilidade estimada pelo modelo EGARCH(1,1,1) no dia t , e v_{teto} é o limite superior definido como 20 vezes o percentil 99 da série *in-sample*.

3.2.3 Teste de Estacionariedade dos Spreads

A aplicação de modelos da família GARCH pressupõe que a série temporal analisada seja estacionária em covariância. Antes do ajuste do EGARCH-t, verificou-se, portanto, a estacionariedade das séries de retorno de *spread* utilizadas como insumo do motor de volatilidade.

Para tanto, aplicou-se o Teste de Dickey-Fuller Aumentado (ADF) sobre as séries de primeiro incremento de *spread* ($\Delta Spread$) dos 529 ativos selecionados para modelagem. O teste avalia a hipótese nula de raiz unitária (série não-estacionária):

- **H0** (ADF): A série de Delta_Spread possui raiz unitária (não-estacionária).
- **H1** (ADF): A série é estacionária (rejeita H0).

A especificação adotada inclui constante sem tendência determinística, com seleção automática de defasagens por Critério de Informação de Akaike (AIC). Os resultados, reportados na Tabela 1, demonstram que a série de *spread* bruto (Taxa_Ativo) é não-estacionária em 91% dos casos, como esperado (a nível de *spread*, as séries são integradas de ordem 1) e após a primeira diferença (Delta Spread), **95,7% das séries rejeitam H0 ao nível de 5%**, validando o pressuposto de estacionariedade necessário para o EGARCH.

Indexador	Total	Estacionárias (Delta Spread)	Taxa (%)	Spread Bruto (Taxa Ativo)
IPCA	286	275	96,2%	NE
CDI Spread	239	227	95,0%	NE
PRE	4	4	100,0%	NE
Total	529	506	95,7%	—

Tabela 1: Resultados do Teste ADF ($\alpha = 5\%$) — Estacionariedade por Indexador.

Nota: NE = Não-Estacionário.

Os ativos que compõem os 3,4% restantes que não rejeitam H0 são, em sua maioria, papéis com histórico extremamente curto (entre 30 e 60 observações) e perfil de iliquidez estrutural, nos quais a baixa frequência de negociação gera séries com longos períodos de retornos nulos que distorcem a convergência do teste, para esses casos, o motor EGARCH produz estimativas de volatilidade de menor confiança, conforme documentado na Seção 3.2.2.

3.2.4 Seleção de variáveis

Nas seções Seção 3.2.1 e Seção 3.2.2 foram listadas as variáveis calculadas:

- Taxa_ZScore
- Volatilidade_EGARCH
- VaR_99
- Expected_Shortfall_99
- Spread_Equivalente
- Spread_Range_Intraday
- Spread_Skew_Intraday

Elas foram utilizadas como um input para um processo de seleção de variáveis, que elegeu as mais relevantes para utilização nos modelos propostos. Devido a natureza não supervisionada desses modelos, a determinação da relevância dessas variáveis não pode ser realizada através dos métodos usuais que são utilizados para os processos de aprendizado supervisionado, por essa razão, a seleção implementada realiza combinações iterativas por meio de um *Grid Search* sobre subconjuntos das variáveis candidatas utilizando os dados de treinamento (*In-Sample*). Com intuito de garantir significado econômico aos clusters, a variável *Taxa_ZScore* foi mantida como obrigatória em todas as combinações, impedindo que o algoritmo selecione apenas variáveis de risco correlacionadas (como a volatilidade EGARCH e o VaR), o que não agregaria valor discriminatório aos *clusters*, devido a carência da precificação relativa ao *spread* de crédito.

Para cada subconjunto testado, os dados foram padronizados utilizando *RobustScaler* devido a sua capacidade de lidar com outliers, conforme apresentado em Seção 2. Os subconjuntos foram então submetidos a uma clusterização primária utilizando K-Means com $k = 3$ regimes (a escolha dos regimes é justificada empiricamente na Seção 3.2.5.1), a qualidade de separabilidade dos agrupamentos foi mensurada através das três métricas listadas na Seção 2.5 (***Silhouette Score*** , ***Índice Davies-Bouldin*** e ***Índice Calinski-Harabasz***).

Uma vez que as métricas atuam em ordens de grandeza e domínios matemáticos distintos, o subconjunto vencedor não é escolhido por médias, mas sim pelo método de agregação de Ranks de Borda (***Borda Count***)¹. O algoritmo computa a posição de cada combinação no ranking individual de cada métrica e o ***Borda Score*** final é dado pela soma das posições invertidas, garantindo uma eleição ordinal, determinística e robusta às magnitudes isoladas de índices específicos.

Como resultado da otimização matemática (***Borda Score***), o subconjunto *Taxa_ZScore* e *Volatilidade_EGARCH* obteve a pontuação máxima no particionamento empírico, no entanto, o subconjunto eleito para a modelagem final incorporou também a estimativa de risco de cauda (*Expected_Shortfall_99*), formando o grupo *Taxa_ZScore*, *Volatilidade_EGARCH* e *Expected_Shortfall_99*, que figurou em segundo lugar no ranking geral, a Figura 6 ilustra o Top 10 das combinações avaliadas. A escolha táctica pelo trio de variáveis é justificada pela necessidade imperativa do modelo possuir sensibilidade preditiva a perdas financeiras extremas, agregando significado econômico aos *clusters* formados.

¹A classificação integral de todas as combinações de variáveis testadas no *Grid Search*, contendo o ranking detalhado de cada métrica de particionamento e o *Borda Score* final, está disponível no repositório público da pesquisa, no diretório [anexos_digitais/](#).




Figura 6: Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.

Uma forma mais lúdica de observar o desempenho dessas variáveis é realizar a comparação de forma multidimensional, a Figura 7 ilustra o desempenho das quatro principais combinações normalizado nos três eixos de avaliação (Coesão, Dispersão e Separação), o gráfico demonstra como a combinação escolhida consegue maximizar satisfatoriamente o *Silhouette Score* e o **Calinski-Harabasz**, mantendo a competitividade no índice de **Davies-Bouldin**.

Comparação Multidimensional - Feature Selection




Figura 7: Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).

Na Figura 7, o conjunto dado pelas variáveis Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99 (segundo lugar) e o conjunto dado pelas variáveis Taxa_ZScore, Volatilidade_EGARCH e VaR_99 (terceiro lugar) parecem ter um desempenho muito similar, mas quando observamos a Figura 6, o primeiro conjunto possui um score superior. A única diferença entre eles é a substituição do Expected Shortfall pelo VaR, porém, o Expected Shortfall possui um score superior em todas as métricas, apesar de ser visualmente difícil a identificação na Figura 7. Além disso, como foi abordado em Seção 2 o Expected shortfall é uma métrica superior, pois enquanto o VaR responde a pergunta “Qual é a perda máxima que posso esperar com 99% de confiança?”, o Expected Shortfall responde a pergunta “Qual é a perda média que posso esperar quando o VaR for excedido?”. Além disso, diferentemente do VaR, o Expected Shortfall é uma medida de risco coerente, reforçando sua escolha, em detrimento do VaR.

3.2.5 K-Means

Eleitas as variáveis de entrada do modelo (Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99), o algoritmo K-Means atua propositalmente como uma *baseline* ingênua (*naive*). Reconhece-se que a aplicação do K-Means em séries temporais financeiras viola o pressuposto de observações independentes e identicamente distribuídas (i.i.d.), uma vez que os retornos apresentam comprovada autocorrelação da variância, contudo, essa violação metodológica é assumida de forma deliberada no desenho da pesquisa para servir como contraponto determinístico ao modelo markoviano (HMM), uma vez que a intenção é provar valor marginal preditivo que a memória temporal agrega sobre a classificação puramente estática, de forma empírica e quantitativa. O processo é realizado iterativamente para cada grupo de indexador (ex: DI, IPCA), a fim de respeitar as dinâmicas particulares de cada mercado.

3.2.5.1 Justificativa Empírica do Número de Clusters ($k = 3$)

A escolha de $k = 3$ regimes — Verde (baixo risco), Amarelo (alerta) e Vermelho (crise) — foi motivada, primariamente, pela semântica financeira do sistema de alertas (analogia aos semáforos, comumente utilizados em risco de crédito). Contudo, para validar formalmente essa escolha, aplicou-se a análise de *Elbow Method* (inércia da soma dos quadrados intra-cluster em função de k) e o *Silhouette Score* médio para $k \in \{2, 3, 4, 5, 6, 7\}$, utilizando rigorosamente os dados padronizados do período *In-Sample* para evitar viés prospectivo (*Data Snooping*).

Os resultados, ilustrados na Figura 8, mostram que para os indexadores IPCA e DI *Spread*: (i) a curva de inércia exibe uma inflexão (*Elbow*) em $k = 3$, indicando redução marginal decrescente a partir deste ponto; (ii) o *Silhouette Score* para $k = 3$ é consistentemente superior ao de $k = 2$ em ambos os grupos, ao mesmo tempo em que $k = 4$ e $k = 5$ não oferecem ganho relevantes de separabilidade. Conclui-se, portanto, que $k = 3$ é a escolha **parcimoniosa** que maximiza a interpretação econômica e a coerência geométrica dos regimes.




Figura 8: Elbow Method e Silhouette Score por número de clusters k — Superior: IPCA, Inferior: CDI Spread

O primeiro passo é a separação da amostra de treino e teste (*In-Sample* para treino, *Out-of-Sample* para teste), conforme detalhado em Seção 3.2.1. Para garantir que *outliers* extremos (como casos que discutimos nas seções anteriores, em que ativos passam dias sem negociação e depois quando voltam a ser negociados apresentam saltos no *spread*), aplica-se uma Winsorização (clipagem) no 1º e 99º percentis utilizando os dados *In-Sample*. Esses limites são posteriormente aplicados aos dados *Out-of-Sample*, prevenindo o viés de antecipação de informação (*look-ahead bias*).

Em seguida, os dados são padronizados através do algoritmo *RobustScaler*. Para capturar o risco relativo de cada papel, o escalonamento é feito individualmente por ativo, possuindo como limitador inferior 10% da variância (IQR) global do indexador, evitando que ativos estruturalmente ilíquidos sofram explosões numéricas. Já, que, uma vez o *RobustScaler* é dado por:

$$\text{Scaled}(x) = \frac{x - Q_2(x)}{Q_3(x) - Q_1(x)} \quad (14)$$

Caso o IQR ($Q_3(x) - Q_1(x)$) seja nulo ou próximo de zero, o escalonamento se torna indefinido.

O K-Means é então treinado nos dados padronizados com $k = 3$ agrupamentos. Devido à natureza não-supervisionada do K-Means, os centróides gerados recebem rótulos arbitrários (este é um problema conhecido como *Label Switching*), o modelo resolve este problema através de um vetor de polaridade de risco (onde valores maiores de volatilidade e *Z-Score* implicam maior risco), ordenando as médias dos agrupamentos para classificar deterministicamente os regimes em Verde (baixo risco), Amarelo (alerta) e Vermelho (crise).

Na etapa preditiva, para a construção de um modelo misto ponderado (conforme será abordado em Seção 3.2.7), a probabilidade de crise (*Prob_Crise_KMeans*) é definida com base na distância euclidiana inversa de cada observação *Out-of-Sample* até o centróide Vermelho.

3.2.6 HMM

Para investigar o valor da memória latente no reconhecimento de padrões da série temporal, estabelecemos a segunda hipótese deste estudo:

- **H0₂**: A inclusão da dependência temporal (matriz de transição markoviana) **não** melhora a capacidade de identificação precoce de eventos de estresse em relação ao particionamento geométrico atemporal (K-Means).
- **H1₂**: O modelo HMM, ao modelar a persistência dos regimes de risco, antecipa a deterioração do crédito com maior *lead time* do que o K-Means para os eventos de crédito observados no período *Out-of-Sample*.

Esta hipótese é avaliada qualitativamente por meio de estudos de caso para uma cesta de debentures e da comparação do primeiro alerta por modelo.

O Modelo Oculto de Markov (HMM - *Hidden Markov Model*) acrescenta a dependência temporal que o K-Means ignora. O pré-processamento para o HMM segue as exatas mesmas premissas de divisão, winsorização e padronização geométrica (piso de variância) descritas em Seção 3.2.5, adicionando apenas a restrição de que a massa de dados obedeça estritamente a ordenação sequencial no tempo, já que para o HMM, essa ordenação é de extrema importância para que o modelo consiga modelar as transições entre os estados latentes.

O treinamento *In-Sample* é realizado através de um HMM Gaussiano (*GaussianHMM*) de 3 estados latentes com matriz de covariância diagonal, aplicando o algoritmo de otimização de **Baum-Welch**. Apesar de ter sido demonstrado em Seção 2 que os retornos do *spread* exigem uma distribuição leptocúrtica (t-Student), as *features* alimentadas ao HMM neste estágio (*Taxa_ZScore* e *Volatilidade_EGARCH*) já foram

previamente modeladas e padronizadas, com a volatilidade condicional já capturando o impacto da cauda pesada.

Para validar empiricamente esta premissa na modelagem, analisou-se o Excesso de Curtose (medida estatística de “peso da cauda”) das séries temporais no período *In-Sample*. Foi constatado que os retornos (sobre as séries de *spread*) apresentaram um Excesso de Curtose de 2683,30, indicando eventos extremos e caudas ultra-pesadas que inviabilizariam o uso de uma matriz Gaussiana, todavia, a *feature* Taxa_ZScore, resultante do filtro estocástico do EGARCH-t, reduziu este Excesso de Curtose para apenas 1,17. Em finanças quantitativas e modelagem multivariada, excessos de curtose localizados no intervalo de -2 a $+2$ (e mesmo sob critérios mais relaxados, até $+7$) são considerados comportados e largamente aceitáveis para a adoção de premissas de normalidade em estimações por Máxima Verossimilhança sem enviesamento grave dos estimadores (Hair et al., 2010). Consequentemente, o espaço latente do HMM encontra-se num domínio de eventos extremos mitigado, o que valida a escolha do modelo Gaussiano para assegurar a estabilidade numérica e convergência na calibração das matrizes, da mesma forma, os vetores de médias estimadas para as emissões Gaussianas sofrem a correção heurística de *Label Switching* para rotular os estados como Verde, Amarelo e Vermelho.

Uma alteração fundamental feita no HMM padrão diz respeito à calibração da Matriz de Transição de Estados (A). Em bases de dados com regimes muito duradouros, pode haver a total ausência empírica de transições entre estados extremos (como saltos diretos de Verde para Vermelho) na amostra de treinamento, o que gera probabilidades de transição iguais a zero, transformando os regimes em “estados absorventes” (uma vez que o modelo entre nesse estado, a probabilidade de sair matematicamente se anula). Para mitigar esse problema, aplicou-se primeiramente a **Suavização de Laplace** (*Additive Smoothing*) sobre a matriz empírica de contagens de transição:

$$P'_{\{ij\}} = \frac{C_{\{ij\}} + \alpha}{\sum_{\{k=1\}}^K C_{\{ik\}} + K\alpha} \quad (15)$$

onde $C_{\{ij\}}$ é a contagem empírica de transições do estado i para o estado j observadas na sequência latente decodificada do *In-Sample*, $K = 3$ é o número de estados, e $\alpha = 1$ atua como o pseudo-fator aditivo.

Complementarmente à Equação 15, para garantir matematicamente que o modelo permaneça reativo aos novos choques de mercado e não dependa excessivamente da inércia do estado anterior, impôs-se um limiar (piso) arbitrário de 1% (0.01) sobre a matriz de probabilidade de transição, seguido por uma re-normalização linha a linha (para assegurar que o somatório das probabilidades convirja para 1):

$$P''_{\{ij\}} = \max(P'_{\{ij\}}, 0.01) \quad (16)$$

$$P_{\{ij\}} = \frac{P''_{\{ij\}}}{\sum_{\{k=1\}}^K P''_{\{ik\}}} \quad (17)$$

Esse mecanismo em duas etapas força o modelo a manter vias probabilísticas ativas e o impede de se tornar inerte, especialmente para a saída do estado de crise (Vermelho).

A inferência nos dados *Out-of-Sample* é desenhada para evitar viés do futuro. Para estimar a probabilidade de um ativo estar em crise no dia t , o modelo recebe apenas a sequência de variáveis observáveis do instante inicial até o instante t (janela causal). A sequência ótima de estados latentes é decodificada utilizando o **Algoritmo de Viterbi**, e a probabilidade marginal instantânea de crise (Prob_Crise_HMM) é inferida simultaneamente pelo *Forward-Backward*.

3.2.7 Modelo Misto (Ensemble)

A intuição de mesclar diferentes modelos parece promissora, mas exige verificação empírica, a quarta hipótese que permeia este trabalho contesta o benefício da modelagem mista:

- **H0₄**: A combinação ponderada (Ensemble) dos modelos K-Means e HMM **não** produz uma estratégia de alocação inferior às estratégias individuais de cada componente, em termos de retorno ajustado ao risco.
- **H1₄**: A ponderação dos sinais dos modelos K-Means e HMM, sem calibração empírica dos pesos, induz ao efeito *whipsaw* e resulta em performance inferior às estratégias individuais.

A avaliação é realizada pela comparação do Calmar Ratio e Retorno Total do Ensemble contra K-Means e HMM individuais nos resultados do Backtest.

As previsões individuais do K-Means (detalhada em Seção 3.2.5) e do HMM (detalhada em Seção 3.2.6) são posteriormente combinadas em uma pontuação final, buscando mesclar a inércia do particionamento geométrico (K-Means) com a memória temporal do filtro bayesiano (HMM).

A combinação matemática é realizada através de uma média ponderada das probabilidades individuais de cada modelo. Para determinar a alocação de pesos ótima e evitar decisões arbitrárias ou vieses prospectivos (*Data Snooping*), executou-se uma rotina de otimização de hiperparâmetros via *Grid-Search* de Força Bruta

($w_{\text{HMM}} \in [0.0, 1.0]$, em incrementos de 0.10) estritamente sobre as previsões do período *In-Sample*, na qual a métrica alvo para a otimização foi o **Calmar Ratio** (retorno anualizado sobre rebaixamento máximo) gerado pelo simulador financeiro. O resultado empírico demonstrou que o melhor retorno ajustado ao risco na amostra de treinamento ocorreu com a proporção de 70% de peso para o HMM e 30% para o K-Means, a Figura 9 ilustra as métricas financeiras obtidas para diferentes combinações de pesos no simulador tático *in-sample* (assumindo liquidação defensiva a partir do estágio de Alerta), ratificando o pico otimizado em $w_{\text{HMM}} = 0.70$.




Figura 9: Análise de Sensibilidade (*Grid-Search*) dos pesos do modelo Ensemble no período *In-Sample*.

A Tabela 2 detalha os resultados quantitativos extraídos da simulação estática, evidenciando como a alocação de 70% do peso para o motor probabilístico (HMM) minimizou o declínio e ofereceu o equilíbrio ótimo frente a estratégias puramente mono-modelo.

w_HMM	w_KMeans	CAGR (%)	Max Drawdown (%)	Calmar Ratio
0.0	1.0	-2.938	-98.289	-0.0299
0.1	0.9	-1.711	-98.817	-0.0173
0.2	0.8	-1.982	-99.163	-0.0200
0.3	0.7	-1.725	-43.616	-0.0396
0.4	0.6	-1.511	-51.129	-0.0296
0.5	0.5	-1.330	-64.830	-0.0205
0.6	0.4	-1.128	-58.108	-0.0194
0.7	0.3	-1.097	-64.392	-0.0170
0.8	0.2	-1.115	-64.648	-0.0173
0.9	0.1	-1.160	-64.542	-0.0180
1.0	0.0	-1.165	-63.599	-0.0183

Tabela 2: Métricas da grade de sensibilidade (*In-Sample*) por par de pesos.

A equação do *Ensemble* aplicada na fase preditiva (*Out-of-Sample*), no instante t , é dada por:

$$\text{Probabilidade Sintética}_t = 0.70 \times \text{Prob_Crise_HMM}_t + 0.30 \times \text{Prob_Crise_KMean}_t \quad (18)$$

Por fim, para garantir uma combinação mais suave e menos suscetível a ruídos de alta frequência, aplicou-se um filtro de média móvel exponencial de 3 dias (EMA_3) sobre a “Probabilidade Sintética”, gerando a pontuação final de risco (que também foi considerado durante a etapa de *Grid Search* para eleição dos pesos, como descrito anteriormente). A fórmula da Média Móvel Exponencial é calculada recursivamente da seguinte forma:

$$\text{Pontuação Final}_t = \alpha \times \text{Probabilidade Sintética}_t + (1 - \alpha) \times \text{Pontuação Final}_{t-1} \quad (19)$$

onde α é o fator de suavização, definido por $\alpha = \frac{2}{N+1}$. Para uma janela de $N = 3$ dias, o fator resulta em $\alpha = 0.5$. Dessa forma, a “Pontuação Final” de risco absorve os choques recentes rapidamente, mas preserva a memória de curto prazo para evitar que a volatilidade diária acione alarmes falsos de crise.

3.3 Protocolos de Validação (Kupiec POF e Backtest)

Para testar a robustez e a aplicabilidade prática do modelo desenvolvido, a etapa de validação foi estruturada em duas dimensões complementares, aplicadas sobre o período *Out-of-Sample* para garantir a ausência de viés prospectivo (*Look-Ahead Bias*). A primeira dimensão avaliada diz respeito a acurácia estatística do modelo, aplicada sobre as saídas do motor EGARCH-t, utilizou-se o Teste de Proporção de Falhas (*POF - Proportion of Failures*) desenvolvido por Kupiec (1995), que avalia se a frequência empírica de violações (quantidade de dias em que a perda real do ativo excedeu a perda máxima estimada pelo VaR) é estatisticamente compatível com o nível de confiança estipulado pelo modelo, nesse caso, rejeitar a hipótese nula do teste indica que o motor de volatilidade subestima ou superestima sistematicamente as caudas pesadas observadas no mercado.

A segunda dimensão avalia a qualidade preditiva do modelo no contexto do mercado de crédito corporativo brasileiro por meio de um *Backtest* financeiro, focado em avaliar a eficácia dos diferentes “Regimes de Risco” sugeridos pelos modelos apresentados, nesse *backtest* é simulado o impacto de diferentes estratégias de liquidação de portfólio baseadas nas pontuações de risco dos modelos (Verde, Amarelo ou Vermelho), comparando duas abordagens de liquidação para cada modelo:

- Venda Retardada: Estratégia reativa, onde a liquidação ocorre quando o modelo acusa um Regime de Risco Vermelho. Idealmente, caso o modelo seja capaz de prever o estado vermelho antes do choque, esse modelo deveria gerar rentabilidade superior, uma vez que a venda ocorre antes ou no exato momento do choque,

evitando assim perdas substanciais. Todavia, se o modelo não for capaz de prever o estado vermelho antes do choque, essa estratégia tende a gerar perdas operacionais, uma vez que o choque já ocorreu e a venda só será realizada após a materialização dos choques no preço dos ativos.

- **Venda Preventiva:** Estratégia ofensiva, onde a liquidação ocorre quando o modelo acusa um Regime de Risco Amarelo. Idealmente, deveria ser superada pela venda retardada em caso de um modelo ideal, porém, na prática, em cenários onde o modelo pode demorar a reagir na classificação para o regime vermelho, essa estratégia tende a gerar rentabilidade superior, uma vez que a venda ocorre assim que são observados os primeiros sinais de deterioração do ativo, antes da materialização completa do choque. Todavia, caso hajam muitos falsos positivos, essa estratégia tende a gerar rentabilidade inferior à venda retardada, uma vez que gera custos operacionais desnecessários e reduz o ganho em cenários de alta volatilidade.

Para tornar a simulação o mais realista possível e capturar a penalidade financeira do *whipsaw* (falsos rompimentos que geram múltiplos sinais de entrada e saída), o *backtest* incorpora uma taxa de custo de transação de 0,5% (50 *bps*). No mercado secundário de crédito brasileiro, caracterizado por menor liquidez e *spreads* de *bid-ask* mais elásticos do que o mercado de ações, a inclusão desse custo é fundamental, já que ele atua como um fator de desconto sobre estratégias excessivamente reativas (com alta rotatividade/*turnover*), testando assim o real valor econômico agregado pelos sinais preditivos contra os custos operacionais de executá-los na prática.

O resultado das estratégias táticas é comparado contra o desempenho passivo de um portfólio *Buy-and-Hold* e, para assegurar o rigor técnico e a reprodutibilidade da simulação financeira, o algoritmo do *backtest* foi estruturado sob as seguintes premissas operacionais:

- **Carteira Inicial:** No primeiro dia útil da janela *Out-of-Sample*, o capital inicial é distribuído de forma equiponderada (*equal-weight*) entre todas as debêntures elegíveis disponíveis na base de dados naquela data.
- **Regra de Venda (Liquidação):** A liquidação ocorre integralmente no momento em que o modelo classifica o ativo no regime de *stop* estipulado pela estratégia (seja “Vermelho” na estratégia retardada, ou “Amarelo/Vermelho” na preventiva). O capital obtido pela venda é deduzido do custo de transação de 0,5% e mantido em caixa.
- **Remuneração de Caixa:** Qualquer montante não alocado em debêntures (caixa livre) é remunerado diariamente pela taxa DI (CDI) histórica real correspondente ao dia da simulação, refletindo o custo de oportunidade livre de risco (*risk-free*). E tentando simular o que ocorreria na realidade,

porque um fundo ou uma pessoa física alocaria esse dinheiro em um CDB-DI com liquidez diária ou fundo de zeragem, por exemplo.

- **Regra de Recompra:** Para evitar re-entradas prematuras (*dead cat bounces*) e a corrosão da rentabilidade pelo excesso de giro, o capital em caixa é redistribuído igualitariamente apenas entre ativos que

atendam simultaneamente aos três filtros:

1. **Quarentena Temporal:** O ativo não pode ter estado em um regime de alerta/crise nos últimos 180 dias (6 meses).
2. **Inércia de Estabilidade:** O ativo deve permanecer ininterruptamente no regime “Verde” por pelo menos 15 dias úteis, confirmando o fim da volatilidade.
3. **Filtro de Payback:** O prêmio de risco anualizado do ativo no instante da compra deve ser matematicamente suficiente para recuperar o pedágio do custo de transação em, no máximo, 3 meses. A condição de elegibilidade é formalizada pela seguinte restrição:

$$\text{Spread Mínimo} = c \times \frac{12}{M} \quad (20)$$

onde c é a taxa do custo de transação (0,5%) e M é o período máximo tolerado de *payback* em meses ($M = 3$). Se o *spread* ofertado pela debênture for inferior a este limite mínimo calculado (neste cenário, 2,0% ao ano), a compra é abortada, visto que o prêmio de risco não justifica o custo operacional e financeiro do giro de portfólio.

- **Tratamento para Vencimentos:** Caso um ativo vença, o caixa recebido na data do vencimento é reaplicado nas debêntures da carteira. Para as carteiras táticas do modelo (que não representam o *benchmark Buy-and-Hold*), a reaplicação do caixa obedece rigorosamente às mesmas regras e filtros de recompra acima. Já para o portfólio de *benchmark (Buy-and-Hold)*, o capital oriundo de vencimentos é redistribuído de forma equiponderada entre os ativos remanescentes da carteira inicial, sem a aplicação de quaisquer filtros táticos ou preditivos.

Essa arquitetura algorítmica de simulação garante que a performance do modelo preditivo não seja um mero artefato teórico, testando a viabilidade de seus sinais diretamente contra as restrições operacionais e os atritos do mercado corporativo brasileiro.

4 RESULTADOS E DISCUSSÕES

Este capítulo apresenta os resultados empíricos obtidos a partir da aplicação da arquitetura de risco desenvolvida e apresentada na Seção 3 aos dados do mercado secundário de crédito corporativo brasileiro. A análise é construída de forma sequencial, iniciando pela validação estatística dos motores de volatilidade e culminando no impacto financeiro gerado pelas estratégias táticas de alocação.

4.1 Validação Estatística dos Motores

A eficácia de um sistema de alerta preventivo (*Early Warning*) no mercado de crédito está atrelada à sua capacidade de modelar as caudas pesadas da distribuição de retornos. Para testar a acurácia do motor EGARCH-t na estimação do *Value at Risk* (VaR) a 99% de confiança, aplicou-se o Teste de Proporção de Falhas de Kupiec (POF)² adotando um nível de significância de 5% ($\alpha = 0,05$).

Os resultados agregados do *backtest* estatístico, agrupados por classe de indexador, evidenciam a proporção de ativos em que a Hipótese Nula (H_0) do teste não foi rejeitada (ou seja, a taxa de falhas observada não diferiu estatisticamente da margem de 1% esperada pelo modelo).

Indexador	Total	Não-Rejeitados (POF)	Não-Rejeitados (Conj. 90%)	Não-Rejeitados (Conj. 95%)	Não-Rejeitados (Conj. 99%)
CDI Percentual	40	21	21 (52,5%)	23 (57,5%)	25 (62,5%)
CDI Spread	257	63	68 (26,4%)	80 (31,1%)	105 (40,8%)
IPCA	365	133	143 (39,1%)	157 (43,0%)	193 (52,8%)
PRÉ-Fixado	1	0	0 (0,0%)	0 (0,0%)	0 (0,0%)

Tabela 3: Resultados do Teste de Kupiec (Não-Rejeição de H_0) por Nível de Confiança

²Devido à volumetria da amostra, os resultados analíticos granulares do Teste de Kupiec, bem como os dados dos demais testes detalhados individualmente por debênture, foram consolidados e encontram-se disponíveis na pasta anexos_digitaís/ no repositório público desta pesquisa no GitHub.

Para efeitos visuais e comparativos da eficácia do modelo, a figura abaixo exhibe a taxa de não-rejeição relativa.




Figura 10: Sensibilidade da Não-Rejeição (Teste Conjunto) a Diferentes Níveis de Confiança

Embora as taxas de rejeição da Hipótese Nula possam parecer elevadas em primeiro momento, estes resultados devem ser interpretados sob a ótica da severidade da janela temporal analisada. O *backtest* de Kupiec foi executado exclusivamente sobre o período *Out-of-Sample* (2023 a 2026). Esta janela temporal engloba a maior crise de crédito privado da história recente do Brasil (marcada pelos colapsos sequenciais das Lojas Americanas e da Light S.A. além do mais recente evento do Grupo Pão de Açúcar), que introduziu choques exógenos severos e propiciou resgates em massa nos fundos de investimento. A sustentação de 57,5% de não-rejeição no grupo CDI Percentual (para um nível de significância de 5%), prevendo o risco sem sobreajuste em meio a choques sistêmicos, atesta uma forte resiliência da premissa autorregressiva.

Adicionalmente, a iliquidez estrutural do mercado secundário de debêntures atua como o principal ofensor analítico do Teste de Proporção de Falhas. Diversos ativos corporativos frequentemente passam dias úteis sem negociação efetiva. Quando o papel é negociado, o prêmio de risco (*spread*) sofre uma reprecificação abrupta, gerando um salto (*jump*) cuja magnitude pontual, em alguns casos, rompe o limite projetado pelo VaR de 99%. Como o modelo EGARCH-t assume que a volatilidade condicional rege-se por uma dinâmica fluida de persistência no tempo, as violações detectadas decorrem sobretudo da fragmentação da continuidade dos preços (falta de fluxo regular de negociação), e não de uma ineficácia intrínseca do filtro matemático. Somando-se a isso, a extrema sensibilidade do teste binomial de Kupiec em amostras

temporais pequenas condena modelos por desvios mínimos acima da tolerância esperada de 1%.

Cabe ressaltar a diferença conceitual e quantitativa entre os ativos “Não-Rejeitados (POF)” e “Não-Rejeitados (Conjunto)”, expostos na Tabela 3. O teste de Kupiec POF avalia estritamente a Cobertura Incondicional (*Unconditional Coverage*), limitando-se a analisar o volume total de falhas. Em contrapartida, as colunas do Teste Conjunto refletem a validação pelo Teste de Christoffersen, que integra a Cobertura Incondicional à Cobertura Condicional (Teste de Independência). Observa-se que a não-rejeição conjunta é sistematicamente superior em todos os indexadores. Isso evidencia que as violações ocorridas no *Out-of-Sample* não estão agrupadas no tempo (*volatility clustering*). Portanto, ainda que o modelo sofra rejeição marginal no teste POF devido a um excesso absoluto de falhas causadas pelos saltos de iliquidez, o Teste Conjunto valida a modelagem ao provar que o motor EGARCH-t capturou e mitigou com precisão a dependência temporal da variância, convertendo os choques do mercado em violações isoladas e estatisticamente aleatórias.

Por fim, a fim de avaliar a robustez destas conclusões, a Figura 10 ilustra a sensibilidade das taxas de não-rejeição do Teste Conjunto frente a variações no nível de significância do próprio teste (α). Ao adotar-se um rigor extremo ($\alpha = 0,10$, ou 90% de confiança para não-rejeição), a não-rejeição no indexador IPCA recua para 39,1%. Em contrapartida, sob um critério mais conservador para rejeição de modelos ($\alpha = 0,01$, ou 99% de confiança), a não-rejeição salta significativamente, alcançando 62,5% no CDI Percentual e 52,8% no IPCA. Essa elasticidade estatística evidencia que grande parte das rejeições no cenário-base (95%) ocorre por infrações marginais ao p-valor estipulado, reforçando que o modelo se encontra muito próximo do limiar de validação, mesmo frente ao severo estresse do mercado *Out-of-Sample*.

A validação estatística focou primariamente nas métricas de VaR. A ausência de um *backtest* independente para o *Expected Shortfall* (ES) é justificado pela natureza estrutural do modelo adotado: sob a premissa de distribuição T de Student assimétrica, o ES condicional derivado do motor EGARCH-t atua como uma função analítica direta e co-dependente do quantil do VaR. Consequentemente, ao comprovar via Teste de Christoffersen que o filtro de volatilidade captura a frequência correta e expurga o agrupamento das violações, a métrica ES está intrinsecamente ancorada e validada, dispensando a exigência de avaliações adicionais.

4.2 O Desempenho do HMM vs K-Means na Classificação

Estabelecida a validade estatística das métricas de risco de cauda, a análise avalia a agilidade e a capacidade dos algoritmos não-supervisionados de transpor essas métricas contínuas em regimes de risco pré estabelecidos (Verde, Amarelo e Vermelho). Nas subseções seguintes serão apresentados os contrastes entre os resultados obtidos pelo particionamento geométrico (K-Means) e a inferência temporal (HMM). A fim de ilustrar empiricamente o comportamento dos modelos nessa tarefa, iremos utilizar como exemplo o caso de estudo do Grupo Pão de Açúcar (GPA) para as debentures CBRDB8 e CBRDA8, ambas são debentures indexadas CDI+. Nas tabelas Tabela 4 e Tabela 5 pode-se verificar as maiores variações de PU e Taxa ocorrida para ambas as debentures no período recente.

Data	Preço Unitário (PU)	Spread (Taxa)
23/10/2025	R\$ 512,13	12,10%
24/10/2025	R\$ 453,59	44,75%
27/10/2025	R\$ 454,35	44,28%
25/02/2026	R\$ 486,91	45,74%
26/02/2026	R\$ 460,13	100,01%
27/02/2026	R\$ 413,24	—

Tabela 4: Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDA8

Data	Preço Unitário (PU)	Spread (Taxa)
21/11/2025	R\$ 764,80	19,75%
25/11/2025	R\$ 630,22	35,01%
26/11/2025	R\$ 681,76	28,73%
23/02/2026	R\$ 864,71	16,04%
24/02/2026	R\$ 738,68	30,11%
25/02/2026	R\$ 793,33	23,61%
11/06/2026	R\$ 456,53	100,38%
17/06/2026	R\$ 312,66	190,66%
06/07/2026	R\$ 361,41	166,10%

Tabela 5: Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDB8

4.2.1 K-Means

A fim de ilustrar o resultado do K-Means, tomemos a debênture CBRDB8 (Grupo Pão de Açúcar). Entre fevereiro e junho de 2026, com o agravamento da percepção de crédito da varejista, o ativo sofreu uma severa reprecificação sistêmica: o prêmio de risco (*spread*) variou inicialmente de 16,04% em 23/02/2026 para 30,11% em

24/02/2026, voltando a patamares próximos de 23,5% no final de fevereiro, antes de saltar para patamares de 190% em junho de 2026. Ocasionalmente uma perda acumulada de mais de 60%. Apesar da magnitude do evento, o K-Means demorou a ancorar o ativo no regime de Crise (Vermelho), como se pode observar na Figura 11, classificando os dias iniciais da quebra como Verde e oscilando erratically para o Amarelo em uma clara demonstração de *flickering* matemático. Por analisar os dados de forma transversal e atemporal, o agrupamento perdeu o poder de inferir a deterioração em curso.

Já no caso da CBRDA8, em 26 de fevereiro de 2026, a taxa do ativo sofreu um salto, variando de 45,7% para 100,0%. Já que a debenture, por estar mais próxima ao vencimento quando comparada a CBRDB8, possuía uma grande sensibilidade a mudanças na percepção de risco. Todavia, o K-Means falhou em reconhecer, neste caso, a degradação do papel, mantendo toda a história do ativo como um regime Verde (Baixo Risco). O exemplo demonstra que o K-Means falha em capturar a natureza sequencial dos dados, o que é crucial para a gestão de risco de crédito.

Além disso, durante o período de treino (período anterior a Jan/2023), o ativo CBRDA8 possuía 77 dias de negociação, com saltos no *spread* que levaram o algoritmo de máxima verossimilhança que ajustou o EGARCH falhar em convergir. Como houve problemas de convergência, o período *Out-of-Sample* começou em uma escala irreal (volatilidade de 170% ao ano) e fez com que o K-Means fosse insensível aos saltos observados. Já para CBRDB8, o período de treino possuía 65 observações, porém, sem saltos erráticos como no caso anterior, a volatilidade do período *Out-of-Sample* iniciou em valores realistas (entre 0.1% e 1.5% ao ano), permitindo ao modelo ter melhor sensibilidade as variações observadas. Na tentativa de limitar, e melhorar a qualidade do resultados observados para casos como CBRDA8 que se implementou a trava de máximo de 20x a variancia *In-Sample* como descrito em Seção 3.2.2.




Figura 11: Resultados do K-Means para o Estudo de Caso do Grupo Pão de Açúcar (GPA)

4.2.2 HMM

Sob a mesma ótica do choque das debêntures do GPA, o Modelo Oculto de Markov provou-se superior ao integrar a dependência temporal inerente às matrizes de transição (A). Para a emissão CBRDB8, sua taxa durante o período *In-Sample* era cerca de 1.7%, porém, com o evento das Lojas Americanas em Janeiro/Fevereiro de 2023, houve um efeito de contágio no mercado, e a taxa do papel passou a ser negociada próximo de 2.5%. Porém, quando essa variação foi comparada com o histórico do papel, foi observada uma variação no Z-Score de 6.5 desvios padrões, levando a classificação no Regime Vermelho já no início do período pelo motor HMM. Como se pode observar na Figura 12.

Já para a CBRDA8, assim como foi dito na Seção 4.2.1, o EGARCH falhou em convergir no período *In-Sample*, fazendo com que a distribuição do regime Verde ficasse larga e achatada. Ou seja, mesmo grandes variações para cima ou para baixo não eram suficientes para fazer o modelo sair do regime de baixo risco, porém, em Fev/2026, com o salto de *spread* de 44% (de 45,7% para 100,0%, conforme a Tabela 4), o motor HMM conseguiu identificar o choque e classificar a debênture no regime de crise.

A capacidade de reação do algoritmo HMM comprovam que a característica matricial de transições das Cadeias de Markov Ocultas é indispensável, para a identificação das alterações de regime e manutenção do estado enquanto não houver alterações bruscas dos sinais de entrada.




Figura 12: Resultados do HMM para o Estudo de Caso do Grupo Pão de Açúcar (GPA)

4.2.3 Ensemble

Um dos problemas observados no HMM contudo, é a sensibilidade a ruídos, que causam instabilidade, conforme demonstrado pela coluna de Probabilidade do Regime Vermelho na Figura 12. Na tentativa de mitigar os efeitos de instabilidade do HMM e ao mesmo tempo aproveitar o poder de previsão observado, foi desenvolvido um modelo Ensemble, combinando a probabilidade estimada a partir do modelo K-Means, conforme descrito em Seção 3.2.5, com a probabilidade de transição de regimes do HMM. A ponderação utilizada pode ser consultada com mais detalhes na Seção 3.2.7.

Em relação aos resultados, pode se observar na Figura 13 que a probabilidade de classificação (*Ensemble Score*), apresentou estabilidade, quando comparada ao HMM, porém, também falhou em capturar a deterioração observada para CBRDA8. Já no caso de CBRDB8, o modelo apresentou variações de estado frequentes, porém, foi capaz de antecipar o choque, ao contrário do K-Means, porém de forma menos agressiva do que o HMM.




Figura 13: Resultados do Ensemble para o Estudo de Caso do Grupo Pão de Açúcar (GPA)

4.2.4 Antecipação de Eventos Sistêmicos (Lead Time)

A fim de fornecer o rigor quantitativo, evitando a dependência excessiva em um único estudo de caso, expandiu-se a avaliação direcional dos modelos para um rol mais abrangente de eventos de crédito observados no mercado corporativo brasileiro entre 2023 e 2026, porém, para evitar-se um detalhamento de todos os casos, que extenderiam em demasia este trabalho, optou-se pela seleção de alguns eventos específicos e análise menos detalhada do que a observada no estudo de caso específico (Grupo Pão de Açúcar). A premissa central de um modelo de alerta precoce (*Early Warning*) é a capacidade de emitir sinalizações quando se inicia um regime de risco elevado (Regime Vermelho) com antecedência suficiente para permitir a liquidação defensiva do portfólio, métrica denominada *Lead Time*.

Através de uma comparação entre eventos recentes de deterioração de créditos e os resultados resultados dessa pesquisa, foram analisados 9 grandes eventos corporativos cujos ativos mantiveram liquidez secundária suficiente para a calibração **Out-of-Sample** dos modelos. A Tabela 6 consolida a capacidade antecipatória de cada algoritmo ao registrar quantos dias antes do choque principal o ativo foi ancorado definitivamente no Regime Vermelho.

Empresa	Evento	Data	Máx Spread	K-Means (dias)	HMM (dias)	Ensemble (dias)
Lojas Americanas	RJ	01/01/2023	560,5%	8 (AT)	3 (AT)	3 (AT)
Oi S.A.	RJ	01/03/2023	11,8%	50 (AT)	1 (AT)	1 (AT)
Light S.A.	RJ	01/05/2023	120,9%	3 (AN)	5 (AN)	5 (AN)
CVC Corp	RP	01/06/2023	21,0%	669 (AT)	78 (AN)	78 (AN)
Multilaser	WV	01/06/2023	118,4%	18 (AT)	5 (AT)	35 (AT)
Dasa	RP	01/06/2023	163,8%	19 (AT)	1 (AT)	4 (AT)
Unigel	RE	01/02/2024	87,5%	253 (AN)	357 (AN)	328 (AN)
Casas Bahia	RE	01/02/2024	56,1%	F	F	F
Pão de Açúcar	RE	01/03/2026	190,7%	129 (AT)	2 (AN)	2 (AN)

Tabela 6: Resumo Comparativo: Antecipação (Lead Time) do Alerta de Crise por Modelo.

Nota: Eventos: RJ = Rec. Judicial; RP = Reperfilamento; WV = Waiver; RE = Rec. Extrajudicial. Status: AN = Antecipado; AT = Atraso; F = Falhou.

A análise da Tabela 6, calculada sob a premissa de estado de alerta contínuo, ou seja, o modelo entrou no estado vermelho e permaneceu até a data do evento sem sair do estado vermelho no período, demonstra empiricamente o valor preditivo que a dependência temporal (matriz de Markov) adiciona à classificação. Ao desconsiderar períodos de instabilidade de regimes (uma vez que só consideramos períodos sem saídas do estado vermelho), o K-Means revelou-se ruidoso, demonstrando atrasos efetivos (como observado nos casos da Oi, Dasa e Multilaser). Com exceção da fraude da Lojas Americanas e da Recuperação Extrajudicial da Casas Bahia (onde todos os algoritmos falharam em manter o alerta ininterrupto), o HMM apresentou robustez preditiva superior. Para o caso da CVC Corp, o HMM foi capaz de sustentar o alerta de crise 78 dias antes do evento, enquanto o mapeamento geométrico (K-Means) sofreu de forte inércia, resultando em um atraso de 669 dias alcançar o estado vermelho de forma ininterrupta.

Adicionalmente, os resultados do *Ensemble* demonstram que o K-Means frequentemente contamina a convicção do modelo. Conclui-se, portanto, que o HMM constitui veículo superior de proteção informacional para a liquidação defensiva de carteiras, quando consideramos apenas a capacidade de antecipação de alertas de forma ininterrupta até a deflagração do choque financeiro. Contudo, se considerarmos

as regras operacionais definidas na metodologia do *Backtest* (Seção 3.3), em que o portfólio adota um filtro de Quarentena Temporal: caso o modelo acuse Regime Vermelho, o ativo é sumariamente vendido e fica expressamente bloqueado para recompra por um período de 180 dias (6 meses), um sinal isolado (ainda que configure instabilidade matemática e não se mantenha ininterrupto até o choque) é suficiente para identificar a necessidade de saída do ativo, desde que ocorra dentro da janela de 180 dias que antecede o evento. A Tabela 7 avalia o *Lead Time* sob essa ótica puramente operacional: contabiliza-se a distância temporal entre o evento de crédito e o primeiro disparo vermelho registrado no semestre anterior.

Empresa	Evento	Data	Máx Spread	K-Means (dias)	HMM (dias)	Ensemble (dias)
Lojas Americanas	RJ	01/01/2023	560,5%	8 (AT)	3 (AT)	3 (AT)
Oi S.A.	RJ	01/03/2023	11,8%	33 (AN)	57 (AN)	15 (AN)
Light S.A.	RJ	01/05/2023	120,9%	102 (AN)	118 (AN)	77 (AN)
CVC Corp	RP	01/06/2023	21,0%	669 (AT)	149 (AN)	149 (AN)
Multilaser	WV	01/06/2023	118,4%	148 (AN)	148 (AN)	120 (AN)
Dasa	RP	01/06/2023	163,8%	106 (AN)	139 (AN)	97 (AN)
Unigel	RE	01/02/2024	87,5%	169 (AN)	169 (AN)	169 (AN)
Casas Bahia	RE	01/02/2024	56,1%	F	F	F
Pão de Açúcar	RE	01/03/2026	190,7%	164 (AN)	180 (AN)	180 (AN)

Tabela 7: Resumo Comparativo: Antecipação (Lead Time) considerando Quarentena de 180 dias.

Nota: Eventos: RJ = Rec. Judicial; RP = Reperfilamento; WV = Waiver; RE = Rec. Extrajudicial. Status: AN = Antecipado; AT = Atraso; F = Falhou.

Ao se aplicar a trava temporal de 180 dias, os resultados operacionais do *Lead Time* se mostram mais robustos. Casos como o da Light S.A., onde a antecipação observada havia sido de poucos dias, passaram a contar com antecipação superior a 3 meses ao considerar-se as regras operacionais estabelecidas. O valor máximo de antecipação dessa métrica fica matematicamente limitado ao teto da quarentena, o que explica os modelos empatarem em 169 dias e 180 dias (Unigel e Pão de Açúcar, respectivamente), configurando o disparo protetivo na borda máxima do semestre. Independentemente da flexibilização operacional demonstrar a viabilidade dos alertas do K-Means e do Ensemble, o HMM manteve superioridade consistente — como

evidenciado pela antecedência superior na Oi S.A. (57 dias) e Dasa (139 dias), demonstrando a superioridade da memória temporal na antecipação de alterações de regime.

4.3 Simulação de Portfólio (Backtest Financeiro)

Para avaliação da utilidade econômica da modelagem desenvolvida, foi realizado um *backtest* financeiro para o período *Out-of-Sample*, conforme descrito na Seção 3.3. O objetivo da simulação não se limita a medir apenas o desempenho dos modelos propostos contra uma estratégia passiva (*Buy-and-Hold*), mas também a avaliar como as diferentes formas de liquidação (preventiva no sinal amarelo vs. retardada no sinal vermelho) impactam a relação risco-retorno.




Figura 14: Resultados do Backtest

Estratégia	Retorno Total	CAGR	Volatilidade	Máx. Drawdown	Calmar Ratio
Buy-and-Hold	22,42%	5,98%	3,50%	-4,79%	1,249
K-Means	27,06%	7,11%	4,29%	-4,16%	1,711
K-Means (Vende Amarelo)	36,18%	9,27%	8,92%	-5,78%	1,603
HMM	25,95%	6,85%	8,82%	-6,71%	1,021
HMM (Vende Amarelo)	32,62%	8,44%	12,56%	-9,74%	0,866
Ensemble	16,37%	4,45%	4,68%	-4,00%	1,111
Ensemble (Vende Amarelo)	17,58%	4,76%	4,70%	-4,12%	1,156

Tabela 8: Métricas de Risco-Retorno do Backtest Financeiro

Os resultados consolidados na Tabela 8 e a evolução temporal da Figura 14 revelam o valor adicionado pelas estratégias de *Early Warning*. Enquanto o índice passivo (*Buy-and-Hold*) gerou um retorno total de 22,42% penalizado pelo carregamento de papéis ilíquidos e depreciados, as estratégias reativas obtiveram retornos superiores, destacando-se a **K-Means Vende Amarelo** e **HMM Vende Amarelo** que apresentaram retornos acumulados de 36.18% e 32.62% respectivamente.

Optou-se pela exclusão da métrica clássica de *Sharpe Ratio* dessa avaliação, uma vez que debêntures pós-fixadas (atreladas ao CDI) possuem correlação direta com a taxa de juros e volatilidade intrínseca artificialmente próxima a zero, o que distorce o índice na avaliação de prêmio de risco (tornando o Sharpe assintótico frente a prêmios negativos). Em seu lugar, as métricas utilizadas foram *Maximum Drawdown* e **Calmar Ratio** (Razão do Retorno Anualizado (CAGR - *Compound Annual Growth Rate*) pelo *Maximum Drawdown*).

Apesar do retorno superior apresentado pelas estratégias ativas, elas também incorreram em maior volatilidade e *Drawdown*, sendo penalizadas quando avaliadas por métricas que ponderam risco e retorno. Em especial, a estratégia **HMM (Vende Amarelo)** apresentou um expressivo *drawdown* de -9,74% em 2026, originado pela marcação simultânea de diversos ativos no estado de Alerta (Amarelo) em decorrência do contágio de crédito gerado pelo evento do grupo GPA. Por possuir uma regra agressiva de *stop loss*, o agente liquidou uma parcela relevante do portfólio no mercado secundário exatamente no momento de forte abertura de *spreads*. Esse comportamento evidencia os riscos da sensibilidade acentuada do filtro Bayesiano quando combinado a uma execução automática.

O portfólio *Buy-and-Hold* apresentou um Calmar de 1,249, sendo superado exclusivamente pelos algoritmos K-Means, com índices de 1,711 (Padrão) e 1,603 (Vende Amarelo). A superioridade do K-Means neste aspecto advém justamente da sua latência: por reagir de forma mais lenta e instável aos choques do que o HMM, a estratégia apresentou um menor giro de ativos. Dessa forma, ela evitou a realização maciça de prejuízos de marcação a mercado simultâneos (mitigando o *drawdown*), mas ainda assim conseguiu se desfazer tempestivamente de ativos que apresentavam deterioração irreversível, distanciando-se do *Buy-and-Hold*. Esse comportamento poupou a carteira das punições transacionais que afetaram o HMM.

Por fim, o modelo *Ensemble* — desenvolvido com o intuito de harmonizar a reatividade do HMM com a inércia do K-Means — apresentou resultados negativos. Embora tenha sustentado um **Calmar Ratio** próximo ao da estratégia passiva (1,111 vs. 1,249), entregou o menor retorno total do período (16,37%), corroído em grande parte pelo efeito *Whipsaw* (efeito chicote). A mediação conflitante dos modelos fez com que o agente acionasse vendas quando o HMM indicava a transição de regime, para logo em seguida recomprar os mesmos ativos assim que a influência do K-Means puxava o *score* novamente para um regime de baixo risco. Conclui-se, portanto, que a modelagem mista falhou estruturalmente ao herdar os custos transacionais da sensibilidade do HMM sem se beneficiar de sua capacidade de proteção definitiva, sofrendo das piores características operacionais de seus precursores.

4.3.1 Significância Estatística das Estratégias — Block Bootstrap

A superioridade das estratégias ativas em termos de retorno absoluto não é, por si só, evidência científica suficiente de que os modelos agregam valor. O período *Out-of-Sample* (2023–2026) foi marcado por eventos excepcionais de crédito, o que levanta a questão: os retornos superiores observados decorrem da capacidade preditiva dos algoritmos, ou são produto de um período amostral específico?

Para responder a essa pergunta, aplicou-se o *Stationary Block Bootstrap* (Politis; Romano, 1994) com $n = 10.000$ amostras e blocos de 20 dias úteis (aproximadamente 1 mês), que preserva a estrutura de autocorrelação temporal dos retornos diários. A hipótese testada é:

- **H0₃**: A estratégia ativa **não** supera o Buy-and-Hold em termos de retorno médio anualizado ($\mu_{\text{estratégia}} \leq \mu_{\text{BnH}}$).
- **H1₃**: A estratégia supera o Buy-and-Hold (teste unilateral à direita, $\alpha = 5\%$).

O p-valor reportado representa a proporção de amostras bootstrap em que o retorno médio da estratégia foi inferior ou igual ao do benchmark, de forma que valores abaixo de 0,05 levam à rejeição de H_{0_3} .

Estratégia	Retorno (%aa)	BnH (%aa)	Diferença (%aa)	p-valor	H_{0_3}
KMeans	6,97%	5,87%	+1,10%	0,134	NR
HMM	7,02%	5,87%	+1,15%	0,225	NR
Ensemble	4,47%	5,87%	-1,41%	0,868	NR
K-Means (Vende Amarelo)	9,27%	5,87%	+3,40%	0,015	R
HMM (Vende Amarelo)	8,90%	5,87%	+3,03%	0,059	NR
Ensemble (Vende Amarelo)	4,76%	5,87%	-1,11%	0,808	NR

Tabela 9: Resultados do Block Bootstrap ($n = 10.000$, $\alpha = 5\%$, bloco=20 dias) — Significância Estatística vs. Buy-and-Hold.

Nota: R = Rejeitada; NR = Não Rejeitada.

Os resultados da Tabela 9 revelam um achado central: **apenas a estratégia K-Means (Vende Amarelo) rejeita H_{0_3} ao nível de 5%** ($p = 0,015$, IC 95%: [+0,33%; +6,78%]). A estratégia HMM (Vende Amarelo) apresenta p-valor de 0,059, próximo ao limiar de significância, não rejeitando H_{0_3} sob o critério convencional de 5%, mas sugerindo evidência marginal de superioridade.

Este resultado é coerente com o diagnóstico do conhecido **Paradoxo da Acurácia-Rentabilidade** (*Accuracy-Profitability Paradox*)³: a inércia do K-Means, que aparentava ser uma deficiência preditiva (menor reatividade a mudanças de regime), transformou-se em vantagem financeira — ao evitar o excesso de giro e o efeito *Whipsaw* que corrói os demais modelos. A estratégia HMM e as estratégias Ensemble, apesar dos retornos nominais superiores ao benchmark, não apresentam superioridade estatisticamente comprovável, evidenciando que seus ganhos estão dentro do intervalo de incerteza esperado para o período amostral específico, podendo a superioridade dos retornos no período ser apenas fruto do acaso.

³Fenômeno documentado na literatura financeira quantitativa onde o aumento da acurácia preditiva de um modelo não se traduz, necessariamente, em retornos financeiros superiores, frequentemente devido ao impacto desproporcional dos custos transacionais decorrentes de falsos alarmes (*whipsaws*). No mercado de crédito corporativo, devido aos altos custos transacionais e restrições de liquidez, a menor sensibilidade reativa do K-Means (sua inércia na mudança de estado) atuou como um filtro natural de ruídos, resultando paradoxalmente em uma proteção de capital superior à entregue pelo modelo probabilístico de alta reatividade.




Figura 15: Forest Plot — Diferença de Retorno vs. Buy-and-Hold com Intervalo de Confiança 95% (Block Bootstrap)

4.3.2 Discussão sobre a Generalização dos Resultados

Os resultados apresentados neste estudo foram obtidos a partir de um conjunto específico de condições empíricas que delimitam sua generalização direta:

1. **Período amostral:** O período *Out-of-Sample* (2023–2026) engloba uma das maiores crises de crédito privado brasileiro da história recente (com colapsos sequenciais de Lojas Americanas, Light S.A. e incertezas em torno do Grupo Pão de Açúcar). A eficácia das estratégias ativas,

especialmente do K-Means (Vende Amarelo), foi alavancada pela necessidade de mitigação de risco no período. Em ciclos de expansão de crédito com baixa volatilidade, estratégias ativas, como as implementadas, podem apresentar performance inferior ao carregamento passivo, devido ao peso dos custos transacionais.

2. **Universo de ativos:** A amostra final se restringe a debêntures com liquidez mínima suficiente para permitir a convergência do motor de estimação EGARCH. Ativos de crédito marcadamente ilíquidos — que operam fora da curva Anbima ou não possuem fluxo de negociação regular em mercado

secundário — não foram testados. Estratégias aplicadas a essas carteiras podem sofrer distorções materiais.

3. **Estrutura de custos operacionais:** A simulação assumiu um custo de transação de 0,5% por operação, considerado aderente à média do mercado secundário corporativo. Contudo, em períodos de estresse extremo, o *bid-ask spread* pode ser significativamente maior, inviabilizando as saídas

defensivas simuladas nesta pesquisa.

4. **Frequência de Negociação:** Ao se utilizar dados de negócios realizados no mercado secundário (mitigando o viés de alisamento da marcação a mercado teórica), os indicadores preditivos tornam-se altamente dependentes do fluxo de liquidez. Em momentos de estresse, a negociação de determinados ativos pode cessar, gerando indisponibilidade de dados do modelo no momento de maior necessidade.

Apesar das limitações inerentes à amostra brasileira e as características intrínsecas do mercado de crédito, os alicerces metodológicos da arquitetura desenvolvida — como a integração da volatilidade condicional leptocúrtica como *feature* para particionamento temporal dinâmico (*Time-Series Clustering*) — constituem um arcabouço que pode ser adaptado e generalizado para outros mercados globais de crédito privado caracterizados por informações assimétricas e baixa liquidez.

5 CONCLUSÃO

Esta dissertação teve como objetivo desenvolver e avaliar uma metodologia quantitativa baseada em Aprendizado de Máquina Não Supervisionado para a identificação precoce de eventos de estresse (*Early Warning*), por meio da criação e monitoramento de regimes de risco no mercado secundário de debêntures brasileiro. Motivada pela assimetria de retornos inerente aos ativos de crédito privado, pela baixa liquidez estrutural e pelos recentes e severos eventos de crédito (como os casos Lojas Americanas, Light e Grupo Pão de Açúcar), a pesquisa buscou responder se algoritmos de clusterização poderiam atuar como ferramentas táticas viáveis para a mitigação de perdas severas, superando o carregamento passivo de portfólios.

5.1 Principais Descobertas

O estudo revelou achados importantes que conectam a modelagem teórica à aplicabilidade financeira prática:

1. **Adequação da Modelagem de Cauda (EGARCH-t):** A adoção do modelo EGARCH-t acoplado ao *Expected Shortfall* provou-se eficaz na precificação do risco isolado dos ativos. A validação por meio dos

testes conjuntos de Christoffersen, conforme apresentado na Seção 4.1, confirmou que o modelo é capaz de absorver a heterocedasticidade condicional e evitar o agrupamento de violações (*volatility clustering*), mesmo frente aos massivos choques de iliquidez do período *Out-of-Sample*, respondendo, assim, às falhas dos modelos de VaR tradicionais citados na Seção 2.2.

2. **O Paradoxo entre Acurácia Preditiva e Desempenho Financeiro:** Observou-se uma dicotomia robusta e quantificada entre o Modelo Oculto de Markov (HMM) e o particionamento geométrico atemporal (K-Means). Conforme

demonstrado através da análise sistêmica de **Lead Time** (Antecipação de Alerta), o HMM demonstrou superioridade analítica preditiva ao integrar a dependência temporal via matrizes de transição, antecipando eventos de crédito severos de forma significativamente mais ágil que as demais metodologias em múltiplos cenários corporativos independentes (como no caso da CVC Corp e do Grupo Pão de Açúcar). Contudo,

no *backtest* financeiro, a estratégia de liquidação pautada pelo K-Means (**Vende Amarelo**) não apenas entregou o maior retorno financeiro absoluto do período (36,18%), mas foi a **única** capaz de superar a estratégia passiva (*Buy-and-Hold*) com significância estatística comprovada por *Block Bootstrap* ($p\text{-valor} < 0,05$). Este fenômeno consolida empiricamente o impacto do **Paradoxo da Acurácia-Rentabilidade** (*Accuracy-Profitability Paradox*): a inércia do K-Means funcionou como um filtro de ruído contra a volatilidade secundária, poupando a carteira do excesso de giro impulsionado pelas matrizes de transição do HMM. Em cenários de iliquidez e altos custos de transação (0,5% por operação), essa ineficiência preditiva transmuta-se, paradoxalmente, em proteção de capital.

3. **A Armadilha da Combinação de Modelos:** O estudo documentou a falha do modelo *Ensemble*. Ao tentar fundir a reatividade do HMM com a inércia do K-Means, a modelagem mista deixou a carteira vulnerável ao efeito chicote (*whipsaw*). O modelo realizava vendas impulsionadas pelo HMM e recompras tardias pelo K-Means, corroendo o capital com excesso de custos transacionais, entregando o pior retorno do período. A combinação acabou exacerbando os defeitos de cada modelo, e reforçando a importância da avaliação do momento de compra e venda dos papéis para evitar que o carregio obtido seja consumido por custos transacionais e perdas decorrentes de operações em momentos inoportunos.

5.2 Implicações Práticas

Para a indústria de gestão de recursos, a metodologia desenvolvida oferece um arcabouço robusto e sistemático para a gestão tática em carteiras de crédito privado. Em um mercado caracterizado por baixa liquidez estrutural e precificação ocasionalmente defasada, a adoção de gatilhos quantitativos pode substituir ou auxiliar o viés comportamental humano, que frequentemente leva gestores a reter posições perdedoras na esperança de uma reversão que muitas vezes não ocorre.

A operacionalização desta pesquisa demonstra que o melhor modelo preditivo não é, necessariamente, a melhor estratégia de *trading*. A escolha do motor de decisão deve estar alinhada aos atritos do mercado e às regras táticas de execução (como, por exemplo, a regra de “quarentena de 180 dias”, que atuou como ponte operacional para viabilizar os sinais do K-Means). Os resultados observados foram frutos de simulações históricas baseadas em parâmetros de *Backtest* (custo de 0,5% e liquidez plena); na prática real de tesouraria, o momento exato do *early warning* sofrerá o impacto do

secamento do *bid-ask spread*, reiterando que o alerta não garante, por si só, o sucesso da liquidação em mercados de crédito ilíquidos.

5.3 Limitações e Recomendações para Trabalhos Futuros

Apesar dos resultados promissores, o presente estudo possui limitações inerentes à estrutura e à qualidade dos dados financeiros brasileiros. A principal limitação concentrou-se na convergência da volatilidade condicional (EGARCH) para ativos extremos, onde longos históricos de ausência de negociação distorceram a estimação dos parâmetros de risco no período *In-Sample*. Adicionalmente, ao pautar a modelagem em dados de negócios efetivamente realizados (mitigando o viés da marcação a mercado teórica), o sistema herda uma dependência do fluxo contínuo de liquidez secundária, o que significa que o modelo pode ficar “cego” nos momentos de maior estresse, quando o mercado cessa suas negociações.

Para trabalhos futuros, recomenda-se a exploração das seguintes frentes:

- A incorporação de modelos de aprendizado profundo focados em sequências temporais não-lineares, como Redes Neurais Recorrentes (LSTMs) ou *Transformers*, que podem lidar de maneira mais nativa com espaços irregulares de negociação (*irregularly sampled time-series*);
- A inclusão de dados não-estruturados, como Análise de Sentimento de notícias corporativas (*Natural Language Processing*) e dados macroeconômicos em tempo real, atuando como variáveis preditoras exógenas (covariáveis)

diretamente nas matrizes de transição probabilísticas do HMM, na tentativa de reduzir a ocorrência de falsos alarmes causados por contágio de mercado secundário;

- A adoção de modelos integrados de volatilidade condicional e mudança de regime, como o *Markov-Switching GARCH* (MS-GARCH) modelado via inferência Bayesiana (*Markov Chain Monte Carlo* - MCMC),

permitindo a calibração unificada do modelo e a inserção de conhecimento de especialistas como distribuições **a priori**;

- O mapeamento do contágio e do risco sistêmico entre emissores por meio da Teoria de Redes e de Cópuas Extremas (*Extreme Copulas*),

para capturar a dependência não-linear de cauda e a topologia de propagação de choques de liquidez no mercado de crédito corporativo.

BIBLIOGRAFIA

- ACERBI, Carlo; TASCHE, Dirk. On the coherence of expected shortfall. **Journal of Banking & Finance**, v. 26, n. 7, p. 1487–1503, 2002.
- ALTMAN, Edward I. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. **The journal of finance**, v. 23, n. 4, p. 589–609, 1968.
- ANBIMA. **Mercado de capitais bate recorde histórico e encerra 2025 com emissão de R\$ 838,8 bilhões**. Disponível em: <<https://data.anbima.com.br/publicacoes/boletim-de-mercado-de-capitais/mercado-de-capitais-bate-recorde-historico-e-encerra-2025-com-emissao-de-8388-bilhoes>>.
- ARDIA, David *et al.* Markov-switching GARCH models in R: The MSGARCH package. **Journal of Statistical Software**, v. 91, n. 4, p. 1–38, 2019.
- ARTZNER, Philippe *et al.* Coherent measures of risk. **Mathematical finance**, v. 9, n. 3, p. 203–228, 1999.
- BAO, Jack; PAN, Jun; WANG, Jiang. The Illiquidity of Corporate Bonds. **The Journal of Finance**, v. 66, n. 3, p. 911–946, 2011.
- BARRA, Anuar de Sousa. **Estudo exploratório sobre a liquidez das debêntures no mercado secundário brasileiro: medidas diretas de liquidez e características dos títulos e emissores**. Dissertação de Mestrado—[S.l.: S.n.].
- BAUM, Leonard E. *et al.* A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. **The annals of mathematical statistics**, v. 41, n. 1, p. 164–171, 1970.
- BISHOP, Christopher M. **Pattern recognition and machine learning**. [S.l.]: Springer, 2006.
- BOLLERSLEV, Tim. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, v. 31, n. 3, p. 307–327, 1986.
- BORDA, Jean-Charles de. Mémoire sur les élections au scrutin. **Histoire de l'Académie Royale des Sciences pour 1781**, 1781.
- CALIŃSKI, Tadeusz; HARABASZ, Jerzy. A dendrite method for cluster analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974.
- CHRISTOFFERSEN, Peter F. Evaluating interval forecasts. **International Economic Review**, v. 39, n. 4, p. 841–862, 1998.

CORRÊA, Paulo Eduardo Gonçalves Camargo; SHENG, Hsia Hua. O apreçamento do spread de liquidez no mercado secundário de debêntures. **Revista de Administração**, v. 45, n. 1, p. 30–42, 2010.

DAVIES, David L. ; BOULDIN, Donald W. A cluster separation measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, n. 2, p. 224–227, 1979.

DUFFIE, Darrell; SINGLETON, Kenneth J. **Credit risk: pricing, measurement, and management**. [S.l.]: Princeton university press, 2003.

ENGLE, Robert F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. **Econometrica**, v. 50, n. 4, p. 987–1007, 1982.

FREITAS, Wilson. **python-bcb: Interface Python para a API de dados abertos do Banco Central do Brasil**. Disponível em: <<https://wilsonfreitas.github.io/python-bcb/>>.

HAAS, Markus; MITTNIK, Stefan; PAOLELLA, Marc S. A new approach to Markov-switching GARCH models. **Journal of financial econometrics**, v. 2, n. 4, p. 493–530, 2004.

HAIR, Joseph F. *et al.* **Multivariate data analysis**. [S.l.]: Pearson Prentice Hall Upper Saddle River, NJ, 2010. v. 7

HAMILTON, James D. **Time series analysis**. [S.l.]: Princeton University Press, 1994.

HO, Tin Kam; HULL, Jonathan J.; SRIHARI, Sargur N. Decision combination in multiple classifier systems. **IEEE transactions on pattern analysis and machine intelligence**, v. 16, n. 1, p. 66–75, 1994.

JORION, Philippe. **Value at Risk: The New Benchmark for Managing Financial Risk**. 3rd. ed. [S.l.]: McGraw-Hill, 2006.

KITTLER, Josef *et al.* On combining classifiers. **IEEE transactions on pattern analysis and machine intelligence**, v. 20, n. 3, p. 226–239, 1998.

KUPIEC, Paul H. Techniques for verifying the accuracy of risk measurement models. **The Journal of Derivatives**, v. 3, n. 2, p. 73–84, 1995.

MERTON, Robert C. On the pricing of corporate debt: The risk structure of interest rates. **The Journal of finance**, v. 29, n. 2, p. 449–470, 1974.

NELSON, Daniel B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, v. 59, n. 2, p. 347–370, 1991.

POLITIS, Dimitris N. ; ROMANO, Joseph P. The stationary bootstrap. **Journal of the American Statistical Association**, v. 89, n. 428, p. 1303–1313, 1994.

RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. **Proceedings of the IEEE**, v. 77, n. 2, p. 257–286, 1989.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987.

ROUSSEEUW, Peter J. ; HUBERT, Mia. Robust statistics for outlier detection. **Wiley interdisciplinary reviews: Data mining and knowledge discovery**, v. 1, n. 1, p. 73–79, 2011.

SAEYS, Yvan; ABEEL, Thomas; PEER, Yves Van de. Robust feature selection using ensemble feature selection techniques. *Em*: 2008.

SHENG, Hsia Hua; SAITO, Richard. Liquidez das debêntures no mercado brasileiro. **Revista de Administração**, v. 43, n. 2, p. 176–185, 2008.

TSAY, Ruey S. **Analysis of financial time series**. 2. ed. [S.l.]: John Wiley & Sons, 2005.