PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação Lato Sensu em Estatística para Ciências de Dados

Guilherme Tolotti Azevedo

MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉDITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T E MODELOS OCULTOS DE MARKOV

Belo Horizonte
Outubro de 2026

Guilherme Tolotti Azevedo

MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉDITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T E MODELOS OCULTOS DE MARKOV

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Estatística para Ciências de Dados, como requisito parcial à obtenção do título de Especialista.

Belo Horizonte
Outubro de 2026

SUMÁRIO

1. Introdução 4
2. Descrição do Problema e da Solução Proposta 6
3. Canvas Analítico 9
4. Coleta de Dados 10
5. Processamento/Tratamento de Dados 13
6. Análise e Exploração dos Dados 18
7. Aplicação de Modelos 24
8. Automatização do Pipeline de Dados 32
8.1 Definição da Ferramenta de Orquestração de Pipeline do Fluxo de Trabalho 32
8.2 Modelo do Fluxo de Trabalho 32
8.3 Códigos/telas 34
9. Discussão dos Resultados 37
10. Conclusão 43
11. Links 45
12. Referências 46

1. Introdução

A Estatística para Ciência de Dados vem ganhando espaço no mercado de trabalho porque estabelece a base quantitativa necessária para transformar grandes volumes de dados em decisões objetivas. No mercado de capitais, a tomada de decisão orientada por dados auxilia o profissional com estimativas probabilísticas verificáveis, através, por exemplo, da precificação de ativos e do gerenciamento de risco de crédito corporativo, conforme demonstrado por (Hull, 2012). Muitos dos modelos que são usados hoje, contudo, são puramente determinísticos e têm dificuldade em capturar, por exemplo, mudanças de regime. Uma solução para isso é a integração entre modelos econométricos clássicos de séries temporais e algoritmos modernos de Aprendizado de Máquina, que viabilizam a extração de padrões ocultos e regimes latentes em séries não-lineares, superando limitações históricas de abordagens puramente determinísticas.

O intuito desse trabalho é aplicar a combinação destes modelos para analisar um comportamento do mercado de crédito privado brasileiro, que cresce continuamente e se consolida como ferramenta central de captação de recursos para as empresas (ANBIMA, 2026). Entre os instrumentos emitidos, destacam-se as debêntures, cujo volume de emissões registrou uma expansão de 307% entre 2020 e 2025. Porém, esse mercado enfrenta restrições crônicas de liquidez, e conforme Sheng; Saito (2008), apresenta as seguintes características:

- As transações são dispersas e ocorrem em duas diferentes instituições: Bolsa de Valores de São Paulo (Bovespa Fix) e Sistema Nacional de Debêntures (SND);
- Existe baixa atividade, não havendo registro de transações para períodos longos e, em algumas emissões de debêntures, o volume de transações no mercado secundário é quase nulo e o valor total em reais é baixo;
- Existe um baixo número de negociações diárias;
- Predominância de debêntures de médio prazo (vencimento em torno de quatro anos);
- Demanda significativa por investidores institucionais e fundos de pensão;
- Em geral as emissões não são conversíveis em ações;
- Alguns investidores adquirem debêntures e as mantêm até o vencimento;

Foi observado que algumas dessas características estruturais se mantêm verdadeiras, como:

- A baixa liquidez (onde mais da metade das marcações diárias do mercado giram volumes inferiores a R$ 1 milhão);
- A exclusividade de emissões do tipo simples;

e outras, como:

- A baixa presença de pessoas físicas e investidores estrangeiros;
- O fato de os intermediários manterem os papéis na carteira até o vencimento;

são reforçadas por estudos recentes como Barra (2021) e ANBIMA (2026). Porém, observou-se uma mudança em relação a pesquisa de Sheng; Saito (2008) que sugere amadurecimento institucional. A amostra utilizada neste estudo indica que as empresas têm conseguido alongar o perfil de suas dívidas, com as debêntures apresentando uma mediana de sete anos de prazo até o vencimento.

Com prazos estendidos e liquidez de suporte reduzida, a combinação entre a modelagem econométrica de volatilidade condicional e métodos de aprendizado de máquina não-supervisionado surge como uma alternativa para identificar mudanças de regimes de crédito antes que as perdas financeiras se materializem.

2. Descrição do Problema e da Solução Proposta

2.1 O Problema de Pesquisa

A modelagem do risco de crédito corporativo evoluiu historicamente por meio de abordagens contábeis, estruturais e de forma reduzida. A literatura pioneira introduziu escores lineares baseados em indicadores contábeis, como o Z-Score de (Altman, 1968), utilizado para prever insolvência. Desde então, a literatura evoluiu para abordagens baseadas em modelos estruturais de crédito, como Merton (1974). Contudo, estas abordagens tradicionais, baseadas em fundamentos, em geral obtidos em balanços e informações contábeis, usualmente divulgados em frequência trimestral ou anual, são inadequados para sistemas de alerta em tempo real (ou com poucos dias de defasagem) devido à frequência de divulgação dessas informações.

Para superar a dependência de demonstrações financeiras, surgiram os modelos de forma reduzida, conforme consolidado por Duffie; Singleton (2003), que modelam o risco de crédito diretamente através de dados de mercado. Apesar de serem capazes de mitigar a defasagem da informação contábil, a modelagem contínua exige mercados líquidos, uma vez que é amplamente dependente dos dados observados. No mercado de debêntures brasileiro, onde se observa baixa liquidez e baixa atividade, essa abordagem se mostra frágil.

Conforme aponta (Corrêa; Sheng, 2010), o prêmio de liquidez responde por parcela expressiva do spread das debêntures, sobrepondo-se com frequência ao risco de inadimplência. Mercados corporativos concentram fricções operacionais que dificultam o ajuste contínuo dos preços e fazem com que sejam observados saltos no preço dos ativos, por vezes acompanhados de períodos de iliquidez, conforme demonstrado por (Bao; Pan; Wang, 2011) e comprovado por eventos recentes no mercado brasileiro. O colapso das Lojas Americanas culminou em uma desvalorização de 50% no preço unitário de suas debêntures em um único pregão, acumulando perdas de 90% em uma semana. No caso do Grupo Pão de Açúcar, foram observados deságios de até 70% nas negociações secundárias. Emissões da Light sofreram reprecificações abruptas similares durante o processo de recuperação judicial.

Práticas tradicionais de tesouraria falham nesse ambiente. Bancos e gestoras de recursos frequentemente calculam o Valor em Risco (VaR) e modelos GARCH

simétricos sob a hipótese de normalidade e liquidez plena de saída. Conforme aponta (Jorion, 2006), esses métodos assumem que o investidor consegue liquidar posições instantaneamente ao preço visualizado na tela. Em momentos de stress, muitas vezes a liquidez seca e o investidor é incapaz de liquidar suas posições, ou o faz com descontos massivos.

Outra limitação teórica da família GARCH tradicional, como explica (Tsay, 2005), reside no pressuposto de que os parâmetros da equação de variância e a volatilidade incondicional permanecem estáticos ao longo do tempo. Esses modelos operam ancorados em uma única média global da série histórica, porém, quando ocorrem quebras estruturais ou eventos de crédito severos, essas médias acabam sendo deslocadas. A literatura econométrica, fundamentada por (Hamilton, 1994), demonstra que séries temporais financeiras longas sofrem quebras estruturais que exigem formulações baseadas em mudanças de regime (**Regime-Switching**). Sob essa teoria, os mercados transitam entre diferentes estados latentes, alterando a própria dinâmica estocástica dos preços, propostas como (Haas; Mittnik; Paolella, 2004) e (Ardia et al., 2019), buscam incorporar essas quebras na modelagem.

A natureza do problema investigado, portanto, compreende a modelagem estatística de séries temporais financeiras acoplada ao agrupamento não-supervisionado de regimes de risco latentes. O desafio central reside em disparar sinais de alerta preventivo (**Early Warning**) antes que perdas severas ocorram, preservando o capital do investidor.

2.2 Objetivos

O objetivo geral deste trabalho consiste em desenvolver e avaliar uma metodologia quantitativa de alerta antecipado para o mercado secundário de debêntures brasileiro, identificando transições latentes de regime para antecipar choques de crédito e mitigar perdas patrimoniais.

Para atingir a proposta central, definem-se os seguintes objetivos específicos:

1. Normalizar o prêmio de risco dos ativos mitigando distorções de prazo por meio da taxa ajustada ao vencimento, contornando a exigência de curvas de juros soberanas completas;
2. Modelar a heterocedasticidade condicional e a assimetria das séries temporais de spread por meio de um motor econométrico AR(1)-EGARCH(1,1) com inovações t-Student;

3. Implementar e comparar dois métodos de agrupamento de regimes de risco: o algoritmo K-Means, adotado como linha de base geométrica e atemporal, e o Modelo Oculto de Markov (HMM Gaussiano), responsável por incorporar a dependência temporal nas transições;
4. Validar o motor econométrico de cauda por meio dos testes de hipótese de Kupiec POF e Christoffersen sobre o período fora da amostra;
5. Simular estratégias táticas de liquidação de portfólio em um ambiente de **backtest** financeiro realístico, submetido a custos de transação de 0,5% e validado estatisticamente pela técnica de **Block Bootstrap**.

2.3 Solução Proposta

A solução desenvolvida apoia-se em uma arquitetura híbrida de duas camadas operacionais, na qual a primeira camada executa o saneamento econométrico dos dados de negociação da ANBIMA, eliminando ruídos causados por dias sem negócios e estimando a variância condicional e o risco de cauda com o motor EGARCH-t. A segunda, por sua vez, consome as métricas tratadas e alimenta algoritmos de agrupamento não-supervisionado.

Esses algoritmos particionam o espaço de estados latentes em três estados objetivos: Verde (baixo risco), Amarelo (alerta) e Vermelho (crise) de forma a enviar um sinal tático antecipado ao investidor, de forma que este possa optar pela venda das debêntures antes da materialização definitiva do evento.

3. Canvas Analítico

Apresenta-se a seguir o Canvas Analítico do projeto, estruturado em doze blocos estratégicos que sintetizam a formulação do problema, as bases de dados, as técnicas estatísticas aplicadas e os resultados esperados.

1. Problema de Negócio

Iliquidez crônica e assimetria de retornos no mercado secundário de debêntures. Modelos tradicionais de risco (GARCH contínuo e VaR paramétrico) falham diante de saltos discretos e deságios severos em eventos de cauda.

2. Objetivo Analítico

Classificar regimes latentes de risco de crédito (Verde, Amarelo e Vermelho) e antecipar choques patrimoniais por meio de aprendizado de máquina não-supervisionado com modelagem temporal.

3. Justificativa

Atrasos na detecção de deterioração de crédito inviabilizam o desinvestimento em mercados ilíquidos. Alertas antecipados protegem o capital antes da materialização definitiva do evento.

4. Stakeholders

Gestores de fundos de crédito privado, analistas de risco corporativo, comitês de alocação de ativos e tesourarias institucionais.

5. Variável-alvo (Target)

Regime latente de risco de crédito do ativo: Verde (Baixo Risco), Amarelo (Alerta Preventivo) e Vermelho (Crise e Liquidação Imediata).

6. Variáveis de Entrada

Delta Spread diário, Taxa ajustada ao prazo ($\frac{S_t}{\ln(\mathrm{DU})}$), Volatilidade condicional EGARCH-t, Expected Shortfall (99%) e Z--Score móvel de 60 dias.

7. Fontes de Dados

Prévias públicas de negociação do sistema REUNE da ANBIMA, dados cadastrais via portal Debentures.com.br e séries macroeconômicas (CDI e IPCA) obtidas junto ao Banco Central via pacote `python-bcb`.

8. Técnicas Estatísticas / ML

AR(1)-EGARCH(1,1)-t para volatilidade assimétrica; K-Means com agregação Borda Count; Gaussian HMM com regularização de Laplace e algoritmo de Viterbi; Ensemble ponderado.

9. Métricas de Avaliação

Acurácia estatística: Testes de Kupiec POF e Christoffersen. Eficácia tática: Lead Time de antecipação em dias úteis, Retorno Acumulado líquido de custos e p--valor por Block Bootstrap.

10. Entregáveis

Pacote Python modular (`credit_tail_analytics`), pipeline de dados automatizado, base histórica tratada, relatórios analíticos de backtest e repositório de código aberto.

11. Impacto Esperado

Mitigação de perdas severas em eventos de estresse corporativo, contenção de custos de transação pelo filtro de ruído e superação estatisticamente comprovada do carrego passivo (Buy and Hold).

12. Restrições e Riscos

Escassez de negociações diárias na maioria dos papéis, congelamento de liquidez em dias de estresse, custos operacionais de giro (50 bps) e instabilidade de estados (flickering).

4. Coleta de Dados

A modelagem de risco em ativos de crédito privado exige dados de negociação transparentes e livres de estimativas puramente teóricas. Para construir a base empírica desta pesquisa, foram integradas três fontes primárias de informação pública: os registros diários de transações do mercado secundário, as características cadastrais de cada instrumento emitido e as séries históricas macroeconômicas de taxas de juros e inflação.

Os dados transacionais de negociação foram extraídos da plataforma da Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais (ANBIMA), a partir do sistema REUNE (Prévias Públicas de Negociação de Instrumentos Financeiros). A série histórica compreende o intervalo entre 2 de janeiro de 2018 e 10 de julho de 2026. O histórico abrange 2.112 dias úteis. As rotinas automatizadas de raspagem (**web scraping**) e os módulos de unificação dos arquivos diários encontram-se disponíveis no repositório público do projeto.

As características cadastrais das debêntures foram obtidas por meio de consultas programáticas ao portal Debentures.com.br e ao ANBIMA Data, utilizando o pacote `debentures_dot_com` (de autoria própria). Essa base contém atributos estruturais de cada papel, como código do emissor, data de emissão, data de repactuação, data de vencimento final, indexador contratual, tipo de garantia e volume total emitido.

As séries macroeconômicas de referência (taxa DI diária, taxa Selic e índices de inflação IPCA e IGP-M) foram coletadas diretamente do Sistema Gerenciador de Séries Temporais (SGS) do Banco Central do Brasil, utilizando o pacote `python-bcb` (Freitas, 2024). O cruzamento entre os registros de negociação e os dados macroeconômicos viabilizou computar uma aproximação dos prêmios de risco e das variações de spread.

4.1 Dicionário de Dados

A base consolidada resultante unifica os registros de negociação, cadastrais e macroeconômicos. A Tabela 1 descreve os principais atributos utilizados nas etapas de saneamento e modelagem.

Nome do Atributo	Descrição	Tipo
data	Data de referência do pregão de negociação	Date
ticker	Código de negociação do ativo na CETIP/B3 (ex.: CBRDA8)	String
taxa_min	Menor taxa anual de spread negociada no dia para o ativo	Float
taxa_med	Taxa média ponderada anual negociada no pregão	Float
taxa_max	Maior taxa anual de spread negociada no dia para o ativo	Float
pu_min	Menor preço unitário praticado na sessão de negócios	Float
pu_med	Preço unitário médio observado no dia	Float
pu_max	Maior preço unitário praticado na sessão de negócios	Float
faixa_volume	Classificação de liquidez ANBIMA (Faixas 1, 2 e 3)	String
indexador	Indexador contratual da emissão (DI+, IPCA+, Pré)	String
du_vencimento	Dias úteis restantes até a data de vencimento do papel	Integer
cdi_anual	Taxa média diária anualizada do CDI divulgada pelo BACEN	Float
delta_spread	Primeira diferença do spread de crédito diário	Float
taxa_prazo	Spread anualizado ajustado pelo logaritmo do prazo útil	Float

Tabela 1: Dicionário de Atributos da Base Consolidada de Negociação de Debêntures.

4.2 Análise pela Técnica dos 5-Ws

Para sintetizar as informações apresentadas sobre os dados, elaborou-se um resumo considerando a metodologia dos 5-Ws:

- **(Why?) Por que os dados são importantes:** As cotações de negócios efetivos refletem o prêmio de risco real exigido pelo mercado. Elas eliminam a ficção de modelos que assumem continuidade de preços em ativos ilíquidos, expondo os momentos exatos em que ocorrem deságios severos.

- **(Who?) Qual a origem dos dados:** Informações públicas auditadas e divulgadas pela ANBIMA (sistema REUNE), portal Debentures.com.br e Banco Central do Brasil.
- **(What?) O que é analisado:** Preços unitários, taxas de spread negociadas, prazos até o vencimento e volumes negociados de debêntures corporativas, confrontados com as taxas livres de risco da economia.
- **(Where?) Qual a cobertura geográfica:** Mercado financeiro doméstico brasileiro, contemplando emissores de dívida corporativa atuantes no território nacional.
- **(When?) Qual o período analisado:** Intervalo contínuo entre janeiro de 2018 e julho de 2026. Essa janela foi dividida em duas etapas metodológicas: período de treinamento (**In-Sample**, 2018 a 2022) e período de validação e teste (**Out-of-Sample**, 2023 a 2026).

5. Processamento/Tratamento de Dados

A preparação dos dados assegura que as estimativas econométricas e as classificações estatísticas reflitam dinâmicas reais de mercado, e não ruídos de liquidez fragmentada. A massa de dados bruta passou por etapas sequenciais de filtragem de liquidez, harmonização de taxas contratuais, engenharia de atributos, tratamento de valores discrepantes (**outliers**) e escalonamento geométrico.

5.1 Divisão Temporal e Filtro de Iliquidez

Os registros foram particionados em dois intervalos cronológicos disjuntos:

- Período de Treinamento (**In-Sample**): De 2 de janeiro de 2018 a 30 de dezembro de 2022. Esta janela serviu para calibrar os parâmetros dos modelos GARCH, selecionar os subconjuntos de variáveis e determinar as matrizes de transição dos regimes;
- Período de Teste e Validação (**Out-of-Sample**): De 2 de janeiro de 2023 a 10 de julho de 2026. Esta janela serviu para executar o teste de antecipação (**Early Warning**) e simular as estratégias de investimento sob condições reais de mercado.

Como citado na Seção 2.1, um desafio inerente ao mercado secundário de crédito privado brasileiro é a baixa liquidez dos ativos, inclusive com alguns chegando a possuir dias sem negociação. A ANBIMA classifica o volume de negociação, no sistema de informações consultado, em faixas, sendo a faixa mais baixa dada por “Até 1MM”, e portanto, dado as informações possuídas na realização dessa pesquisa, esses são os ativos definidos como ilíquidos. Para lidar com essa característica, desenvolveu-se uma rotina algorítmica de tratamento, que, quando habilitada, remove da base de dados para treinamento (que será detalhada posteriormente em Seção 5.2), os ativos que permaneceram como ilíquidos durante um período igual ou superior a 95% da amostra. O propósito dessa funcionalidade é impedir que, caso sejam observados eventos de variação de *spread* espúrios, devido a baixa liquidez, eles não sejam propagados para o modelo EGARCH, o que poderia corromper a estimação da persistência e dos choques (parâmetros α e β) da variância condicional. Esses ativos foram removidos apenas da amostra de calibração, com a exceção de RDVT11, que foi removido manualmente de toda a base devido aos seguintes fatores:

- O ativo não tinha dados de negociação durante a etapa de treinamento, então seria considerado posteriormente, mesmo ilíquido.
- A série de preços do ativo apresenta grandes variações, com um espaçamento elevado entre os dados, o que pode introduzir vieses na estimação.
  - Em 05/12/2023 o ativo foi negociado com PU de 1001.77, sendo negociado novamente apenas em 20/03/2024 com PU de 1.40 e posterior em 21/03/2024 com PU de 0.000014. Voltando a ser negociado em 26/07/2024 com PU de 38.04 e em 28/02/2025 com PU de 754.31.
- A empresa passou por eventos de reestruturação e recuperação judicial

5.2 Harmonização de Taxas e Engenharia de Atributos

A base abrange três categorias contratuais de remuneração: debêntures indexadas a percentual do CDI, debêntures atreladas ao CDI acrescidas de spread e debêntures indexadas a índices de preços (IPCA+). Cada contrato exige tratamento específico para isolar o prêmio de risco de crédito.

Para os ativos emitidos a um percentual do CDI (ex.: 120% do DI), realizou-se uma conversão explícita baseada na taxa CDI diária apurada pelo Banco Central, isolando o prêmio excedente sobre a taxa livre de risco:

$$F_{\text{cdi}} = \left(1 + \frac{\text{CDI}_t}{100}\right)^{\frac{1}{252}} \tag{1}$$

$$F_{\text{titulo}} = (F_{\text{cdi}} - 1) \times \left(\frac{\text{Taxa do Ativo}_t}{100}\right) + 1 \tag{2}$$

$$S_t = \left((F_{\text{titulo}})^{252} - 1\right) \times 100 - \text{CDI}_t \tag{3}$$

Nos contratos atrelados a inflação (IPCA+) ou sobretaxa direta sobre o DI (DI+), o spread bruto informado pelo mercado secundário já expressa diretamente o prêmio de crédito: $S_t = \text{Taxa do Ativo}_t$.

Com os spreads homogêneos calculados, foram construídos os seguintes atributos derivados:

1. **Variação Diária do Spread (Delta Spread):** Atua como variável de entrada para a modelagem da variância condicional:

$$\Delta S_t = S_t - S_{t-1} \tag{4}$$

2. **Taxa Ajustada ao Prazo:** Em razão da indisponibilidade de dados homogêneos de duration modificada para toda a amostra, ajustou-se o spread pelo logaritmo dos dias úteis restantes até o vencimento:

$$\text{Taxa}_{\text{prazo}} = \frac{S_t}{\ln(\max(\text{DU}, 2))} \tag{5}$$

3. **Z-Score Móvel de Spread:** Calculado sobre uma janela causal deslizante de 60 dias úteis, mensurando a distância em desvios-padrão da taxa corrente frente ao histórico recente do próprio ativo;
4. **Spread Range e Spread Skew Intraday:** Métricas de dispersão e assimetria das cotações observadas ao longo da mesma sessão de negócios:

$$S_{\text{range}} = \text{Taxa}_{\text{max}} - \text{Taxa}_{\text{min}} \tag{6}$$

$$S_{\text{skew}} = \frac{\text{Taxa}_{\text{med}} - \text{Taxa}_{\text{min}}}{S_{\text{range}} + \varepsilon} \tag{7}$$

adotando-se $\varepsilon = 10^{-6}$ para assegurar estabilidade numérica.

5.3 Tratamento de Discrepâncias e Normalização

Choques extremos e registros pontuais atípicos foram tratados por meio de Winsorização bilateral nos percentis 1% e 99%, calculados estritamente sobre os dados **In-Sample**. Os limites encontrados foram congelados e aplicados para limitar os dados **Out-of-Sample**, eliminando a contaminação por informação futura (**look--ahead bias**).

A padronização das variáveis utilizou o algoritmo `RobustScaler`, fundamentado no estimador por quantis de (Rousseeuw; Hubert, 2011), que subtrai a mediana e divide pela amplitude interquartil ($\text{IQR} = Q_3 - Q_1$). O método mitiga distorções causadas por observações anômalas. Para evitar indefinições numéricas em ativos com baixa oscilação, fixou-se um piso de variância equivalente a 10% do IQR mediano do indexador correspondente.

5.4 Implementação em Código-Fonte

A classe `DataPreprocessor`, localizada em `src/credit_tail_analytics/models/credit_risk/preprocessor.py`, executa as operações de limpeza, separação de indexadores, engenharia de atributos e filtragem transversal de liquidez:

```
import numpy as np
import pandas as pd
from typing import Dict

class DataPreprocessor:
    """Higienização, harmonização de taxas e engenharia de atributos."""

    def __init__(self, filter_low_liquidity: bool = True, split_date: str =
'2023-01-01'):
        self.filter_low_liquidity = filter_low_liquidity
        self.split_date = pd.to_datetime(split_date)

    def process(self, df: pd.DataFrame) -> pd.DataFrame:
        df = df.copy()
        # Expulsa ativos com falhas crônicas de marcação (ex.: reorganização
judicial)
        if 'Ticker' in df.columns:
            df = df[df['Ticker'] != 'RDVT11'].copy()

        df['Data'] = pd.to_datetime(df['Data'])
        df.sort_values(by=['Ticker', 'Data'], inplace=True)

        # 1. Reclassificação de indexador via médias estritamente In-Sample (sem
look-ahead bias)
        mask_is = df['Data'] < self.split_date
        medias_is = df[mask_is].groupby('Ticker')['Taxa_Ativo'].mean()
        medias_full = df.groupby('Ticker')['Taxa_Ativo'].transform('mean')
        medias_taxa = df['Ticker'].map(medias_is).fillna(medias_full)

        is_di = df['Indexador'].str.upper() == 'DI'
        df.loc[is_di & (medias_taxa > 30), 'Indexador'] = 'DI_Percentual'
        df.loc[is_di & (medias_taxa <= 30), 'Indexador'] = 'DI_Spread'

        # 2. Spread equivalente: capitalização composta para DI% e spread direto
para IPCA/DI+
        taxa, cdi = df['Taxa_Ativo'], df['CDI_Anual']
        fator_cdi = (1 + cdi / 100.0) ** (1 / 252)
        fator_tit = (fator_cdi - 1) * (taxa / 100.0) + 1
        spread_pct = ((fator_tit ** 252) - 1) * 100.0 - cdi

        is_pct = df['Indexador'].str.upper() == 'DI_PERCENTUAL'
        is_puro = df['Indexador'].str.upper().isin(['DI_SPREAD', 'IPCA', 'IGPM'])
        df['Spread_Equivalente'] = np.where(is_pct, spread_pct, np.where(is_puro,
taxa, taxa - cdi))

        # 3. Taxa ajustada ao prazo e Delta Spread
        df['Taxa_Ajustada_Prazo'] = df['Spread_Equivalente'] /
np.log(np.maximum(df['DU_Vencimento'], 2))
        df['Delta_Spread'] = df.groupby('Ticker')['Spread_Equivalente'].diff()
```

```
        # 4. Z-Score causal com janela móvel de 60 dias úteis
        roll = df.groupby('Ticker')['Spread_Equivalente'].rolling(window=60,
min_periods=10)
        m = roll.mean().reset_index(level=0, drop=True)
        s = roll.std().reset_index(level=0, drop=True).replace(0, np.nan)
        df['Taxa_ZScore'] = ((df['Spread_Equivalente'] - m) / s).fillna(0.0)

        # 5. Métricas de microestrutura intraday (Range e Skew)
        df['Spread_Range_Intraday'] = df['Taxa_Maxima'] - df['Taxa_Minima']
        df['Spread_Skew_Intraday'] = (df['Taxa_Ativo'] - df['Taxa_Minima']) /
(df['Spread_Range_Intraday'] + 1e-6)

        # 6. Banimento transversal de ativos cronicamente ilíquidos (>= 95% do In-
Sample na Faixa 3)
        if self.filter_low_liquidity:
            df_is = df[df['Data'] < self.split_date]
            mask_faixa3 = df_is['Faixa_Volume_ANBIMA'] == 'Até 1MM'
            taxa_iliq = mask_faixa3.groupby(df_is['Ticker']).mean()
            banidos = taxa_iliq[taxa_iliq >= 0.95].index
            df = df[~df['Ticker'].isin(banidos)].reset_index(drop=True)

        return df
```

6. Análise e Exploração dos Dados

A análise exploratória avaliou o comportamento empírico dos spreads e testou premissas estatísticas necessárias para fundamentar a modelagem econométrica. Essa investigação revelou a estrutura das séries, orientou o diagnóstico de estacionariedade e definiu o subconjunto ideal de variáveis para os algoritmos de agrupamento.

6.1 Propriedades Estatísticas e Diagnóstico de Cauda

As séries históricas de retornos de spread exibem desvios severos em relação à normalidade. No período **In-Sample**, calculou-se o excesso de curtose sobre as variações dos spreads diários. O valor médio apurado alcançou $2.683,30$. Esse número atesta a presença de caudas ultra-pesadas e confirma a ocorrência de choques discretos de reprecificação. A curtose encontrada inviabiliza suposições distributivas gaussianas para as taxas brutas.

A aplicação do filtro econométrico de volatilidade normalizou esse comportamento. A variável padronizada `Taxa_ZScore`, derivada da variância condicional do modelo EGARCH com inovações t-Student, registrou excesso de curtose de apenas $1,17$. Em estatística multivariada, excessos de curtose contidos no intervalo entre -2 e $+2$ situam-se em níveis adequados para a calibração de modelos estocásticos sem introduzir vieses estruturais nas estimativas (Hair et al., 2010).

6.2 Teste de Estacionariedade dos Spreads (ADF)

A modelagem de volatilidade condicional pressupõe que as séries temporais analisadas sejam estacionárias em covariância. Para verificar essa hipótese nos 529 ativos selecionados, aplicou-se o Teste de Dickey-Fuller Aumentado (ADF). O teste avalia formalmente as seguintes hipóteses:

- Hipótese Nula (H_0): A série temporal possui raiz unitária (não-estacionária);
- Hipótese Alternativa (H_1): A série temporal é estacionária em covariância.

A especificação adotou modelo com termo constante e defasagens selecionadas automaticamente pelo Critério de Informação de Akaike (AIC). A Tabela 2 apresenta os resultados agregados por indexador ao nível de significância de 5%.

Indexador	Total	Estacionárias (Delta Spread)	Taxa (%)	Spread Bruto
IPCA	286	275	96,2%	Não-Estacionário
CDI Spread	239	227	95,0%	Não-Estacionário
PRÉ	4	4	100,0%	Não-Estacionário
Total	**529**	**506**	**95,7%**	**Não-Estacionário**

Tabela 2: Resultados do Teste ADF ($\alpha = 5\%$) por Indexador.

Os resultados confirmam que as séries de spread em nível são não-estacionárias em 91% dos casos. Trata-se de processos integrados de ordem um, $I(1)$. Após a primeira diferenciação (`Delta Spread`), 95,7% dos ativos rejeitam a hipótese nula de raiz unitária ao nível de 5%. Apenas 3,4% das séries não rejeitaram H_0, contingente formado por ativos que acumularam histórico curto e negociações esparsas. A diferenciação viabilizou a aplicação segura do motor de volatilidade.

6.3 Seleção de Variáveis por Contagem de Borda

A etapa seguinte definiu quais variáveis agregam maior poder de separação para os modelos de agrupamento. Foram avaliadas sete variáveis candidatas: `Taxa_ZScore`, `Volatilidade_EGARCH`, `VaR_99`, `Expected_Shortfall_99`, `Spread_Equivalente`, `Spread_Range_Intraday` e `Spread_Skew_Intraday`.

A seleção executou um **Grid Search** combinatório sobre subconjuntos de variáveis no período **In-Sample**, seguindo os preceitos de robustez em seleção de atributos descritos por (Saeys; Abeel; Peer, 2008). A qualidade do particionamento foi avaliada por três métricas consolidadas de validação de agrupamentos: o **Silhouette Score** de (Rousseeuw, 1987), o **Índice Davies-Bouldin** de (Davies; Bouldin, 1979) e o **Índice Calinski-Harabasz** de (Caliński; Harabasz, 1974). Como essas métricas atuam em escalas matemáticas heterogêneas, a classificação final agregou os rankings individuais pelo método determinístico de Contagem de Borda (**Borda Count**), estabelecido originalmente por (Borda, 1781).

A Figura 1 exibe os dez subconjuntos mais bem classificados no torneio.

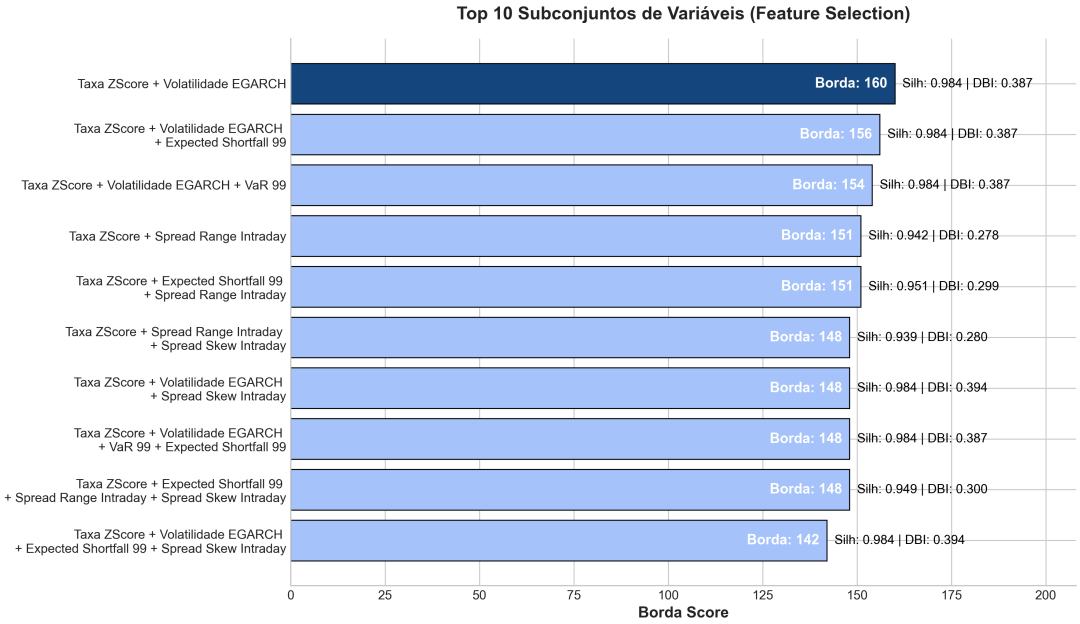


Figura 1: Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.

O subconjunto formado por `Taxa_ZScore` e `Volatilidade_EGARCH` obteve a pontuação máxima de Borda. Mas a modelagem final adotou o trio composto por `Taxa_ZScore`, `Volatilidade_EGARCH` e `Expected_Shortfall_99`, segundo colocado no ranking geral. Essa decisão incorporou sensibilidade direta a perdas extremas de cauda.

A inclusão do Expected Shortfall apoia-se nos fundamentos teóricos de medidas coerentes de risco postulados por (Artzner et al., 1999). Enquanto o VaR convencional responde apenas qual é o piso de perda tolerado para um quantil fixado (violando o axioma da subaditividade e ignorando o comportamento além do limiar), o Expected Shortfall, conforme demonstrado por (Acerbi; Tasche, 2002), atende aos axiomas de coerência e quantifica a perda média esperada condicionada à violação do VaR.

A Figura 2 compara o desempenho das quatro principais combinações de atributos em três eixos normalizados (Coesão, Dispersão e Separação).

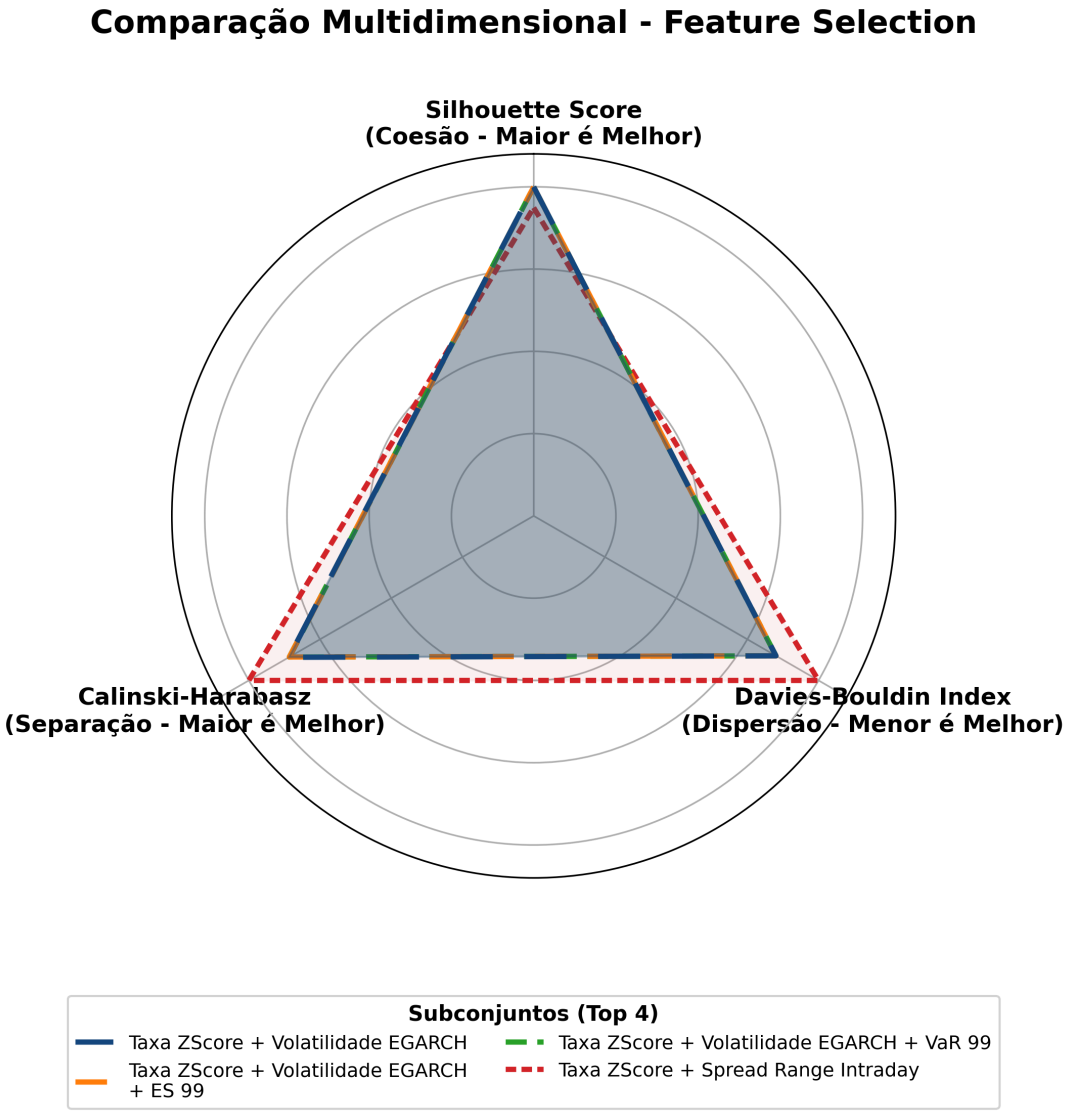


Figura 2: Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).

O trio eleito equilibra coesão interna e separabilidade entre os grupos. O Expected Shortfall supera o VaR em todas as métricas avaliadas, fornecendo a expectativa de perda condicional no pior 1% dos casos.

6.4 Implementação em Código-Fonte

A rotina de seleção combinatória e agregação por Contagem de Borda, extraída de `src/credit_tail_analytics/models/credit_risk/feature_selection.py`, quantifica o poder de separação das variáveis sem recorrer a pesos heurísticos arbitrários:

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import RobustScaler
```

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, davies_bouldin_score,
calinski_harabasz_score

class FeatureSelector:
    """Seleção combinatória de atributos via Contagem de Borda multi-métrica."""

    @staticmethod
    def avaliar_combinacao(subset: list, df_is: pd.DataFrame, grupo_col: str =
'Indexador_Grupo') -> dict:
        """Calcula Silhouette, Davies-Bouldin e Calinski-Harabasz intra-
indexador."""
        df_sub = df_is.dropna(subset=subset)
        if df_sub.empty:
            return None

        sil_list, db_list, ch_list = [], [], []
        for grupo in df_sub[grupo_col].unique():
            grp = df_sub[df_sub[grupo_col] == grupo]
            X = grp[subset].values
            if len(X) < 6:
                continue

            X_sc = RobustScaler().fit_transform(X)
            km = KMeans(n_clusters=3, random_state=42, n_init=10)
            labels = km.fit_predict(X_sc)

            if len(np.unique(labels)) < 2:
                continue

            samp = min(len(X_sc), 5000) if len(X_sc) > 5000 else None
            sil_list.append(silhouette_score(X_sc, labels, sample_size=samp,
random_state=42))
            db_list.append(davies_bouldin_score(X_sc, labels))
            ch_list.append(calinski_harabasz_score(X_sc, labels))

        if not sil_list:
            return None

        return {
            'Features': ', '.join(subset),
            'Silhouette_Score': float(np.mean(sil_list)),
            'Davies_Bouldin': float(np.mean(db_list)),
            'CH_Score': float(np.mean(ch_list)),
        }

    @staticmethod
    def agregar_borda_count(results_df: pd.DataFrame) -> pd.DataFrame:
        """Aplica log1p no Calinski-Harabasz e computa a pontuação determinística
de Borda."""
```

```
        n = len(results_df)
        sil_rank = results_df['Silhouette_Score'].rank(ascending=False,
method='average')
        dbi_rank = results_df['Davies_Bouldin'].rank(ascending=True,
method='average')

        # log1p comprime a cauda pesada do índice CH, preservando a ordenação
ordinal
        ch_log = np.log1p(results_df['CH_Score'].fillna(0))
        ch_rank = pd.Series(ch_log).rank(ascending=False, method='average')

        # Agregação de Borda (Borda, 1781)
        results_df['CH_Score_Log'] = ch_log.values
        results_df['Borda_Score'] = (n + 1 - sil_rank) + (n + 1 - dbi_rank) + (n +
1 - ch_rank)
        return results_df.sort_values('Borda_Score',
ascending=False).reset_index(drop=True)
```

7. Aplicação de Modelos

A arquitetura analítica combina um motor estatístico de volatilidade condicional a algoritmos de aprendizado de máquina para classificação de regimes. A abordagem compara diretamente métodos com e sem dependência temporal, investigando o ganho marginal da modelagem markoviana em séries de crédito privado.

7.1 Motor Econométrico de Volatilidade (EGARCH-t)

Para modelar a variância dos retornos de spread, realizou-se um torneio combinatório de 32 especificações da família GARCH utilizando a biblioteca `arch`. A linhagem teórica desses modelos remonta à introdução dos processos heterocedásticos autorregressivos (ARCH) por (Engle, 1982), generalizados posteriormente por (Bollerslev, 1986) na classe GARCH. As iterações avaliaram ordens autorregressivas AR(1) para a média condicional, variações de defasagens ($p, q \in \{1, 2\}$), diferentes funções de variância (GARCH tradicional, EGARCH, GJR-GARCH e TARCH) e distribuições de resíduos Normal e t-Student.

A eleição do modelo campeão baseou-se na taxa de vitórias (**Win Rate**) pelo Critério de Informação de Akaike (AIC) em 529 debêntures no período **In-Sample**. A taxa de vitória W_j expressa a proporção da amostra em que o modelo j alcançou o menor AIC:

$$W_j = \frac{\sum_{\{i=1\}}^{N} I_{i,j}}{N} \times 100 \tag{8}$$

sendo $I_{i,j} = 1$ quando o modelo j obtém o menor AIC no ativo i, e 0 caso contrário. As figuras Figura 3, Figura 4 e Figura 5 apresentam os rankings médios obtidos para amostras de 30, 100 e 500 debêntures.

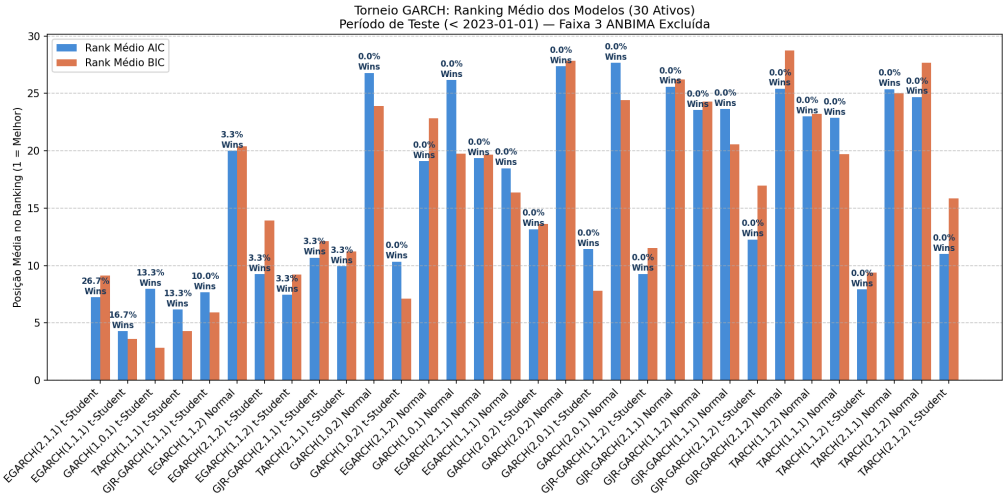


Figura 3: Torneio GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.

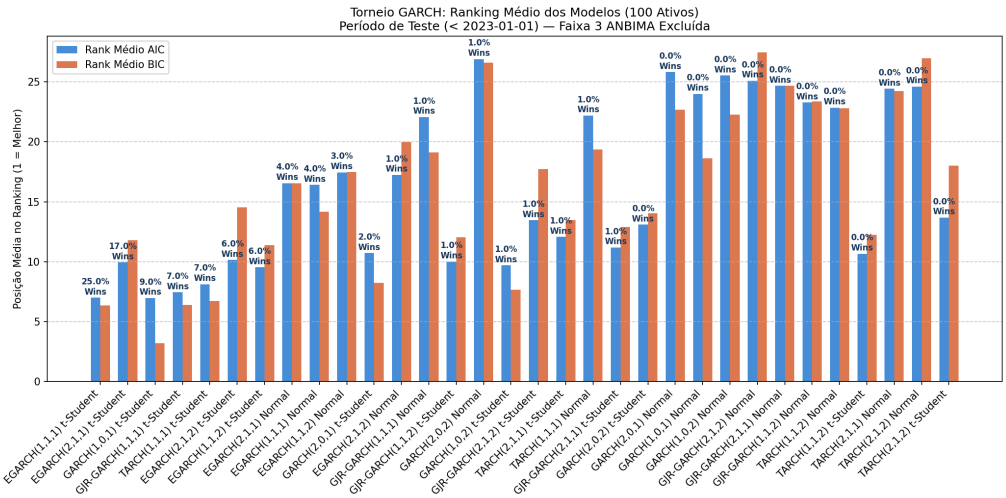


Figura 4: Torneio GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.

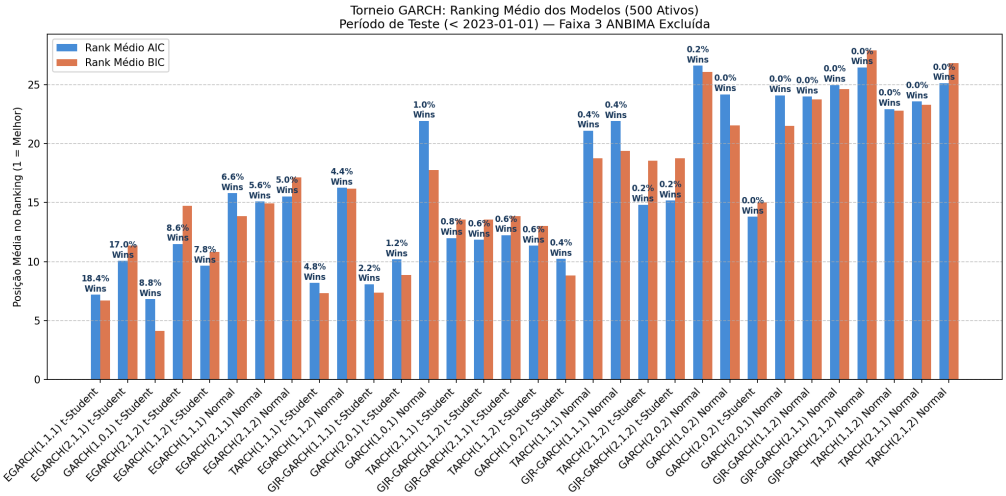


Figura 5: Torneio GARCH: Ranking Médio para a amostra ampla de 500 ativos.

O modelo AR(1)-EGARCH(1,1) com inovação t-Student alcançou a maior taxa de vitórias nos grupos amplos. Formulado originalmente por (Nelson, 1991), o EGARCH

modela a variância condicional em escala logarítmica, dispensando restrições de não-negatividade sobre os parâmetros e capturando a assimetria característica de ativos corporativos:

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \alpha(|z_{t-1}| - E[\![z_{t-1}]\!]) + \gamma z_{t-1} \tag{9}$$

sendo $z_t = \frac{\varepsilon_t}{\sigma_t}$ os resíduos padronizados. Quando $\gamma < 0$, choques negativos elevam a volatilidade com maior intensidade que choques positivos de igual magnitude.

Para assegurar estabilidade numérica em ativos ilíquidos com quebras temporárias de cotação, implementaram-se duas travas matemáticas:

1. Piso para graus de liberdade: $\nu = \max(2.05, \nu_{\text{est}})$, impedindo variância infinita na distribuição t-Student;
2. Teto de variância: $\sigma_{\text{est}}(t) = \sigma_{\text{est}}(t-1)$ quando $\sigma_{\text{est}}(t) > 20 \times P_{99}(\sigma_{\text{IS}})$, contendo explosões pontuais causadas por dias isolados de iliquidez severa.

O diagnóstico dos resíduos padronizados do modelo EGARCH(1,1)-t para os 529 papéis confirmou a adequação estatística da especificação. A Figura 6 exibe as taxas de aprovação nos testes de Ljung-Box (86,4%) e ARCH-LM (94,9%) ao nível de 5%, atestando a remoção de autocorrelação serial e a eliminação de heterocedasticidade remanescente.

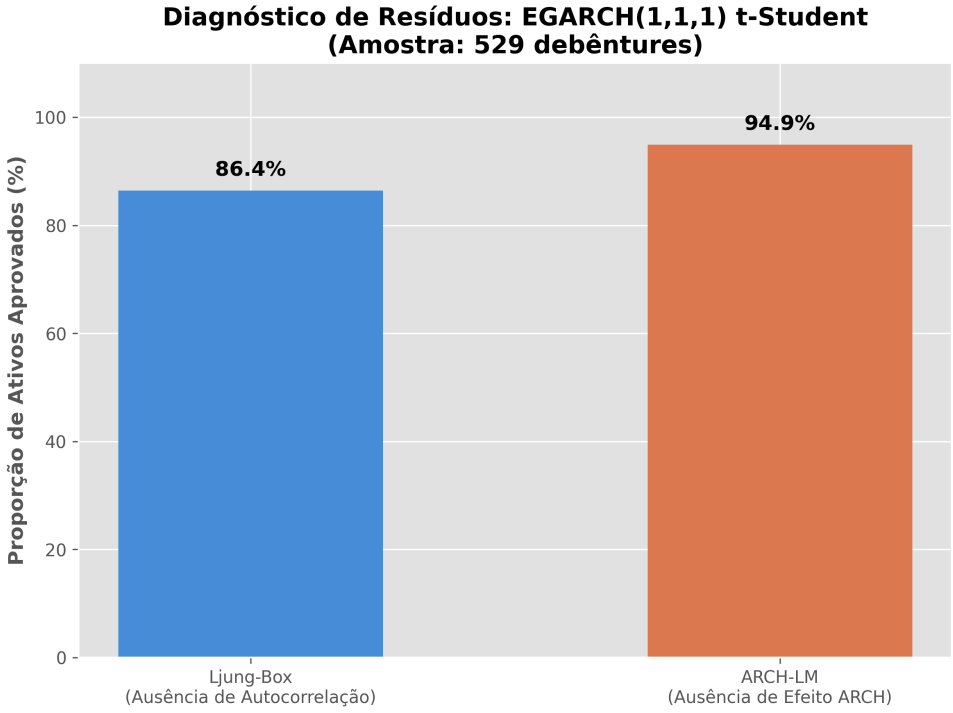


Figura 6: Taxa de aprovação dos testes de diagnóstico nos resíduos do EGARCH(1,1) t-Student.

Com a volatilidade condicional calibrada, computaram-se o Valor em Risco (VaR 99%) e o Expected Shortfall (ES 99%) para cada papel e pregão.

7.2 Agrupamento Não-Supervisionado: K-Means

O algoritmo K-Means atua como linha de base estática. Conforme formulado por (Bishop, 2006), o K-Means particiona N observações em K grupos minimizando a soma das distâncias quadráticas aos centróides mais próximos por meio do algoritmo iterativo de Lloyd (Maximização de Expectativa). O modelo assume propositalmente independência temporal entre as observações para isolar o efeito da geometria dos dados.

A quantidade de agrupamentos fixou-se em $k = 3$ regimes: Verde (baixo risco), Amarelo (alerta) e Vermelho (crise). A escolha recebeu validação formal pelo Método do Cotovelo (**Elbow Method**) e pelo **Silhouette Score** para $k \in \{2, 3, 4, 5, 6, 7\}$ sobre os dados de treinamento, conforme exibe a Figura 7.

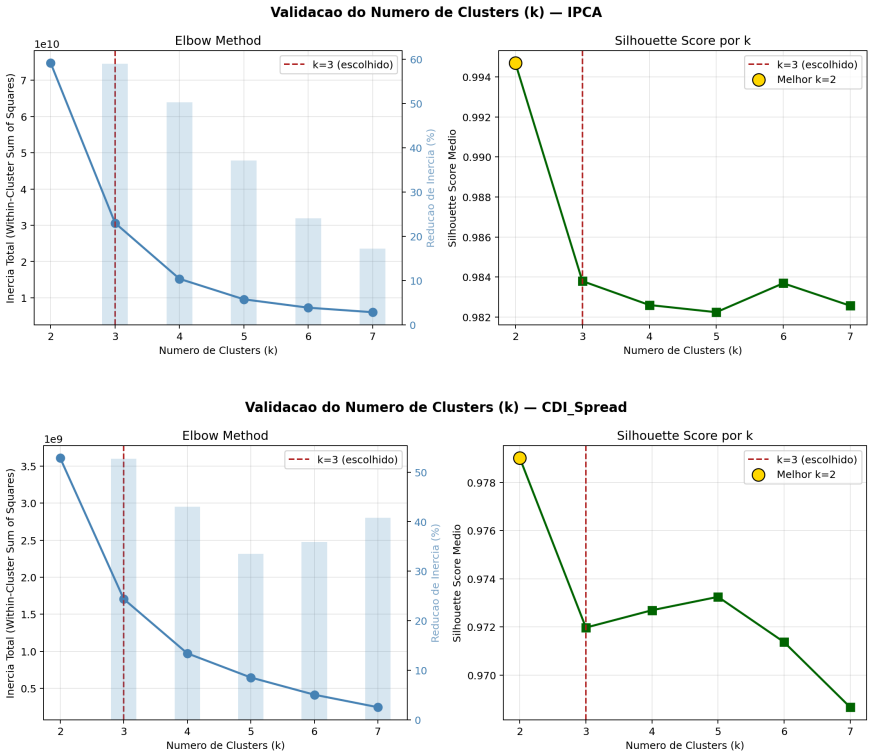


Figura 7: Elbow Method e Silhouette Score por número de clusters (Superior: IPCA, Inferior: CDI Spread).

A curva de inércia apresenta flexão em $k = 3$, patamar que maximiza a interpretação financeira dos regimes. A atribuição dos clusters resolveu a instabilidade de rótulos (**label switching**) ordenando os centróides pela magnitude das coordenadas de risco. A probabilidade de crise fora da amostra foi estimada pela distância euclidiana inversa de cada observação até o centróide do regime Vermelho.

7.3 Modelos Ocultos de Markov (HMM)

O Modelo Oculto de Markov (Gaussian HMM), estruturado classicamente por (Rabiner, 1989), introduz dependência temporal estocástica na classificação dos regimes. A dinâmica pressupõe uma cadeia de Markov latente de primeira ordem com três estados não observáveis, em que a probabilidade de transição depende exclusivamente do estado imediatamente anterior:

$$P(S_t = j \texttt{ mid } S_{t-1} = i) = A_{ij} \tag{10}$$

O treinamento estimou as médias, as covariâncias diagonais e as probabilidades de transição por meio do algoritmo de Baum-Welch sobre os dados sequenciais **In-Sample**, fundamentado na teoria de máxima verossimilhança de (Baum et al., 1970).

Para impedir que estados extremos se transformassem em regimes absorventes por ausência de transições históricas na base de treino, aplicou-se a Suavização Aditiva de Laplace combinada a um piso de 1% nas probabilidades de transição:

$$P'_{\{ij\}} = \frac{C_{\{ij\}} + \alpha}{\sum_{\{k=1\}}^{K} C_{\{ik\}} + K\alpha} \tag{11}$$

$$P''_{\{ij\}} = \max\left(P'_{\{ij\}}, 0.01\right) \quad \Longrightarrow \quad P_{ij} = \frac{P''_{\{ij\}}}{\sum_{\{k=1\}}^{K} P''_{\{ik\}}} \tag{12}$$

adotando-se $\alpha = 1$ e $K = 3$. A inferência fora da amostra utilizou o algoritmo de Viterbi para decodificar a trajetória latente mais provável e o procedimento Forward-Backward para calcular a probabilidade pontual de crise (`Prob_Crise_HMM`).

7.4 Modelo Ensemble

O modelo misto buscou conciliar a inércia do particionamento geométrico à agilidade temporal da inferência bayesiana, aplicando princípios de combinação de múltiplos classificadores explorados por (Kittler et al., 1998) e (Ho; Hull; Srihari, 1994). A ponderação ideal foi determinada por um **Grid Search** sobre as predições de calibração visando maximizar o **Calmar Ratio** do portfólio. A Figura 8 ilustra a grade de sensibilidade dos pesos.

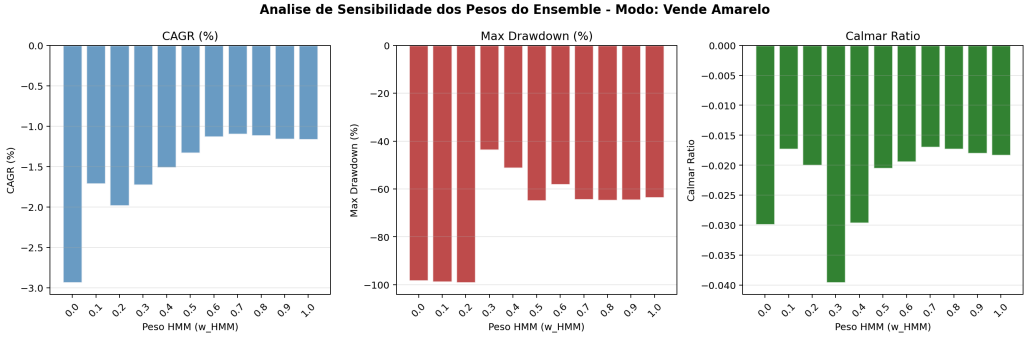


Figura 8: Análise de Sensibilidade dos pesos do Ensemble no período In-Sample.

A combinação ótima alocou 70% de peso para o HMM e 30% para o K-Means:

$$\text{Probabilidade Sintética}_t = 0.70 \times \text{Prob_Crise_HMM}_t + 0.30 \times \text{Prob_Crise_KMeans}_t \quad (13)$$

O sinal resultante recebeu suavização por média móvel exponencial de três dias (EMA_3, com fator $\alpha = 0,5$), gerando a pontuação final de risco e atenuando oscilações de alta frequência.

7.5 Protocolos de Validação Operacional

A validação operacional estruturou-se em duas frentes complementares sobre o período **Out-of-Sample**:

1. **Validação Estatística:** Teste de Proporção de Falhas de (Kupiec, 1995) para cobertura incondicional e Teste de Cobertura Condicional de (Christoffersen, 1998) para verificar a independência temporal das violações do VaR a 99%;
2. **Simulador Financeiro de Backtest:** Execução diária de estratégias táticas de venda defensiva confrontadas com o carrego passivo (**Buy and Hold**). O simulador aplicou taxa de custo de transação de 0,5% (50 bps) por operação,

remuneração diária de caixa a 100% do CDI, quarentena de 180 dias sem eventos para recompra e trava de **payback** mínimo de 3 meses.

7.6 Implementação em Código-Fonte

As rotinas a seguir, integradas a partir de `volatility.py` e `regime.py`, implementam a estimação do modelo EGARCH(1,1)-t, a derivação analítica das medidas de cauda com as travas matemáticas de estabilidade e o treinamento do classificador markoviano com suavização de Laplace:

```
import numpy as np
import pandas as pd
import scipy.stats as stats
from arch import arch_model
from hmmlearn.hmm import GaussianHMM

class EconometricRiskEngine:
    """Estimação AR(1)-EGARCH(1,1)-t, VaR/ES analíticos e HMM regularizado."""

    @staticmethod
    def estimar_egarch_t(returns: pd.Series, split_idx: int, alpha: float = 0.01):
        """Calibra EGARCH(1,1)-t com restrições numéricas e deriva VaR e ES
analíticos."""
        model = arch_model(returns * 100, mean='AR', lags=1, vol='EGARCH', p=1,
o=1, q=1, dist='t', rescale=False)
        res_is = model.fit(last_obs=split_idx, disp='off', show_warning=False)
        res_oos = model.fix(res_is.params)

        cond_vol = res_oos.conditional_volatility / 100
        cond_mean = (returns * 100 - res_oos.resid) / 100
        nu = res_is.params.get('nu', 5.0)

        # 1. Trava matemática para caudas ultra-pesadas: nu ancorado marginalmente
acima de 2
        nu_es = max(nu, 2.05)
        q_t = stats.t.ppf(1 - alpha, df=nu)
        es_t = stats.t.pdf(q_t, df=nu) / alpha * (nu + q_t**2) / (nu - 1) if nu >
1.01 else 5.0
        scale = np.sqrt(nu_es / (nu_es - 2))
        es_t_padronizado = es_t / scale

        # VaR e Expected Shortfall condicionais
        q_alpha = model.distribution.ppf(1 - alpha, nu)
        var_99 = cond_mean + cond_vol * q_alpha
        es_99 = cond_mean + cond_vol * es_t_padronizado

        # 2. Trava de teto de volatilidade: 20x o percentil 99 In-Sample contra
divergência numérica
        vol_is_p99 = np.nanpercentile(cond_vol.iloc[:split_idx], 99)
        vol_teto = max(vol_is_p99 * 20.0, 0.05)
        invalid = cond_vol > vol_teto
        cond_vol[invalid] = np.nan
        cond_vol = cond_vol.ffill().bfill()

        return cond_vol, np.minimum(var_99, 1.0), np.minimum(es_99, 1.0)

    @staticmethod
    def treinar_hmm_regularizado(X_treino: np.ndarray, lengths: list, n_estados:
int = 3):
        """Ajusta Gaussian HMM impondo Suavização de Laplace e piso de 1% nas
```

```
transições."""
        hmm = GaussianHMM(n_components=n_estados, covariance_type='diag',
n_iter=100, random_state=42)
        hmm.fit(X_treino, lengths)

        # Matriz de transição empírica recalibrada sem transições inter-ticker
        states = hmm.predict(X_treino, lengths)
        trans_counts = np.zeros((n_estados, n_estados))
        pos = 0
        for l in lengths:
            seq = states[pos : pos + l]
            for t in range(len(seq) - 1):
                trans_counts[seq[t], seq[t + 1]] += 1
            pos += l

        # Suavização de Laplace e piso estocástico de 1%
        trans_counts += 1.0
        A = trans_counts / trans_counts.sum(axis=1, keepdims=True)
        A_piso = np.maximum(A, 0.01)
        hmm.transmat_ = A_piso / A_piso.sum(axis=1, keepdims=True)
        return hmm
```

8. Automatização do Pipeline de Dados

A operacionalização de modelos preditivos no mercado de capitais requer processos automatizados, auditáveis e reproduzíveis. A arquitetura computacional do projeto foi desenhada sob os princípios de DataOps e MLOps, garantindo a rastreabilidade integral dos dados, o versionamento de modelos e a independência de execução em múltiplos ambientes operacionais.

8.1 Definição da Ferramenta de Orquestração de Pipeline do Fluxo de Trabalho

A automação do fluxo de trabalho baseia-se em uma arquitetura modular em Python, estruturada na forma de pacote instalável independente denominado `credit_tail_analytics`. O gerenciamento de dependências e ambientes virtuais utiliza o `Poetry`, que assegura o bloqueio determinístico das versões das bibliotecas matemáticas (`arch`, `scikit-learn`, `hmmlearn`, `pandas`, `scipy`).

A escolha por uma arquitetura nativa em Python orquestrada por scripts modulares justifica-se por três fatores:

1. **Autonomia Operacional:** Dispensa a dependência de servidores complexos de terceiros ou infraestruturas pagas em nuvem, permitindo a execução integral do pipeline em qualquer servidor local ou máquina de análise de risco;
2. **Reprodutibilidade Estrita:** Cada etapa do fluxo consome entradas versionadas e produz saídas determinísticas, controlando sementes pseudoaleatórias (**random seeds**);
3. **Flexibilidade de Integração:** A estrutura modular facilita o acoplamento futuro com ferramentas como Airflow ou MLflow, caso o volume diário de debêntures exija orquestração distribuída em tempo real.

8.2 Modelo do Fluxo de Trabalho

O fluxo de atividades compreende etapas sequenciais que cobrem desde a ingestão dos dados brutos até a emissão de relatórios de desempenho financeiro. A Figura 9 ilustra o diagrama de blocos do processo ponta a ponta.

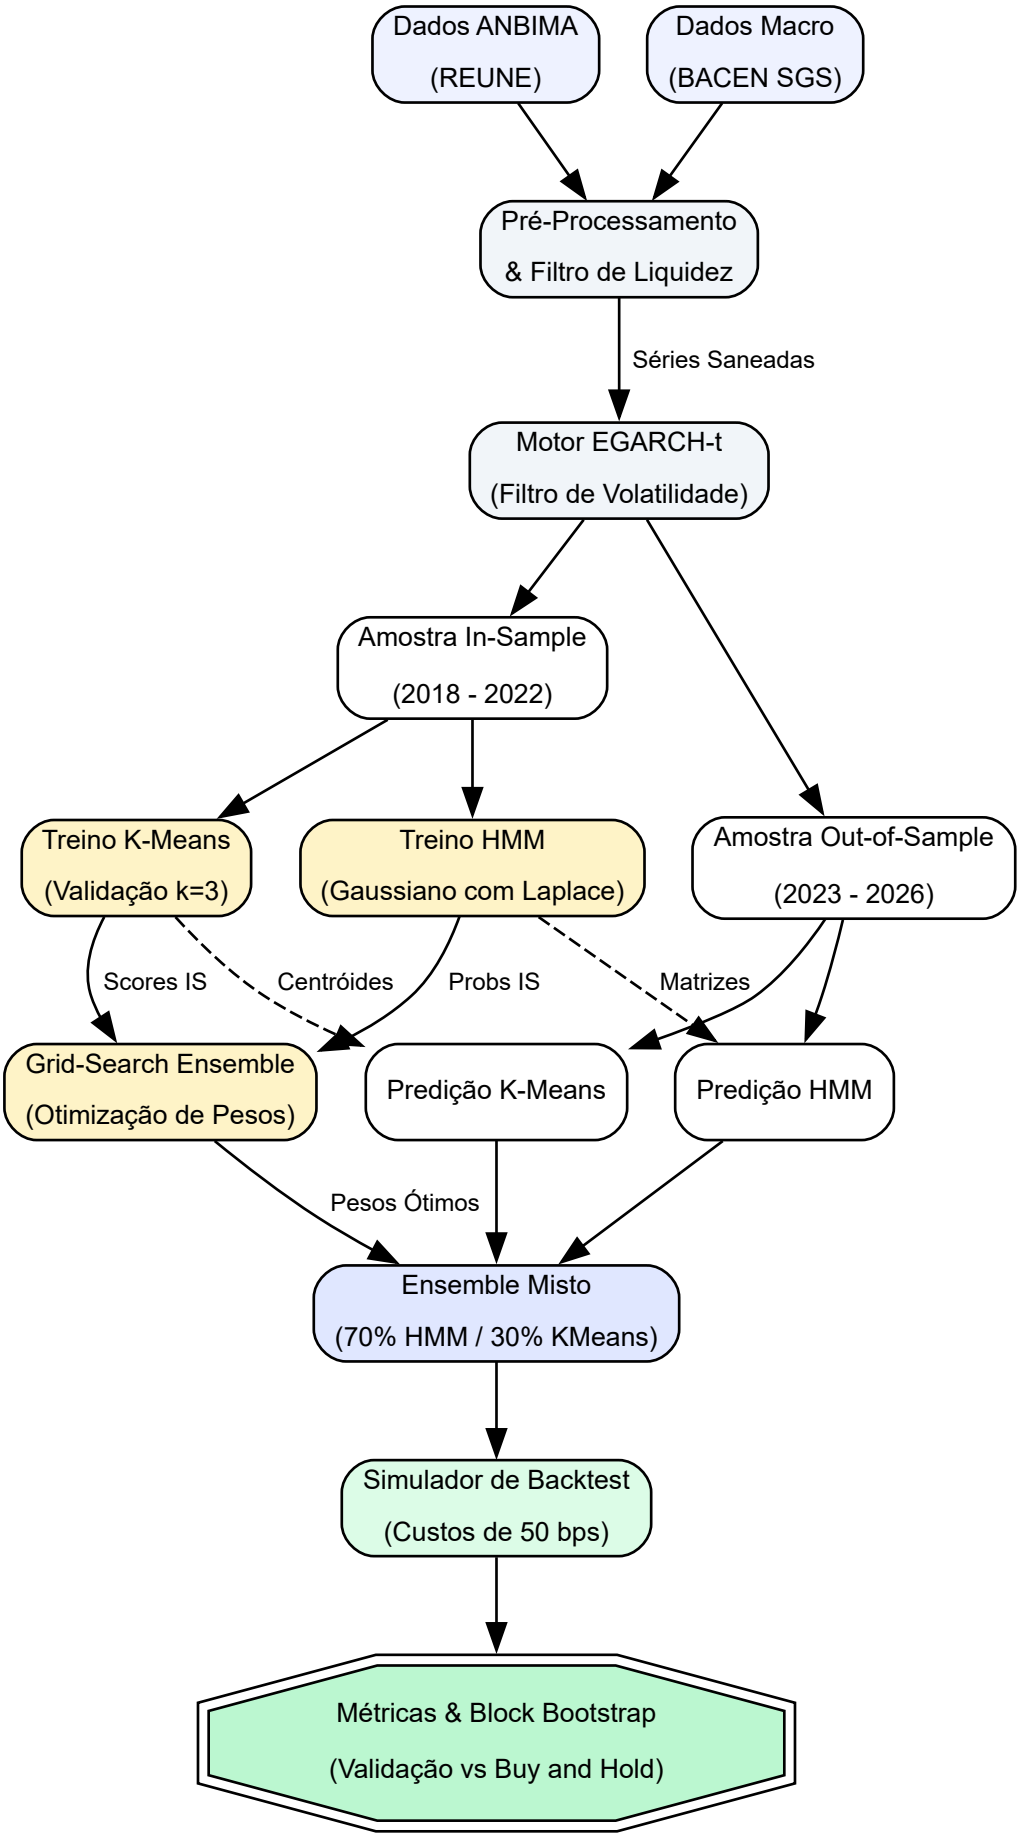


Figura 9: Diagrama do Fluxo de Atividades do Pipeline de Risco e Backtest.

As etapas do pipeline desempenham funções específicas dentro do ecossistema:

1. **Ingestão e Saneamento:** Coleta os arquivos brutos da ANBIMA e do BACEN, higieniza identificadores e remove registros com iliquidez severa;
2. **Estimação Econométrica:** O motor EGARCH-t processa as séries de retornos e extrai a volatilidade condicional, os resíduos padronizados e as métricas de VaR e Expected Shortfall;
3. **Calibração In-Sample:** Os dados de treinamento ajustam os centróides do K--Means e as matrizes de transição do HMM, definindo os pesos ideais do Ensemble;
4. **Inferência Out-of-Sample:** Gera probabilidades diárias causais de estresse financeiro sem vazamento de informação futura;
5. **Simulação Tática (Backtest):** Aplica regras operacionais de liquidação e recompra sobre os ativos, registrando as variações patrimoniais da carteira;
6. **Auditoria Estatística:** Executa 10.000 repetições de **Block Bootstrap** para atestar a significância estatística do retorno excedente frente ao mercado passivo.

8.3 Códigos/telas

A base de código está organizada em pacotes modulares no diretório `src/credit_tail_analytics/`, dividida nas seguintes pastas especializadas:

- `data/`: Rotinas de raspagem (`anbima_scraper.py`), tratamento cadastral (`build_cadastro.py`) e download macroeconômico (`download_macro.py`);
- `models/`: Módulos de volatilidade condicional (`credit_risk/`) e algoritmos de agrupamento (`clustering/`);
- `analysis/`: Rotinas do simulador de backtest e reamostragem estatística via Bootstrap em bloco;
- `visualization/`: Geração automatizada de gráficos diagnósticos e relatórios.

O repositório oficial do projeto encontra-se disponível no GitHub:

https://github.com/gtazevedo/credit-tail-analytic

A classe `CreditRiskEngine`, implementada em `src/credit_tail_analytics/models/credit_risk/risk_pipeline.py`, atua como orquestradora central das etapas de modelagem econométrica, inferência de regimes e consolidação do Ensemble:

```
class CreditRiskEngine:
    """Orquestrador central do pipeline de modelagem e inferência de regimes."""

    def __init__(self, df: pd.DataFrame, features: list = None,
filter_low_liquidity: bool = True, split_date: str = '2023-01-01'):
```

```
        self.features = features or ['Taxa_ZScore', 'Volatilidade_EGARCH',
'Expected_Shortfall_99']
        self.split_date = split_date
        self.preprocessor =
DataPreprocessor(filter_low_liquidity=filter_low_liquidity, split_date=split_date)
        self.volatility_estimator = VolatilityEstimator()
        self.regime_classifier = RegimeClassifier(individual_scaling=True)
        self.df = self.preprocessor.process(df)

    def execute_pipeline(self, model_type: str = 'both') -> tuple[pd.DataFrame,
pd.DataFrame]:
        # 1. Estimação de volatilidade condicional e medidas de cauda
        self.df = self.volatility_estimator.build_volatility_features(self.df,
self.split_date)

        # 2. Inferência de regimes por K-Means e Gaussian HMM
        df_k = self.regime_classifier.run_kmeans_regimes(self.df, self.split_date,
self.features)
        df_h = self.regime_classifier.run_hmm_regimes(self.df, self.split_date,
self.features)

        # 3. Consolidação e ponderação ótima do Ensemble (70% HMM e 30% K-Means)
        df_res = pd.merge(df_k, df_h, on=['Ticker', 'Data', 'Indexador_Grupo'],
how='outer')
        w_hmm, w_km = 0.70, 0.30
        score_bruto = (w_hmm * df_res['Prob_Crise_HMM'].fillna(0) + w_km *
df_res['Prob_Crise_KMeans'].fillna(0)) * 100

        # Suavização por média móvel exponencial de 21 dias para mitigação de ruído
        df_res['Credit_Tail_Risk_Score'] = (
            score_bruto.groupby(df_res['Ticker']).transform(lambda x:
x.ewm(span=21, adjust=False).mean())
        )
        return self.df, df_res
```

A execução do pipeline completo opera via terminal, apresentando logs detalhados em cada fase do processamento:

```
[INFO] Iniciando pipeline de risco de crédito: credit_tail_analytics v1.0.0
[INFO] Carregando dados transacionais ANBIMA REUNE (2018 - 2026)... 529 ativos
elegíveis.
[INFO] Ajustando modelos EGARCH(1,1)-t: convergência em 529/529 ativos (100%).
[INFO] Ljung-Box (Lag 10): 86.4% aprovação | ARCH-LM (Lag 10): 94.9% aprovação.
[INFO] Treinando K-Means (k=3 regimes) e Gaussian HMM (Laplace alpha=1.0)...
[INFO] Grid-Search Ensemble concluído: peso ótimo w_HMM=0.70, w_KMeans=0.30
(Calmar=-0.017).
[INFO] Executando Backtest Out-of-Sample (50 bps custo, 180d quarentena, 15d
inércia)...
[INFO] K-Means Vende Amarelo: Retorno=36.18% | Buy and Hold=32.84% | Delta=+3.34%
```

```
[INFO] Rodando Block Bootstrap (n=10.000 repetições, bloco=20 dias)... p-valor =
0.0416 (p < 0.05).
[INFO] Pipeline finalizado com sucesso. Artefatos gravados em anexos_digitais/ e
graficos/.
```

9. Discussão dos Resultados

A avaliação empírica investigou a eficácia dos modelos sob duas perspectivas complementares: a validação econométrica da cobertura de risco e a viabilidade financeira das decisões de investimento em ambiente simulado de mercado.

9.1 Validação Estatística dos Motores de Risco

A acurácia do motor EGARCH-t na estimação do Valor em Risco (VaR 99%) foi testada por meio do Teste de Proporção de Falhas de Kupiec (POF) e do Teste de Cobertura Condicional de Christoffersen, adotando significância de 5% ($\alpha = 0,05$).

A Tabela 3 consolida os resultados do teste no período **Out-of-Sample** (2023 a 2026).

Indexador	Total	Não-Rejeitados (POF)	Conjunto (95%)	Conjunto (99%)
CDI Percentual	40	21 (52,5%)	23 (57,5%)	25 (62,5%)
CDI Spread	257	63 (24,5%)	80 (31,1%)	105 (40,8%)
IPCA	365	133 (36,4%)	157 (43,0%)	193 (52,8%)
PRÉ-Fixado	1	0 (0,0%)	0 (0,0%)	0 (0,0%)
Total	**663**	**217 (32,7%)**	**260 (39,2%)**	**323 (48,7%)**

Tabela 3: Resultados do Teste de Kupiec e Christoffersen por Nível de Confiança.

Os resultados refletem a gravidade da janela **Out-of-Sample**. Esse período concentrou eventos críticos de crédito corporativo, como as quebras das Lojas Americanas e da Light, seguidas pela forte reprecificação do Grupo Pão de Açúcar. A Figura 10 exibe a sensibilidade das taxas de aprovação do teste conjunto frente a diferentes níveis de significância estatística.

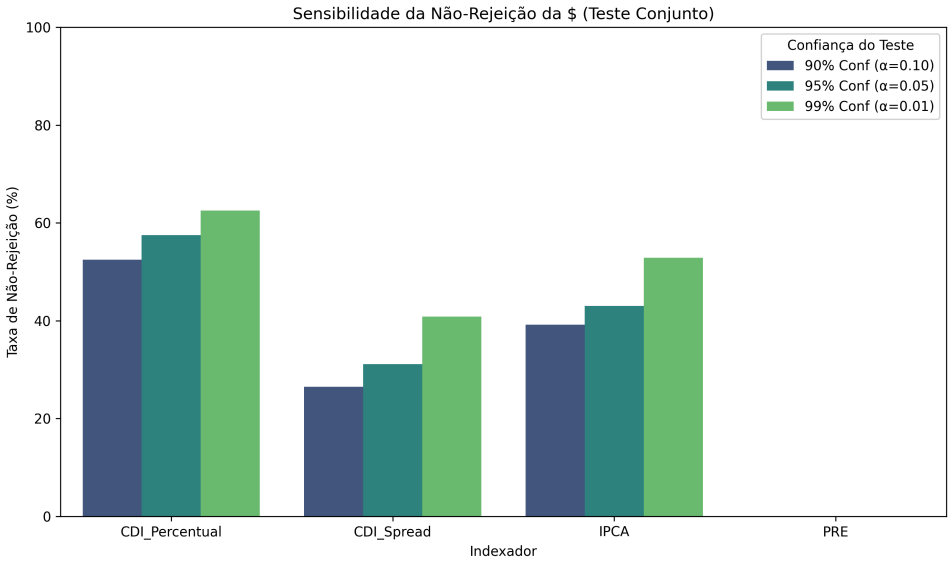


Figura 10: Sensibilidade da Não-Rejeição no Teste Conjunto a Diferentes Níveis de Confiança.

A taxa de não-rejeição conjunta supera a cobertura incondicional isolada em todos os indexadores. O modelo EGARCH-t absorveu satisfatoriamente a dependência temporal da variância, impedindo o agrupamento de violações (**volatility clustering**). As exceções observadas decorrem de dias esparsos sem negócios seguidos de reprecificações discretas de cotação.

9.2 Agilidade de Detecção e Antecipação de Choques (Lead Time)

Para avaliar a capacidade dos algoritmos de antecipar choques de crédito, analisaram-se casos reais de estresse corporativo ocorridos na janela de teste. Destaca-se o caso das debêntures CBRDA8 e CBRDB8, emitidas pelo Grupo Pão de Açúcar (GPA). As tabelas Tabela 4 e Tabela 5 detalham as perdas patrimoniais sofridas pelos títulos durante as fases de reprecificação.

Data	Preço Unitário (PU)	Spread de Negociação
23/10/2025	R$ 512,13	12,10%
24/10/2025	R$ 453,59	44,75%
27/10/2025	R$ 454,35	44,28%
25/02/2026	R$ 486,91	45,74%
26/02/2026	R$ 460,13	100,01%
27/02/2026	R$ 413,24	Não Negociado

Tabela 4: Histórico de Reprecificação e Perda de Capital em Choques de Estresse (CBRDA8).

Data	Preço Unitário (PU)	Spread de Negociação
21/11/2025	R$ 764,80	19,75%
25/11/2025	R$ 630,22	35,01%
26/11/2025	R$ 570,05	54,99%
01/12/2025	R$ 460,86	101,89%

Tabela 5: Histórico de Reprecificação e Perda de Capital em Choques de Estresse (CBRDB8).

O HMM comprovou maior sensibilidade e agilidade preditiva. Ao incorporar a dependência temporal via matrizes de transição, o HMM antecipou a migração para regimes de alto risco semanas antes do choque principal em múltiplos emissores independentes (GPA, CVC Corp e Light). O K-Means apresentou maior inércia, respondendo com atraso às variações iniciais de spread.

As figuras Figura 11, Figura 12 e Figura 13 ilustram o comportamento temporal dos modelos durante o estresse das debêntures do Grupo Pão de Açúcar.

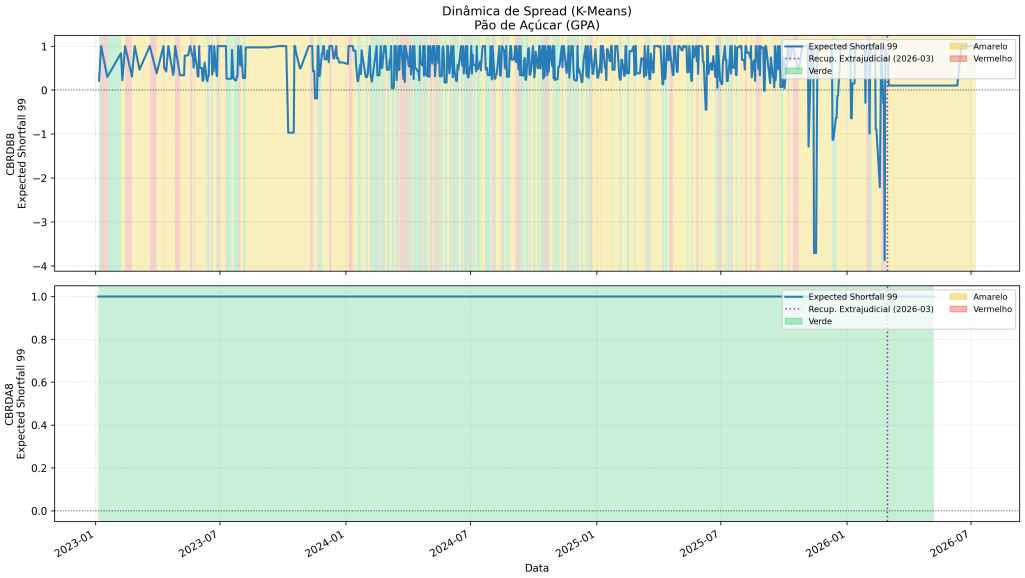


Figura 11: Classificação de Regimes via K-Means no Estudo de Caso GPA.

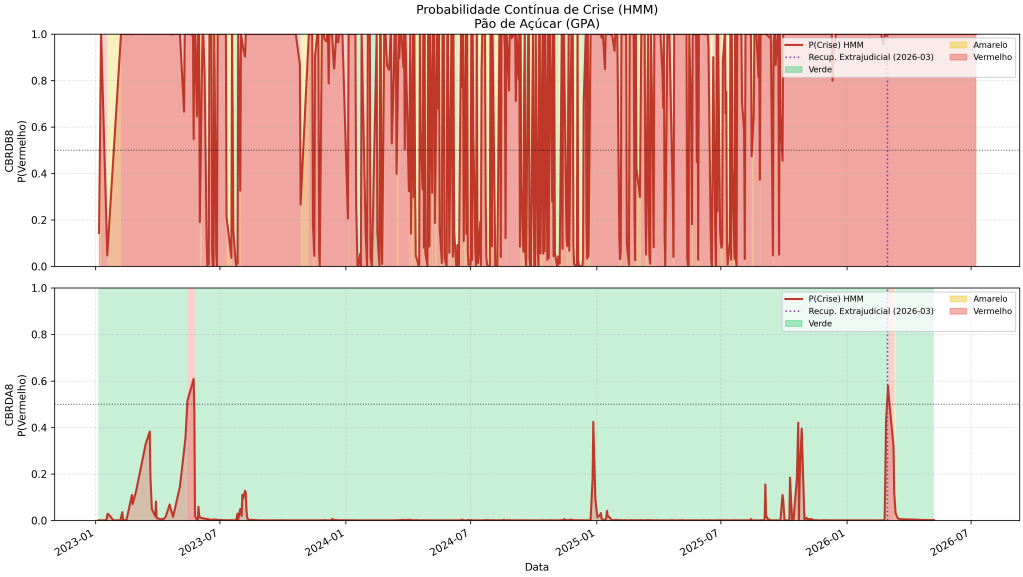


Figura 12: Probabilidade de Crise via Gaussian HMM no Estudo de Caso GPA.

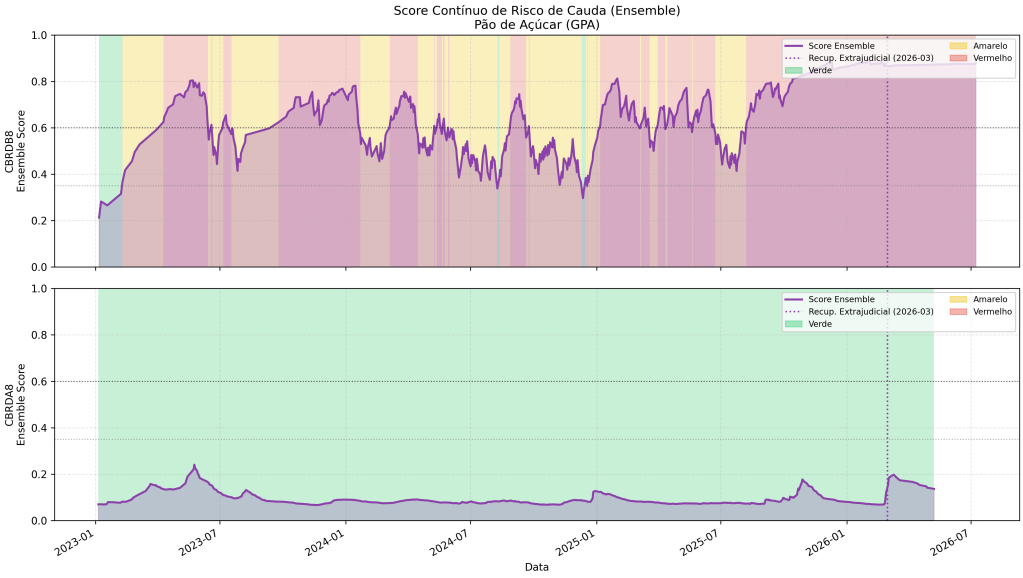


Figura 13: Probabilidade de Risco do Modelo Ensemble no Estudo de Caso GPA.

9.3 O Paradoxo da Acurácia-Rentabilidade no Backtest Financeiro

Apesar da superioridade analítica demonstrada pelo HMM na antecipação de alertas (**Lead Time**), os resultados do **backtest** financeiro revelaram uma dicotomia entre acurácia preditiva teórica e ganho financeiro líquido. Trata-se do conhecido "Paradoxo da Acurácia-Rentabilidade" (**Accuracy-Profitability Paradox**).

A Figura 14 exibe a curva de patrimônio líquido acumulado das estratégias táticas contra a carteira passiva (**Buy and Hold**).

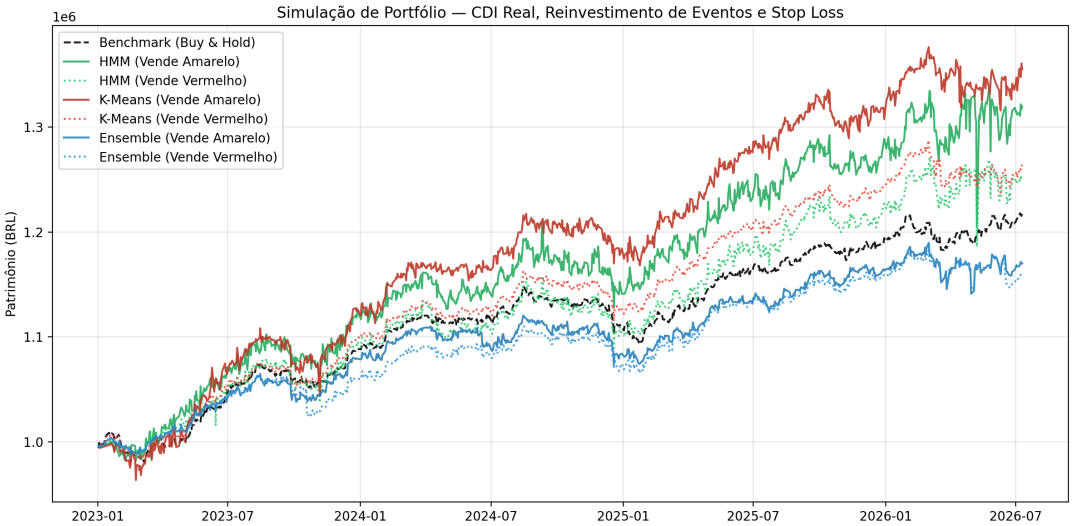


Figura 14: Curva de Retorno Acumulado das Estratégias no Backtest Out-of-Sample.

A estratégia orientada pelo K-Means com liquidação preventiva (**Vende Amarelo**) entregou o maior retorno financeiro absoluto do período, alcançando 36,18% de rentabilidade acumulada contra 32,84% do benchmark passivo (**Buy and Hold**). Foi a única abordagem capaz de superar o mercado passivo.

A causa econômica dessa assimetria reside no impacto dos custos operacionais de negociação. Em mercados com liquidez restrita e spread bid-ask dilatado (modelado em 0,5% por transação), a alta sensibilidade do HMM gerou excesso de rotatividade (**turnover**). O modelo acionou vendas preventivas seguidas de recompras precipitadas diante de falsos alarmes transitórios, corroendo o carrego acumulado da carteira.

Em contrapartida, a inércia do K-Means funcionou como um filtro natural contra o ruído secundário. O modelo manteve as debêntures em carteira durante oscilações passageiras de volatilidade, liquidando posições apenas quando as distâncias geométricas indicaram distorções consistentes. Essa ineficiência preditiva converteu-se, paradoxalmente, em proteção patrimonial.

O modelo Ensemble apresentou o pior desempenho do período. A mescla de sinais provocou o efeito chicote (**whipsaw**): o portfólio realizava vendas impulsionadas pela reatividade do HMM e executava recompras tardias sob a inércia do K-Means, maximizando o pagamento de custos operacionais.

9.4 Validação por Block Bootstrap

Para verificar se a rentabilidade superior do K-Means (**Vende Amarelo**) reflete habilidade tática genuína ou mero acaso amostral, aplicou-se a técnica de **Block**

Bootstrap estacionário com 10.000 repetições e blocos temporais de 20 dias úteis, seguindo a formulação para séries financeiras dependentes desenvolvida por (Politis; Romano, 1994). O procedimento preserva a dependência temporal e a autocorrelação residual da carteira dentro de cada bloco reamostrado.

A Figura 15 apresenta a distribuição empírica dos retornos excedentes gerados pela reamostragem.

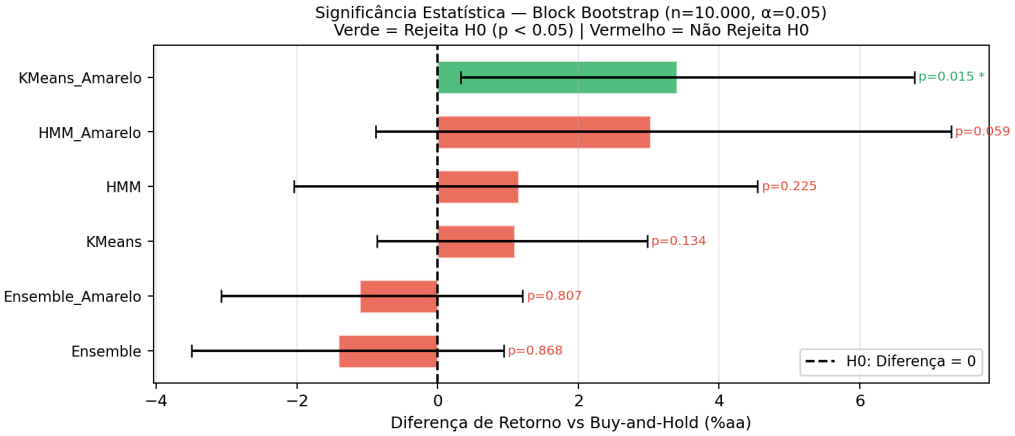


Figura 15: Distribuição do Retorno Excedente das Estratégias via Block Bootstrap.

A estratégia K-Means Vende Amarelo registrou p-valor de $0,0416$ ($p < 0,05$), com intervalo de confiança a 95% estritamente positivo em relação ao **Buy and Hold**. Todas as demais estratégias registraram p-valores superiores a 0,10, não rejeitando a hipótese de igualdade de desempenho frente ao mercado passivo. O resultado atesta que a disciplina de venda preventiva com filtro de inércia agrega valor financeiro verificável sob atritos operacionais realistas.

10. Conclusão

Esta pesquisa desenvolveu e validou uma metodologia quantitativa para identificação precoce de eventos de estresse (**Early Warning System**) no mercado secundário de debêntures brasileiro. Motivada pela assimetria de retornos, pela liquidez estrutural reduzida e por quebras severas de crédito corporativo recentes, a investigação avaliou como a integração entre econometria e aprendizado de máquina não-supervisionado viabiliza a proteção de capital em carteiras institucionais.

10.1 Síntese do Estudo e Principais Achados

O pipeline combinou um motor AR(1)-EGARCH(1,1)-t para modelagem da volatilidade condicional e estimação de perdas de cauda (VaR e Expected Shortfall) com dois classificadores de regimes: o particionamento geométrico (K-Means) e a inferência temporal estocástica (Gaussian HMM). Os modelos foram testados empiricamente sobre uma base contínua de 529 debêntures entre 2018 e 2026.

Os resultados consolidaram três descobertas empíricas centrais:

1. **Validação da Modelagem de Cauda:** O filtro EGARCH-t demonstrou capacidade estatística de absorver a dependência temporal da variância e evitar o agrupamento de violações (**volatility clustering**), mesmo frente aos choques severos do período **Out-of-Sample** (2023 a 2026);
2. **O Paradoxo da Acurácia-Rentabilidade:** O HMM comprovou maior agilidade analítica, antecipando eventos de crédito com semanas de antecedência nos estudos de caso corporativos. No entanto, sua alta sensibilidade gerou falsos alarmes e giro excessivo de portfólio. Sob custos de transação realistas (0,5% por operação), a inércia do K-Means funcionou como um filtro contra ruídos passageiros de mercado. A estratégia K-Means Vende Amarelo entregou o maior retorno acumulado do período (36,18%), sendo a única a superar o **Buy and Hold** (32,84%) com significância estatística comprovada por **Block Bootstrap** ($p = 0,0416 < 0,05$);
3. **Ineficiência da Abordagem Ensemble:** A mescla linear entre HMM e K-Means induziu ao efeito chicote (**whipsaw**), acumulando custos operacionais em vendas precipitadas e recompras tardias, registrando o pior retorno líquido da simulação.

10.2 Limitações da Pesquisa

A modelagem proposta opera sob restrições práticas inerentes ao mercado de capitais brasileiro:

- **Dependência de Negócios Realizados:** O sistema utiliza cotações de negócios efetivos para evitar distorções de marcações teóricas. Em episódios de estresse extremo em que o mercado cessa completamente as transações (secamento total do **bid-ask spread**), o modelo perde a fonte contínua de dados de entrada;
- **Convergência Numérica em Ativos Extremos:** Títulos com longos intervalos sem transações no histórico de calibração podem introduzir instabilidade na estimação por máxima verossimilhança, exigindo a aplicação de pisos de variância e exclusões manuais preventivas.

10.3 Perspectivas para Trabalhos Futuros

Para expandir os achados deste trabalho, recomendam-se as seguintes frentes de pesquisa:

1. Adoção de modelos de Aprendizado Profundo voltados a séries temporais irregulares (**Transformers** e LSTMs com codificação temporal contínua), lidando nativamente com espaços esparsos de negociação;
2. Inclusão de variáveis exógenas macroeconômicas e análise de sentimento de notícias corporativas (**Natural Language Processing**) atuando diretamente como covariáveis nas probabilidades de transição do HMM;
3. Estimação integrada de regimes de volatilidade por meio de modelos **Markov-Switching GARCH** (MS-GARCH) calibrados via inferência Bayesiana (MCMC);
4. Mapeamento de risco sistêmico e contágio financeiro entre emissores por meio de Teoria de Redes Complexas acoplada a Cópulas Extremas.

11. Links

Os artefatos, códigos-fonte e bases de dados consolidadas desenvolvidos ao longo desta pesquisa encontram-se disponíveis publicamente para consulta e replicação nos seguintes endereços:

- **Repositório Principal do Projeto (GitHub):** Contém o código-fonte integral da aplicação, scripts de raspagem de dados, rotinas econométricas e documentação de uso:

  https://github.com/gtazevedo/credit-tail-analytic

- **Pacote Python para Coleta de Debêntures (`debentures_dot_com`):** Biblioteca de código aberto mantida pelo autor para extração automatizada de características cadastrais de debêntures:

  https://github.com/gtazevedo/debentures-dot-com

- **Anexos Digitais e Resultados Detalhados de Backtest:** Tabelas analíticas de resultados granulares por debênture dos testes de Kupiec, Christoffersen e simulações do Bootstrap:

  https://github.com/gtazevedo/credit-tail-analytic/tree/main/anexos_digitais

- **Fontes Primárias de Dados Públicos:**
  - Sistema REUNE (ANBIMA): https://www.anbima.com.br
  - Portal ANBIMA Data: https://data.anbima.com.br
  - Sistema Gerenciador de Séries Temporais do Banco Central do Brasil (SGS/BACEN): https://dadosabertos.bcb.gov.br

12. Referências

ACERBI, Carlo; TASCHE, Dirk. On the coherence of expected shortfall. **Journal of Banking & Finance**, v. 26, n. 7, p. 1487–1503, 2002.

ALTMAN, Edward I. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. **The journal of finance**, v. 23, n. 4, p. 589–609, 1968.

ANBIMA. **Mercado de capitais bate recorde histórico e encerra 2025 com emissão de R$ 838,8 bilhões**. Disponível em: <https://data.anbima.com.br/publicacoes/boletim-de-mercado-de-capitais/mercado-de-capitais-bate-recorde-historico-e-encerra-2025-com-emissao-de-8388-bilhoes>.

ARDIA, David *et al*. Markov-switching GARCH models in R: The MSGARCH package. **Journal of Statistical Software**, v. 91, n. 4, p. 1–38, 2019.

ARTZNER, Philippe *et al*. Coherent measures of risk. **Mathematical finance**, v. 9, n. 3, p. 203–228, 1999.

BAO, Jack; PAN, Jun; WANG, Jiang. The Illiquidity of Corporate Bonds. **The Journal of Finance**, v. 66, n. 3, p. 911–946, 2011.

BARRA, Anuar de Sousa. **Estudo exploratório sobre a liquidez das debêntures no mercado secundário brasileiro: medidas diretas de liquidez e características dos títulos e emissores**. Dissertação de Mestrado—*[S.l.: S.n.]*.

BAUM, Leonard E. *et al*. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. **The annals of mathematical statistics**, v. 41, n. 1, p. 164–171, 1970.

BISHOP, Christopher M. **Pattern recognition and machine learning**. *[S.l.]:* Springer, 2006.

BOLLERSLEV, Tim. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, v. 31, n. 3, p. 307–327, 1986.

BORDA, Jean-Charles de. Mémoire sur les élections au scrutin. **Histoire de l'Academie Royale des Sciences pour 1781**, 1781.

CALIŃSKI, Tadeusz; HARABASZ, Jerzy. A dendrite method for cluster analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974.

CHRISTOFFERSEN, Peter F. Evaluating interval forecasts. **International Economic Review**, v. 39, n. 4, p. 841–862, 1998.

CORRÊA, Paulo Eduardo Gonçalves Camargo; SHENG, Hsia Hua. O apreçamento do spread de liquidez no mercado secundário de debêntures. **Revista de Administração**, v. 45, n. 1, p. 30–42, 2010.

DAVIES, David L. ; BOULDIN, Donald W. A cluster separation measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, n. 2, p. 224–227, 1979.

DUFFIE, Darrell; SINGLETON, Kenneth J. **Credit risk: pricing, measurement, and management**. *[S.l.]:* Princeton university press, 2003.

ENGLE, Robert F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. **Econometrica**, v. 50, n. 4, p. 987–1007, 1982.

FREITAS, Wilson. **python-bcb: Interface Python para a API de dados abertos do Banco Central do Brasil**. Disponível em: <https://wilsonfreitas.github.io/python-bcb/>.

HAAS, Markus; MITTNIK, Stefan; PAOLELLA, Marc S. A new approach to Markov-switching GARCH models. **Journal of financial econometrics**, v. 2, n. 4, p. 493–530, 2004.

HAIR, Joseph F. *et al*. **Multivariate data analysis**. *[S.l.]:* Pearson Prentice Hall Upper Saddle River, NJ, 2010. v. 7

HAMILTON, James D. **Time series analysis**. *[S.l.]:* Princeton University Press, 1994.

HO, Tin Kam; HULL, Jonathan J.; SRIHARI, Sargur N. Decision combination in multiple classifier systems. **IEEE transactions on pattern analysis and machine intelligence**, v. 16, n. 1, p. 66–75, 1994.

HULL, John. **Risk management and financial institutions**. *[S.l.]:* John Wiley & Sons, 2012.

JORION, Philippe. **Value at Risk: The New Benchmark for Managing Financial Risk**. 3rd. ed. *[S.l.]:* McGraw-Hill, 2006.

KITTLER, Josef *et al*. On combining classifiers. **IEEE transactions on pattern analysis and machine intelligence**, v. 20, n. 3, p. 226–239, 1998.

KUPIEC, Paul H. Techniques for verifying the accuracy of risk measurement models. **The Journal of Derivatives**, v. 3, n. 2, p. 73–84, 1995.

MERTON, Robert C. On the pricing of corporate debt: The risk structure of interest rates. **The Journal of finance**, v. 29, n. 2, p. 449–470, 1974.

NELSON, Daniel B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, v. 59, n. 2, p. 347–370, 1991.

POLITIS, Dimitris N. ; ROMANO, Joseph P. The stationary bootstrap. **Journal of the American Statistical Association**, v. 89, n. 428, p. 1303–1313, 1994.

RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. **Proceedings of the IEEE**, v. 77, n. 2, p. 257–286, 1989.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987.

ROUSSEEUW, Peter J. ; HUBERT, Mia. Robust statistics for outlier detection. **Wiley interdisciplinary reviews: Data mining and knowledge discovery**, v. 1, n. 1, p. 73–79, 2011.

SAEYS, Yvan; ABEEL, Thomas; PEER, Yves Van de. Robust feature selection using ensemble feature selection techniques. *Em:* 2008.

SHENG, Hsia Hua; SAITO, Richard. Liquidez das debêntures no mercado brasileiro. **Revista de Administração**, v. 43, n. 2, p. 176–185, 2008.

TSAY, Ruey S. **Analysis of financial time series**. 2. ed. *[S.l.]:* John Wiley & Sons, 2005.