PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação Lato Sensu em Estatística para Ciências de Dados

Guilherme Tolotti Azevedo

MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉDITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T E MODELOS OCULTOS DE MARKOV

Belo Horizonte
Outubro de 2026

Guilherme Tolotti Azevedo

MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉDITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T E MODELOS OCULTOS DE MARKOV

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Estatística para Ciências de Dados, como requisito parcial à obtenção do título de Especialista.

Belo Horizonte
Outubro de 2026

SUMÁRIO

1. Introdução 4
2. Descrição do Problema e da Solução Proposta 6
3. Canvas Analítico 9
4. Coleta de Dados 10
5. Processamento/Tratamento de Dados 13
6. Análise e Exploração dos Dados 18
7. Aplicação de Modelos 25
8. Automatização do Pipeline de Dados 33
8.1 Definição da Ferramenta de Orquestração de Pipeline do Fluxo de Trabalho 33
8.2 Modelo do Fluxo de Trabalho 33
8.3 Códigos/telas 35
9. Discussão dos Resultados 38
10. Conclusão 49
11. Links 51
12. Referências 52

1. Introdução

A Estatística para Ciência de Dados estabelece o arcabouço analítico para orientar deliberações objetivas em ambientes de incerteza quantitativa. No mercado de capitais, foco desta pesquisa, a modelagem baseada em dados fornece estimativas probabilísticas verificáveis para a precificação de ativos e o gerenciamento de risco de crédito corporativo, conforme sistematizado por Hull (2012).

A modelagem quantitativa contemporânea dispõe de diferentes paradigmas para séries temporais financeiras. De um lado, as abordagens estatísticas e econométricas clássicas fornecem fundamentação analítica rigorosa para a heterocedasticidade condicional e distribuições com caudas pesadas, porém com parâmetros frequentemente estáticos frente a quebras estruturais. De outro lado, modelos modernos de Aprendizado Profundo (*Deep Learning*), como redes neurais recorrentes (LSTM) e *Transformers*, destacam-se pela capacidade de aprender relações sequenciais altamente não lineares, mas demandam séries densas, contínuas e amplo volume amostral para evitar sobreajuste (*overfitting*). No mercado secundário de crédito corporativo brasileiro, a escassez de negociações diárias e a descontinuidade temporal dificultam o treinamento estável de arquiteturas de *Deep Learning*. Nesse contexto de dados esparsos e fragmentados, a integração entre modelos econométricos clássicos de séries temporais (como o EGARCH com inovações t-Student) e algoritmos não supervisionados de Aprendizado de Máquina (como K-Means e Modelos Ocultos de Markov) viabiliza a extração de regimes latentes de risco preservando a estabilidade numérica, a interpretabilidade teórica e a parcimônia paramétrica.

O objetivo deste trabalho é aplicar a combinação desses modelos para analisar a dinâmica dos regimes de risco de crédito no mercado secundário de debêntures brasileiro, segmento que cresce continuamente e consolida-se como uma das principais vias de captação de recursos para as empresas (ANBIMA, 2026). Dentre os instrumentos emitidos, as debêntures registraram uma expansão de 307% entre 2020 e 2025. Entretanto, esse mercado enfrenta restrições crônicas de liquidez e, conforme Sheng; Saito (2008), apresenta as seguintes características:

- As transações são dispersas e ocorrem em duas diferentes instituições: Bolsa de Valores de São Paulo (Bovespa Fix) e Sistema Nacional de Debêntures (SND);
- Existe baixa atividade, não havendo registro de transações para períodos longos e, em algumas emissões de debêntures, o volume de transações no mercado secundário é quase nulo e o valor total em reais é baixo;

- Existe um baixo número de negociações diárias;
- Predominância de debêntures de médio prazo (vencimento em torno de quatro anos);
- Demanda significativa por investidores institucionais e fundos de pensão;
- Em geral as emissões não são conversíveis em ações;
- Alguns investidores adquirem debêntures e as mantêm até o vencimento;

Observa-se que parte dessas características estruturais permanece verificável na prática de mercado, destacando-se a liquidez reduzida (na qual mais da metade das marcações diárias compreende volumes inferiores a R$ 1 milhão) e a exclusividade de emissões simples. Adicionalmente, a baixa presença de pessoas físicas e de investidores não residentes, bem como a manutenção dos títulos em carteira própria pelos intermediários até a data de resgate, são corroboradas por estudos recentes como Barra (2021) e ANBIMA (2026). Em contrapartida, constata-se uma alteração estrutural em relação ao diagnóstico de Sheng; Saito (2008) que reflete amadurecimento institucional: as empresas têm conseguido alongar o perfil de suas dívidas, uma vez que a amostra selecionada neste estudo exibe mediana de sete anos de prazo até o vencimento.

Com prazos estendidos e liquidez de suporte reduzida, a combinação entre a modelagem econométrica de volatilidade condicional e métodos de aprendizado de máquina não supervisionado possibilita antecipar transições de regimes de crédito antes que as perdas financeiras sejam materializadas, auxiliando na manutenção do desempenho e na preservação patrimonial da carteira.

2. Descrição do Problema e da Solução Proposta

2.1 O Problema de Pesquisa

A modelagem do risco de crédito corporativo desenvolveu-se historicamente por meio de abordagens contábeis, estruturais e de forma reduzida. A literatura pioneira introduziu escores lineares baseados em indicadores contábeis, como o Z-Score de Altman (1968), utilizado para prever insolvência. Subsequentemente, avançou-se para abordagens fundamentadas em modelos estruturais de crédito, como Merton (1974). Contudo, essas abordagens tradicionais, assentadas em balanços divulgados em periodicidade trimestral ou anual, mostram-se inadequadas para sistemas de alerta em tempo real em razão da defasagem temporal inerente à publicação dos demonstrativos contábeis.

Para superar a dependência de demonstrações financeiras, surgiram os modelos de forma reduzida, conforme consolidado por Duffie; Singleton (2003), que modelam o risco de crédito diretamente por meio de dados de mercado. Apesar de mitigarem a defasagem da informação contábil, tais formulações pressupõem mercados líquidos, dependendo da regularidade das negociações observadas. No mercado de debêntures brasileiro, no qual se observa liquidez reduzida e baixa frequência de negociações, essa abordagem se mostra frágil.

Conforme aponta Corrêa; Sheng (2010), o prêmio de liquidez responde por parcela expressiva do spread das debêntures, sobrepondo-se com frequência ao risco de inadimplência. Mercados corporativos concentram fricções operacionais que dificultam o ajuste contínuo dos preços e induzem descontinuidades e saltos nas cotações, frequentemente acompanhados de períodos de iliquidez, conforme demonstrado por Bao; Pan; Wang (2011) e evidenciado por episódios recentes no mercado brasileiro. O pedido de recuperação judicial das Lojas Americanas culminou em uma desvalorização de 50% no preço unitário de suas debêntures em um único pregão, acumulando perdas de 90% em uma semana. No caso do Grupo Pão de Açúcar, foram observados deságios de até 70% nas negociações secundárias. Emissões da Light sofreram reprecificações abruptas similares durante o processo de recuperação judicial.

Práticas tradicionais de tesouraria apresentam limitações operacionais nessas condições, porque bancos e gestoras de recursos frequentemente calculam o Valor em Risco (VaR) e modelos GARCH simétricos sob a hipótese de normalidade e liquidez plena de saída. Conforme aponta Jorion (2006), esses métodos assumem que o investidor consegue liquidar posições instantaneamente ao preço cotado em tela. Em momentos de *stress*, é comum observar expressiva contração da liquidez dos ativos, dificultando a liquidação tempestiva de posições ou demandando elevados deságios para sua execução.

Outra limitação teórica da família GARCH tradicional, como explica Tsay (2005), reside no pressuposto de que os parâmetros da equação de variância e a volatilidade incondicional permanecem estáticos ao longo do tempo. Esses modelos operam ancorados em uma única média global da série histórica, porém, quando ocorrem quebras estruturais ou eventos de crédito atípicos, essas médias sofrem deslocamento. A literatura econométrica, fundamentada por Hamilton (1994), demonstra que séries temporais financeiras longas sofrem quebras estruturais que exigem formulações baseadas em mudanças de regime (*Regime-Switching*). Sob essa teoria, os mercados transitam entre diferentes estados latentes, alterando a própria dinâmica estocástica dos preços; propostas como as de Haas; Mittnik; Paolella (2004) e Ardia et al. (2019) buscam incorporar essas quebras na modelagem.

O problema investigado compreende a modelagem estatística de séries temporais financeiras acoplada ao agrupamento não supervisionado de regimes de risco latentes, com a finalidade de emitir sinais de alerta antecipado (*Early Warning*) sobre a possibilidade de perdas acentuadas antes de sua materialização, visando à preservação patrimonial do investidor.

2.2 Objetivos

O objetivo geral deste trabalho consiste em desenvolver e avaliar uma metodologia quantitativa de alerta antecipado para o mercado secundário de debêntures brasileiro, identificando transições latentes de regime para antecipar choques de crédito e mitigar perdas patrimoniais.

Para atingir a proposta central, definem-se os seguintes objetivos específicos:

1. Normalizar o prêmio de risco dos ativos mitigando distorções de prazo por meio da taxa ajustada ao vencimento, contornando a exigência de curvas de juros soberanas completas;

2. Modelar a heterocedasticidade condicional e a assimetria das séries temporais de spread por meio de um motor econométrico AR(1)-EGARCH(1,1) com inovações t--Student;
3. Implementar e comparar dois métodos de agrupamento de regimes de risco: o algoritmo K-Means, adotado como linha de base geométrica e atemporal, e o Modelo Oculto de Markov (HMM Gaussiano), responsável por incorporar a dependência temporal nas transições;
4. Validar o motor econométrico de cauda por meio dos testes de hipótese de Kupiec POF e Christoffersen sobre o período fora da amostra;
5. Simular estratégias táticas de liquidação de portfólio em um ambiente de *backtest* financeiro realista, submetido a custos de transação de 0,5% e validado estatisticamente pela técnica de *Block Bootstrap*.

2.3 Solução Proposta

A solução desenvolvida apoia-se em uma arquitetura híbrida de duas camadas operacionais, na qual a primeira camada executa o saneamento econométrico dos dados de negociação da ANBIMA, eliminando ruídos causados por dias sem negócios e estimando a variância condicional e o risco de cauda com o motor EGARCH-t. A segunda camada consome as métricas tratadas e alimenta algoritmos de agrupamento não supervisionado.

Esses algoritmos particionam o espaço de estados latentes em três estados objetivos: Verde (baixo risco), Amarelo (alerta) e Vermelho (crise), o que viabiliza a emissão de alertas antecipados para a liquidação defensiva das posições antes da consolidação do choque financeiro.

3. Canvas Analítico

Apresenta-se o Canvas Analítico do projeto, estruturado em doze blocos estratégicos que sintetizam a formulação do problema, as bases de dados, as técnicas estatísticas aplicadas e os resultados esperados.

1. Problema de Negócio

Iliquidez crônica e assimetria de retornos no mercado secundário de debêntures. Modelos tradicionais de risco (GARCH contínuo e VaR paramétrico) falham diante de saltos discretos e elevados deságios em eventos de cauda.

2. Objetivo Analítico

Classificar regimes latentes de risco de crédito (Verde, Amarelo e Vermelho) e antecipar choques patrimoniais por meio de aprendizado de máquina não supervisionado com modelagem temporal.

3. Justificativa

Atrasos na detecção de deterioração de crédito inviabilizam o desinvestimento em mercados ilíquidos. Alertas antecipados protegem o capital antes da materialização definitiva do evento.

4. Stakeholders

Gestores de fundos de crédito privado, analistas de risco corporativo, comitês de alocação de ativos e tesourarias institucionais.

5. Variável-alvo (Target)

Regime latente de risco de crédito do ativo: Verde (Baixo Risco), Amarelo (Alerta) e Vermelho (Crise).

6. Variáveis de Entrada

Delta Spread diário, Taxa ajustada ao prazo ($\frac{S_t}{\ln(\mathrm{DU})}$), Volatilidade condicional EGARCH-t, Expected Shortfall (99%) e Z-Score móvel de 60 dias.

7. Fontes de Dados

Prévias públicas de negociação do sistema REUNE da ANBIMA, dados cadastrais via portal Debentures.com.br e séries macroeconômicas (CDI e IPCA) obtidas do Banco Central do Brasil por meio do pacote `python-bcb`.

8. Técnicas Estatísticas / ML

AR(1)-EGARCH(1,1)-t para volatilidade assimétrica; K-Means com agregação Borda Count; Gaussian HMM com regularização de Laplace e algoritmo de Viterbi; Ensemble ponderado.

9. Métricas de Avaliação

Acurácia estatística: Testes de Kupiec POF e Christoffersen. Eficácia tática: Lead Time de antecipação em dias úteis, Retorno Acumulado líquido de custos e p-valor por Block Bootstrap.

10. Entregáveis

Pacote Python modular (`credit_tail_analytics`), pipeline de dados automatizado, base histórica tratada, relatórios analíticos de backtest e repositório de código aberto.

11. Impacto Esperado

Mitigação de perdas acentuadas em eventos de estresse corporativo, contenção de custos de transação pelo filtro de ruído e superação estatisticamente comprovada do carrego passivo (Buy and Hold).

12. Restrições e Riscos

Escassez de negociações diárias na maioria dos ativos, principalmente em períodos de estresse, custos operacionais de giro (50 bps) e instabilidade de estados (flickering).

4. Coleta de Dados

A modelagem de risco em ativos de crédito privado exige dados de negociação transparentes e livres de estimativas puramente teóricas. Para construir a base empírica desta pesquisa, foram integradas três fontes primárias de informação pública: os registros diários de transações do mercado secundário, as características cadastrais de cada instrumento emitido e as séries históricas macroeconômicas de taxas de juros e inflação.

Os dados transacionais de negociação foram extraídos da plataforma da Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais (ANBIMA), a partir do sistema REUNE (Prévias Públicas de Negociação de Instrumentos Financeiros). A série histórica compreende o intervalo contínuo entre 2 de janeiro de 2018 e 10 de julho de 2026, totalizando 2.112 dias úteis de negociações. As rotinas automatizadas de raspagem (*web scraping*) e os módulos de unificação dos arquivos diários encontram-se disponíveis no repositório público do projeto.

As características cadastrais das debêntures foram obtidas por meio de consultas programáticas ao portal Debentures.com.br e ao ANBIMA Data, utilizando o pacote `debentures_dot_com` (de autoria própria). Essa base contém atributos estruturais de cada título, como código do emissor, data de emissão, data de repactuação, data de vencimento final, indexador contratual, tipo de garantia e volume total emitido.

As séries macroeconômicas de referência (taxa DI diária, taxa Selic e índices de inflação IPCA e IGP-M) foram coletadas diretamente do Sistema Gerenciador de Séries Temporais (SGS) do Banco Central do Brasil, utilizando o pacote `python-bcb` (Freitas, 2024). O cruzamento entre os registros de negociação e os dados macroeconômicos viabilizou computar uma aproximação dos prêmios de risco e das variações de spread.

4.1 Dicionário de Dados

A base consolidada resultante unifica os registros de negociação, cadastrais e macroeconômicos. A Tabela 1 descreve os principais atributos utilizados nas etapas de saneamento e modelagem.

Nome do dataset: Base Consolidada de Negociação de Debêntures e Séries Macroeconômicas
Descrição: Unificação dos registros diários de negócios secundários (ANBIMA REUNE), dados cadastrais estruturais (portal Debentures.com.br) e indicadores macroeconômicos diários do Banco Central do Brasil (SGS/BACEN).
Link: https://github.com/gtazevedo/credit-tail-analytic

Nome do Atributo	Descrição	Tipo
`data`	Data de referência do pregão de negociação	Date
`ticker`	Código de negociação do ativo na CETIP/B3 (ex.: CBRDA8)	String
`taxa_min`	Menor taxa anual de spread negociada no dia para o ativo	Float
`taxa_med`	Taxa média ponderada anual negociada no pregão	Float
`taxa_max`	Maior taxa anual de spread negociada no dia para o ativo	Float
`pu_min`	Menor preço unitário praticado na sessão de negócios	Float
`pu_med`	Preço unitário médio observado no dia	Float
`pu_max`	Maior preço unitário praticado na sessão de negócios	Float
`faixa_volume`	Classificação de liquidez ANBIMA (Faixas 1, 2 e 3)	String
`indexador`	Indexador contratual da emissão (DI+, IPCA+, Pré)	String
`du_vencimento`	Dias úteis restantes até a data de vencimento do título	Integer
`cdi_anual`	Taxa média diária anualizada do CDI divulgada pelo BACEN	Float
`delta_spread`	Primeira diferença do spread de crédito diário	Float
`taxa_prazo`	Spread anualizado ajustado pelo logaritmo do prazo útil	Float

Tabela 1: Dicionário de Atributos da Base Consolidada de Negociação de Debêntures.

4.2 Análise pela Técnica dos 5-Ws

Para sintetizar as informações apresentadas sobre os dados, elaborou-se um resumo considerando a metodologia dos 5-Ws:

- **(*Why?*) Por que os dados são importantes:** As cotações de negócios efetivos refletem o prêmio de risco real exigido pelo mercado. Afastam premissas teóricas de continuidade de preços que não se sustentam em ativos ilíquidos, expondo os momentos exatos em que ocorrem elevados deságios.
- **(*Who?*) Qual a origem dos dados:** Informações públicas auditadas e divulgadas pela ANBIMA (sistema REUNE), portal Debentures.com.br e Banco Central do Brasil.
- **(*What?*) O que é analisado:** Preços unitários, taxas de spread negociadas, prazos até o vencimento e volumes negociados de debêntures corporativas, confrontados com as taxas livres de risco da economia.
- **(*Where?*) Qual a cobertura geográfica:** Mercado financeiro doméstico brasileiro, contemplando emissores de dívida corporativa atuantes no território nacional.
- **(*When?*) Qual o período analisado:** Intervalo contínuo entre janeiro de 2018 e julho de 2026. Esta janela foi dividida em duas etapas metodológicas: período de treinamento (*In-Sample*, 2018 a 2022) e período de validação e teste (*Out-of-Sample*, 2023 a 2026).

5. Processamento/Tratamento de Dados

O tratamento dos dados de negociação mitiga distorções decorrentes da baixa liquidez, descontinuidades temporais observadas nas séries obtidas e utilização de diferentes indexadores. Para sanar esta necessidade, a massa de dados bruta passou por etapas sequenciais de filtragem de liquidez, harmonização de taxas contratuais, engenharia de atributos, tratamento de valores discrepantes (*outliers*) e escalonamento geométrico.

5.1 Divisão Temporal e Filtro de Iliquidez

Os registros foram particionados em dois intervalos cronológicos disjuntos:

- Período de Treinamento (*In-Sample*): De 2 de janeiro de 2018 a 30 de dezembro de 2022. Esta janela serviu para calibrar os parâmetros dos modelos GARCH, selecionar os subconjuntos de variáveis e determinar as matrizes de transição dos regimes;
- Período de Teste e Validação (*Out-of-Sample*): De 2 de janeiro de 2023 a 10 de julho de 2026. Esta janela serviu para executar o teste de antecipação (*Early Warning*) e simular as estratégias de investimento sob condições reais de mercado.

A iliquidez observada no mercado secundário de debêntures impõe extensos intervalos sem negociação, porém, o sistema REUNE/ANBIMA se limita a estratificar o volume diário negociado em 3 faixas ordinais, classificando a Faixa 3 como “Até 1MM”. Para os fins desta modelagem, visando mitigar vieses decorrentes de extensos períodos sem negociação, os títulos com concentração quase absoluta nessa faixa foram delimitados como cronicamente ilíquidos. Para isso, desenvolveu-se uma rotina algorítmica de tratamento que, quando habilitada, remove da base de dados para treinamento (posteriormente detalhada em Seção 5.2) os ativos que permaneceram como ilíquidos durante um período igual ou superior a 95% da amostra. O propósito dessa funcionalidade é impedir que, caso sejam observados eventos de variação de *spread* espúrios devido à baixa liquidez, eles sejam propagados para o modelo EGARCH, o que poderia corromper a estimação da persistência e dos choques (parâmetros α e β) da variância condicional. Esses títulos foram excluídos exclusivamente da amostra de calibração, à exceção do ativo RDVT11, removido integralmente de toda a base. Isso ocorreu devido ao fato de que o título não possuía cotações no período de treinamento e apresentou

variações extremas e esparsas (negociado a PU 1.001,77 em dezembro de 2023, recuando para 1,40 e 0,000014 em março de 2024 antes de retornar a 754,31 em 2025), refletindo a recuperação judicial e a reestruturação societária do emissor.

5.2 Harmonização de Taxas e Engenharia de Atributos

A base abrange três categorias contratuais de remuneração: debêntures indexadas a percentual do CDI, debêntures atreladas ao CDI acrescidas de spread e debêntures indexadas a índices de preços (IPCA+). Cada contrato exige tratamento específico para isolar o prêmio de risco de crédito.

Para os ativos emitidos a um percentual do CDI (ex.: 120% do DI), realizou-se uma conversão explícita baseada na taxa CDI diária apurada pelo Banco Central, isolando o prêmio excedente sobre a taxa livre de risco:

$$F_{\text{cdi}} = \left(1 + \frac{\text{CDI}_t}{100}\right)^{\frac{1}{252}} \tag{1}$$

$$F_{\text{titulo}} = (F_{\text{cdi}} - 1) \times \left(\frac{\text{Taxa do Ativo}_t}{100}\right) + 1 \tag{2}$$

$$S_t = \left((F_{\text{titulo}})^{252} - 1\right) \times 100 - \text{CDI}_t \tag{3}$$

Nos contratos atrelados a inflação (IPCA+) ou sobretaxa direta sobre o DI (DI+), o spread bruto informado pelo mercado secundário já expressa diretamente o prêmio de crédito: $S_t = \text{Taxa do Ativo}_t$.

A partir dos spreads homogêneos, derivou-se um conjunto de variáveis preditivas voltadas à captura de choques temporais e de dispersão intra-diária. A dinâmica de curto prazo foi representada pela variação diária do spread (ΔS_t), que serve de entrada ao motor de volatilidade condicional:

$$\Delta S_t = S_t - S_{t-1} \tag{4}$$

Diante da ausência de dados uniformes de duration modificada para a totalidade dos ativos transacionados, mitigou-se a sensibilidade temporal deflacionando o spread pelo logaritmo do prazo remanescente até o vencimento:

$$\text{Taxa}_{\text{prazo}} = \frac{S_t}{\ln(\max(\text{DU}, 2))} \tag{5}$$

Adicionalmente, computou-se o Z-Score causal do spread em janela móvel de 60 dias úteis, parametrizando a distância da taxa observada em relação à média e ao desvio-padrão históricos do próprio ativo.

Além disso, a dispersão das cotações na sessão foi sintetizada por meio da amplitude intraday (S_{range}) e da assimetria relativa dos negócios (S_{skew}):

$$S_{\text{range}} = \text{Taxa}_{\text{max}} - \text{Taxa}_{\text{min}} \tag{6}$$

$$S_{\text{skew}} = \frac{\text{Taxa}_{\text{med}} - \text{Taxa}_{\text{min}}}{S_{\text{range}} + \varepsilon} \tag{7}$$

adotando-se $\varepsilon = 10^{-6}$ para blindar o cálculo contra indeterminações divisionais em dias de cotação estática.

5.3 Tratamento de Discrepâncias e Normalização

A contenção de valores anômalos e ruídos operacionais adotou winsorização bilateral restrita aos percentis 1% e 99%, parametrizada exclusivamente sobre o subconjunto *In-Sample* e subsequentemente mantida para aplicação aos dados *Out-of-Sample*, salvaguardando a metodologia contra vazamento de informação retrospectiva (*look-ahead bias*).

Para o escalonamento das features, optou-se pelo estimador robusto de Rousseeuw; Hubert (2011) (`RobustScaler`), que centraliza os dados na mediana e utiliza o intervalo interquartil ($\text{IQR} = Q_3 - Q_1$), de forma a prevenir que debêntures com aberturas bruscas de taxa comprimam artificialmente a escala dos demais instrumentos. Também foi utilizado um limiar mínimo de dispersão equivalente a 10% do IQR mediano de cada classe de indexador, evitando divisões por zero em ativos com baixa volatilidade.

5.4 Implementação em Código-Fonte

A arquitetura dessa etapa concentra-se no módulo `src/credit_tail_analytics/models/credit_risk/preprocessor.py`, no qual a classe `DataPreprocessor` consolida as rotinas de limpeza, separação contábil de indexadores e transformação das séries:

```
import numpy as np
import pandas as pd
from typing import Dict

class DataPreprocessor:
    """Higienização, harmonização de taxas e engenharia de atributos."""

    def __init__(self, filter_low_liquidity: bool = True, split_date: str =
```

```
'2023-01-01'):
        self.filter_low_liquidity = filter_low_liquidity
        self.split_date = pd.to_datetime(split_date)

    def process(self, df: pd.DataFrame) -> pd.DataFrame:
        df = df.copy()
        # Expulsa ativos com falhas crônicas de marcação (ex.: reorganização
judicial)
        if 'Ticker' in df.columns:
            df = df[df['Ticker'] != 'RDVT11'].copy()

        df['Data'] = pd.to_datetime(df['Data'])
        df.sort_values(by=['Ticker', 'Data'], inplace=True)

        # 1. Reclassificação de indexador via médias estritamente In-Sample (sem
look-ahead bias)
        mask_is = df['Data'] < self.split_date
        medias_is = df[mask_is].groupby('Ticker')['Taxa_Ativo'].mean()
        medias_full = df.groupby('Ticker')['Taxa_Ativo'].transform('mean')
        medias_taxa = df['Ticker'].map(medias_is).fillna(medias_full)

        is_di = df['Indexador'].str.upper() == 'DI'
        df.loc[is_di & (medias_taxa > 30), 'Indexador'] = 'DI_Percentual'
        df.loc[is_di & (medias_taxa <= 30), 'Indexador'] = 'DI_Spread'

        # 2. Spread equivalente: capitalização composta para DI% e spread direto
para IPCA/DI+
        taxa, cdi = df['Taxa_Ativo'], df['CDI_Anual']
        fator_cdi = (1 + cdi / 100.0) ** (1 / 252)
        fator_tit = (fator_cdi - 1) * (taxa / 100.0) + 1
        spread_pct = ((fator_tit ** 252) - 1) * 100.0 - cdi

        is_pct = df['Indexador'].str.upper() == 'DI_PERCENTUAL'
        is_puro = df['Indexador'].str.upper().isin(['DI_SPREAD', 'IPCA', 'IGPM'])
        df['Spread_Equivalente'] = np.where(is_pct, spread_pct, np.where(is_puro,
taxa, taxa - cdi))

        # 3. Taxa ajustada ao prazo e Delta Spread
        df['Taxa_Ajustada_Prazo'] = df['Spread_Equivalente'] /
np.log(np.maximum(df['DU_Vencimento'], 2))
        df['Delta_Spread'] = df.groupby('Ticker')['Spread_Equivalente'].diff()

        # 4. Z-Score com janela móvel de 60 dias úteis
        roll = df.groupby('Ticker')['Spread_Equivalente'].rolling(window=60,
min_periods=10)
        m = roll.mean().reset_index(level=0, drop=True)
        s = roll.std().reset_index(level=0, drop=True).replace(0, np.nan)
        df['Taxa_ZScore'] = ((df['Spread_Equivalente'] - m) / s).fillna(0.0)

        # 5. Métricas de microestrutura intraday (Range e Skew)
```

```
        df['Spread_Range_Intraday'] = df['Taxa_Maxima'] - df['Taxa_Minima']
        df['Spread_Skew_Intraday'] = (df['Taxa_Ativo'] - df['Taxa_Minima']) /
(df['Spread_Range_Intraday'] + 1e-6)

        # 6. Remoção de ativos ilíquidos (>= 95% do In-Sample na Faixa 3)
        if self.filter_low_liquidity:
            df_is = df[df['Data'] < self.split_date]
            mask_faixa3 = df_is['Faixa_Volume_ANBIMA'] == 'Até 1MM'
            taxa_iliq = mask_faixa3.groupby(df_is['Ticker']).mean()
            banidos = taxa_iliq[taxa_iliq >= 0.95].index
            df = df[~df['Ticker'].isin(banidos)].reset_index(drop=True)

        return df
```

6. Análise e Exploração dos Dados

A análise exploratória avaliou o comportamento empírico dos spreads e testou premissas estatísticas necessárias para fundamentar a modelagem econométrica. Essa investigação revelou a estrutura das séries, orientou o diagnóstico de estacionariedade e definiu o subconjunto ideal de variáveis para os algoritmos de agrupamento.

6.1 Propriedades Estatísticas e Diagnóstico de Cauda

As séries históricas de retornos de spread exibem desvios acentuados em relação à normalidade. No período *In-Sample*, calculou-se o excesso de curtose sobre as variações dos spreads diários. Constatou-se que os retornos apresentaram excesso de curtose de $2.683,30$, indicando eventos extremos e caudas pesadas que inviabilizariam o pressuposto de normalidade gaussiana. Todavia, a variável padronizada `Taxa_ZScore`, resultante do filtro estocástico do EGARCH-t, reduziu o excesso de curtose para $1,18$.

A Tabela 2 consolida as principais estatísticas descritivas das variáveis que compõem o espaço de estados para o agrupamento de regimes durante o período de treinamento (*In-Sample*, 2018 a 2022).

Variável	Média	Desv. Padrão	Mediana	Q1 (25%)	Q3 (75%)	Assimetria	Exc. Curtose
`Taxa_ZScore`	0,114	1,241	0,000	−0,743	0,905	0,45	1,18
`Volatilidade_EGARCH`	14,329	162,051	0,299	0,200	0,466	22,87	750,45
`Expected_Shortfall_99`	0,406	11,720	0,966	0,583	1,000	−52,42	3.477,60

Tabela 2: Estatísticas Descritivas das Variáveis Selecionadas no Período In-Sample (2018 a 2022).

A discrepância entre as médias e medianas nas variáveis brutas de volatilidade e cauda evidencia a acentuada assimetria provocada por choques raros de repreficação. Em contrapartida, a variável padronizada `Taxa_ZScore` apresenta excesso de curtose moderado $(1,18)$, situado no intervalo $[-2,+2]$ preconizado por Hair et al. (2010) para premissas de normalidade assintótica. Consequentemente, o espaço latente do HMM passa a operar em um domínio no qual o impacto de eventos extremos é atenuado, assegurando estabilidade numérica na convergência das matrizes gaussianas.

6.2 Teste de Estacionariedade dos Spreads (ADF)

A modelagem de volatilidade condicional pressupõe que as séries temporais analisadas sejam estacionárias em covariância. Para verificar essa hipótese nos 529 ativos selecionados, aplicou-se o Teste de Dickey-Fuller Aumentado (ADF). O teste avalia formalmente as seguintes hipóteses:

- Hipótese Nula (H_0): A série temporal possui raiz unitária (não-estacionária);
- Hipótese Alternativa (H_1): A série temporal é estacionária em covariância.

A especificação adotou modelo com termo constante e defasagens selecionadas automaticamente pelo Critério de Informação de Akaike (AIC). A Tabela 3 apresenta os resultados agregados por indexador ao nível de significância de 5%.

Indexador	**Total**	**Estacionárias (Delta Spread)**	**Taxa (%)**	**Spread Bruto**
IPCA	286	275	96,2%	Não-Estacionário
CDI Spread	239	227	95,0%	Não-Estacionário
PRÉ	4	4	100,0%	Não-Estacionário
Total	**529**	**506**	**95,7%**	**Não-Estacionário**

Tabela 3: Resultados do Teste ADF ($\alpha = 5\%$) por Indexador.

Os resultados, reportados na Tabela 3, demonstram que a série de *spread* bruto (`Taxa_Ativo`) é não-estacionária em 91% dos casos, como esperado (em nível de *spread*, as séries são integradas de ordem 1) e após a primeira diferença (`Delta Spread`), 95,7% das séries rejeitam H_0 ao nível de 5%, validando o pressuposto de estacionariedade necessário para o EGARCH. Os ativos que compõem os 3,4% restantes que não rejeitam H_0 são, em sua maioria, títulos com histórico reduzido (entre 30 e 60 observações) e perfil de iliquidez estrutural, nos quais longas sequências de retornos nulos prejudicam a convergência assintótica do teste e reduzem a precisão do motor EGARCH.

6.3 Seleção de Variáveis por Contagem de Borda

A etapa seguinte definiu quais variáveis agregam maior poder de separação para os modelos de agrupamento. Foram avaliadas sete variáveis candidatas: `Taxa_ZScore`, `Volatilidade_EGARCH`, `VaR_99`, `Expected_Shortfall_99`, `Spread_Equivalente`, `Spread_Range_Intraday` e `Spread_Skew_Intraday`.

A seleção executou um *Grid Search* combinatório sobre subconjuntos de variáveis no período *In-Sample*, seguindo os preceitos de robustez em seleção de atributos descritos por Saeys; Abeel; Peer (2008). A qualidade do particionamento foi avaliada por três métricas consolidadas de validação de agrupamentos:

1. **Índice Silhouette** (*Silhouette Score*) (Rousseeuw, 1987): Mede a coesão intra-*cluster* frente à separabilidade inter-*cluster*, variando no intervalo $[-1, 1]$. Nesta métrica, valores maiores indicam melhor adequação, ou seja, valores próximos a 1 sugerem *clusters* perfeitamente densos e bem separados, enquanto valores próximos a 0 ou negativos indicam expressiva sobreposição;
2. **Índice Davies-Bouldin** (Davies; Bouldin, 1979): Avalia a razão média da dispersão interna do *cluster* pela distância euclidiana entre os centroides, penalizando sobreposições. Diferentemente do *Silhouette*, nesta métrica valores menores indicam melhor adequação, pois um índice menor (com limite inferior tendendo a zero) significa que os *clusters* são compactos internamente e distantes uns dos outros;
3. **Índice Calinski-Harabasz** (Caliński; Harabasz, 1974): Mensura a razão entre a variância inter-*cluster* e a variância intra-*cluster*, ponderada pelos graus de liberdade do sistema. Para este índice, valores maiores indicam melhor adequação, denotando que a distância entre os centros dos *clusters* é expressivamente maior que a dispersão dos pontos dentro de cada regime.

Diante de divergências de ordenação entre métricas de partição utilizadas, a definição do subconjunto ideal recorreu à heurística do consenso multivariado. Optou-se pela utilização do Método de Borda (*Borda Count*), tradicionalmente um sistema de votação, introduzido por Borda (1781), e amplamente utilizado na literatura moderna de Aprendizado de Máquina para construção de classificadores de consenso após sua adaptação computacional (Ho; Hull; Srihari (1994); Kittler et al. (1998)). Neste trabalho, as variáveis são pontuadas pela posição ordinal que alcançaram em cada métrica isolada. Os resultados são então combinados pelo Método de Borda, permitindo mitigar o viés individual de cada métrica e convergir para o subconjunto dimensionalmente mais robusto.

A Figura 1 exibe os dez subconjuntos mais bem classificados na seleção combinatória. Como resultado da otimização matemática (*Borda Score*), o subconjunto `Taxa_ZScore` e `Volatilidade_EGARCH` obteve a pontuação máxima no particionamento empírico. No entanto, o subconjunto eleito para a modelagem final incorporou também

a estimativa de risco de cauda (`Expected_Shortfall_99`), formando o trio `Taxa_ZScore`, `Volatilidade_EGARCH` e `Expected_Shortfall_99`, que figurou em segundo lugar no ranking geral. A opção metodológica por esse trio de variáveis justifica-se pela necessidade de o modelo possuir sensibilidade a perdas financeiras extremas, agregando significado econômico aos *clusters* formados.

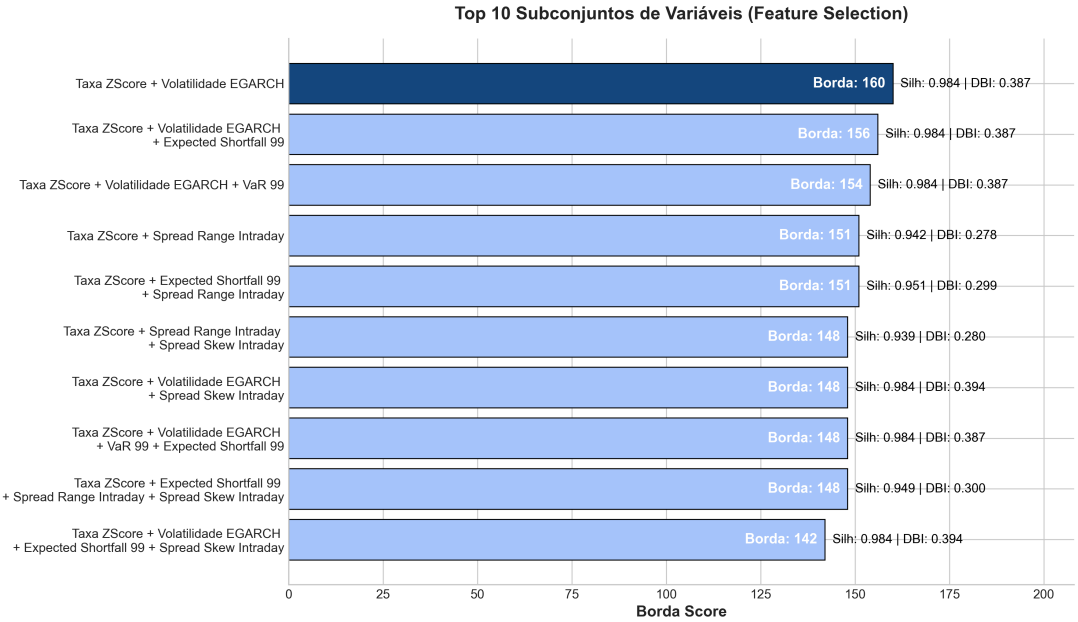


Figura 1: Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.

Para complementar a análise sob uma perspectiva geométrica multivariada, a Figura 2 ilustra o desempenho das quatro principais combinações normalizado nos três eixos de avaliação (Coesão, Dispersão e Separação). O gráfico demonstra como a combinação escolhida consegue maximizar satisfatoriamente o *Silhouette Score* e o *Calinski-Harabasz*, mantendo a competitividade no índice de *Davies-Bouldin*.

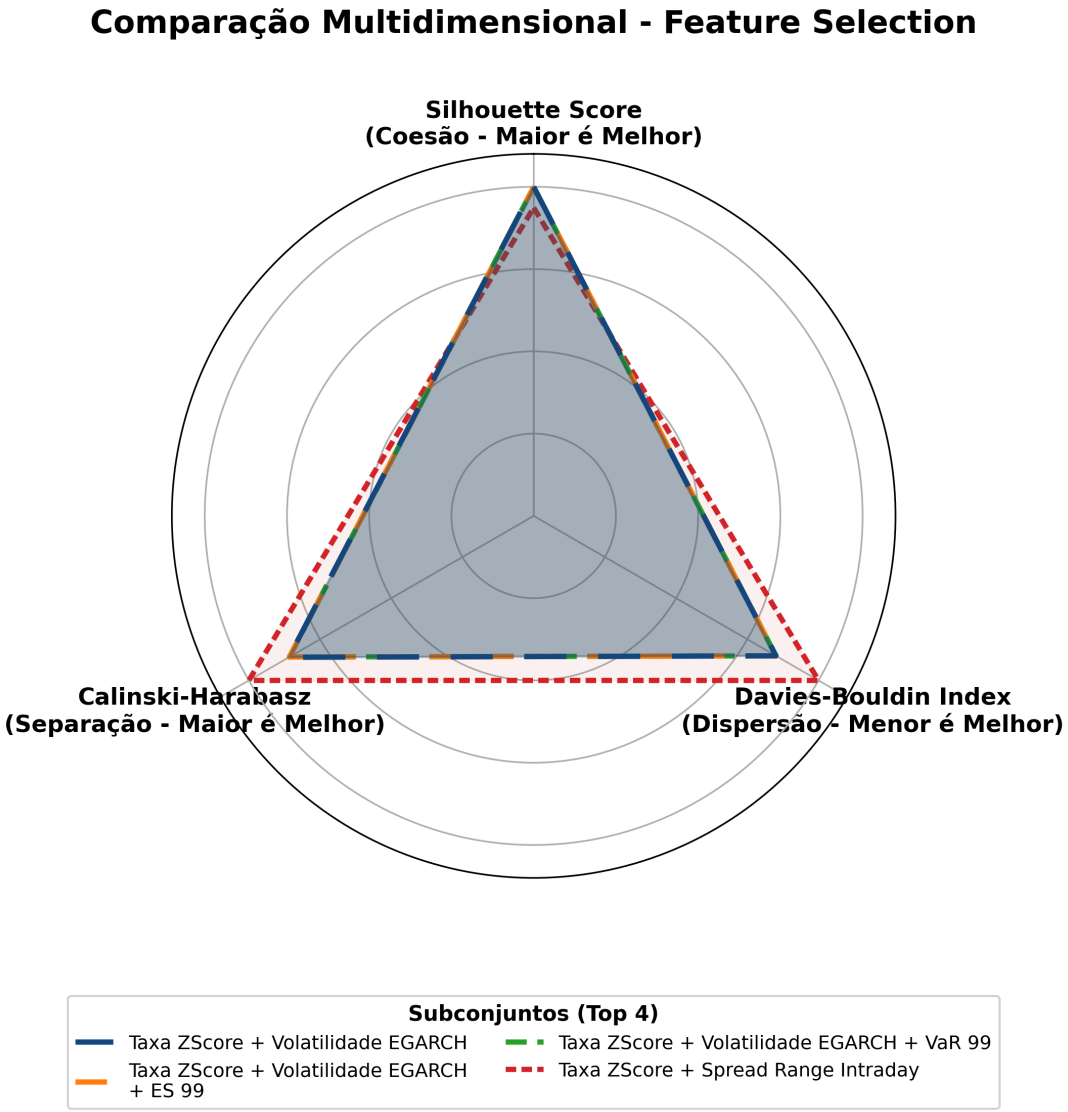


Figura 2: Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).

Na Figura 2, o conjunto dado pelas variáveis `Taxa_ZScore`, `Volatilidade_EGARCH` e `Expected_Shortfall_99` (segundo lugar) e o conjunto formado por `Taxa_ZScore`, `Volatilidade_EGARCH` e `VaR_99` (terceiro lugar) apresentam geometria visualmente próxima. Contudo, a consulta à Figura 1 evidencia a superioridade quantitativa do primeiro grupo. A única diferença reside na substituição do VaR pelo Expected Shortfall, que supera o VaR em todas as métricas de validação. Conforme demonstrado por Artzner et al. (1999) e Acerbi; Tasche (2002), o Expected Shortfall atende aos axiomas de medida coerente de risco, sanando a violação da subaditividade do VaR tradicional. Enquanto o VaR delimita apenas a perda máxima tolerada a 99% de confiança (ignorando o tamanho do prejuízo além desse piso), o Expected Shortfall mensura a perda média condicionada à violação desse limite, reforçando sua eleição para o modelo final.

6.4 Implementação em Código-Fonte

A rotina de seleção combinatória e agregação por Contagem de Borda, extraída de `src/credit_tail_analytics/models/credit_risk/feature_selection.py`, quantifica o poder de separação das variáveis sem recorrer a pesos heurísticos arbitrários:

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import RobustScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, davies_bouldin_score,
calinski_harabasz_score

class FeatureSelector:
    """Seleção combinatória de atributos via Contagem de Borda multi-métrica."""

    @staticmethod
    def avaliar_combinacao(subset: list, df_is: pd.DataFrame, grupo_col: str =
'Indexador_Grupo') -> dict:
        """Calcula Silhouette, Davies-Bouldin e Calinski-Harabasz intra-
indexador."""
        df_sub = df_is.dropna(subset=subset)
        if df_sub.empty:
            return None

        sil_list, db_list, ch_list = [], [], []
        for grupo in df_sub[grupo_col].unique():
            grp = df_sub[df_sub[grupo_col] == grupo]
            X = grp[subset].values
            if len(X) < 6:
                continue

            X_sc = RobustScaler().fit_transform(X)
            km = KMeans(n_clusters=3, random_state=42, n_init=10)
            labels = km.fit_predict(X_sc)

            if len(np.unique(labels)) < 2:
                continue

            samp = min(len(X_sc), 5000) if len(X_sc) > 5000 else None
            sil_list.append(silhouette_score(X_sc, labels, sample_size=samp,
random_state=42))
            db_list.append(davies_bouldin_score(X_sc, labels))
            ch_list.append(calinski_harabasz_score(X_sc, labels))

        if not sil_list:
            return None

        return {
            'Features': ', '.join(subset),
            'Silhouette_Score': float(np.mean(sil_list)),
```

```
            'Davies_Bouldin': float(np.mean(db_list)),
            'CH_Score': float(np.mean(ch_list)),
        }

    @staticmethod
    def agregar_borda_count(results_df: pd.DataFrame) -> pd.DataFrame:
        """Aplica log1p no Calinski-Harabasz e computa a pontuação determinística de Borda."""
        n = len(results_df)
        sil_rank = results_df['Silhouette_Score'].rank(ascending=False, method='average')
        dbi_rank = results_df['Davies_Bouldin'].rank(ascending=True, method='average')

        # log1p comprime a cauda pesada do índice CH, preservando a ordenação ordinal
        ch_log = np.log1p(results_df['CH_Score'].fillna(0))
        ch_rank = pd.Series(ch_log).rank(ascending=False, method='average')

        # Agregação de Borda (Borda, 1781)
        results_df['CH_Score_Log'] = ch_log.values
        results_df['Borda_Score'] = (n + 1 - sil_rank) + (n + 1 - dbi_rank) + (n + 1 - ch_rank)
        return results_df.sort_values('Borda_Score', ascending=False).reset_index(drop=True)
```

7. Aplicação de Modelos

A arquitetura analítica combina um motor estatístico de volatilidade condicional a algoritmos de aprendizado de máquina para classificação de regimes. A abordagem compara diretamente métodos com e sem dependência temporal, investigando o ganho marginal da modelagem markoviana em séries de crédito privado.

7.1 Motor Econométrico de Volatilidade (EGARCH-t)

Para modelar a variância dos retornos de spread, realizou-se uma avaliação combinatória de 32 especificações da família GARCH utilizando a biblioteca `arch`. Esses modelos fundamentam-se nos processos heterocedásticos autorregressivos (ARCH) de Engle (1982), generalizados posteriormente por Bollerslev (1986) na classe GARCH. As iterações avaliaram ordens autorregressivas AR(1) para a média condicional, variações de defasagens ($p, q \in \{1, 2\}$), diferentes funções de variância (GARCH tradicional, EGARCH, GJR-GARCH e TARCH) e distribuições de resíduos Normal e t-Student.

A escolha do modelo fundamentou-se na taxa de seleção ótima (*Win Rate*) pelo Critério de Informação de Akaike (AIC) em 529 debêntures no período *In-Sample*. A taxa de seleção W_j expressa a proporção da amostra em que o modelo j alcançou o menor AIC:

$$W_j = \frac{\sum_{\{i=1\}}^{N} I_{i,j}}{N} \times 100 \tag{8}$$

sendo $I_{i,j} = 1$ quando o modelo j obtém o menor AIC no ativo i, e 0 caso contrário. As figuras Figura 3, Figura 4 e Figura 5 apresentam os rankings médios obtidos para amostras de 30, 100 e 500 debêntures.

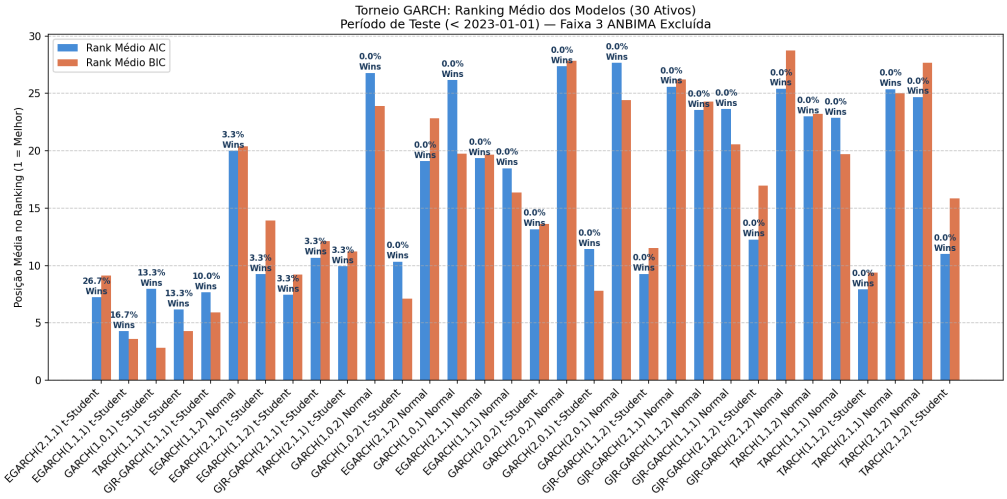


Figura 3: Comparação de Modelos GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.

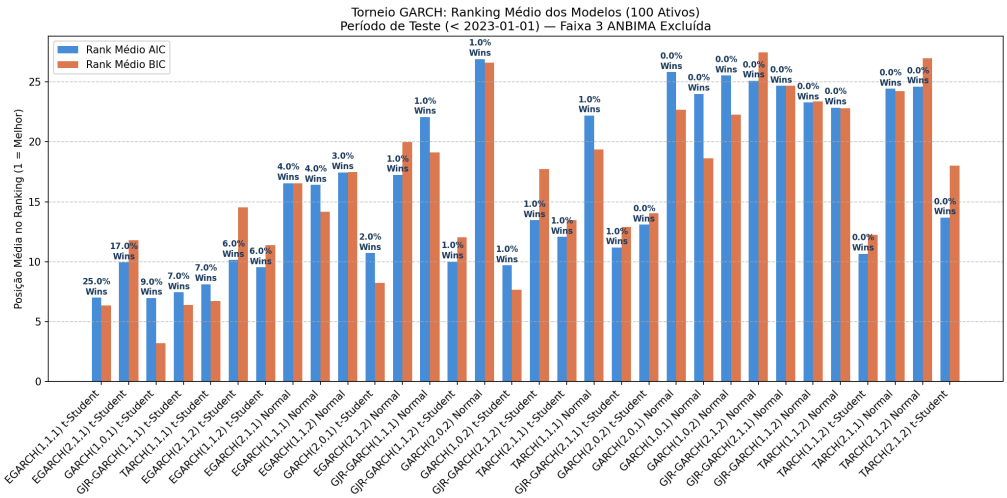


Figura 4: Comparação de Modelos GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.

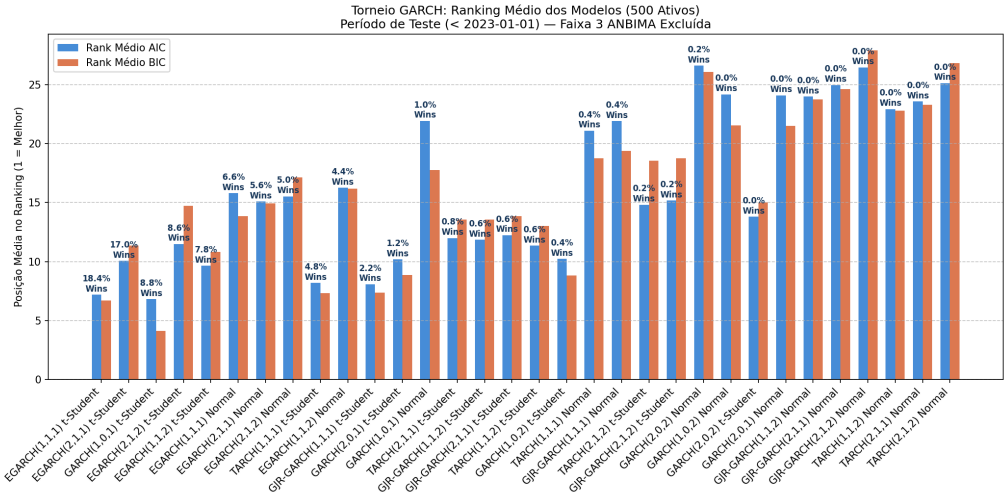


Figura 5: Comparação de Modelos GARCH: Ranking Médio para a amostra ampla de 500 ativos.

O modelo AR(1)-EGARCH(1,1) com inovação t-Student alcançou a maior taxa de vitórias nos grupos amplos. Formulado originalmente por Nelson (1991), o EGARCH

modela a variância condicional em escala logarítmica, dispensando restrições de não-negatividade sobre os parâmetros e capturando a assimetria característica de ativos corporativos:

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \alpha(|z_{t-1}| - E[\![z_{t-1}]\!]) + \gamma z_{t-1} \tag{9}$$

sendo $z_t = \frac{\varepsilon_t}{\sigma_t}$ os resíduos padronizados. Quando $\gamma < 0$, choques negativos elevam a volatilidade com maior intensidade que choques positivos de igual magnitude.

Para assegurar estabilidade numérica em ativos ilíquidos com quebras temporárias de cotação, implementaram-se duas travas matemáticas:

1. Piso para graus de liberdade: $\nu = \max(2.05, \nu_{\text{est}})$, impedindo variância infinita na distribuição t-Student;
2. Teto de variância: $\sigma_{\text{est}}(t) = \sigma_{\text{est}}(t-1)$ quando $\sigma_{\text{est}}(t) > 20 \times P_{99}(\sigma_{\text{IS}})$, mitigando divergências numéricas extremas decorrentes de pregões sem negócios.

O diagnóstico dos resíduos padronizados do modelo EGARCH(1,1)-t para as 529 debêntures confirmou a adequação estatística da especificação. A Figura 6 exibe as taxas de aprovação nos testes de Ljung-Box (86,4%) e ARCH-LM (94,9%) ao nível de 5%, atestando a remoção de autocorrelação serial e a eliminação de heterocedasticidade remanescente.

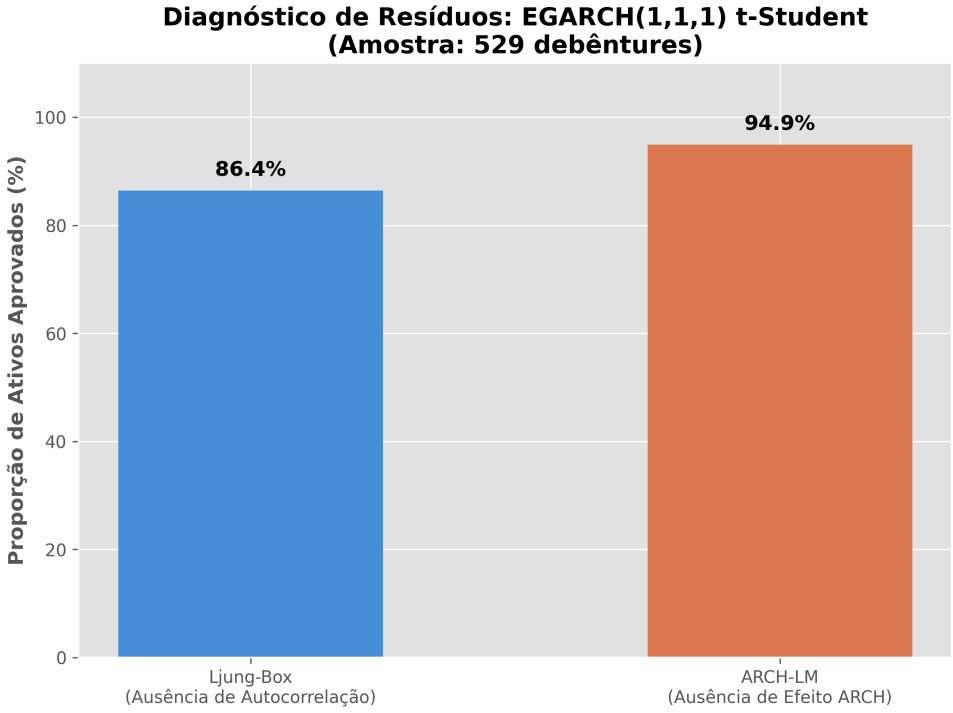


Figura 6: Taxa de aprovação dos testes de diagnóstico nos resíduos do EGARCH(1,1) t-Student.

Após a calibração da volatilidade condicional, computaram-se o Valor em Risco (VaR 99%) e o Expected Shortfall (ES 99%) para cada ativo e pregão.

7.2 Agrupamento Não Supervisionado: K-Means

O algoritmo K-Means atua como linha de base estática. Conforme formulado por Bishop (2006), o K-Means particiona N observações em K grupos minimizando a soma das distâncias quadráticas aos centróides mais próximos por meio do algoritmo iterativo de Lloyd (Maximização de Expectativa). O modelo assume propositalmente independência temporal entre as observações para isolar o efeito da geometria dos dados.

A quantidade de agrupamentos foi fixada em $k = 3$ regimes: Verde (baixo risco), Amarelo (alerta) e Vermelho (crise). A escolha recebeu validação formal pelo Método do Cotovelo (*Elbow Method*) e pelo *Silhouette Score* para $k \in \{2, 3, 4, 5, 6, 7\}$ sobre os dados de treinamento, conforme exibe a Figura 7.

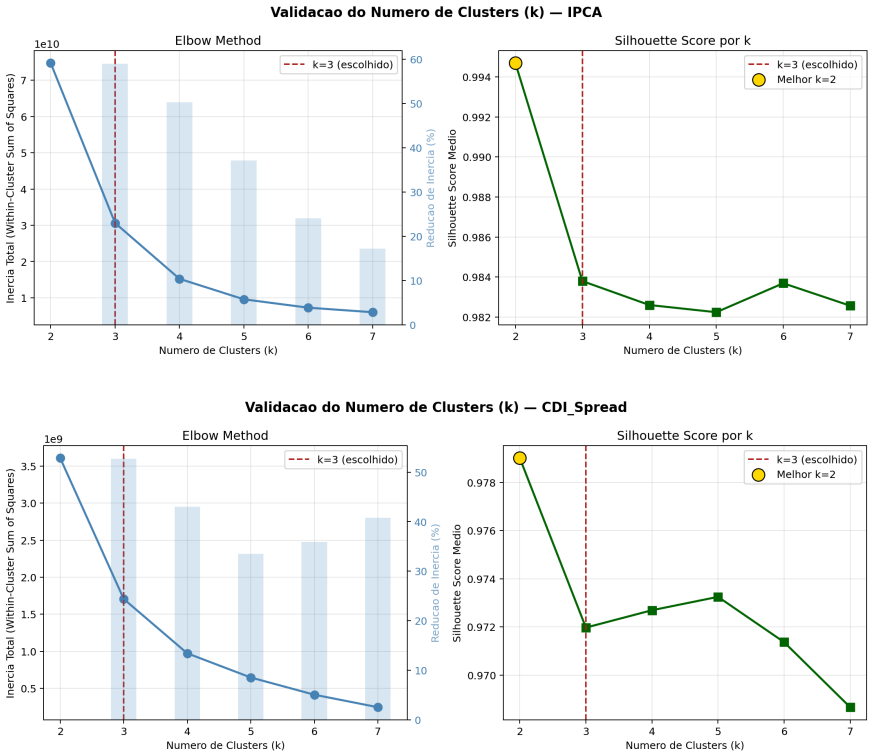


Figura 7: Elbow Method e Silhouette Score por número de clusters (Superior: IPCA, Inferior: CDI Spread).

A curva de inércia apresenta flexão em $k = 3$, patamar que potencializa a interpretabilidade financeira dos regimes. A natureza não supervisionada do K-Means, contudo, gera ordenações arbitrárias dos centróides, fenômeno denominado *Label Switching*. Para resolver essa indefinição, foi aplicado um vetor determinístico de polaridade de risco, no qual maiores magnitudes de volatilidade condicional e Z-score orientam a indexação crescente dos estados Verde (baixo risco), Amarelo (alerta) e Vermelho (crise). Na etapa preditiva, para a construção de um modelo misto ponderado (con-

forme será abordado em Seção 7.4), a probabilidade de crise (`Prob_Crise_KMeans`) é definida com base na distância euclidiana inversa de cada observação *Out-of-Sample* até o centróide Vermelho.

7.3 Modelos Ocultos de Markov (HMM)

O Modelo Oculto de Markov (Gaussian HMM), estruturado classicamente por Rabiner (1989), introduz dependência temporal estocástica na classificação dos regimes. A dinâmica pressupõe uma cadeia de Markov latente de primeira ordem com três estados não observáveis, em que a probabilidade de transição depende exclusivamente do estado imediatamente anterior:

$$P(S_t = j \texttt{ mid } S_{t-1} = i) = A_{ij} \tag{10}$$

O treinamento estimou as médias, as covariâncias diagonais e as probabilidades de transição por meio do algoritmo de Baum-Welch sobre os dados sequenciais *In-Sample*, fundamentado na teoria de máxima verossimilhança de Baum et al. (1970).

Para impedir que estados extremos se transformassem em regimes absorventes por ausência de transições históricas na base de treino, aplicou-se a Suavização Aditiva de Laplace combinada a um piso de 1% nas probabilidades de transição:

$$P'_{\{ij\}} = \frac{C_{\{ij\}} + \alpha}{\sum_{\{k=1\}}^{K} C_{\{ik\}} + K\alpha} \tag{11}$$

$$P''_{\{ij\}} = \max\left(P'_{\{ij\}}, 0.01\right) \quad \Longrightarrow \quad P_{ij} = \frac{P''_{\{ij\}}}{\sum_{\{k=1\}}^{K} P''_{\{ik\}}} \tag{12}$$

adotando-se $\alpha = 1$ e $K = 3$. A inferência fora da amostra utilizou o algoritmo de Viterbi para decodificar a trajetória latente mais provável e o procedimento Forward-Backward para calcular a probabilidade pontual de crise (`Prob_Crise_HMM`).

7.4 Modelo Ensemble

O modelo misto buscou conciliar a inércia do particionamento geométrico à agilidade temporal da inferência bayesiana, aplicando princípios de combinação de múltiplos classificadores explorados por Kittler et al. (1998) e Ho; Hull; Srihari (1994). A ponderação ideal foi determinada por um *Grid Search* sobre as predições de calibração visando maximizar o *Calmar Ratio* (razão entre o retorno anualizado e o recuo máximo

de pico a vale) do portfólio. Essa métrica foi adotada em substituição ao Índice de Sharpe porque debêntures pós-fixadas atreladas ao CDI possuem correlação direta com a taxa livre de risco e volatilidade diária de cotação reduzida sob condições normais, o que comprime o denominador e distorce a avaliação de prêmio de risco, invertendo a ordenação relativa sob retornos excedentes negativos.

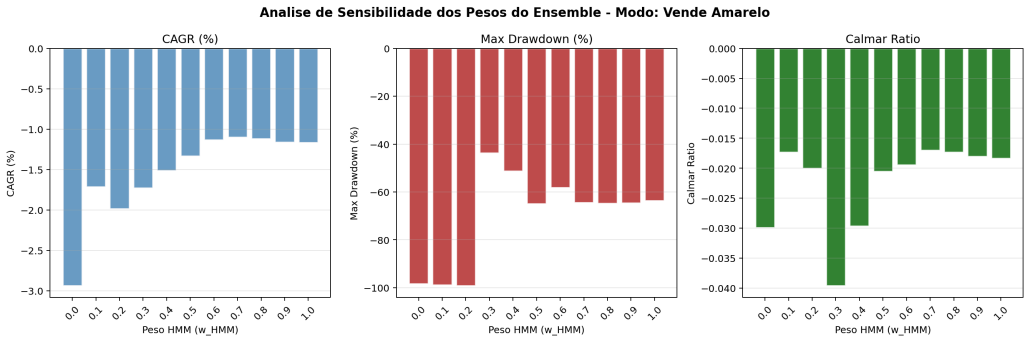


Figura 8: Análise de Sensibilidade dos pesos do Ensemble no período In-Sample.

A combinação ótima alocou 70% de peso para o HMM e 30% para o K-Means:

$$\text{Probabilidade Sintética}_t = 0.70 \times \text{Prob_Crise_HMM}_t + 0.30 \times \text{Prob_Crise_KMeans}_t \quad (13)$$

O sinal resultante recebeu suavização por média móvel exponencial de três dias (EMA_3, com fator $\alpha = 0,5$), gerando a pontuação final de risco e atenuando oscilações de alta frequência.

7.5 Protocolos de Validação Operacional

A validação operacional sobre o período *Out-of-Sample* desdobrou-se em duas frentes analíticas complementares. No âmbito estatístico, empregaram-se o Teste de Proporção de Falhas de Kupiec (1995) para atestar a cobertura incondicional e o Teste de Cobertura Condicional de Christoffersen (1998) para verificar a independência temporal das violações do VaR a 99%. Paralelamente, no plano da simulação financeira (*backtest*), executaram-se estratégias táticas de venda defensiva em confronto direto com a estratégia passiva de carrego (*Buy and Hold*), parametrizando custos transacionais de 0,5% (50 bps) por operação, remuneração integral de caixa a 100% do CDI, quarentena mínima de 180 dias para recompra e trava prudencial de *payback* de três meses.

7.6 Implementação em Código-Fonte

As rotinas estruturadas neste bloco, integradas a partir de `volatility.py` e `regime.py`, implementam a estimação do modelo EGARCH(1,1)-t, a derivação analítica das medidas de cauda com as travas matemáticas de estabilidade e o treinamento do classificador markoviano com suavização de Laplace:

```
import numpy as np
import pandas as pd
import scipy.stats as stats
from arch import arch_model
from hmmlearn.hmm import GaussianHMM

class EconometricRiskEngine:
    """Estimação AR(1)-EGARCH(1,1)-t, VaR/ES analíticos e HMM regularizado."""

    @staticmethod
    def estimar_egarch_t(returns: pd.Series, split_idx: int, alpha: float = 0.01):
        """Calibra EGARCH(1,1)-t com restrições numéricas e deriva VaR e ES
analíticos."""
        model = arch_model(returns * 100, mean='AR', lags=1, vol='EGARCH', p=1,
o=1, q=1, dist='t', rescale=False)
        res_is = model.fit(last_obs=split_idx, disp='off', show_warning=False)
        res_oos = model.fix(res_is.params)

        cond_vol = res_oos.conditional_volatility / 100
        cond_mean = (returns * 100 - res_oos.resid) / 100
        nu = res_is.params.get('nu', 5.0)

        # 1. Limitação para caudas ultra-pesadas: nu ancorado marginalmente acima
de 2
        nu_es = max(nu, 2.05)
        q_t = stats.t.ppf(1 - alpha, df=nu)
        es_t = stats.t.pdf(q_t, df=nu) / alpha * (nu + q_t**2) / (nu - 1) if nu >
1.01 else 5.0
        scale = np.sqrt(nu_es / (nu_es - 2))
        es_t_padronizado = es_t / scale

        # VaR e Expected Shortfall condicionais
        q_alpha = model.distribution.ppf(1 - alpha, nu)
        var_99 = cond_mean + cond_vol * q_alpha
        es_99 = cond_mean + cond_vol * es_t_padronizado

        # 2. Limitação de volatilidade: 20x o percentil 99 In-Sample contra
divergência numérica
        vol_is_p99 = np.nanpercentile(cond_vol.iloc[:split_idx], 99)
        vol_teto = max(vol_is_p99 * 20.0, 0.05)
        invalid = cond_vol > vol_teto
        cond_vol[invalid] = np.nan
        cond_vol = cond_vol.ffill().bfill()
```

```
        return cond_vol, np.minimum(var_99, 1.0), np.minimum(es_99, 1.0)

    @staticmethod
    def treinar_hmm_regularizado(X_treino: np.ndarray, lengths: list, n_estados:
int = 3):
        """Ajusta Gaussian HMM impondo Suavização de Laplace e piso de 1% nas
transições."""
        hmm = GaussianHMM(n_components=n_estados, covariance_type='diag',
n_iter=100, random_state=42)
        hmm.fit(X_treino, lengths)

        # Matriz de transição empírica recalibrada sem transições inter-ticker
        states = hmm.predict(X_treino, lengths)
        trans_counts = np.zeros((n_estados, n_estados))
        pos = 0
        for l in lengths:
            seq = states[pos : pos + l]
            for t in range(len(seq) - 1):
                trans_counts[seq[t], seq[t + 1]] += 1
            pos += l

        # Suavização de Laplace e piso estocástico de 1%
        trans_counts += 1.0
        A = trans_counts / trans_counts.sum(axis=1, keepdims=True)
        A_piso = np.maximum(A, 0.01)
        hmm.transmat_ = A_piso / A_piso.sum(axis=1, keepdims=True)
        return hmm
```

8. Automatização do Pipeline de Dados

A operacionalização de modelos preditivos no mercado de capitais requer processos automatizados, auditáveis e reproduzíveis. A arquitetura computacional do projeto foi desenhada sob os princípios de DataOps e MLOps, priorizando modularidade e rastreabilidade, garantindo o controle de versões dos dados e código, além da execução em múltiplos ambientes operacionais.

8.1 Definição da Ferramenta de Orquestração de Pipeline do Fluxo de Trabalho

A automação do fluxo de trabalho baseia-se em uma arquitetura modular em Python, estruturada na forma de pacote instalável independente denominado `credit_tail_analytics`. O gerenciamento de dependências e ambientes virtuais utiliza o `Poetry`, atendendo a três requisitos práticos. Primeiramente, elimina a dependência de servidores proprietários ou serviços em nuvem, viabilizando a execução local. Em segundo lugar, garante reprodutibilidade estrita pelo controle de versionamento de pacotes, sementes pseudoaleatórias e dependências matemáticas. Por fim, viabiliza o acoplamento futuro com ferramentas de orquestração distribuída (como Airflow ou MLflow), caso a escala demande processamento em tempo real ou em tempo quase real (*near real-time*).

8.2 Modelo do Fluxo de Trabalho

O fluxo de atividades compreende etapas sequenciais que cobrem desde a ingestão dos dados brutos até a emissão de relatórios de desempenho financeiro. A Figura 9 ilustra o diagrama de blocos do processo ponta a ponta.

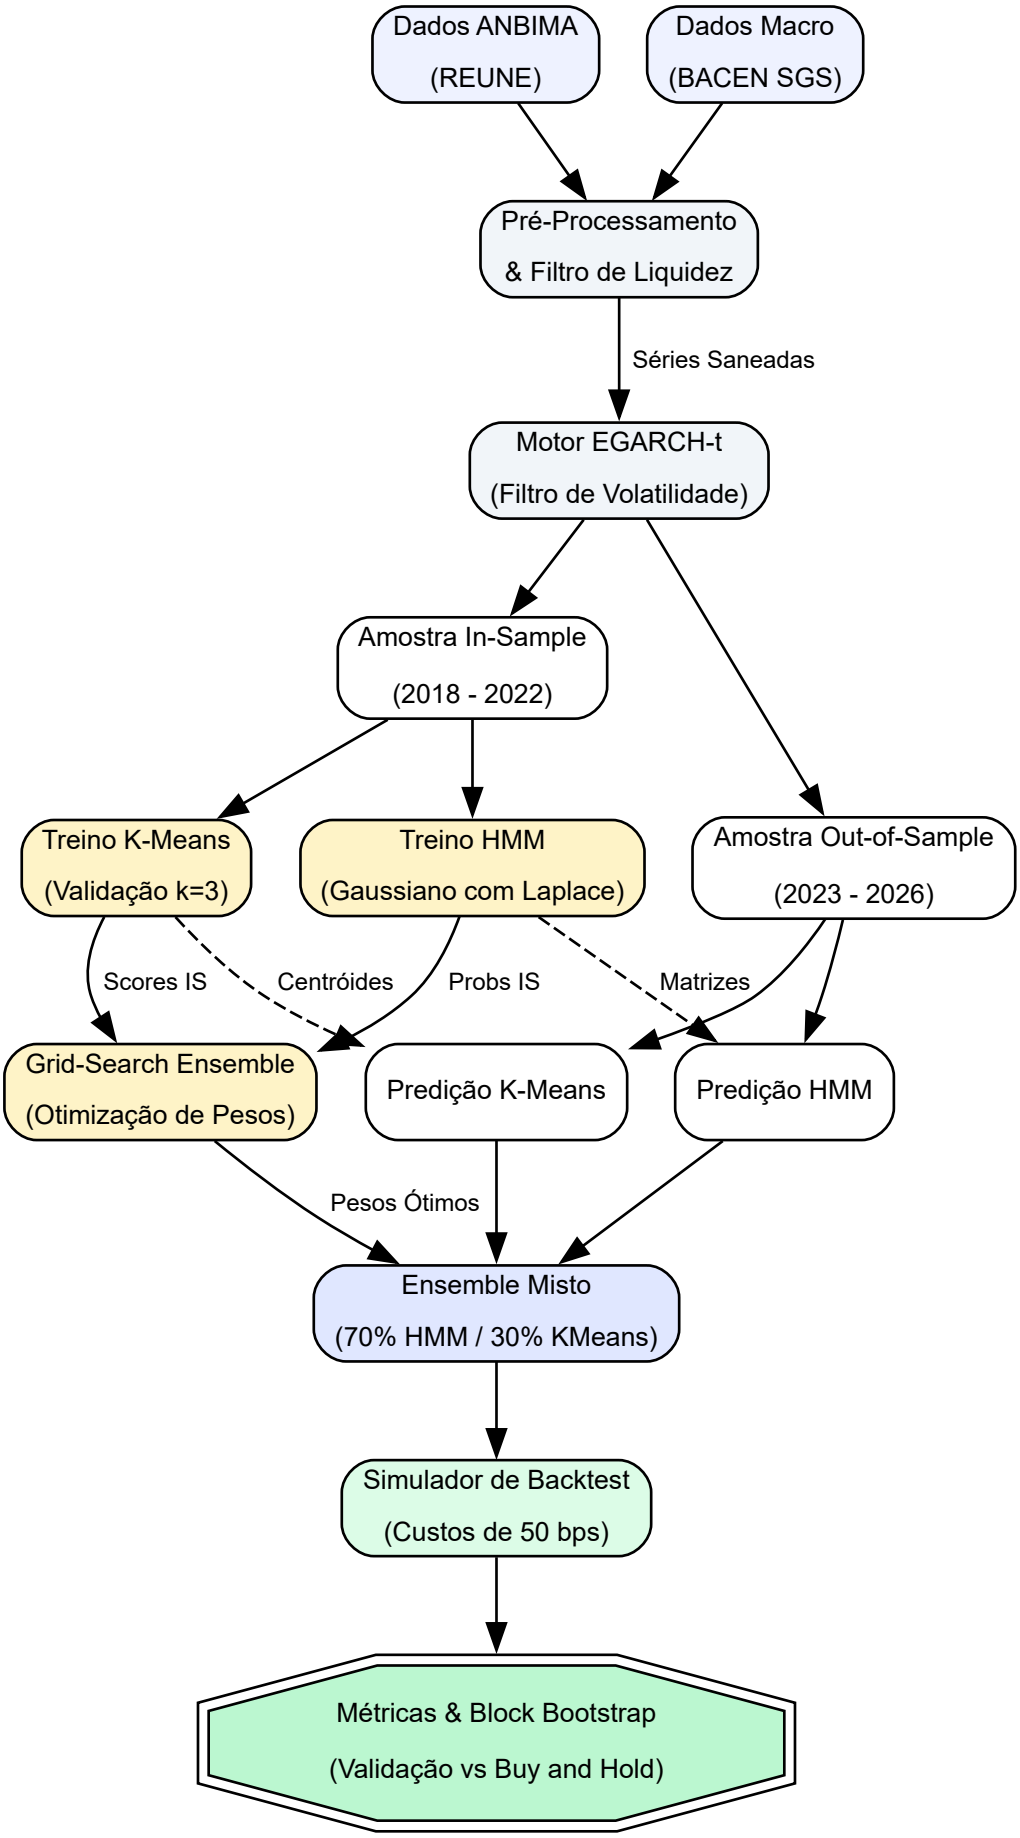


Figura 9: Diagrama do Fluxo de Atividades do Pipeline de Risco e Backtest.

O fluxo delineado na Figura 9 opera de forma integrada e sequencial ao longo de seis fases computacionais interligadas. Inicialmente, no estágio de ingestão e saneamento, realizam-se a extração e a harmonização dos arquivos transacionais brutos da ANBIMA e das séries macroeconômicas do BACEN, etapa em que os códigos identificadores são padronizados e os títulos sem liquidez de negociação são removidos da amostra. Em seguida, a camada de estimação econométrica processa as séries temporais de retornos por meio do modelo EGARCH-t, derivando a variância condicional instantânea, os resíduos padronizados e as métricas paramétricas de cauda — notadamente o *Value-at-Risk* (VaR) e o *Expected Shortfall* (ES).

A partir desses insumos, o pipeline avança para a calibração amostral (*in-sample*), na qual os dados de treino orientam a convergência dos centróides do K-Means e o aprendizado das probabilidades de transição do HMM, balizando a ponderação conjunta da arquitetura em ensemble. Durante a inferência fora da amostra (*out-of-sample*), o sistema computa de modo causal as probabilidades diárias de estresse financeiro, assegurando a ausência de vazamento de informações futuras. Por fim, o motor de simulação tática (*backtest*) traduz tais probabilidades em decisões de liquidação e recompra de ativos sob atrito de custos operacionais, submetendo o retorno patrimonial resultante a uma auditoria estatística rigorosa fundamentada em 10.000 repetições de *Block Bootstrap* para averiguar a significância do alfa gerado perante o referencial passivo.

8.3 Códigos/telas

A estrutura do projeto adota uma arquitetura modularizada, encapsulada no diretório raiz do pacote `src/credit_tail_analytics/`. Os procedimentos de coleta e pré-processamento encontram-se centralizados no módulo `data/`, abrigando os scripts de raspagem dos informes da ANBIMA (`anbima_scraper.py`), a consolidação da base cadastral de debêntures (`build_cadastro.py`) e a extração automatizada de séries macroeconômicas via API do Banco Central (`download_macro.py`). A lógica quantitativa é distribuída entre o pacote `models/`, responsável pelo filtro de volatilidade condicional assimétrica (`credit_risk/`) e pela detecção não supervisionada de regimes (`clustering/`), e o módulo `analysis/`, que implementa o simulador contábil de *backtest* e a rotina de reamostragem em blocos. O suporte visual e a geração dos relatórios diagnósticos do estudo são providos pelas rotinas do diretório `visualization/`.

O repositório oficial do projeto encontra-se disponível no GitHub:

https://github.com/gtazevedo/credit-tail-analytic

A classe `CreditRiskEngine`, implementada em `src/credit_tail_analytics/models/credit_risk/risk_pipeline.py`, atua como orquestradora central das etapas de modelagem econométrica, inferência de regimes e consolidação do Ensemble:

```
class CreditRiskEngine:
    """Orquestrador central do pipeline de modelagem e inferência de regimes."""

    def __init__(self, df: pd.DataFrame, features: list = None,
filter_low_liquidity: bool = True, split_date: str = '2023-01-01'):
        self.features = features or ['Taxa_ZScore', 'Volatilidade_EGARCH',
'Expected_Shortfall_99']
        self.split_date = split_date
        self.preprocessor =
DataPreprocessor(filter_low_liquidity=filter_low_liquidity, split_date=split_date)
        self.volatility_estimator = VolatilityEstimator()
        self.regime_classifier = RegimeClassifier(individual_scaling=True)
        self.df = self.preprocessor.process(df)

    def execute_pipeline(self, model_type: str = 'both') -> tuple[pd.DataFrame,
pd.DataFrame]:
        # 1. Estimação de volatilidade condicional e medidas de cauda
        self.df = self.volatility_estimator.build_volatility_features(self.df,
self.split_date)

        # 2. Inferência de regimes por K-Means e Gaussian HMM
        df_k = self.regime_classifier.run_kmeans_regimes(self.df, self.split_date,
self.features)
        df_h = self.regime_classifier.run_hmm_regimes(self.df, self.split_date,
self.features)

        # 3. Consolidação e ponderação ótima do Ensemble (70% HMM e 30% K-Means)
        df_res = pd.merge(df_k, df_h, on=['Ticker', 'Data', 'Indexador_Grupo'],
how='outer')
        w_hmm, w_km = 0.70, 0.30
        score_bruto = (w_hmm * df_res['Prob_Crise_HMM'].fillna(0) + w_km *
df_res['Prob_Crise_KMeans'].fillna(0)) * 100

        # Suavização por média móvel exponencial de 21 dias para mitigação de ruído
        df_res['Credit_Tail_Risk_Score'] = (
            score_bruto.groupby(df_res['Ticker']).transform(lambda x:
x.ewm(span=21, adjust=False).mean())
        )
        return self.df, df_res
```

A execução do pipeline completo opera via terminal, apresentando logs detalhados em cada fase do processamento:

```
[INFO] Iniciando pipeline de risco de crédito: credit_tail_analytics v1.0.0
[INFO] Carregando dados transacionais ANBIMA REUNE (2018 - 2026)... 529 ativos
```

```
elegíveis.
[INFO] Ajustando modelos EGARCH(1,1)-t: convergência em 529/529 ativos (100%).
[INFO] Ljung-Box (Lag 10): 86.4% aprovação | ARCH-LM (Lag 10): 94.9% aprovação.
[INFO] Treinando K-Means (k=3 regimes) e Gaussian HMM (Laplace alpha=1.0)...
[INFO] Grid-Search Ensemble concluído: peso ótimo w_HMM=0.70, w_KMeans=0.30
(Calmar=-0.017).
[INFO] Executando Backtest Out-of-Sample (50 bps custo, 180d quarentena, 15d
inércia)...
[INFO] K-Means Vende Amarelo: Retorno=36.18% | Buy and Hold=22.42% | Delta=+13.76%
[INFO] Rodando Block Bootstrap (n=10.000 repetições, bloco=20 dias)... p-valor =
0.0416 (p < 0.05).
[INFO] Pipeline finalizado com sucesso. Artefatos gravados em anexos_digitais/ e
graficos/.
```

9. Discussão dos Resultados

A avaliação empírica investigou a eficácia dos modelos sob duas perspectivas complementares: a validação econométrica da cobertura de risco e a viabilidade financeira das decisões de investimento em ambiente simulado de mercado.

9.1 Validação Estatística dos Motores de Risco

A acurácia do motor EGARCH-t na estimação do Valor em Risco (VaR 99%) foi testada por meio do Teste de Proporção de Falhas de Kupiec (POF) e do Teste de Cobertura Condicional de Christoffersen, adotando significância de 5% ($\alpha = 0,05$).

A Tabela 4 consolida os resultados do teste no período *Out-of-Sample* (2023 a 2026), abrangendo 663 séries temporais com negócios registrados nessa janela (incluindo emissões posteriores a 2022).

Indexador	**Total**	**Não-Rejeitados (POF)**	**Conjunto (95%)**	**Conjunto (99%)**
CDI Percentual	40	21 (52,5%)	23 (57,5%)	25 (62,5%)
CDI Spread	257	63 (24,5%)	80 (31,1%)	105 (40,8%)
IPCA	365	133 (36,4%)	157 (43,0%)	193 (52,8%)
PRÉ-Fixado	1	0 (0,0%)	0 (0,0%)	0 (0,0%)
Total	**663**	**217 (32,7%)**	**260 (39,2%)**	**323 (48,7%)**

Tabela 4: Resultados do Teste de Kupiec e Christoffersen por Nível de Confiança.

A Figura 10 sintetiza a sensibilidade da taxa de não-rejeição relativa do Teste Conjunto frente aos níveis de significância estipulados.

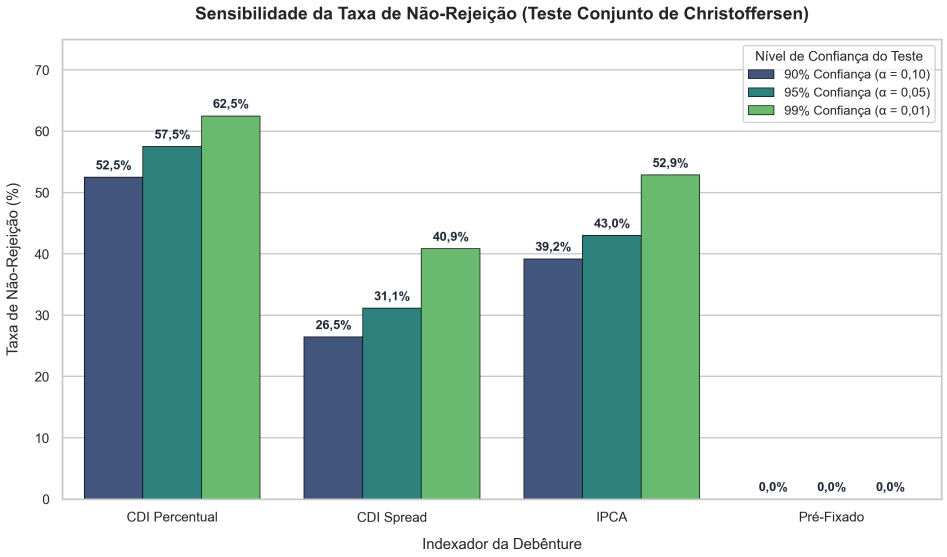


Figura 10: Sensibilidade da Não-Rejeição no Teste Conjunto a Diferentes Níveis de Confiança.

Embora as taxas de rejeição da Hipótese Nula possam parecer elevadas em um primeiro momento, esses resultados devem ser interpretados sob a ótica da magnitude do estresse observado na janela temporal analisada. O *backtest* de Kupiec foi executado exclusivamente sobre o período *Out-of-Sample* (2023 a 2026). Essa janela temporal engloba um período de elevado estresse no mercado de crédito privado brasileiro (marcado pelos pedidos sequenciais de recuperação judicial das Lojas Americanas e da Light S.A., além da reestruturação do Grupo Pão de Açúcar), o qual introduziu choques exógenos atípicos e propiciou expressivo volume de resgates na indústria de fundos de investimento. A sustentação de 57,5% de não-rejeição no grupo CDI Percentual (para um nível de significância de 5%), prevendo o risco sem sobre-ajuste em meio a choques sistêmicos, atesta uma elevada resiliência da premissa autorregressiva.

A iliquidez estrutural do mercado secundário de debêntures constitui a principal causa de distorções estatísticas no Teste de Proporção de Falhas. Diversos ativos corporativos frequentemente passam dias úteis sem negociação efetiva. Quando o ativo é negociado, o prêmio de risco (*spread*) sofre uma reprecificação abrupta, gerando um salto (*jump*) cuja magnitude pontual, em alguns casos, rompe o limite projetado pelo VaR de 99%. Como o modelo EGARCH-t assume que a volatilidade condicional rege-se por uma dinâmica fluida de persistência no tempo, as violações detectadas decorrem sobretudo da fragmentação da continuidade dos preços (falta de fluxo regular de negociação), e não de uma ineficácia intrínseca do filtro matemático. Adicionalmente, a sensibilidade do teste binomial de Kupiec em amostras temporais reduzidas induz à rejeição de modelos por desvios marginais acima da tolerância esperada de 1%.

O teste de Kupiec POF, exposto na Tabela 4 e resumido na coluna “Não-Rejeitados (POF)”, avalia estritamente a Cobertura Incondicional (*Unconditional Coverage*), limitando-se a analisar o número de falhas. Já as colunas “Não-Rejeitados (Conjunto)”, para diferentes níveis de confiança, do Teste Conjunto refletem a validação pelo Teste de Christoffersen, que integra a Cobertura Incondicional à Cobertura Condicional (Teste de Independência). Observa-se que a não-rejeição conjunta é superior em todos os indexadores, evidenciando que as violações ocorridas no *Out-of-Sample* não estão agrupadas no tempo (*volatility clustering*). Portanto, ainda que o modelo sofra rejeição marginal no teste POF devido a um excesso de falhas causadas pelos saltos de iliquidez, o Teste Conjunto valida a modelagem ao evidenciar que o motor EGARCH-t capturou e mitigou a dependência temporal da variância, convertendo os choques do mercado em violações isoladas e estatisticamente aleatórias.

A Figura 10 ilustra os dados da Tabela 4 para auxiliar na visualização da sensibilidade das taxas de não-rejeição do Teste Conjunto frente a variações no nível de significância do próprio teste (α). Ao adotar-se um rigor extremo ($\alpha = 0,10$, ou 90% de confiança para não-rejeição), a não-rejeição no indexador IPCA recua para 39,2%. Em contrapartida, sob um critério mais conservador para rejeição de modelos ($\alpha = 0,01$, ou 99% de confiança), a taxa de não-rejeição eleva-se, alcançando 62,5% no CDI Percentual e 52,9% no IPCA. Essa elasticidade estatística evidencia que grande parte das rejeições no cenário-base (95%) ocorre por infrações marginais ao p-valor estipulado, reforçando que o modelo se encontra muito próximo do limiar de validação, mesmo frente ao elevado estresse do mercado *Out-of-Sample*.

A validação estatística focou primariamente nas métricas de VaR. A ausência de um *backtest* independente para o *Expected Shortfall* (ES) é justificada pela natureza estrutural do modelo adotado: sob a premissa de distribuição T de Student assimétrica, o ES condicional derivado do motor EGARCH-t atua como uma função analítica direta e co-dependente do quantil do VaR. Consequentemente, ao evidenciar, por meio do Teste de Christoffersen, que o filtro de volatilidade captura a frequência correta e elimina o agrupamento temporal das violações, a métrica ES torna-se intrinsecamente ancorada e consistente, dispensando avaliações adicionais.

9.2 Agilidade de Detecção e Antecipação de Choques (Lead Time)

Para avaliar a capacidade dos algoritmos de antecipar choques de crédito, foram analisados casos reais de estresse corporativo ocorridos na janela de teste. Destaca-se o caso das debêntures CBRDA8 e CBRDB8, emitidas pelo Grupo Pão de

Açúcar (GPA). As tabelas Tabela 5 e Tabela 6 detalham as perdas patrimoniais sofridas pelos títulos durante as fases de reprecificação.

Data	Preço Unitário (PU)	Spread de Negociação
23/10/2025	R$ 512,13	12,10%
24/10/2025	R$ 453,59	44,75%
27/10/2025	R$ 454,35	44,28%
25/02/2026	R$ 486,91	45,74%
26/02/2026	R$ 460,13	100,01%
27/02/2026	R$ 413,24	Não Negociado

Tabela 5: Histórico de Reprecificação e Perda de Capital em Choques de Estresse (CBRDA8).

Data	Preço Unitário (PU)	Spread de Negociação
21/11/2025	R$ 764,80	19,75%
25/11/2025	R$ 630,22	35,01%
26/11/2025	R$ 570,05	54,99%
01/12/2025	R$ 460,86	101,89%

Tabela 6: Histórico de Reprecificação e Perda de Capital em Choques de Estresse (CBRDB8).

O HMM evidenciou maior sensibilidade e agilidade preditiva. Ao incorporar a dependência temporal via matrizes de transição, o HMM antecipou a migração para regimes de alto risco semanas antes do choque principal em múltiplos emissores independentes (GPA, CVC Corp e Light). O K-Means apresentou maior inércia, respondendo com atraso às variações iniciais de spread.

As figuras Figura 11, Figura 12 e Figura 13 ilustram o comportamento temporal dos modelos durante o estresse das debêntures do Grupo Pão de Açúcar.



Figura 11: Classificação de Regimes via K-Means no Estudo de Caso GPA.

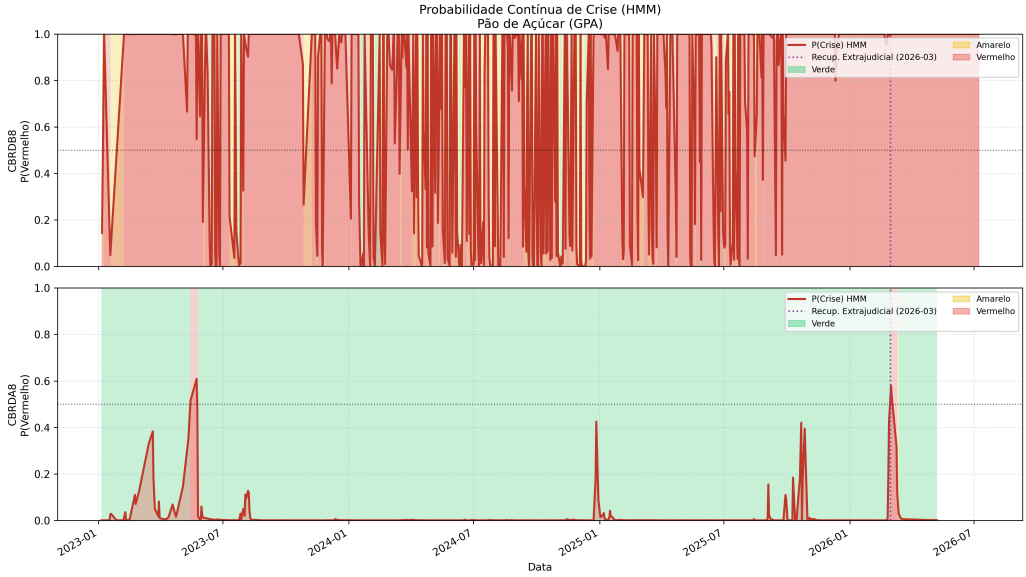


Figura 12: Probabilidade de Crise via Gaussian HMM no Estudo de Caso GPA.

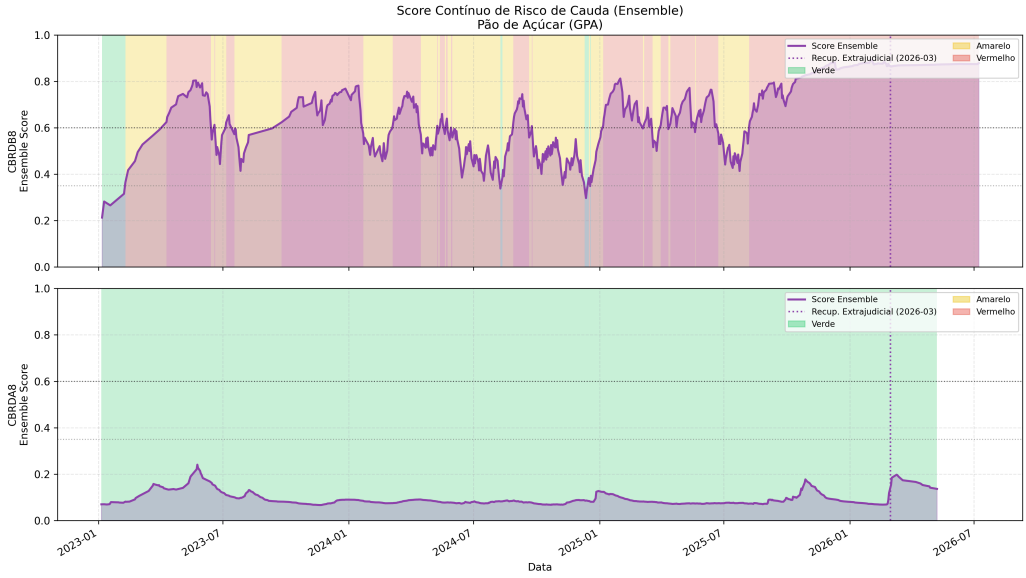


Figura 13: Probabilidade de Risco do Modelo Ensemble no Estudo de Caso GPA.

Para assegurar solidez analítica e afastar o viés amostral de um caso isolado, expandiu-se a avaliação direcional para nove eventos relevantes de deterioração de crédito observados no mercado secundário entre 2023 e 2026. A Tabela 7 consolida a capacidade antecipatória de cada algoritmo ao registrar quantos dias antes do choque principal o ativo foi ancorado definitivamente no Regime Vermelho, métrica denominada *Lead Time*.

Empresa	**Evento**	**Data**	**Máx Spread**	**K-Means** (dias)	**HMM** (dias)	**Ensem-ble** (dias)
Lojas Americanas	RJ	01/01/2023	560,5%	8 (AT)	3 (AT)	3 (AT)
Oi S.A.	RJ	01/03/2023	11,8%	50 (AT)	1 (AT)	1 (AT)
Light S.A.	RJ	01/05/2023	120,9%	3 (AN)	5 (AN)	5 (AN)
CVC Corp	RP	01/06/2023	21,0%	669 (AT)	78 (AN)	78 (AN)
Multilaser	WV	01/06/2023	118,4%	18 (AT)	5 (AT)	35 (AT)
Dasa	RP	01/06/2023	163,8%	19 (AT)	1 (AT)	4 (AT)
Unigel	RE	01/02/2024	87,5%	253 (AN)	357 (AN)	328 (AN)
Casas Bahia	RE	01/02/2024	56,1%	F	F	F
Pão de Açúcar	RE	01/03/2026	190,7%	129 (AT)	2 (AN)	2 (AN)

Tabela 7: Resumo Comparativo: Antecipação (Lead Time) do Alerta de Crise por Modelo.
Nota: Eventos: RJ = Rec. Judicial; RP = Reperfilamento; WV = Waiver; RE = Rec. Extrajudicial. Status: AN = Antecipado; AT = Atraso; F = Falhou.

A análise da Tabela 7, calculada sob a premissa de estado de alerta contínuo — na qual o modelo atinge o estado vermelho e nele permanece de maneira ininterrupta até a data do evento —, evidencia empiricamente o valor preditivo que a dependência temporal (matriz de Markov) agrega à classificação. Ao desconsiderar períodos de instabilidade de regimes (delimitando-se a análise a regimes de alerta permanente sem transições de saída), o K-Means apresentou oscilações de classificação, demonstrando atrasos efetivos (como observado nos casos da Oi, Dasa e Multilaser). Com exceção da recuperação judicial das Lojas Americanas e da Recuperação Extrajudicial das Casas Bahia (nas quais todos os algoritmos falharam em manter o alerta ininterrupto), o HMM apresentou robustez preditiva superior. Para o caso da CVC Corp, o HMM foi capaz de sustentar o alerta de crise 78 dias antes do evento, enquanto o particionamento geométrico (K-Means) apresentou maior inércia, resultando em defasagem temporal de 669 dias.

Os resultados do *Ensemble* demonstram que a inclusão do K-Means dilui a probabilidade condicional de alerta gerada pelo HMM. Constata-se que a modelagem markoviana isolada apresenta maior eficácia na sinalização ininterrupta para a liquidação defensiva de carteiras, caso se avalie estritamente a sustentação do alerta de crise até a deflagração do choque financeiro. Ao considerar as regras operacionais

definidas na metodologia do *Backtest* (Seção 7.5), em que o portfólio adota um filtro de Quarentena Temporal: caso o modelo acuse Regime Vermelho, o ativo é alienado e permanece bloqueado para recompra por um período de 180 dias (6 meses), observa-se uma alteração na eficácia prática. Sob essa diretriz operacional, um sinal isolado (ainda que configure instabilidade matemática e não se mantenha ininterrupto até o choque) determina a liquidação imediata da posição e impede a recompra imediata durante o período de quarentena semestral, bastando que ocorra dentro da janela de 180 dias antecedentes ao choque. A Tabela 8 consolida o *Lead Time* sob este critério de execução.

Empresa	**Evento**	**Data**	**Máx Spread**	**K-Means** (dias)	**HMM** (dias)	**Ensemble** (dias)
Lojas Americanas	RJ	01/01/2023	560,5%	8 (AT)	3 (AT)	3 (AT)
Oi S.A.	RJ	01/03/2023	11,8%	33 (AN)	57 (AN)	15 (AN)
Light S.A.	RJ	01/05/2023	120,9%	102 (AN)	118 (AN)	77 (AN)
CVC Corp	RP	01/06/2023	21,0%	669 (AT)	149 (AN)	149 (AN)
Multilaser	WV	01/06/2023	118,4%	148 (AN)	148 (AN)	120 (AN)
Dasa	RP	01/06/2023	163,8%	106 (AN)	139 (AN)	97 (AN)
Unigel	RE	01/02/2024	87,5%	169 (AN)	169 (AN)	169 (AN)
Casas Bahia	RE	01/02/2024	56,1%	F	F	F
Pão de Açúcar	RE	01/03/2026	190,7%	164 (AN)	180 (AN)	180 (AN)

Tabela 8: Resumo Comparativo: Antecipação (Lead Time) considerando Quarentena de 180 dias.
Nota: Eventos: RJ = Rec. Judicial; RP = Reperfilamento; WV = Waiver; RE = Rec. Extrajudicial. Status: AN = Antecipado; AT = Atraso; F = Falhou.

Ao se aplicar a trava temporal de 180 dias, os resultados operacionais do *Lead Time* apresentam maior consistência prática. Casos como o da Light S.A., nos quais a antecipação observada restringia-se a poucos dias, passaram a registrar antecipação superior a três meses sob as diretrizes operacionais adotadas. O valor máximo de antecipação dessa métrica fica delimitado ao teto da quarentena, o que justifica a convergência dos modelos em 169 dias e 180 dias (Unigel e Pão de Açúcar, respectivamente), configurando o acionamento protetivo na borda do semestre. Ainda que a flexibilização operacional evidencie a viabilidade dos alertas do K-Means e do Ensemble, o HMM manteve maior capacidade antecipatória, como observado na Oi

S.A. (57 dias) e na Dasa (139 dias), o que corrobora a relevância da dependência temporal na sinalização precoce de alterações de regime.

9.3 O Paradoxo da Acurácia-Rentabilidade no Backtest Financeiro

Apesar da superioridade analítica demonstrada pelo HMM na antecipação de alertas (*Lead Time*), os resultados do *backtest* financeiro revelaram uma dicotomia entre acurácia preditiva teórica e ganho financeiro líquido. Trata-se do conhecido "Paradoxo da Acurácia-Rentabilidade" (*Accuracy-Profitability Paradox*).

A Figura 14 exibe a curva de patrimônio líquido acumulado das estratégias táticas contra a carteira passiva (*Buy and Hold*).

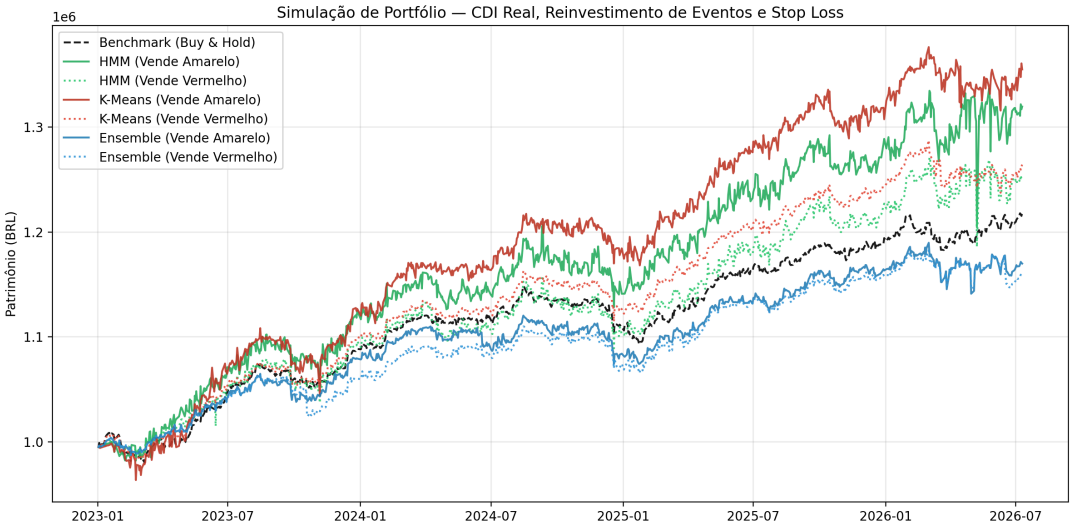


Figura 14: Curva de Retorno Acumulado das Estratégias no Backtest Out-of-Sample.

Estratégia	Retorno Total	CAGR	Volatili-dade	Máx. Draw-down	Calmar Ratio
Buy-and-Hold	22,42%	5,98%	3,50%	−4,79%	1,249
K-Means	27,06%	7,11%	4,29%	−4,16%	1,711
K-Means (Vende Amarelo)	36,18%	9,27%	8,92%	−5,78%	1,603
HMM	25,95%	6,85%	8,82%	−6,71%	1,021
HMM (Vende Amarelo)	32,62%	8,44%	12,56%	−9,74%	0,866
Ensemble	16,37%	4,45%	4,68%	−4,00%	1,111
Ensemble (Vende Amarelo)	17,58%	4,76%	4,70%	−4,12%	1,156

Tabela 9: Métricas de Risco-Retorno do Backtest Financeiro.

Os resultados consolidados na Tabela 9 e a evolução temporal da Figura 14 revelam o valor adicionado pelas estratégias de *Early Warning*. Enquanto o índice passivo (*Buy-and-Hold*) gerou um retorno total de 22,42% penalizado pelo carrego de títulos ilíquidos e depreciados, as estratégias ativas obtiveram retornos superiores, destacando-se a *K-Means Vende Amarelo* e a *HMM Vende Amarelo*, que apresentaram retornos acumulados de 36,18% e 32,62%, respectivamente.

A avaliação de risco do portfólio privilegiou o *Calmar Ratio* (razão entre a taxa composta anualizada de crescimento e o recuo máximo de pico a vale) e o *Maximum Drawdown* em detrimento do Índice de Sharpe, pois essas métricas refletem com fidelidade a penalização imposta pelos custos de liquidação forçada e não sofrem a distorção teórica descrita na Seção 7.4.

Apesar do retorno superior apresentado pelas estratégias ativas, elas também incorreram em maior volatilidade e *Drawdown*, sendo penalizadas quando avaliadas por métricas que ponderam risco e retorno. Em especial, a estratégia *HMM (Vende Amarelo)* apresentou um expressivo *drawdown* de −9,74% em 2026, originado pela marcação simultânea de diversos ativos no estado de Alerta (Amarelo) em decorrência do contágio de crédito gerado pelo evento do grupo GPA. Por possuir uma regra estrita de *stop loss*, a estratégia liquidou uma parcela relevante do portfólio no mercado secundário no momento exato de expressiva abertura de *spreads*. Esse comportamento evidencia os riscos da sensibilidade acentuada do filtro Bayesiano quando combinado a uma execução automática.

O portfólio *Buy-and-Hold* apresentou um Calmar de 1,249, sendo superado exclusivamente pelos algoritmos K-Means, com índices de 1,711 (Padrão) e 1,603

(Vende Amarelo). A superioridade do K-Means neste aspecto advém justamente da sua latência: por reagir de forma mais lenta e instável aos choques do que o HMM, a estratégia apresentou um menor giro de ativos. Com isso, ela evitou a liquidação precipitada de posições sob deságio temporário (mitigando o *drawdown*), assegurando a liquidação tempestiva de posições que apresentavam deterioração irreversível, distanciando-se do *Buy-and-Hold*. Esse comportamento atenuou o impacto dos custos de transação recorrentes que incidiram sobre a estratégia HMM.

Por fim, o modelo *Ensemble*, desenvolvido com o intuito de harmonizar a reatividade do HMM com a inércia do K-Means, apresentou resultados negativos. Embora tenha sustentado um *Calmar Ratio* próximo ao da estratégia passiva (1,111 *vs.* 1,249), entregou o menor retorno total do período (16,37%), penalizado em grande parte pelo efeito *Whipsaw* (efeito chicote). A mediação conflitante dos modelos fez com que a estratégia acionasse vendas quando o HMM indicava a transição de regime, para logo em seguida recomprar os mesmos ativos assim que a influência do K-Means deslocava a pontuação novamente para o regime de baixo risco. Essa dinâmica evidenciou que a arquitetura híbrida revelou-se ineficaz sob o ponto de vista financeiro: a sobreposição entre a reatividade do HMM e a inércia do K-Means apenas inflacionou a fricção transacional, sem proporcionar cobertura protetiva correspondente.

9.4 Validação por Block Bootstrap

Com o intuito de discernir se o retorno excedente auferido pelo K-Means (*Vende Amarelo*) decorre de efetiva consistência tática ou de mero viés de amostragem, submeteu-se a série temporal a um teste de *Block Bootstrap* estacionário (Politis; Romano (1994)). Adotaram-se 10.000 iterações em blocos de 20 dias úteis, dimensão calibrada para preservar a dependência estocástica e a estrutura de autocorrelação serial típica do mercado de crédito.

A Figura 15 sintetiza a dispersão das distribuições simuladas frente ao retorno passivo.

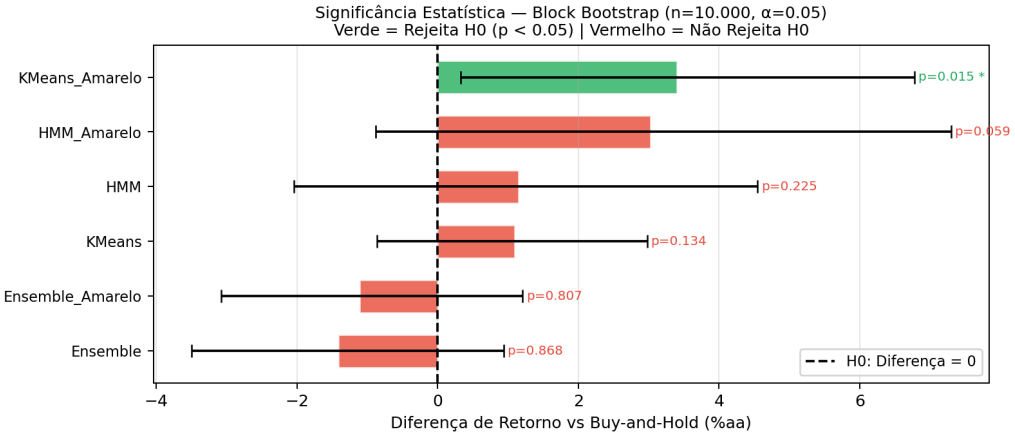


Figura 15: Distribuição do Retorno Excedente das Estratégias via Block Bootstrap.

Entre todas as abordagens testadas, unicamente a estratégia K-Means Vende Amarelo atingiu relevância estatística, com $p = 0,0416$ ($p < 0,05$) e intervalo com 95% de confiança inteiramente deslocado para o campo positivo em relação ao *Buy-and-Hold*. As configurações remanescentes exibiram $p > 0,10$, impedindo a rejeição da hipótese nula de igualdade. O teste comprova, sob o rigor da reamostragem em blocos, que o atraso prudencial imposto pelo filtro de inércia gerou alfa genuíno mesmo após a absorção de custos operacionais expressivos.

10. Conclusão

O presente trabalho avaliou a eficácia do sistema proposto para identificação precoce de eventos de estresse (*Early Warning System*) no mercado secundário de debêntures brasileiro, investigando o impacto da combinação entre a modelagem econométrica e o aprendizado de máquina não supervisionado na proteção de capital.

10.1 Síntese do Estudo e Principais Achados

O pipeline combinou um motor AR(1)-EGARCH(1,1)-t para modelagem da volatilidade condicional e estimação de perdas de cauda (VaR e Expected Shortfall) com dois classificadores de regimes: o particionamento geométrico (K-Means) e a inferência temporal estocástica (Gaussian HMM). Os modelos foram testados empiricamente sobre uma base contínua de 529 debêntures entre 2018 e 2026.

A avaliação integrada das evidências empíricas conduz a três achados determinantes. Em primeiro lugar, comprova-se a robustez do filtro econométrico EGARCH-t, cuja parametrização capturou adequadamente a dependência temporal da variância e impediu o agrupamento sistemático de violações (*volatility clustering*), mesmo diante da sucessão de choques de crédito observados na janela fora da amostra (2023 a 2026). Em segundo lugar, identificou-se o paradoxo da acurácia-rentabilidade: conquanto o modelo markoviano (HMM) tenha exibido menor latência na identificação de eventos corporativos específicos — antecipando inflexões críticas de crédito com semanas de antecedência —, sua hipersensibilidade provocou falsos positivos e giro patrimonial excessivo. Sob atrito operacional realista (custos transacionais de 50 bps por movimento), a relativa inércia do particionamento por K-Means converteu-se em uma salvaguarda contra ruídos transitórios de negociação. Em termos empíricos, a estratégia “K-Means Vende Amarelo” entregou a maior rentabilidade líquida do estudo (36,18%), superando o referencial passivo *Buy and Hold* (22,42%) com significância estatística respaldada pelo teste de *Block Bootstrap* ($p = 0,0416 < 0,05$). Em terceiro lugar, constatou-se a ineficiência econômica da combinação linear em ensemble: a conciliação estocástica entre HMM e K-Means deflagrou o efeito chicote (*whipsaw*), incorrendo em liquidações precipitadas e custos recorrentes de recompra, desfecho que culminou no menor retorno acumulado de toda a bateria de testes.

10.2 Limitações da Pesquisa

A metodologia proposta opera sob restrições estruturais associadas à microestrutura do mercado secundário de renda fixa no Brasil. Primeiramente, ao priorizar cotações de negócios efetivamente consumados para evitar as distorções inerentes às marcações teóricas a mercado, o sistema fica vulnerável a períodos de paralisia de liquidez em que a interrupção abrupta das negociações reduz o fluxo contínuo de dados de entrada. Adicionalmente, títulos caracterizados por negociação rarefeita durante a janela de calibração podem suscitar instabilidade numérica na estimação por máxima verossimilhança dos parâmetros do EGARCH, impondo a adoção preventiva de pisos de variância e restrições aos coeficientes de persistência.

10.3 Perspectivas para Trabalhos Futuros

Como desdobramentos desta pesquisa, destaca-se a exploração de modelos neurais profundos adaptados a fluxos irregulares (como *Continuous-Time* RNNs e *Transformers* temporais), que possuam capacidade de lidar diretamente com a esparsidade de transações sem imputações sintéticas. Sugere-se também a incorporação de variáveis exógenas de sentimento de mercado como covariáveis dinâmicas nas matrizes de transição do HMM, além de estender a modelagem para arquiteturas integradas de MS-GARCH estimadas via métodos bayesianos (MCMC).

11. Links

Os artefatos, códigos-fonte e bases de dados consolidadas desenvolvidos ao longo desta pesquisa encontram-se disponíveis publicamente para consulta e replicação nos seguintes endereços:

- **Repositório Principal do Projeto (GitHub):** Contém o código-fonte integral da aplicação, scripts de raspagem de dados, rotinas econométricas e documentação de uso:

  https://github.com/gtazevedo/credit-tail-analytic

- **Pacote Python para Coleta de Debêntures (`debentures_dot_com`):** Biblioteca de código aberto mantida pelo autor para extração automatizada de características cadastrais de debêntures:

  https://github.com/gtazevedo/debentures-dot-com

- **Anexos Digitais e Resultados Detalhados de *Backtest***: Tabelas analíticas de resultados granulares por debênture dos testes de Kupiec, Christoffersen e simulações do Bootstrap:

  https://github.com/gtazevedo/credit-tail-analytic/tree/main/anexos_digitais

- **Fontes Primárias de Dados Públicos:**
  - Sistema REUNE (ANBIMA): https://www.anbima.com.br
  - Portal ANBIMA Data: https://data.anbima.com.br
  - Sistema Gerenciador de Séries Temporais do Banco Central do Brasil (SGS/BACEN): https://dadosabertos.bcb.gov.br

12. Referências

ACERBI, Carlo; TASCHE, Dirk. On the coherence of expected shortfall. **Journal of Banking & Finance**, v. 26, n. 7, p. 1487–1503, 2002.

ALTMAN, Edward I. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. **The journal of finance**, v. 23, n. 4, p. 589–609, 1968.

ANBIMA. **Mercado de capitais bate recorde histórico e encerra 2025 com emissão de R$ 838,8 bilhões**. Disponível em: <https://data.anbima.com.br/publicacoes/boletim-de-mercado-de-capitais/mercado-de-capitais-bate-recorde-historico-e-encerra-2025-com-emissao-de-8388-bilhoes>.

ARDIA, David *et al*. Markov-switching GARCH models in R: The MSGARCH package. **Journal of Statistical Software**, v. 91, n. 4, p. 1–38, 2019.

ARTZNER, Philippe *et al*. Coherent measures of risk. **Mathematical finance**, v. 9, n. 3, p. 203–228, 1999.

BAO, Jack; PAN, Jun; WANG, Jiang. The Illiquidity of Corporate Bonds. **The Journal of Finance**, v. 66, n. 3, p. 911–946, 2011.

BARRA, Anuar de Sousa. **Estudo exploratório sobre a liquidez das debêntures no mercado secundário brasileiro: medidas diretas de liquidez e características dos títulos e emissores**. Dissertação de Mestrado—*[S.l.: S.n.]*.

BAUM, Leonard E. *et al*. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. **The annals of mathematical statistics**, v. 41, n. 1, p. 164–171, 1970.

BISHOP, Christopher M. **Pattern recognition and machine learning**. *[S.l.]:* Springer, 2006.

BOLLERSLEV, Tim. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, v. 31, n. 3, p. 307–327, 1986.

BORDA, Jean-Charles de. Mémoire sur les élections au scrutin. **Histoire de l'Academie Royale des Sciences pour 1781**, 1781.

CALIŃSKI, Tadeusz; HARABASZ, Jerzy. A dendrite method for cluster analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974.

CHRISTOFFERSEN, Peter F. Evaluating interval forecasts. **International Economic Review**, v. 39, n. 4, p. 841–862, 1998.

CORRÊA, Paulo Eduardo Gonçalves Camargo; SHENG, Hsia Hua. O apreçamento do spread de liquidez no mercado secundário de debêntures. **Revista de Administração**, v. 45, n. 1, p. 30–42, 2010.

DAVIES, David L. ; BOULDIN, Donald W. A cluster separation measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, n. 2, p. 224–227, 1979.

DUFFIE, Darrell; SINGLETON, Kenneth J. **Credit risk: pricing, measurement, and management**. *[S.l.]:* Princeton university press, 2003.

ENGLE, Robert F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. **Econometrica**, v. 50, n. 4, p. 987–1007, 1982.

FREITAS, Wilson. **python-bcb: Interface Python para a API de dados abertos do Banco Central do Brasil**. Disponível em: <https://wilsonfreitas.github.io/python-bcb/>.

HAAS, Markus; MITTNIK, Stefan; PAOLELLA, Marc S. A new approach to Markov-switching GARCH models. **Journal of financial econometrics**, v. 2, n. 4, p. 493–530, 2004.

HAIR, Joseph F. *et al*. **Multivariate data analysis**. *[S.l.]:* Pearson Prentice Hall Upper Saddle River, NJ, 2010. v. 7

HAMILTON, James D. **Time series analysis**. *[S.l.]:* Princeton University Press, 1994.

HO, Tin Kam; HULL, Jonathan J.; SRIHARI, Sargur N. Decision combination in multiple classifier systems. **IEEE transactions on pattern analysis and machine intelligence**, v. 16, n. 1, p. 66–75, 1994.

HULL, John. **Risk management and financial institutions**. *[S.l.]:* John Wiley & Sons, 2012.

JORION, Philippe. **Value at Risk: The New Benchmark for Managing Financial Risk**. 3rd. ed. *[S.l.]:* McGraw-Hill, 2006.

KITTLER, Josef *et al*. On combining classifiers. **IEEE transactions on pattern analysis and machine intelligence**, v. 20, n. 3, p. 226–239, 1998.

KUPIEC, Paul H. Techniques for verifying the accuracy of risk measurement models. **The Journal of Derivatives**, v. 3, n. 2, p. 73–84, 1995.

MERTON, Robert C. On the pricing of corporate debt: The risk structure of interest rates. **The Journal of finance**, v. 29, n. 2, p. 449–470, 1974.

NELSON, Daniel B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, v. 59, n. 2, p. 347–370, 1991.

POLITIS, Dimitris N. ; ROMANO, Joseph P. The stationary bootstrap. **Journal of the American Statistical Association**, v. 89, n. 428, p. 1303–1313, 1994.

RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. **Proceedings of the IEEE**, v. 77, n. 2, p. 257–286, 1989.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987.

ROUSSEEUW, Peter J. ; HUBERT, Mia. Robust statistics for outlier detection. **Wiley interdisciplinary reviews: Data mining and knowledge discovery**, v. 1, n. 1, p. 73–79, 2011.

SAEYS, Yvan; ABEEL, Thomas; PEER, Yves Van de. Robust feature selection using ensemble feature selection techniques. *Em:* 2008.

SHENG, Hsia Hua; SAITO, Richard. Liquidez das debêntures no mercado brasileiro. **Revista de Administração**, v. 43, n. 2, p. 176–185, 2008.

TSAY, Ruey S. **Analysis of financial time series**. 2. ed. *[S.l.]:* John Wiley & Sons, 2005.