

Nome da Universidade / Instituição

Guilherme Tolotti Azevedo

**MODELAGEM DE RISCO DE CAUDA NO MERCADO DE CRÉ-
DITO PRIVADO: UMA ABORDAGEM HÍBRIDA VIA EGARCH-T
E MODELOS OCULTOS DE MARKOV**

Dissertação apresentada como requisito parcial
para obtenção do grau de Especialista.
Orientador: Nome do Orientador

São Paulo, SP
2026

SUMÁRIO

Resumo	4
Abstract	5
Lista de Figuras	6
Lista de Tabelas	7
1 Introdução	8
1.1 O Problema de Pesquisa	8
1.2 Objetivos (Geral e Específicos)	9
2 Revisão da Literatura	11
2.1 Modelos de Early Warning de Crédito	11
2.2 Value-at-Risk e Modelos da Família GARCH	12
2.2.1 Expected Shortfall (ES) e Testes de Backtesting	12
2.3 A Hipótese de Mudança de Regimes (Regime-Switching)	14
2.4 Aprendizado de Máquina Não Supervisionado	14
2.4.1 K-Means	15
2.4.2 Hidden Markov Models (HMM)	16
2.5 Seleção de Atributos e Avaliação de Clusters	17
3 Metodologia e Dados	19
3.1 Coleta e Tratamento de Dados (ANBIMA)	19
3.2 O Pipeline de Risco (EGARCH, K-Means e HMM)	21
3.2.1 Pré-processamento de Dados e Filtros	23
3.2.2 EGARCH	24
3.2.3 Teste de Estacionariedade dos Spreads	28
3.2.4 Seleção de variáveis	29
3.2.5 K-Means	33
3.2.6 HMM	35
3.2.7 Modelo Misto (Ensemble)	37
3.3 Protocolos de Validação (Kupiec POF e Backtest)	39
4 Resultados e Discussões	41
4.1 Validação Estatística dos Motores	41
4.2 O Desempenho do HMM vs K-Means na Classificação	43
4.2.1 K-Means	44
4.2.2 HMM	46
4.2.3 Ensemble	47
4.3 Simulação de Portfólio (Backtest Financeiro)	47
4.3.1 Significância Estatística das Estratégias — Block Bootstrap	50

4.3.2 Discussão sobre a Generalização dos Resultados	51
5 Conclusão	53
5.1 Principais Descobertas	53
5.2 Implicações Práticas	54
5.3 Limitações e Recomendações para Trabalhos Futuros	54
Bibliografia	56

RESUMO

O mercado secundário de crédito privado brasileiro, com foco em debêntures, apresenta o desafio da escassez de liquidez estrutural e da assimetria de retornos. Recentes eventos de estresse em grandes empresas corporativas brasileiras expuseram a incapacidade de métricas tradicionais de risco (como o VaR) em precificar corretamente o risco de cauda e alertar investidores de forma tempestiva. Neste contexto, este trabalho propõe a construção e a validação de um **Early Warning System** tático, arquitetado como um modelo de múltiplos estágios que combina aprendizado de máquina não supervisionado e volatilidade condicional. Inicialmente, o motor EGARCH-t é empregado para filtrar a variância condicional e amortecer o risco isolado, mitigando os retornos não-normais e padronizando as características latentes dos ativos. Posteriormente, o algoritmo K-Means e os Modelos Ocultos de Markov (HMM) particionam os ativos em três regimes de risco distintos: baixo risco, alerta e crise. O estudo demonstra a dicotomia inerente entre as abordagens topológicas e probabilísticas: enquanto o HMM evidencia maior acurácia de decodificação a mercado e reatividade temporal aos choques, o K-Means atinge os melhores retornos ajustados ao risco em simulações financeiras (**Backtest**), atuando como um filtro de inércia que poupa o portfólio de alarmes falsos e custos transacionais. Por fim, a pesquisa valida a ineficácia do modelo **Ensemble** misto. Os resultados comprovam a viabilidade e a superioridade de sistemas autônomos e táticos de crédito na proteção do capital frente a estratégias passivas (**Buy and Hold**) durante choques extremos.

Palavras-chave: Risco de Crédito. Early Warning. Debêntures. EGARCH. Cadeias de Markov. K-Means.

ABSTRACT

The secondary market for Brazilian private credit, particularly debentures, faces structural challenges regarding liquidity and asymmetric returns. Recent credit events in large corporations have exposed the inability of traditional risk metrics (such as VaR) to properly price tail risk and warn investors in a timely manner. In this context, this study proposes the construction and validation of a tactical Early Warning System, architected as a multi-stage model combining unsupervised machine learning and conditional volatility. Initially, the EGARCH-t engine is employed to filter conditional variance and dampen isolated risk, standardizing non-normal returns. Subsequently, the K-Means algorithm and Gaussian Hidden Markov Models (HMM) partition the assets into three distinct risk regimes: low risk, warning, and crisis. The study demonstrates an inherent dichotomy between the topological and probabilistic approaches: while the HMM shows higher mark-to-market decoding accuracy and temporal reactivity to shocks, the K-Means achieves the best risk-adjusted returns in financial simulations (Backtest) by acting as an inertia filter that saves the portfolio from false alarms and transaction costs. Finally, the research validates the ineffectiveness of the mixed Ensemble model. The results confirm the viability and superiority of autonomous tactical credit systems in preserving capital against passive (Buy and Hold) strategies during extreme market shocks.

Keywords: Credit Risk. Early Warning. Debentures. EGARCH. Markov Chains. K-Means.

LISTA DE FIGURAS

Figura 1	Arquitetura do Pipeline de Risco e Backtest	22
Figura 2	Torneio GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.	25
Figura 3	Torneio GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.	25
Figura 4	Torneio GARCH: Ranking Médio para a amostra ampla de 5000 ativos.	26
Figura 5	Taxa de aprovação dos testes de diagnóstico nos resíduos padronizados do EGARCH(1,1,1) t-Student para 529 debêntures. ...	27
Figura 6	Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.	31
Figura 7	Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).	32
Figura 8	Elbow Method e Silhouette Score por número de clusters k — Superior: IPCA, Inferior: CDI Spread	34
Figura 9	Análise de Sensibilidade (Grid-Search) dos pesos do modelo Ensemble no período In-Sample	38
Figura 10	Sensibilidade da Não-Rejeição (Teste Conjunto) a Diferentes Níveis de Confiança	42
Figura 11	Resultados do K-Means para o Estudo de Caso do Grupo Pão de Açúcar (GPA)	45
Figura 12	Resultados do HMM para o Estudo de Caso do Grupo Pão de Açúcar (GPA)	46
Figura 13	Resultados do Ensemble para o Estudo de Caso do Grupo Pão de Açúcar (GPA)	47
Figura 14	Resultados do Backtest	48
Figura 15	Forest Plot — Diferença de Retorno vs. Buy-and-Hold com Intervalo de Confiança 95% (Block Bootstrap)	51

LISTA DE TABELAS

Tabela 1	Resultados do Teste ADF ($\alpha = 5\%$) — Estacionariedade por Indexador	29
Tabela 2	Métricas da grade de sensibilidade (In-Sample) por par de pesos. .	38
Tabela 3	Resultados do Teste de Kupiec (Não-Rejeição de H_0) por Nível de Confiança	41
Tabela 4	Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDA8	44
Tabela 5	Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDB8	44
Tabela 6	Métricas de Risco-Retorno do Backtest Financeiro	48
Tabela 7	Resultados do Block Bootstrap ($n = 10.000$, $\alpha = 5\%$, bloco=20 dias) — Significância Estatística vs. Buy-and-Hold	50

1 INTRODUÇÃO

O mercado de crédito privado brasileiro vem crescendo continuamente, e se consolidando como uma ferramenta de captação de recursos para as empresas, como se pode observar em ANBIMA (2026). Uma das principais ferramentas de crédito privado utilizadas são as debêntures, que tiveram um crescimento de 307% no volume de emissões quando comparamos o volume observado em 2020 contra o volume observado em 2025. Porém, esse mercado enfrenta problemas de liquidez, e conforme Sheng; Saito (2008), apresenta as seguintes características:

- As transações são dispersas e ocorrem em duas diferentes instituições - Bolsa de Valores de São Paulo (Bovespa Fix) e Sistema Nacional de Debêntures (SND);
- Existe baixa atividade, não havendo registro de transações para períodos longos e, em algumas emissões de debêntures, o volume de transações no mercado secundário é quase nulo e o valor total em reais é baixo;
- Existe um baixo número de negociações diárias;
- Predominância de debêntures de médio prazo (vencimento em torno de quatro anos);
- Demanda significativa por investidores institucionais e fundos de pensão;
- Em geral as emissões não são conversíveis em ações;
- Alguns investidores adquirem debêntures e as mantêm até o vencimento;

Apesar de algumas dessas características estruturais se manterem verdadeiras, como:

- A baixa liquidez (onde mais da metade das marcações diárias do mercado giram volumes inferiores a R\$ 1 milhão);
- A exclusividade de emissões do tipo simples;

e outras características, como:

- A baixa presença de pessoas físicas e investidores estrangeiros;
- O fato de os intermediários manterem os papéis na carteira até o vencimento;

serem reforçadas por estudos mais recentes como Barra (2021) e ANBIMA (2026), houve algumas mudanças relevantes que sugerem um amadurecimento institucional. A amostra deste estudo indica que as empresas têm conseguido alongar o perfil de suas dívidas, com as debêntures apresentando uma mediana de sete anos de prazo até o vencimento.

1.1 O Problema de Pesquisa

Apesar do crescimento e amadurecimento do mercado de crédito privado brasileiro, a baixa liquidez no mercado secundário representa um desafio para a precificação e acompanhamento de risco do papel. Estudos como Corrêa; Sheng (2010) focam em problemas de apreçamento do spread de crédito, enquanto estudos como Sheng; Saito (2008) analisam os fatores que afetam o prêmio de liquidez em debêntures. Contudo, muitos modelos assumem situações normais de mercado, enquanto outros fazem suposições ainda mais fortes que não condizem com a realidade do mercado brasileiro. Bancos e assets muitas vezes seguem controlando o risco de cauda de debêntures baseado em GARCH e VaR contínuos, que possuem suposições violadas quando ocorrem eventos extremos, e podem estar subestimando o risco observado.

Como demonstrado por Bao; Pan; Wang (2011), o mercado de crédito corporativo apresenta fricções de liquidez que impedem o ajuste contínuo dos preços, eventos recentes envolvendo o Grupo Pão de Açúcar e Americanas são exemplos dos saltos observados nos preços das debêntures desses emissores; No caso das Americanas, houve uma queda de 50% no valor das debentures em um dia, acumulando perdas de cerca de 90% em uma semana; Já no caso do Grupo Pão de Açúcar, foram observados deságios de até cerca de 70%. Nessas situações, modelos GARCH e VaR tradicionais falham em capturar o risco de cauda, uma vez que segundo Jorion (2006), assumem que a liquidação será instantânea a preço de tela. Para corrigir essas suposições e capturar quebras estruturais, a literatura mais moderna defende a transição para modelos baseados em mudanças de regime (Markov-Switching), conforme proposto por Haas; Mittnik; Paoletta (2004) e Ardia et al. (2019).

1.2 Objetivos (Geral e Específicos)

A proposta desse trabalho é desenvolver e avaliar os resultados de uma modelagem de risco de crédito adotada a realidade do mercado brasileiro de debêntures. Ao invés de tentarmos prever flutuações contínuas, o modelo busca identificar eventos de mudança de regime para disparar alertas de risco antes de que se observem grandes perdas, possibilitando ao detentor das debentures, um tempo hábil para tentar vender o papel antes que as perdas se materializem.

Para isso, serão utilizadas duas abordagens de modelagem de risco, uma baseada em K-Means e outra em HMM, ambas utilizando como features a volatilidade e o spread das debentures, utilizando dados abertos divulgados pela Anbima. Além disso, toda a aplicação, feita em python, será disponibilizada para consulta pública no

GitHub, permitindo que qualquer interessado possa replicar os resultados, incluindo o download das informações utilizadas no trabalho, já que os dados são públicos.

2 REVISÃO DA LITERATURA

A ideia central deste trabalho parte da modelagem de risco de crédito de debêntures. Mas, para entender esse conceito, é necessário entender primeiramente, “O que é risco?”. Existem várias definições, Jorion (2006) possui uma das mais simples e intuitivas, na qual afirma que risco é a volatilidade dos resultados inesperados, seja no valor de ativos, patrimônio ou resultados. E esse risco pode ser originado de várias formas, criados pelos humanos, como ciclos de negócios, inflação, mudanças políticas, guerras, etc., ou pode ocorrer devido a fenômenos naturais como terremotos, tsunamis, etc. É na tentativa de combater esses riscos que a economia cresce e as tecnologias se desenvolvem.

Parte significativa do mercado financeiro atual foi desenvolvida na tentativa de lidar ou compartilhar esses riscos. Ao mesmo tempo que o mercado se desenvolveu, foi gerada a necessidade de limitar as perdas potenciais sem deixar de tomar risco. Existem controles **ex post**, mas esses não conseguem garantir que as perdas sejam próximas ao limite desejado, ao depender da sorte, podem ser maiores. A solução é o uso de modelos quantitativos **ex ante** que limitam a exposição a determinados ativos ou fatores de risco baseados em distribuições de probabilidade, como por exemplo os modelos de **Value at Risk**.

2.1 Modelos de Early Warning de Crédito

Os primeiros sistemas formais de alerta precoce de **distress** corporativo remontam ao modelo de Altman (1968), que utiliza combinações lineares de índices financeiros (Altman Z-Score) para prever insolvência. Desde então, a literatura evoluiu para abordagens baseadas em modelos estruturais de crédito (Merton, 1974) e modelos de forma reduzida conforme apresentado por (Duffie; Singleton, 2003), que modelam o spread de crédito diretamente.

Contudo, esses modelos requerem dados contábeis de frequência trimestral ou anual e são inadequados para alertas de alta frequência em mercados secundários de baixa liquidez. Esta lacuna motiva a abordagem proposta neste trabalho, que utiliza exclusivamente dados de mercado (spread e volatilidade) para inferir o risco de crédito de forma diária, ou, se permitido pela capacidade de obtenção de informações, de forma intradiária.

2.2 Value-at-Risk e Modelos da Família GARCH

O **Value at Risk** (VaR) pode ser definido de forma intuitiva como a maior perda esperada de uma carteira em um determinado período de tempo, com um determinado nível de confiança. Ou, de forma mais formal, é o quantil da distribuição de ganhos e perdas projetadas para um horizonte de tempo. Muitas vezes para séries temporais, essa projeção é feita por meio de modelos da família GARCH (**Generalized Autoregressive Conditional Heteroskedasticity**), cuja formulação fundamental foi introduzida por Engle (1982) e posteriormente generalizada por Bollerslev (1986). Apesar de amplamente utilizado, o GARCH tradicional falha em choques assimétricos, como observamos nos eventos recentes envolvendo o Grupo Pão de Açúcar e Americanas. Para superar essa fraqueza, Nelson (1991) propõe o modelo EGARCH, que captura assimetrias na volatilidade dos ativos financeiros.

Matematicamente, a especificação da variância condicional do EGARCH(1,1) de Nelson (1991) é dada por:

$$\ln(\sigma_t^2) = \omega + \alpha \left[|z_{t-1}| - \sqrt{\frac{2}{\pi}} \right] + \gamma z_{t-1} + \beta \ln(\sigma_{t-1}^2) \quad (1)$$

Onde:

- σ_t^2 é a variância condicional no tempo t .
- z_t é o resíduo padronizado ($z_t = \varepsilon_t / \sigma_t$).
- α mensura o “efeito tamanho” (a magnitude do choque).
- γ captura o **efeito assimétrico** (o sinal do choque).
- β mede a persistência da volatilidade.

Se $\gamma < 0$, os choques negativos em $t - 1$ aumentam a variância em t mais do que choques positivos da mesma magnitude, diferentemente do modelo GARCH tradicional.

Contudo, além da assimetria, os retornos de ativos de crédito exibem forte leptocurtose (caudas pesadas), onde perdas extremas ocorrem com frequência superior ao previsto pela distribuição normal. Para contornar este problema, a modelagem EGARCH pode ser combinada a uma distribuição T de Student condicional, que permite modelar as caudas da distribuição por meio dos graus de liberdade nu.

2.2.1 Expected Shortfall (ES) e Testes de Backtesting

Apesar de sua ampla adoção, o VaR apresenta uma limitação matemática: ele não é uma medida de risco subaditiva e, conseqüentemente, não é uma métrica

“coerente” de risco, conforme Artzner et al. (1999). Em outras palavras, ele responde apenas à pergunta “Qual é a perda máxima esperada com 99% de confiança?”, sendo cego em relação ao que ocorre na cauda extrema, ou seja, ele desconsidera os 1% da distribuição e os impactos de um possível evento dessa cauda.

Para solucionar essa limitação, a literatura e regulações como Basileia III têm migrado para o **Expected Shortfall (ES)** (Acerbi; Tasche, 2002), que calcula a perda média esperada condicionada ao nível de confiança. Diferentemente do VaR, o ES é uma métrica de risco coerente e provê uma avaliação robusta da magnitude das perdas extremas. Ou seja, enquanto o VaR nos diz qual a perda máxima esperada, por exemplo, para um dia com 99% de confiança, o ES nos informa que a perda média esperada, caso ocorra um evento de quebra do VaR (os piores 1% dos cenários).

Adicionalmente, modelos de estimação de risco requerem validação estatística formal (**Backtesting**). Os dois métodos utilizados para validação do VaR são:

- **Teste de Proporção de Falhas (POF) de Kupiec** (Kupiec, 1995): Avalia a “Cobertura Incondicional”, ou seja, verifica se a quantidade total de falhas (quebras do limite do VaR)

é estatisticamente idêntica à proporção esperada.

- **Teste de Independência e Teste Conjunto de Christoffersen** (Christoffersen, 1998): Avalia a “Cobertura Condicional”. Testa se as violações do VaR ocorrem de forma agrupada no tempo

(**volatility clustering**). Se as violações forem estatisticamente independentes, o modelo prova que capturou e exauriu corretamente a dinâmica temporal da variância, resultando em um modelo validado no Teste Conjunto (que unifica e avalia simultaneamente a Cobertura Incondicional e a Independência).

Para formalizar a validação empírica do motor de volatilidade frente às anomalias discutidas, este estudo adota a seguinte hipótese:

- **H₀₁**: O modelo EGARCH-t **não** produz uma taxa de falhas estatisticamente compatível com o nível de confiança de 99% estipulado, i.e., a frequência empírica de violações

do VaR difere significativamente de 1%.

- **H₁₁**: O modelo EGARCH-t produz uma taxa de falhas estatisticamente compatível com 1%, e as violações ocorrem de forma independente no tempo.

A rejeição generalizada de H₀₁ no portfólio analisado indicaria inadequação estrutural do filtro de volatilidade para capturar as dinâmicas de cauda pesada no mercado secundário de debêntures.

2.3 A Hipótese de Mudança de Regimes (Regime-Switching)

Porém, mesmo o modelo EGARCH que possui o tratamento da assimetria dos retornos possui limitações. A família GARCH, como explicado por Tsay (2005), assume que os parâmetros do modelo (ou seja, os pesos ω , α , γ e β da Equação 1) e a “variância incondicional” não mudam ao longo do tempo. Eles são constantes, baseados em uma única média do comportamento global da série.

Devido a essa constância, esses modelos tem dificuldade em se adaptarem quando existe uma quebra de regime, como os eventos de crédito que foram comentados acima, que uma vez divulgados, alteram a dinâmica de negociação e preço dos papéis. As informações observadas antes do evento não deixam de possuir a mesma relevância para prever o comportamento futuro dos ativos afetados. Hamilton (1994) mostra que essas quebras estruturais ocorrem na maioria das series macroeconomicas ou financeiras que possuem um período suficientemente longo. Como solução a esse problema, o autor propõe a hipótese de mudanças de regime (**Regime-Switching**). Segundo essa teoria, a economia e os mercados não têm um estado único. Eles transitam entre diferentes estados, onde as equações que regem os preços mudam dependendo do regime atual. Para solucionar esse problema, foi proposto a utilização de Cadeias de Markov para modelar a transição entre diferentes estados da economia.

2.4 Aprendizado de Máquina Não Supervisionado

Enquanto alguns autores na literatura propõem a integração direta (como os modelos MS-GARCH unificados), neste trabalho adotam-se algoritmos não supervisionados para agrupar e classificar os regimes de risco latentes.

Algoritmos de clusterização baseados em distância espacial euclidiana são extremamente sensíveis a valores discrepantes (**outliers**) e grandezas numéricas não uniformes. No mercado de debêntures, onde os ativos apresentam distorções bruscas, a padronização dos dados (pré-processamento) é indispensável. Em vez de utilizar os escalonadores tradicionais, a literatura recomenda o uso de padronizadores robustos, como o RobustScaler. Este algoritmo subtrai a mediana e divide os dados pelo intervalo interquartil (IQR, ou seja, a diferença entre o 3º e o 1º quartil). Ao ancorar-se em quantis robustos, ele mitiga estatisticamente o peso das caudas anômalas (**outliers**) e permite que o agrupador avalie a matriz de características livre de distorções induzidas por anomalias momentâneas.

2.4.1 K-Means

Um algoritmo popular para problemas de clusterização é o **K-means** que particiona os dados em K grupos distintos, minimizando a variância intra-cluster. Para utilizá-lo no problema em questão, foram criados três clusters de acordo com o nível de risco do papel, de forma que o esperado é que conforme um papel começa apresentar durante o seu período de negociação uma variação mais errática do seu spread ele vá migrando do cluster de baixo ao cluster de alto risco.

Para entender melhor essa aplicação vamos tomar como base Bishop (2006), em nosso problema temos que identificar grupos ou **clusters** de dados em um espaço multidimensional. Suponha que esse espaço seja dado por $\{x_1, x_2, \dots, x_N\}$ onde cada um dos N pontos no espaço multidimensional é um vetor de dimensão D .

O objetivo do algoritmo de K-means é particionar os dados em K grupos distintos, de forma que a soma do quadrado das distancias de cada ponto com o vetor μ_k mais próximo seja minimizada. Ou de forma mais formal:

$$J = \sum_{\{n=1\}}^N \sum_{\{k=1\}}^K r_{nk} \|x_n - \mu_k\|^2 \quad (2)$$

Onde $r_{nk} \in \{0, 1\}$ é uma variável indicadora, onde $r_{nk} = 1$ se o ponto x_n foi alocado ao **cluster** k e $r_{nj} = 0$ para $j \neq k$, enquanto μ_k representa o vetor centroide do **cluster** k . O objetivo é encontrar os valores de r_{nk} e μ_k que minimizam J . Isso pode ser realizado por meio de um algoritmo iterativo, dividido em duas etapas, conhecido como Algoritmo de Lloyd (ou, mais genericamente, algoritmo de maximização de expectativa (EM)).

O modelo, por vezes apresenta um problema conhecido como **Label Switching**, no qual os centróides gerados recebem rótulos arbitrários, isso ocorre porque o algoritmo inicializa os centróides (μ_k) de forma aleatória e busca minimizar a soma das distancias quadráticas (conforme a Equação 2), independentemente dos rótulos atribuídos aos centróides. Porém, existem muitas formas conhecidas de tratar esse problema. A forma adotada nesse trabalho será detalhada em Seção 3.2.5, mas envolve a aplicação de um vetor de polaridade de risco para fixar os rótulos nos regimes Verde (baixo risco), Amarelo (alerta) e Vermelho (crise).

Apesar de sua eficiência em separar os períodos de forma estática, minimizando J , o K-Means é cego para o tempo: ele ignora a probabilidade de transição de um dia para o outro, e como será analisado posteriormente, isso dá maior estabilidade aos resultados, porém, faz com seu tempo de reação seja mais lento, ou em alguns casos seja insensível devido a uma quebra de regime abrupta.

2.4.2 Hidden Markov Models (HMM)

Para corrigir a imperfeição temporal do K-Means, utiliza-se o HMM (**Hidden Markov Model**), um modelo probabilístico estruturado classicamente por Rabiner (1989) e amplamente adotado para modelagem de dados sequenciais com estados latentes. Conforme detalhado por Bishop (2006), o HMM parte do princípio de que os dados medidos no mercado (como o **spread** e a volatilidade) são reflexos de um estado que não pode ser observado diretamente. Esse estado é a causa do comportamento dos preços, e é chamado de **variável latente** (ou *hidden state*).

Seja z_n a variável latente que representa o regime oculto do mercado no tempo n . No HMM, a dinâmica temporal é regida por um processo de Markov onde a probabilidade do estado atual z_n depende estritamente do estado imediatamente anterior $z_{\{n-1\}}$, denotado por $p(z_n | z_{\{n-1\}})$.

Como as variáveis latentes assumem K regimes categóricos (neste estudo, 3 níveis de risco), essa distribuição corresponde matematicamente à matriz de transição de estados A . Adicionalmente, o modelo é governado pelas probabilidades de emissão B , que descrevem a distribuição contínua das observações x_n dado o estado z_n (modeladas aqui por distribuições Gaussianas), e pelo vetor de probabilidades iniciais π . Em conjunto, o modelo é parametrizado por $\theta = \{A, B, \pi\}$.

Segundo Rabiner (1989), a viabilidade do HMM depende da solução matemática de dois problemas fundamentais presentes na arquitetura do motor de risco: a calibração dos parâmetros θ e a decodificação da sequência ótima de regimes.

Para calibrar o HMM sem possuir os rótulos originais de crise, utiliza-se o algoritmo de **Baum-Welch**, um caso especial do algoritmo de **Expectation-Maximization** (EM). Na etapa de Expectativa (**E-Step**), estimam-se as probabilidades de cada estado usando o procedimento **Forward-Backward** formalizado por Baum et al. (1970). A etapa **Forward** calcula as probabilidades observando o histórico até n , denotado por $\alpha(z_n)$, enquanto a etapa **Backward** condensa a probabilidade sob a ótica do futuro de n em diante, denotado por $\beta(z_n)$.

Na etapa de Maximização (**M-Step**), as matrizes A , B e o vetor π são iterativamente atualizados por Máxima Verossimilhança até a convergência. Uma vez calibrado o HMM, a identificação do nível de risco no tempo n é realizada filtrando a probabilidade condicional de cada regime, ou ainda, decodificando a trajetória oculta mais provável via **Algoritmo de Viterbi**. Dessa forma, o HMM captura simultaneamente a topologia multivariada dos dados e a inércia estrutural das transições de crédito.

2.5 Seleção de Atributos e Avaliação de Clusters

Para que os algoritmos não-supervisionados (como o K-Means) convirjam para partições representativas, a escolha adequada das variáveis de entrada é crucial. Como, diferentemente de algoritmos supervisionados, não existem os rótulos esperados para guiar os modelos, a qualidade do agrupamento deve ser mensurada matematicamente por meio de métricas de validação interna da geometria dos grupos gerados:

1. **Silhouette Score** (Rousseeuw (1987)): Mede a coesão intra-cluster frente à separabilidade inter-cluster, variando no intervalo $[-1, 1]$. Nesta métrica, valores maiores indicam melhor adequação, ou seja, valores próximos a 1

sugerem clusters perfeitamente densos e bem separados, enquanto valores próximos a 0 ou negativos indicam forte sobreposição.

2. **Índice Davies-Bouldin** (Davies; Bouldin (1979)): Avalia a razão média da dispersão interna do cluster pela distância euclidiana entre os centróides, penalizando sobreposições. Diferente do Silhouette, nesta métrica valores menores indicam melhor adequação, pois

um índice menor (com limite inferior tendendo a zero) significa que os clusters são compactos internamente e distantes uns dos outros.

3. **Índice Calinski-Harabasz** (Caliński; Harabasz (1974)): Mensura a razão entre a variância inter-cluster e a variância intra-cluster, ponderada pelos graus de liberdade do sistema. Para este índice, valores maiores indicam melhor adequação,

denotando que a distância entre os centros dos clusters é expressivamente maior que a dispersão dos pontos dentro de cada regime.

Dado que não existe uma solução unificada no Aprendizado de Máquina, frequentemente estas três métricas fornecem orientações sobre qual o melhor particionamento. A solução matemática moderna para este dilema repousa sobre as heurísticas de consenso (ou **Ensembles**). O **Método de Borda (Borda Count)**, tradicionalmente um sistema de votação, foi historicamente introduzido por (Borda, 1781), contudo, sua adaptação computacional moderna o torna um mecanismo imparcial e poderoso para consolidar múltiplos sistemas de classificação e validação multivariada. Esse método foi amplamente estendido na literatura moderna de Aprendizado de Máquina, sendo validado na construção de classificadores de consenso por Ho; Hull; Srihari (1994) e Kittler et al. (1998), bem como na seleção robusta de atributos (**ensembles**) por Saeys; Abeel; Peer (2008). No contexto deste trabalho, as partições (**features**) são pontuadas pela posição ordinal que alcançaram em cada métrica isolada. Somando-se as avaliações de Borda, o analista mitiga o viés puramente individual de cada

índice e converge deterministicamente para o subconjunto dimensionalmente mais democrático e robusto.

3 METODOLOGIA E DADOS

A análise do risco de crédito das debentures requer uma coleta extensa de dados e análise rigorosa de sua qualidade para que o modelo implementado seja acurado e capaz de capturar as nuances desejadas. Este capítulo detalha os procedimentos que foram adotados para a coleta, tratamento e análise dos dados. Além dos modelos e validações aplicados neste estudo.

Uma vez que o estudo será disponibilizado juntamente dos códigos-fonte utilizados para sua implementação, todos os procedimentos detalhados abaixo podem ser replicados pelo leitor de forma independente. Para facilitar a reprodução, as funções utilizadas em cada etapa serão citadas, a fim de auxiliar a compreensão do leitor. Os detalhes sobre a utilização de cada função e da ferramenta como um todo poderão ser encontrados na documentação do projeto disponível no repositório do GitHub.

3.1 Coleta e Tratamento de Dados (ANBIMA)

Os dados base de spread por debenture e dia, que alimentam essa pesquisa foram extraídos do site da ANBIMA, mais especificamente na seção de Prévias Públicas de Negociação de Instrumentos Financeiros, que pertence ao sistema REUNE. O período da amostra foi do segundo dia de janeiro de 2018 a 10 de julho de 2026. Os dados diários extraídos possuem as seguintes colunas: Código Cetip, Tipo, Agrupamento, Taxa Mínima, Taxa Média, Taxa Máxima, Preço Mínimo, Preço Médio, Preço Máximo e Faixa de Volume. O leitor pode replicar esse download por meio da classe `data.anbima_scraper.AnbimaScraper`; para maior comodidade também se pode utilizar `data.run_scraper_full.rodar_extracao` e posteriormente `data.unify_csvs.unify_csvs`, uma vez que o download gera um arquivo csv por dia de consulta.

Já as informações cadastrais foram obtidas na página Debentures.com.br (que será substituída pelo ANBIMA Data) por meio de consulta utilizando o pacote `debentures_dot_com`. As informações obtidas são referentes a emissão das debentures e incluem informações como: Ticker, Indexador, Data de Emissão, Data Vencimento, Empresa, CNPJ, Emissão, Situação, Classe, Garantia, Quantidade Emitida, Quantidade Mercado, Taxa Emissão, Motivo de Saída, entre outras; para mais informações sobre os campos citados ou campos disponíveis consultar a página do ANBIMA Data

e/ou o pacote `debentures_dot_com`. O leitor pode replicar esse download por meio da função `data.build_cadastro.build_cadastro_mestre`.

As informações macroeconômicas (CDI, Selic, IPCA Mensal e 12M e IGPM Mensal) foram extraídas utilizando o pacote `python-bcb`. O leitor pode replicar esse download por meio da função `data.download_macro.download_macro_data`, que é uma aplicação direta do pacote de Freitas ([S.d.]) para as variáveis de interesse para a pesquisa.

Na etapa de pré-processamento, mais detalhada em Seção 3.2.1, foi realizada a normalização e tratamento das variáveis. Como a base de dados extraída da ANBIMA abrange múltiplos indexadores (como IPCA+, DI+ e % do CDI), foi necessário separar esse grupos treinar e aplicar o modelo de forma independente, criando uma instância de modelagem por indexador, conforme será detalhado nas sessões seguintes, uma vez que os papéis de diferentes indexadores possuem comportamento de risco distintos, assim como distinta sensibilidade a variação da taxa.

Como citado em Seção 1, um desafio inerente ao mercado secundário de crédito privado brasileiro é a baixa liquidez dos ativos, inclusive com alguns chegando a possuir dias sem negociação. A ANBIMA classifica o volume de negociação em faixas, sendo a faixa mais baixa dada por “Até 1MM”, e portanto, dado as informações possuídas na realização dessa pesquisa, esses são os ativos definidos como ilíquidos. No código implementado, desenvolveu-se uma rotina de tratamento governada pela flag `filter_low_liquidity`. Quando habilitada, essa rotina remove da base de dados para treinamento (que será detalhada posteriormente), os ativos que permaneceram como ilíquidos durante um período igual ou superior a 95% da amostra. O propósito dessa funcionalidade é impedir que, caso sejam observados eventos de variação de spread expurios, devido a baixa liquidez, eles não sejam propagados para o modelo EGARCH, o que poderia corromper a estimação da persistência e dos choques (parâmetros α e β) da variância condicional. É importante notar que esses ativos foram removidos apenas da amostra de teste, com a exceção de RDVT11, que foi removido manualmente da amostra devido aos seguintes fatores:

- O ativo não tinha dados de negociação durante a etapa de treinamento, então seria considerado posteriormente, mesmo ilíquido.
- A série de preços do ativo apresenta grandes variações, com um espaçamento elevado entre os dados, o que pode introduzir vieses na estimação.
 - Em 05/12/2023 o ativo foi negociado com PU de 1001.77, sendo negociado novamente apenas em 20/03/2024 com PU de 1.40 e posterior em 21/03/2024 com PU de 0.000014. Voltando a ser negociado em 26/07/2024 com PU de 38.04 e em 28/02/2025 com PU de 754.31.
- A empresa passou por eventos de reestruturação e recuperação judicial

A princípio, a empresa deveria ser um exemplo natural de evento de **tail risk** que o modelo deveria prever. Contudo, devido ao espaçamento temporal irregular de marcações a mercado e à extrema escassez de liquidez, as séries de retorno tornaram-se puramente espúrias, o que compromete severamente a convergência do estimador de máxima verossimilhança do motor EGARCH. Por esse motivo, a exclusão sumária deste ativo da amostra final foi necessária para preservar a integridade estatística da modelagem.

3.2 O Pipeline de Risco (EGARCH, K-Means e HMM)

Para a implementação dos modelos, foi criado um **pipeline** de risco, que, através de um fluxo linear estima as variáveis de maior impacto para o modelo, realiza o cálculo do volatilidade, VaR e **Expected Shortfall** (ES) por papel e, por fim, aplica o algoritmo K-Means e o Modelo Oculto de Markov (HMM). Uma vez obtidos os resultados do K-Means e HMM, se gera um modelo **Ensemble**, ponderando os resultados de cada modelo. Para mais detalhes sobre o funcionamento do **pipeline**, do ponto de vista de execução dos scripts listados, consultar a documentação do projeto disponível no repositório do GitHub. Abaixo será detalhada a metodologia aplicada em cada etapa. Para facilitar a compreensão sistêmica, a Figura 1 ilustra a arquitetura global do **pipeline**, desde a coleta de dados e divisão temporal até o processamento nos motores estocásticos e a simulação final (**Backtest**).




Figura 1: Arquitetura do Pipeline de Risco e Backtest

3.2.1 Pré-processamento de Dados e Filtros

Os dados coletados em Seção 3.1 foram divididos em dois períodos **In-Sample** e **Out-of-Sample**, sendo o período **In-Sample**, iniciado em janeiro de 2018 até dezembro de 2022 utilizados para a seleção e estimação dos parâmetros dos modelos e o período **Out-of-Sample**, iniciado em janeiro de 2023 até julho de 2026, utilizado para a implementação, observação e validação dos modelos, incluindo a avaliação do modelo em eventos de crédito realizado como o Grupo Pão de Açúcar, amplamente citado nessa pesquisa, devido a suas proporções e ao fato de ter sido o evento mais recente, dado o momento em que este trabalho foi escrito.

Além disso, as variáveis obtidas na etapa Seção 3.1 foram utilizadas como base para o cálculo de outras métricas. Para papéis indexados a um percentual do CDI (ex: 120% do DI), foi realizada uma conversão explícita baseada na taxa CDI anualizada (extraída via `python-bcb`, conforme a Seção 3.1). A transformação anualiza o fator diário do título e extrai o prêmio absoluto sobre a taxa livre de risco, conforme abaixo:

$$F_{\text{cdi}} = \left(1 + \frac{\text{CDI}_t}{100}\right)^{\frac{1}{252}} \quad (3)$$

$$F_{\text{título}} = (F_{\text{cdi}} - 1) \times \left(\frac{\text{Taxa do Ativo}_t}{100}\right) + 1 \quad (4)$$

$$S_t = \left((F_{\text{título}})^{252} - 1\right) \times 100 - \text{CDI}_t \quad (5)$$

Para os títulos atrelados a índices de inflação (como IPCA, IGPM) ou por um prêmio direto sobre o DI (DI Spread), a própria taxa informada no secundário já reflete o prêmio de risco puro:

$$S_t = \text{Taxa do Ativo}_t \quad (6)$$

A partir dessa informação, foi calculado a variação diária do **spread (Delta Spread)**, que atua como o principal input para o ajuste temporal do modelo EGARCH.

$$\Delta S_t = S_t - S_{t-1} \quad (7)$$

Devido a indisponibilidade de dados suficientes para o cálculo de duration se utilizou como base a quantidade de dias úteis para o vencimento do papel (limitado ao mínimo de dois dias), para calcular a taxa ajustada ao prazo, conforme abaixo:

$$\text{Taxa}_{\text{prazo}} = \frac{S_t}{\ln(\max(\text{DU}, 2))}$$

Foi também calculado o z-score do spread, utilizando uma janela móvel de 60 dias, além do **Spread Range Intraday** e **Spread Skew Intraday**, dados respectivamente por:

$$S_{\text{range}} = \text{Taxa do Ativo}_{\text{max}} - \text{Taxa do Ativo}_{\text{min}}$$

$$S_{\text{skew}} = \frac{\text{Taxa do Ativo} - \text{Taxa do Ativo}_{\text{min}}}{S_{\text{range}} + \varepsilon}$$

Sendo $\varepsilon = 1e - 6$ para evitar divisão por zero. A implementação desses cálculos é realizada de maneira estruturada na classe `DataPreprocessor`.

3.2.2 EGARCH

Apesar do viés teórico discutido em Seção 2, para se optar pelo modelo EGARCH, foram testados vários modelos da família GARCH em um modelo de torneio de **grid-search**, para diferentes tamanhos de amostra. O torneio avaliou os dados a partir de 2018 até o fim de 2022, que foi o período utilizado para treinamento do modelo, sendo o período a partir de 2023 o período de validação dos resultados, conforme detalhado em Seção 3.2.1. O código listou todos os ativos e filtrou os 30, 50, 100, 500, 1000, 3000, 5000 mais líquidos do período.

Para cada um dos ativos selecionados, o otimizador testou um grid combinatório de 32 especificações da família GARCH (utilizando o pacote `arch`). Os hiperparâmetros iterados foram:

- Média Condicional: Fixada em um modelo Autorregressivo de ordem 1 (AR(1)).
- Famílias de Volatilidade: GARCH tradicional, EGARCH (exponencial), GJR-GARCH (assimétrico) e TARCH.
- Defasagens (Lags) p : 1 e 2 (Impacto da variância passada).
- Defasagens (Lags) q : 1 e 2 (Impacto dos choques correntes).
- Distribuição dos Resíduos: Normal e t-Student.

A variável de entrada, conforme detalhado em Seção 3.2.1 foi o **Delta Spread**. Para cada combinação de modelo e ativo foi calculado o Critério de Informação de Akaike (AIC) e então para cada papel o modelo escolhido foi aquele que apresentou menor valor de AIC, cada vez que o modelo foi eleito foi considerado uma vitória. Ao final foi calculado a taxa média de vitórias de cada modelo e eleito aquele que apresentou um maior percentual de vitórias. Matematicamente, a taxa de vitória W_j de um modelo j é dada por:

$$W_j = \frac{\sum_{i=1}^N I_{i,j}}{N} \times 100 \quad (8)$$

onde N é o número total de ativos avaliados e $I_{i,j}$ é uma função indicadora que assume valor 1 se o modelo j apresentar o menor AIC para o ativo i (ou seja, $AIC_{i,j} = \min_k AIC_{i,k}$), e 0 caso contrário.

Adotou-se o modelo que maximizou W_j , garantindo a escolha empírica do algoritmo que melhor se adapta à maior proporção do mercado de crédito. Para amostras pequenas o destaque foi o modelo EGARCH(2,1,1) utilizando a distribuição t-student, porém, a partir de 100 amostras, o EGARCH(1,1,1) com a distribuição t-student passou a apresentar uma maior taxa de vitórias, como se pode observar nas figuras abaixo:




Figura 2: Torneio GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.




Figura 3: Torneio GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.




Figura 4: Torneio GARCH: Ranking Médio para a amostra ampla de 5000 ativos.

Além disso, nas Figura 3, Figura 4 podemos observar que apesar do EGARCH(1,1,1) com a distribuição t-student apresentar maior taxa de vitórias, o GARCH(1,0,1) com a distribuição t-student apresentou melhor rank médio no teste. Esse resultado é, de certa forma, esperado, uma vez que para debentures liquidas que não possuem grandes choques, o GARCH, como visto em Seção 2 tem alto poder preditivo em condições de normalidade, enquanto o EGARCH pode ser penalizado pela tentativa de estimar assimetria (e parâmetros a mais quando comparamos apenas as versões supra citadas), uma vez que o AIC penaliza modelos que possuem parâmetros extras caso eles não tragam ganhos de aderência significativos. Contudo, nos papéis que passam por mais eventos de estresse, é esperado que o EGARCH performe melhor, por ser capaz de capturar assimetrias, além da heterocedasticidade condicional. O que poderia justificar os resultados observados.

Como o intuito dessa pesquisa é estudar justamente os casos de estresse, e não a dinâmica da normalidade, foi adotado o modelo que apresentou maior **Win Rate**, e não aquele que apresentou o melhor rank médio. Essa escolha é justificada pelo fato de que, desejamos possuir o modelo que possui maior taxa de acertos, em detrimento da otimização de parâmetros, o que também justifica a escolha do AIC como métrica principal em detrimento do BIC, que possui maior penalização por parâmetros extras, favorecendo modelos mais simples. Além disso, o EGARCH modela a variancia em escala logarítmica, o que garante que a variancia seja sempre positiva, diferentemente do GARCH tradicional.

Após a eleição do EGARCH(1,1,1) com distribuição t-Student como o motor principal de volatilidade condicional, foram aplicados testes de diagnóstico aos resíduos gerados por este modelo para atestar sua qualidade estatística:

1. **Ljung-Box (Lag 10):** Para confirmar a ausência de autocorrelação serial remanescente, atestando que a média condicional AR(1) foi bem especificada.
2. **ARCH-LM (Lag 10):** O teste do multiplicador de Lagrange (Lagrange Multiplier) para verificar se toda a heterocedasticidade condicional foi devidamente absorvida pela variância EGARCH, impossibilitando a persistência do efeito ARCH nos resíduos.

Como a modelagem GARCH é realizada univariadamente (ativo a ativo), ajustou-se o modelo campeão para o universo viável de debêntures do período de teste, totalizando uma amostra de 529 debêntures. Este número representa a quantidade de debentures na amostra utilizada para o período que preencheram simultaneamente os critérios de elegibilidade: alta liquidez (exclusão de dias com volume “Até 1MM”), convergência numérica no otimizador de máxima verossimilhança e um histórico contínuo mínimo de 50 observações válidas. Os testes de hipótese foram aplicados aos resíduos de cada um dos ativos, considerando um nível de significância de 5%.

Os resultados demonstram um excelente grau de aderência do modelo ao mercado de crédito secundário brasileiro. Conforme ilustrado na Figura 5, 86,4% dos papéis modelados passaram no teste de Ljung-Box e 94,9% dos ativos passaram no teste ARCH-LM. A aprovação no teste ARCH-LM evidencia que o modelo EGARCH é adequado para a maioria das debêntures analisadas.




Figura 5: Taxa de aprovação dos testes de diagnóstico nos resíduos padronizados do EGARCH(1,1,1) t-Student para 529 debêntures.

Para mais detalhes a respeito dessa implementação, consultar o script `diagnostico_residuos.py` e a classe `ValidadorEconometrico`.

Uma vez definido e implementado o modelo EGARCH(1,1,1) com distribuição t-Student, a distribuição estimada para cada ativo foi utilizada também para o cálculo do Valor em Risco (VaR) e Expected Shortfall (ES) (com percentil de 99%, que foram atribuídos as variáveis `VaR_99` e `Expected_Shortfall_99`, respectivamente) como forma de precificar o risco das debentures analisadas baseado na série de volatilidade estimada. Como a distribuição escolhida para os resíduos foi a t-student, se $\nu \leq 2$ então a variancia da distribuição se torna infinita, levando a erros numericos no python quando se tenta calcular o VaR e ES, para evitar tais erros, foi aplicado um limite nos graus de liberdade, de forma que ν sempre será maior que 2.05, matematicamente, temos que o tratamento aplicado foi:

$$\nu = \max(2.05, \nu_{\text{est}}) \quad (9)$$

Onde ν_{est} é o valor estimado pelo modelo EGARCH(1,1,1). Além disso, durante a estimação da volatilidade, foram encontrados alguns problemas de otimização devido a instabilidade de algumas séries, principalmente as que permanecem dias sem negociação e quando são negociadas apresentam “saltos” no spread. Como o intuito do modelo é uma classificação de warning, aplicou-se uma limitação na volatilidade calculada, de forma que caso o EGARCH estime um valor que seja 20 vezes maior que o percentil 99% da volatilidade observada do ativo, estimada pelo desvio padrão, o valor é removido da amostra e replica-se a volatilidade observada no dia anterior, matematicamente, temos que o tratamento aplicado foi:

$$\sigma_{\text{est}}(t) = \sigma_{\text{est}}(t-1) \quad \text{se} \quad \sigma_{\text{est}}(t) > v_{\text{teto}} \quad (10)$$

onde $\sigma_{\text{est}}(t)$ é a volatilidade estimada pelo modelo EGARCH(1,1,1) no dia t , e v_{teto} é o limite superior definido como 20 vezes o percentil 99 da série in-sample. Para mais detalhes a respeito dessa implementação, consultar o script `volatility.py` e a classe `VolatilityEstimator`.

3.2.3 Teste de Estacionariedade dos Spreads

A aplicação de modelos da família GARCH pressupõe que a série temporal analisada seja estacionária em covariância. Antes do ajuste do EGARCH-t, verificou-se, portanto, a estacionariedade das séries de retorno de spread utilizadas como insumo do motor de volatilidade.

Para tanto, aplicou-se o Teste de Dickey-Fuller Aumentado (ADF) sobre as séries de primeiro incremento de spread (`Delta_Spread`) dos 529 ativos selecionados

para modelagem. O teste avalia a hipótese nula de raiz unitária (série não-estacionária):

- **H0** (ADF): A série de Delta_Spread possui raiz unitária (não-estacionária).
- **H1** (ADF): A série é estacionária (rejeita H0).

A especificação adotada inclui constante sem tendência determinística (regression='c'), com seleção automática de defasagens por Critério de Informação de Akaike (AIC). Os resultados, reportados na Tabela 1, demonstram que a série de spread bruto (Taxa_Ativo) é não-estacionária em 91% dos casos, como esperado (a nível de spread, as séries são integradas de ordem 1). Após a primeira diferença (Delta_Spread), **95,7% das séries rejeitam H0 ao nível de 5%**, validando o pressuposto de estacionariedade necessário para o EGARCH.

Indexador	Total	Estacionárias (Delta_Spread)	Taxa (%)	Spread Bruto (Taxa_Ativo)
IPCA	286	275	96,2%	não-estacionário
CDI Spread	239	227	95,0%	não-estacionário
PRE	4	4	100,0%	não-estacionário
Total	529	506	95,7%	—

Tabela 1: Resultados do Teste ADF ($\alpha = 5\%$) — Estacionariedade por Indexador

Os ativos que compõem os 3,4% restantes que não rejeitam H0 são, em sua maioria, papéis com histórico extremamente curto (entre 30 e 60 observações) e perfil de iliquidez estrutural, nos quais a baixa frequência de negociação gera séries com longos períodos de retornos nulos que distorcem a convergência do teste. Para esses casos, o motor EGARCH produz estimativas de volatilidade de menor confiança, conforme documentado na Seção 3.2.2.

3.2.4 Seleção de variáveis

Nas seções Seção 3.2.1 e Seção 3.2.2 foram listadas as variáveis calculadas:

- Taxa_ZScore
- Volatilidade_EGARCH
- VaR_99
- Expected_Shortfall_99

- Spread_Equivalente
- Spread_Range_Intraday
- Spread_Skew_Intraday

Estas variáveis foram utilizadas como um input para um processo de seleção de variáveis, que eligiu as mais relevantes para utilização nos modelos propostos. Devido a natureza não supervisionada desses modelos, a determinação da relevância dessas variáveis não pode ser realizada através dos métodos usuais que são utilizados para os processos de aprendizado supervisionado. Por essa razão, a seleção de variáveis implementada realiza combinações iterativas por meio de um **Grid Search** sobre subconjuntos das variáveis candidatas utilizando os dados de treinamento (**In-Sample**). Com intuito de garantir significado econômico aos clusters, a variável Taxa_ZScore foi mantida como obrigatória em todas as combinações. Impedindo que o algoritmo selecione apenas variáveis de risco correlacionadas (como a volatilidade EGARCH e o VaR), o que não agregaria valor discriminatório aos clusters, devido a carencia da preficicação relativa ao spread de crédito.

Para cada subconjunto testado, os dados foram padronizados utilizando **RobustScaler** devido a sua capacidade de lidar com outliers, conforme apresentado em Seção 2. Os subconjuntos foram então submetidos a uma clusterização primária utilizando K-Means com $k = 3$ regimes (a escolha dos regimes é justificada empiricamente na Seção 3.2.5.1). A qualidade de separabilidade dos agrupamentos foi mensurada através das três métricas listadas na Seção 2.5 (**Silhouette Score** , **Índice Davies-Bouldin** e **Índice Calinski-Harabasz**).

Uma vez que as métricas atuam em ordens de grandeza e domínios matemáticos distintos, o subconjunto vencedor não é escolhido por médias absolutas, mas sim pelo método de agregação de Ranks de Borda (**Borda Count**). O algoritmo computa a posição de cada combinação no ranking individual de cada métrica. O **Borda Score** final é dado pela soma das posições invertidas, garantindo uma eleição ordinal, determinística e robusta às magnitudes isoladas de índices específicos.

Como resultado da otimização, o subconjunto eleito como vencedor combinou as variáveis Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99. A Figura 6 ilustra o Top 10 das combinações avaliadas, ordenadas pelo **Borda Score**, evidenciando o desempenho superior do trio escolhido na capacidade de particionamento latente.




Figura 6: Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.

Uma forma mais lúdica de observar o desempenho superior dessas variáveis, é realizar a comparação de forma multidimensional, a Figura 7 ilustra o desempenho das quatro principais combinações normalizado nos três eixos de avaliação (Coesão, Dispersão e Separação). O gráfico demonstra graficamente como a combinação vencedora consegue maximizar simultaneamente o **Silhouette Score** e o **Calinski-Harabasz**, enquanto minimiza o índice de **Davies-Bouldin**.

Comparação Multidimensional - Feature Selection




Figura 7: Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).

Na Figura 7, o conjunto dado pelas variáveis Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99 e o conjunto dado pelas variáveis Taxa_ZScore, Volatilidade_EGARCH e VaR_99 parecem ter um desempenho muito similar, mas quando observamos a Figura 6, o primeiro conjunto possui um score superior. A única diferença entre eles é a substituição do Expected Shortfall pelo VaR, porém, o Expected Shortfall possui um score superior em todas as métricas, apesar de ser visualmente difícil a identificação na Figura 7. Além disso, como foi abordado em Seção 2 o Expected Shortfall é uma métrica superior, pois enquanto o VaR responde a pergunta “Qual é a perda máxima que posso esperar com 99% de confiança?”, o Expected Shortfall responde a pergunta “Qual é a perda média que posso esperar quando o VaR for excedido?”. Além disso, diferentemente do VaR, o Expected Shortfall é uma medida de risco coerente, o que o torna uma métrica superior.

3.2.5 K-Means

Eleitas as variáveis de entrada do modelo (Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99), o algoritmo K-Means atua propositalmente como uma **baseline** ingênua (**naive**). Reconhece-se que a aplicação do K-Means em séries temporais financeiras viola o pressuposto de observações independentes e identicamente distribuídas (i.i.d.), visto que os retornos apresentam comprovada autocorrelação da variância. Contudo, essa violação metodológica é assumida de forma deliberada no desenho da pesquisa para servir como contraponto determinístico ao modelo markoviano (HMM). A intenção é provar empírica e quantitativamente o valor marginal preditivo que a memória temporal agrega sobre a classificação puramente estática. O processo é realizado iterativamente para cada grupo de indexador (ex: DI, IPCA), a fim de respeitar as dinâmicas particulares de cada mercado.

3.2.5.1 Justificativa Empírica do Número de Clusters ($k = 3$)

A escolha de $k = 3$ regimes — Verde (baixo risco), Amarelo (alerta) e Vermelho (crise) — foi motivada primariamente pela semântica financeira do sistema de alertas (à analogia dos semáforos de risco de crédito). Contudo, para validar formalmente essa escolha, aplicou-se a análise de **Elbow Method** (inerção da soma dos quadrados intra-cluster em função de k) e o **Silhouette Score** médio para $k \in \{2, 3, 4, 5, 6, 7\}$, utilizando rigorosamente os dados padronizados do período **In-Sample** para evitar viés prospectivo (**Data Snooping**).

Os resultados, ilustrados na Figura 8, mostram que para os indexadores IPCA e CDI Spread: (i) a curva de inerção exibe uma inflexão (**Elbow**) em $k = 3$, indicando redução marginal decrescente a partir deste ponto; (ii) o **Silhouette Score** para $k = 3$ é consistentemente superior ao de $k = 2$ em ambos os grupos, ao mesmo tempo em que $k = 4$ e $k = 5$ não oferecem ganho relevantes de separabilidade. Conclui-se, portanto, que $k = 3$ é a escolha **parcimoniosa** que maximiza a interpretação econômica e a coerência geométrica dos regimes.




Figura 8: Elbow Method e Silhouette Score por número de clusters k — Superior: IPCA, Inferior: CDI Spread

O primeiro passo é a separação da amostra de treino e teste (**In-Sample** para treino, **Out-of-Sample** para teste), conforme detalhado em Seção 3.2.1. Para garantir que **outliers** extremos (como casos que discutimos nas seções anteriores, em que ativos passam dias sem negociação e depois quando voltam a ser negociados apresentam saltos no spread), aplica-se uma Winsorização (clipagem) no 1º e 99º percentis utilizando os dados **In-Sample**. Esses limites são posteriormente aplicados aos dados **Out-of-Sample**, prevenindo o viés de antecipação de informação (**look-ahead bias**).

Em seguida, os dados são padronizados através do algoritmo **RobustScaler**. Para capturar o risco relativo de cada papel, o escalonamento é feito individualmente por ativo, possuindo como limitador inferior 10% da variância (IQR) global do indexador, evitando que ativos estruturalmente ilíquidos sofram explosões numéricas. Já, que, uma vez o **RobustScaler** é dado por:

$$\text{Scaled}(x) = \frac{x - Q_2(x)}{Q_3(x) - Q_1(x)} \quad (11)$$

Caso o IQR ($Q_3(x) - Q_1(x)$) seja nulo ou próximo de zero, o escalonamento se torna indefinido.

O K-Means é então treinado nos dados padronizados com $k = 3$ agrupamentos. Devido à natureza não-supervisionada do K-Means (o problema do **Label Switching**), os centróides gerados recebem rótulos arbitrários. O modelo resolve este problema através de um vetor de polaridade de risco (onde valores maiores de volatilidade e **Z-Score** implicam maior risco), ordenando as médias dos agrupamentos para classificar deterministicamente os regimes em Verde (baixo risco), Amarelo (alerta) e Vermelho (crise).

Na etapa preditiva, para a construção de um modelo misto ponderado (conforme será abordado em Seção 3.2.7), a probabilidade de crise (Prob_Crise_KMeans) é definida com base na distância euclidiana inversa de cada observação **Out-of-Sample** até o centróide Vermelho.

3.2.6 HMM

Para investigar o valor da memória latente no reconhecimento de padrões da série temporal, estabelecemos a segunda hipótese deste estudo:

- **H0₂**: A inclusão da dependência temporal (matriz de transição markoviana) **não** melhora a capacidade de identificação precoce de eventos de estresse em relação ao particionamento geométrico atemporal (K-Means).
- **H1₂**: O modelo HMM, ao modelar a inércia dos regimes de risco, antecipa a deterioração do crédito com maior **lead time** do que o K-Means para os eventos de crédito observados no período **Out-of-Sample**.

Esta hipótese é avaliada qualitativamente por meio do estudo de caso do Grupo Pão de Açúcar (§ Resultados) e da comparação do primeiro alerta por modelo.

O Modelo Oculto de Markov (HMM - **Hidden Markov Model**) acrescenta a dependência temporal que o K-Means ignora. O pré-processamento para o HMM segue as exatas mesmas premissas de divisão, winsorização e padronização geométrica (piso de variância) descritas em Seção 3.2.5, adicionando apenas a restrição de que a massa de dados obedeça estritamente a ordenação sequencial no tempo. Já que para o HMM, essa ordenação é de extrema importância para que o modelo consiga modelar as transições entre os estados latentes.

O treinamento **In-Sample** é realizado através de um HMM Gaussiano (GaussianHMM) de 3 estados latentes com matriz de covariância diagonal, aplicando o algoritmo de otimização de **Baum-Welch**. Apesar de ter sido demonstrado em Seção 2 que os retornos brutos da taxa exigem uma distribuição leptocúrtica (t-Student), as **features** alimentadas ao HMM neste estágio (Taxa_ZScore e $\text{Volatilidade_EGARCH}$)

já foram previamente modeladas e padronizadas, com a volatilidade condicional já capturando o impacto da cauda pesada.

Para validar empiricamente esta premissa na modelagem, analisou-se o Excesso de Curtose (medida estatística de “peso da cauda”) das séries temporais no período **In-Sample**. Foi constatado que os retornos brutos apresentaram um Excesso de Curtose de 2683,30, indicando eventos extremos e caudas ultra-pesadas que inviabilizariam o uso de uma matriz Gaussiana. Todavia, a **feature** Taxa_ZScore, resultante do filtro estocástico do EGARCH-t, reduziu este Excesso de Curtose para apenas 1,17. Em finanças quantitativas e modelagem multivariada, excessos de curtose localizados no intervalo de -2 a $+2$ (e mesmo sob critérios mais relaxados, até $+7$) são considerados comportados e largamente aceitáveis para a adoção de premissas de normalidade em estimações por Máxima Verossimilhança sem enviesamento grave dos estimadores (Hair et al., 2010). Consequentemente, o espaço latente de emissão do HMM encontra-se num domínio estruturalmente mitigado de eventos extremos, o que atesta a escolha do modelo Gaussiano não apenas como estatisticamente aceitável, mas fundamental para assegurar a estabilidade numérica e convergência na calibração das matrizes. Da mesma forma, os vetores de médias estimadas para as emissões Gaussianas sofrem a correção heurística de **Label Switching** para rotular os estados como Verde, Amarelo e Vermelho.

Uma alteração fundamental feita no HMM padrão diz respeito à calibração da Matriz de Transição de Estados (A). Em bases de dados com regimes muito duradouros, pode haver a total ausência empírica de transições entre estados extremos (como saltos diretos de Verde para Vermelho) na amostra de treinamento. Isso gera probabilidades de transição iguais a zero, transformando os regimes em “estados absorventes” (uma vez que o modelo entre nesse estado, a probabilidade de sair matematicamente se anula). Para mitigar esse problema, aplicou-se primeiramente a **Suavização de Laplace (Additive Smoothing)** sobre a matriz empírica de contagens de transição:

$$P'_{\{ij\}} = \frac{C_{\{ij\}} + \alpha}{\sum_{\{k=1\}}^K C_{\{ik\}} + K\alpha} \quad (12)$$

onde $C_{\{ij\}}$ é a contagem empírica de transições do estado i para o estado j observadas na sequência latente decodificada do **In-Sample**, $K = 3$ é o número de estados, e $\alpha = 1$ atua como o pseudo-fator aditivo.

Complementarmente à Equação 12, para garantir matematicamente que o modelo permaneça reativo aos novos choques de mercado em tempo real e não dependa excessivamente da inércia do estado anterior, impôs-se um limiar (piso) arbitrário de 1% (0.01) sobre a matriz de probabilidade de transição, seguido por uma

re-normalização linha a linha (para assegurar que o somatório das probabilidades convirja para 1):

$$P''_{\{ij\}} = \max(P'_{\{ij\}}, 0.01) \quad (13)$$

$$P_{\{ij\}} = \frac{P''_{\{ij\}}}{\sum_{\{k=1\}}^K P''_{\{ik\}}} \quad (14)$$

Esse mecanismo em duas etapas força o modelo a manter vias probabilísticas ativas e o impede de tornar-se inerte, especialmente para a saída do estado de crise (Vermelho).

A inferência nos dados **Out-of-Sample** é rigorosamente desenhada para evitar viés do futuro. Para estimar a probabilidade de um ativo estar em crise no dia t , o modelo recebe apenas a sequência de variáveis observáveis do instante inicial até o instante t (janela expansiva causal). A sequência ótima de estados latentes é decodificada utilizando o **Algoritmo de Viterbi**, e a probabilidade marginal instantânea de crise (Prob_Crise_HMM) é inferida simultaneamente pelo algoritmo **Forward-Backward**.

3.2.7 Modelo Misto (Ensemble)

A intuição de mesclar modelos conflitantes pode parecer promissora, mas exige verificação empírica. A quarta hipótese que permeia este trabalho contesta o benefício da modelagem mista:

- **H0₄**: A combinação ponderada (Ensemble) dos modelos K-Means e HMM **não** produz uma estratégia de alocação inferior às estratégias individuais de cada componente, em termos de retorno ajustado ao risco.
- **H1₄**: A ponderação dos sinais contraditórios dos modelos K-Means e HMM, sem calibração empírica dos pesos, induz ao efeito **whipsaw** e resulta em performance inferior às estratégias individuais.

A avaliação é realizada pela comparação do Calmar Ratio e Retorno Total do Ensemble contra K-Means e HMM individuais nos resultados do Backtest.

As previsões individuais do K-Means (detalhada em Seção 3.2.5) e do HMM (detalhada em Seção 3.2.6) são posteriormente combinadas em uma pontuação final, buscando mesclar a estabilidade atemporal do particionamento geométrico (K-Means) com a agilidade e memória temporal do filtro bayesiano (HMM).

A combinação matemática é realizada através de uma média ponderada das probabilidades individuais de cada modelo. Para determinar a alocação de pesos ótima e evitar decisões arbitrárias ou vieses prospectivos (**Data Snooping**), executou-

-se uma rotina de otimização de hiperparâmetros via **Grid-Search** de Força Bruta ($w_{\text{HMM}} \in [0.0, 1.0]$, em incrementos de 0.10) estritamente sobre as predições do período **In-Sample**. A métrica alvo para a otimização foi o **Calmar Ratio** (retorno anualizado sobre rebaixamento máximo) gerado pelo simulador financeiro. O resultado empírico demonstrou que o melhor retorno ajustado ao risco na amostra de treinamento ocorreu com a proporção de 70% de peso para o HMM e 30% para o K-Means. A Figura 9 ilustra as métricas financeiras obtidas para diferentes combinações de pesos no simulador tático **in-sample** (assumindo liquidação defensiva a partir do estágio de Alerta), ratificando o pico otimizado em $w_{\text{HMM}} = 0.70$.




Figura 9: Análise de Sensibilidade (**Grid-Search**) dos pesos do modelo Ensemble no período **In-Sample**.

A Tabela 2 detalha os resultados quantitativos extraídos da simulação estática, evidenciando como a alocação de 70% do peso para o motor probabilístico (HMM) minimizou o declínio e ofereceu o equilíbrio ótimo frente a estratégias puramente mono-modelo.

w_HMM	w_KMeans	CAGR (%)	Max Drawdown (%)	Calmar Ratio
0.0	1.0	-2.938	-98.289	-0.0299
0.1	0.9	-1.711	-98.817	-0.0173
0.2	0.8	-1.982	-99.163	-0.0200
0.3	0.7	-1.725	-43.616	-0.0396
0.4	0.6	-1.511	-51.129	-0.0296
0.5	0.5	-1.330	-64.830	-0.0205
0.6	0.4	-1.128	-58.108	-0.0194
0.7	0.3	-1.097	-64.392	-0.0170
0.8	0.2	-1.115	-64.648	-0.0173
0.9	0.1	-1.160	-64.542	-0.0180
1.0	0.0	-1.165	-63.599	-0.0183

Tabela 2: Métricas da grade de sensibilidade (**In-Sample**) por par de pesos.

A equação do **Ensemble** aplicada na fase preditiva (**Out-of-Sample**), no instante t , é dada por:

$$\text{Probabilidade Sintética}_t = 0.70 \times \text{Prob_Crise_HMM}_t + 0.30 \times \text{Prob_Crise_KMean}_t \quad (15)$$

Por fim, para garantir uma combinação mais suave e menos suscetível a ruídos de alta frequência, aplicou-se um filtro de média móvel exponencial de 3 dias (EMA_3) sobre a “Probabilidade Sintética”, gerando a pontuação final de risco. A fórmula da Média Móvel Exponencial é calculada recursivamente da seguinte forma:

$$\text{Pontuação Final}_t = \alpha \times \text{Probabilidade Sintética}_t + (1 - \alpha) \times \text{Pontuação Final}_{t-1} \quad (16)$$

onde α é o fator de suavização, definido por $\alpha = \frac{2}{N+1}$. Para uma janela de $N = 3$ dias, o fator resulta em $\alpha = 0.5$. Dessa forma, a “Pontuação Final” de risco absorve os choques recentes rapidamente, mas preserva a memória de curto prazo para evitar que a volatilidade diária acione alarmes falsos de crise.

3.3 Protocolos de Validação (Kupiec POF e Backtest)

Para testar a robustez e a aplicabilidade prática do modelo desenvolvido, a etapa de validação foi estruturada em duas dimensões complementares, aplicadas sobre o período **Out-of-Sample** para garantir a ausência de viés prospectivo (**Look-Ahead Bias**). A primeira dimensão avaliada diz respeito a acurácia estatística do modelo, aplicada sobre as saídas do motor EGARCH-t. Foi utilizado o Teste de Proporção de Falhas (**POF - Proportion of Failures**) desenvolvido por Kupiec (1995), que avalia se a frequência empírica de violações (quantidade de dias em que a perda real do ativo excedeu a perda máxima estimada pelo VaR) é estatisticamente compatível com o nível de confiança estipulado pelo modelo. Rejeitar a hipótese nula do teste indica que o motor de volatilidade subestima ou superestima sistematicamente as caudas pesadas observadas no mercado.

A segunda dimensão avalia a qualidade preditiva do modelo no contexto do mercado de crédito corporativo brasileiro por meio de um **Backtest** financeiro, focado em avaliar a eficácia dos diferentes “Regimes de Risco” sugeridos pelos modelos apresentados. O **backtest** simula o impacto de diferentes estratégias de liquidação de portfólio baseadas nas pontuações de risco dos modelos (Verde, Amarelo ou Vermelho), comparando duas abordagens de liquidação para cada modelo:

- Venda Retardada: Estratégia reativa, onde a liquidação ocorre quando o modelo acusa um Regime de Risco Vermelho. Idealmente,

caso o modelo seja capaz de prever o estado vermelho antes do choque, esse modelo deveria gerar rentabilidade superior, uma vez que a venda ocorre antes ou no exato momento do choque, evitando assim perdas substanciais. Todavia, se o modelo não for capaz de prever o estado vermelho antes do choque, essa estratégia tende a gerar perdas operacionais, uma vez que o choque já ocorreu e a venda só será realizada após a materialização dos choques no preço dos ativos.

- Venda Preventiva: Estratégia ofensiva, onde a liquidação ocorre quando o modelo acusa um Regime de Risco Amarelo. Idealmente,

deveria ser superada pela venda retardada em caso de um modelo ideal, porém, na prática, em cenários onde o modelo pode demorar a reagir na classificação para o regime vermelho, essa estratégia tende a gerar rentabilidade superior, uma vez que a venda ocorre assim que são observados os primeiros sinais de deterioração do ativo, antes da materialização completa do choque. Todavia, caso haja muitos falsos positivos, essa estratégia tende a gerar rentabilidade inferior à venda retardada, uma vez que gera custos operacionais desnecessários e reduz o ganho em cenários de alta volatilidade.

Para tornar a simulação o mais realista possível e capturar a penalidade financeira do **whipsaw** (falsos rompimentos que geram múltiplos sinais de entrada e saída), o **backtest** incorpora uma taxa de custo de transação de 0,5% (50 **bps**). No mercado secundário de crédito brasileiro, caracterizado por menor liquidez e **spreads** de **bid-ask** mais elásticos do que o mercado de ações, a inclusão desse custo é fundamental. Ele atua como um fator de desconto sobre estratégias excessivamente reativas (com alta rotatividade

4 RESULTADOS E DISCUSSÕES

Este capítulo apresenta os resultados empíricos obtidos a partir da aplicação da arquitetura de risco desenvolvida e apresentada em Seção 3 aos dados do mercado secundário de crédito corporativo brasileiro. A análise é construída de forma sequencial, iniciando pela validação estatística rigorosa dos motores de volatilidade e culminando no impacto financeiro real gerado pelas estratégias táticas de alocação.

4.1 Validação Estatística dos Motores

A eficácia de um sistema de alerta preventivo (**Early Warning**) no mercado de crédito está atrelada à sua capacidade de modelar as caudas pesadas da distribuição de retornos. Para testar a acurácia do motor EGARCH-t na estimação do **Value at Risk** (VaR) a 99% de confiança, aplicou-se o Teste de Proporção de Falhas de Kupiec (POF) adotando um nível de significância de 5% ($\alpha = 0,05$).

Os resultados agregados do backtest estatístico, agrupados por classe de indexador, evidenciam a proporção de ativos em que a Hipótese Nula (H_0) do teste não foi rejeitada (ou seja, a taxa de falhas observada não diferiu estatisticamente da margem de 1% esperada pelo modelo).

Indexador	Total	Não-Rejeitadosn(POF)	Não-Rejeitadosn(Conj. 90%)	Não-Rejeitadosn(Conj. 95%)	Não-Rejeitadosn(Conj. 99%)
CDI Percentual	40	21	21 (52,5%)	23 (57,5%)	25 (62,5%)
CDI Spread	257	63	68 (26,4%)	80 (31,1%)	105 (40,8%)
IPCA	365	133	143 (39,1%)	157 (43,0%)	193 (52,8%)
PRÉ-Fixado	1	0	0 (0,0%)	0 (0,0%)	0 (0,0%)

Tabela 3: Resultados do Teste de Kupiec (Não-Rejeição de H_0) por Nível de Confiança

Para efeitos visuais e comparativos da eficácia do modelo, a figura abaixo exhibe a taxa de não-rejeição relativa.




Figura 10: Sensibilidade da Não-Rejeição (Teste Conjunto) a Diferentes Níveis de Confiança

Embora as taxas de rejeição da Hipótese Nula possam parecer elevadas em primeiro momento, estes resultados devem ser interpretados sob a ótica da severidade da janela temporal analisada. O backtest de Kupiec foi executado exclusivamente sobre o período **Out-of-Sample** (2023 a 2026). Esta janela temporal engloba a maior crise de crédito privado da história recente do Brasil (marcada pelos colapsos sequenciais das Lojas Americanas e da Light S.A. além do mais recente evento do Grupo Pão de Açúcar), que introduziu choques exógenos severos e propiciou resgates em massa nos fundos de investimento. A sustentação de 57,5% de não-rejeição no grupo CDI Percentual (para um nível de significância de 5%), prevendo o risco sem sobreajuste em meio a choques sistêmicos, atesta uma forte resiliência da premissa autorregressiva.

Adicionalmente, a iliquidez estrutural do mercado secundário de debêntures atua como o principal ofensor analítico do Teste de Proporção de Falhas. Diversos ativos corporativos frequentemente passam dias úteis sem negociação efetiva. Quando o papel é negociado, o prêmio de risco (**spread**) sofre uma reprecificação abrupta, gerando um salto (**jump**) cuja magnitude pontual, em alguns casos, rompe o limite projetado pelo VaR de 99%. Como o modelo EGARCH-t assume que a volatilidade condicional rege-se por uma dinâmica fluida de persistência no tempo, as violações detectadas decorrem sobretudo da fragmentação da continuidade dos preços (falta de fluxo regular de negociação), e não de uma ineficácia intrínseca do filtro matemático. Somando-se a isso, a extrema sensibilidade do teste binomial de Kupiec em amostras temporais pequenas condena modelos por desvios mínimos acima da tolerância esperada de 1%.

Cabe ressaltar a diferença conceitual e quantitativa entre os ativos “Não-Rejeitados (POF)” e “Não-Rejeitados (Conjunto)”, expostos na Tabela 3. O teste de Kupiec POF avalia estritamente a Cobertura Incondicional (**Unconditional Coverage**), limitando-se a analisar o volume total de falhas. Em contrapartida, as colunas do Teste Conjunto refletem a validação pelo Teste de Christoffersen, que integra a Cobertura Incondicional à Cobertura Condicional (Teste de Independência). Observa-se que a não-rejeição conjunta é sistematicamente superior em todos os indexadores. Isso evidencia que as violações ocorridas no **Out-of-Sample** não estão agrupadas no tempo (**volatility clustering**). Portanto, ainda que o modelo sofra rejeição marginal no teste POF devido a um excesso absoluto de falhas causadas pelos saltos de iliquidez, o Teste Conjunto valida a modelagem ao provar que o motor EGARCH-t capturou e mitigou com precisão a dependência temporal da variância, convertendo os choques do mercado em violações isoladas e estatisticamente aleatórias.

Por fim, a fim de avaliar a robustez destas conclusões, a Figura 10 ilustra a sensibilidade das taxas de não-rejeição do Teste Conjunto frente a variações no nível de significância do próprio teste (α). Ao adotar-se um rigor extremo ($\alpha = 0,10$, ou 90% de confiança para não-rejeição), a não-rejeição no indexador IPCA recua para 39,1%. Em contrapartida, sob um critério mais conservador para rejeição de modelos ($\alpha = 0,01$, ou 99% de confiança), a não-rejeição salta significativamente, alcançando 62,5% no CDI Percentual e 52,8% no IPCA. Essa elasticidade estatística evidencia que grande parte das rejeições no cenário-base (95%) ocorre por infrações marginais ao p-valor estipulado, reforçando que o modelo se encontra muito próximo do limiar de validação, mesmo frente ao severo estresse do mercado **Out-of-Sample**.

A validação estatística focou primariamente nas métricas de VaR. A ausência de um **backtest** independente para o **Expected Shortfall** (ES) é justificado pela natureza estrutural do modelo adotado: sob a premissa de distribuição T de Student assimétrica, o ES condicional derivado do motor EGARCH-t atua como uma função analítica direta e co-dependente do quantil do VaR. Consequentemente, ao comprovar via Teste de Christoffersen que o filtro de volatilidade captura a frequência correta e expurga o agrupamento das violações, a métrica ES está intrinsecamente ancorada e validada, dispensando a exigência de avaliações adicionais.

4.2 O Desempenho do HMM vs K-Means na Classificação

Estabelecida a validade estatística das métricas de risco de cauda, a análise avalia a agilidade e a capacidade dos algoritmos não-supervisionados de transpor essas métricas contínuas em regimes de risco pré estabelecidos (Verde, Amarelo e

Vermelho). Nas subseções seguintes serão apresentados os contrastes entre os resultados obtidos pelo particionamento geométrico (K-Means) e a inferência temporal (HMM). A fim de ilustrar empiricamente o comportamento dos modelos nessa tarefa, iremos utilizar como exemplo o caso de estudo do Grupo Pão de Açúcar (GPA) para as debentures CBRDB8 e CBRDA8, ambas são debentures indexadas CDI+. Nas tabelas Tabela 4 e Tabela 5 pode-se verificar as maiores variações de PU e Taxa ocorrida para ambas as debentures no período recente.

Data	Preço Unitário (PU)	Spread (Taxa)
23/10/2025	R\$ 512,13	12,10%
24/10/2025	R\$ 453,59	44,75% (Choque)
27/10/2025	R\$ 454,35	44,28%
25/02/2026	R\$ 486,91	45,74%
26/02/2026	R\$ 460,13	100,01% (Choque)
27/02/2026	R\$ 413,24	—

Tabela 4: Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDA8

Data	Preço Unitário (PU)	Spread (Taxa)
21/11/2025	R\$ 764,80	19,75%
25/11/2025	R\$ 630,22	35,01% (Choque)
26/11/2025	R\$ 681,76	28,73%
23/02/2026	R\$ 864,71	16,04%
24/02/2026	R\$ 738,68	30,11% (Choque)
25/02/2026	R\$ 793,33	23,61%
11/06/2026	R\$ 456,53	100,38%
17/06/2026	R\$ 312,66	190,66% (Choque)
06/07/2026	R\$ 361,41	166,10%

Tabela 5: Histórico de Reprecificação e Perda de Capital em Eventos de Estresse - CBRDB8

4.2.1 K-Means

A fim de ilustrar o resultado do K-Means, tomemos a debênture CBRDB8 (Grupo Pão de Açúcar). Entre fevereiro e junho de 2026, com o agravamento da percepção de crédito da varejista, o ativo sofreu uma severa reprecificação sistêmica: o prêmio de risco (**spread**) variou inicialmente de 16,04% em 23/02/2026 para 30,11% em 24/02/2026, voltando a patamares próximos de 23,5% no final de fevereiro, antes de saltar para patamares de 190% em junho de 2026. Ocasionalmente uma perda acumulada de mais de 60%. Apesar da magnitude do evento, o K-Means demorou a

ancorar o ativo no regime de Crise (Vermelho), como se pode observar na Figura 11, classificando os dias iniciais da quebra como Verde e oscilando erráticamente para o Amarelo em uma clara demonstração de **flickering** matemático. Por analisar os dados de forma transversal e atemporal, o agrupamento perdeu o poder de inferir a deterioração em curso.

Já no caso da CBRDA8, em 26 de fevereiro de 2026, a taxa do ativo sofreu um salto, variando de 45,7% para 100,0%. Já que a debenture, por estar mais próxima ao vencimento quando comparada a CBRDB8, possuía uma grande sensibilidade a mudanças na percepção de risco. Todavia, o K-Means falhou em reconhecer, neste caso, a degradação do papel, mantendo toda a história do ativo como um regime Verde (Baixo Risco). O exemplo demonstra que o K-Means falha em capturar a natureza sequencial dos dados, o que é crucial para a gestão de risco de crédito.

Além disso, durante o período de treino (período anterior a Jan/2023), o ativo CBRDA8 possuía 77 dias de negociação, com saltos no spread que levaram o algoritmo de máxima verossimilhança que ajustou o EGARCH falhar em convergir. Como houve problemas de convergência, o período **Out-of-Sample** começou em uma escala irreal (volatilidade de 170% ao ano) e fez com que o K-Means fosse insensível aos saltos observados. Já para CBRDB8, o período de treino possuía 65 observações, porém, sem saltos erráticos como no caso anterior, a volatilidade do período **Out-of-Sample** iniciou em valores realistas (entre 0.1% e 1.5% ao ano), permitindo ao modelo ter melhor sensibilidade as variações observadas. Na tentativa de limitar, e melhorar a qualidade do resultados observados para casos como CBRDA8 que se implementou a trava de maximo de 20x a variancia **In-Sample** como descrito em Seção 3.2.2.




Figura 11: Resultados do K-Means para o Estudo de Caso do Grupo Pão de Açúcar (GPA)

4.2.2 HMM

Sob a mesma ótica do choque das debêntures do GPA, o Modelo Oculto de Markov provou-se superior ao integrar a dependência temporal inerente às matrizes de transição (A). Para a emissão CBRDB8, sua taxa durante o período **In-Sample** era cerca de 1.7%, porém, com o evento das Lojas Americanas em Janeiro/Fevereiro de 2023, houve um efeito de contágio no mercado, e a taxa do papel passou a ser negociada próximo de 2.5%. Porém, quando essa variação foi comparada com o histórico do papel, foi observada uma variação no Z-Score de 6.5 desvios padrões, levando a classificação no Regime Vermelho já no início do período pelo motor HMM. Como se pode observar na Figura 12.

Já para a CBRDA8, assim como foi dito na Seção 4.2.1, o EGARCH falhou em convergir no período **In-Sample**, fazendo com que a distribuição do regime Verde ficasse larga e achatada. Ou seja, mesmo grandes variações para cima ou para baixo não eram suficientes para fazer o modelo sair do regime de baixo risco, porém, em Fev/2026, com o salto de spread de 44% (de 45,7% para 100,0%, conforme a Tabela 4), o motor HMM conseguiu identificar o choque e classificar a debênture no regime de crise.

A capacidade de reação do algoritmo HMM comprovam que a característica matricial de transições das Cadeias de Markov Ocultas é indispensável, para a identificação das alterações de regime e manutenção do estado enquanto não houver alterações bruscas dos sinais de entrada.




Figura 12: Resultados do HMM para o Estudo de Caso do Grupo Pão de Açúcar (GPA)

4.2.3 Ensemble

Um dos problemas observados no HMM contudo, é a sensibilidade a ruídos, que causam instabilidade, conforme demonstrado pela coluna de Probabilidade do Regime Vermelho na Figura 12. Na tentativa de mitigar os efeitos de instabilidade do HMM e ao mesmo tempo aproveitar o poder de predição observado, foi desenvolvido um modelo Ensemble, combinando a probabilidade estimada a partir do modelo K-Means, conforme descrito em Seção 3.2.5, com a probabilidade de transição de regimes do HMM. A ponderação utilizada pode ser consultada com mais detalhes na Seção 3.2.7.

Em relação aos resultados, pode se observar na Figura 13 que a probabilidade de classificação (**Ensemble Score**), apresentou estabilidade, quando comparada ao HMM, porém, também falhou em capturar a deterioração observada para CBRDA8. Já no caso de CBRDB8, o modelo apresentou variações de estado frequentes, porém, foi capaz de antecipar o choque, ao contrário do K-Means, porém de forma menos agressiva do que o HMM.




Figura 13: Resultados do Ensemble para o Estudo de Caso do Grupo Pão de Açúcar (GPA)

4.3 Simulação de Portfólio (Backtest Financeiro)

Para avaliação da utilidade econômica da modelagem desenvolvida, foi realizado um **backtest** financeiro para o período **Out-of-Sample**, conforme descrito na Seção 3.3. O objetivo da simulação não se limita a medir apenas o desempenho direcional dos modelos propostos contra uma estratégia passiva (**Buy-and-Hold**), mas

também a avaliar como as diferentes formas de liquidação (preventiva no sinal amarelo **vs.** retardada no sinal vermelho) impactam a relação risco-retorno da carteira.




Figura 14: Resultados do Backtest

Estratégia	Retorno Total	CAGR	Volatili- dade	Máx. Draw- down	Calmar Ratio
Buy-and-Hold	22,42%	5,98%	3,50%	-4,79%	1,249
K-Means	27,06%	7,11%	4,29%	-4,16%	1,711
K-Means (Vende Amarelo)	36,18%	9,27%	8,92%	-5,78%	1,603
HMM	25,95%	6,85%	8,82%	-6,71%	1,021
HMM (Vende Amarelo)	32,62%	8,44%	12,56%	-9,74%	0,866
Ensemble	16,37%	4,45%	4,68%	-4,00%	1,111
Ensemble (Vende Amarelo)	17,58%	4,76%	4,70%	-4,12%	1,156

Tabela 6: Métricas de Risco-Retorno do Backtest Financeiro

Os resultados consolidados na Tabela 6 e a evolução temporal da Figura 14 revelam o valor adicionado pelas estratégias de **Early Warning**. Enquanto o índice passivo (**Buy-and-Hold**) gerou um retorno total de 22,42% penalizado pelo carregio de papéis ilíquidos e depreciados, as estratégias reativas obtiveram retornos superiores, destacando-se a **K-Means Vende Amarelo** e **HMM Vende Amarelo** que apresentaram retornos acumulados de 36.18% e 32.62% respectivamente.

Optou-se pela exclusão da métrica clássica de **Sharpe Ratio** dessa avaliação, uma vez que debêntures pós-fixadas (atreladas ao CDI) possuem correlação direta

com a taxa de juros e volatilidade intrínseca artificialmente próxima a zero, o que distorce o índice na avaliação de prêmio de risco (tornando o Sharpe assintótico frente a prêmios negativos). Em seu lugar, as métricas utilizadas foram **Maximum Drawdown** e **Calmar Ratio** (Razão do Retorno Anualizado (CAGR - **Compound Annual Growth Rate**) pelo **Maximum Drawdown**).

Apesar do retorno superior apresentado pelas estratégias ativas, elas também incorreram em maior volatilidade e **Drawdown**, sendo penalizadas quando avaliadas por métricas que ponderam risco e retorno. Em especial, a estratégia **HMM (Vende Amarelo)** apresentou um expressivo **drawdown** de -9,74% em 2026, originado pela marcação simultânea de diversos ativos no estado de Alerta (Amarelo) em decorrência do contágio de crédito gerado pelo evento do grupo GPA. Por possuir uma regra agressiva de **stop loss**, o agente liquidou uma parcela relevante do portfólio no mercado secundário exatamente no momento de forte abertura de **spreads**. Esse comportamento evidencia os riscos da sensibilidade acentuada do filtro Bayesiano quando acoplado a uma execução automática.

O portfólio **Buy-and-Hold** apresentou um Calmar de 1,249, sendo superado exclusivamente pelos algoritmos K-Means, com índices de 1,711 (Padrão) e 1,603 (Vende Amarelo). A superioridade ruidosa do K-Means neste aspecto advém justamente da sua latência: por reagir de forma mais lenta e instável aos choques do que o HMM, a estratégia apresentou um menor giro de ativos. Dessa forma, ela evitou a realização maciça de prejuízos de marcação a mercado simultâneos (mitigando o **drawdown**), mas ainda assim conseguiu se desfazer tempestivamente de papéis que apresentavam deterioração irreversível, distanciando-se do **Buy-and-Hold**. Esse comportamento acidental poupou a carteira das severas punições transacionais que afetaram o HMM.

Por fim, o modelo **Ensemble** — desenvolvido com o intuito de harmonizar a reatividade do HMM com a inércia do K-Means — apresentou resultados amplamente negativos. Embora tenha sustentado um **Calmar Ratio** próximo ao da estratégia passiva (1,111 **vs.** 1,249), entregou o pior retorno total do período (16,37%), corroído quase integralmente pelo efeito **Whipsaw** (efeito chicote). A mediação conflitante dos modelos fez com que o agente acionasse vendas quando o HMM indicava a transição de regime, para logo em seguida recomprar os mesmos ativos assim que a influência do K-Means puxava o **score** novamente para um regime de baixo risco. Conclui-se, portanto, que a modelagem mista falhou estruturalmente ao herdar os custos transacionais da sensibilidade do HMM sem se beneficiar de sua capacidade de proteção definitiva, sofrendo das piores características operacionais de seus precursores.

4.3.1 Significância Estatística das Estratégias — Block Bootstrap

A superioridade das estratégias ativas em termos de retorno absoluto não é, por si só, evidência científica suficiente de que os modelos adicionam valor. O período **Out-of-Sample** (2023–2026) foi marcado por eventos excepcionais de crédito, o que levanta a questão: os retornos superiores observados decorrem genuinamente da capacidade preditiva dos algoritmos, ou são produto do período amostral específico?

Para responder a essa pergunta, aplicou-se o **Stationary Block Bootstrap** (Politis; Romano, 1994) com $n = 10.000$ amostras e blocos de 20 dias úteis (≈ 1 mês), que preserva a estrutura de autocorrelação temporal dos retornos diários. A hipótese testada é:

- **H₀**: A estratégia ativa **não** supera o Buy-and-Hold em termos de retorno médio anualizado ($\mu_{\text{estratégia}} \leq \mu_{\text{BnH}}$).
- **H₁**: A estratégia supera o Buy-and-Hold (teste unilateral à direita, $\alpha = 5\%$).

O p-valor reportado representa a proporção de amostras bootstrap em que o retorno médio da estratégia foi inferior ou igual ao do benchmark, de forma que valores abaixo de 0,05 levam à rejeição de H₀.

Estratégia	Retorno (n(%) ao ano)	BnH (n(%) ao ano)	Diferença (n(%) ao ano)	p-valor	H ₀
KMeans	6,97%	5,87%	+1,10%	0,134	Não Rejeitada
HMM	7,02%	5,87%	+1,15%	0,225	Não Rejeitada
Ensemble	4,47%	5,87%	-1,41%	0,868	Não Rejeitada
K-Means (Vende Amarelo)	9,27%	5,87%	+3,40%	0,015	Rejeitada ✓
HMM (Vende Amarelo)	8,90%	5,87%	+3,03%	0,059	Não Rejeitada
Ensemble (Vende Amarelo)	4,76%	5,87%	-1,11%	0,808	Não Rejeitada

Tabela 7: Resultados do Block Bootstrap ($n = 10.000$, $\alpha = 5\%$, bloco=20 dias) — Significância Estatística vs. Buy-and-Hold

Os resultados da Tabela 7 revelam um achado central: **apenas a estratégia K-Means (Vende Amarelo) rejeita H₀ ao nível de 5%** ($p = 0,015$, IC 95%: [+0,33%; +6,78%]). A estratégia HMM (Vende Amarelo) apresenta p-valor de 0,059, próximo ao limiar de significância, não rejeitando H₀ sob o critério convencional de 5%, mas sugerindo evidência marginal de superioridade.

Este resultado é coerente com o diagnóstico do **Paradoxo da Latência**: a inércia do K-Means, que aparentava ser uma deficiência preditiva (menor reatividade a mudanças de regime), transformou-se em vantagem financeira — ao evitar o excesso de giro e o efeito **Whipsaw** que corrói os demais modelos. A estratégia HMM puro e as estratégias Ensemble, a despeito de retornos nominais superiores ao benchmark, não apresentam superioridade estatisticamente comprovável, evidenciando que seus ganhos estão dentro do intervalo de incerteza esperado para o período amostral específico.




Figura 15: Forest Plot — Diferença de Retorno vs. Buy-and-Hold com Intervalo de Confiança 95% (Block Bootstrap)

4.3.2 Discussão sobre a Generalização dos Resultados

Os resultados apresentados neste estudo foram obtidos a partir de um conjunto específico de condições empíricas que delimitam sua generalização direta:

1. **Período amostral:** O período **Out-of-Sample** (2023–2026) engloba uma das maiores crises de crédito privado brasileiro da história recente (com colapsos sequenciais de Lojas Americanas, Light S.A. e incertezas em torno do Grupo Pão de Açúcar). A eficácia contundente das estratégias ativas, especialmente do K-Means (Vende Amarelo), foi alavancada pela necessidade extrema de mitigação de risco durante choques agudos. Em ciclos de expansão de crédito com baixa volatilidade, estratégias ativas podem apresentar performance marginal inferior ao carregamento passivo, devido ao peso dos custos transacionais sem a contrapartida de grandes eventos de cauda.
2. **Universo de ativos:** A amostra final se restringe a debêntures com liquidez mínima suficiente para permitir a convergência do motor de estimação EGARCH. Ativos de crédito marcadamente ilíquidos — que operam fora da curva Anbima ou não possuem fluxo de negociação regular em mercado secundário — não foram testa-

dos por essa metodologia estrutural. Estratégias aplicadas a essas carteiras podem sofrer distorções materiais.

3. **Estrutura de custos operacionais:** A simulação assumiu um custo de transação de 0,5% por operação, considerado conservador e aderente à média do mercado secundário corporativo em tempos normais. Contudo, sob estresse extremo, a liquidez direcional do mercado seca e os **spreads** de compra-venda (**bid-ask spread**) podem expandir severamente, inviabilizando ou majorando exponencialmente as saídas defensivas executadas pelos algoritmos.
4. **Qualidade da informação (Marcação a Mercado):** Os indicadores preditivos dependem intimamente do reflexo primário dos **spreads** na curva indicativa (Anbima). O alisamento intrínseco aos processos de marcação a mercado no Brasil introduz latência que pode atrasar a identificação quantitativa de risco por parte dos motores bayesianos.

Apesar dessas limitações inerentes à amostra brasileira, os alicerces metodológicos da arquitetura desenvolvida — notadamente a integração da volatilidade condicional leptocúrtica como **feature** para particionamento temporal dinâmico (**Time-Series Clustering**) — constituem um arcabouço inovador que pode ser adaptado e generalizado para outros mercados globais de crédito estruturado caracterizados por informações assimétricas e baixa liquidez.

5 CONCLUSÃO

Esta dissertação teve como objetivo desenvolver e avaliar uma metodologia quantitativa baseada em Aprendizado de Máquina Não Supervisionado para a identificação precoce de eventos de estresse (**Early Warning**), por meio da criação e monitoramento de regimes de risco no mercado secundário de debêntures brasileiro. Motivada pela assimetria de retornos inerente aos ativos de crédito privado, pela baixa liquidez estrutural e pelos recentes e severos eventos de crédito (como os casos Lojas Americanas, Light e Grupo Pão de Açúcar), a pesquisa buscou responder se algoritmos de clusterização poderiam atuar como ferramentas táticas viáveis para a mitigação de perdas severas, superando o carregamento passivo de portfólios.

5.1 Principais Descobertas

O estudo revelou achados importantes que conectam a modelagem teórica à aplicabilidade financeira prática:

1. **Adequação da Modelagem de Cauda (EGARCH-t):** A adoção do modelo EGARCH-t acoplado ao **Expected Shortfall** provou-se eficaz na precificação do risco isolado dos ativos. A validação por meio dos

testes conjuntos de Christoffersen, conforme apresentado na Seção 4.1, confirmou que o modelo é capaz de absorver a heterocedasticidade condicional e evitar o agrupamento de violações (**volatility clustering**), mesmo frente aos massivos choques de iliquidez do período **Out-of-Sample**, respondendo, assim, à falha dos modelos de VaR tradicionais citados na Seção 2.2.

2. **O Paradoxo entre Acurácia Preditiva e Desempenho Financeiro:** Observou-se uma dicotomia entre o Modelo Oculto de Markov (HMM) e o particionamento geométrico (K-Means). O HMM demonstrou superioridade

analítica ao integrar a dependência temporal (matrizes de transição), conseguindo antecipar de forma ágil a deterioração de crédito em eventos como o do Grupo Pão de Açúcar, conforme apresentado na Seção 4.2.1 e Seção 4.2.2. Contudo, no **backtest** financeiro, a estratégia baseada no K-Means (**Vende Amarelo**) entregou a melhor relação risco-retorno (**Calmar Ratio** de 1,603 contra 0,866 do HMM). Conforme apresentado na Seção 4.3, a “lentidão” apresentada pelo K-Means para mudança de regimes funcionou como um filtro de ruído contra o efeito contágio do mercado, poupando a carteira do excesso de giro e dos custos de transação (que conforme

Seção 3.3, foi definido como 0,5% por operação) que penalizaram o HMM com **draw-downs** profundos gerados por alarmes falsos.

3. **A Armadilha da Combinação de Modelos:** O estudo documentou a falha do modelo **Ensemble**. Ao tentar fundir a reatividade do HMM com a estabilidade do K-Means,

a modelagem mista deixou a carteira vulnerável ao efeito chicote (**whipsaw**). O modelo realizava vendas impulsionadas pelo HMM e recompras tardias pelo K-Means, corroendo o capital com excesso de custos transacionais, entregando o pior retorno do período. A combinação acabou exacerbando os defeitos de cada modelo, e reforçando a necessidade da importância da avaliação do momento de compra e venda dos papéis para evitar que o carregamento obtido seja consumido por custos transacionais e perdas decorrentes de operações em momentos inoportunos.

5.2 Implicações Práticas

Para a indústria de gestão de recursos, a metodologia desenvolvida oferece um arcabouço robusto e sistemático para a gestão tática em carteiras de crédito privado. Em um mercado caracterizado por baixa liquidez estrutural e precificação ocasionalmente defasada, a adoção de gatilhos quantitativos pode substituir ou auxiliar o viés comportamental humano, que frequentemente leva gestores a reter posições perdedoras na esperança de uma reversão que muitas vezes não ocorre.

A operacionalização desta pesquisa demonstra que o melhor modelo preditivo não é, necessariamente, a melhor estratégia de **trading**. A escolha do motor de decisão deve estar alinhada aos atritos do mercado e aos objetivos do portfólio. Os resultados observados foram frutos de simulações históricas baseado em regras fixadas e comparados contra uma estratégia buy-and-hold, durante uma atuação no mercado secundário para fechamento de posições devido a early warnings, outros fatores podem influenciar no preço e capacidade de liquidação das posições

5.3 Limitações e Recomendações para Trabalhos Futuros

Apesar dos resultados promissores, o presente estudo possui limitações inerentes à estrutura e à qualidade dos dados financeiros brasileiros. A principal limitação concentrou-se na convergência da volatilidade condicional (EGARCH) para ativos extremos, onde longos históricos de ausência de negociação distorceram a estimação dos parâmetros de risco no período **In-Sample**. Além disso, a dependência exclusiva

da curva de apreçamento divulgada pela Anbima impõe que o modelo herde a possível ineficiência temporal ou “suavização” de preços inerente ao fechamento indicativo da associação.

Para trabalhos futuros, recomenda-se a exploração das seguintes frentes:

- A incorporação de modelos de aprendizado profundo focados em sequências temporais não-lineares, como Redes Neurais Recorrentes (LSTMs) ou **Transformers**, que podem lidar de maneira mais nativa com espaços irregulares de negociação (**irregularly sampled time-series**);

- A inclusão de dados não-estruturados, como Análise de Sentimento de notícias corporativas (**Natural Language Processing**) e dados macroeconômicos em tempo real, atuando como variáveis preditoras exógenas (covariáveis)

diretamente nas matrizes de transição probabilísticas do HMM, na tentativa de reduzir a ocorrência de falsos alarmes causados por contágio de mercado secundário;

- A adoção de modelos integrados de volatilidade condicional e mudança de regime, como o **Markov-Switching GARCH** (MS-GARCH) modelado via inferência Bayesiana (**Markov Chain Monte Carlo** - MCMC),

permitindo a calibração unificada do modelo e a inserção de conhecimento de especialistas como distribuições **a priori**;

- O mapeamento do contágio e do risco sistêmico entre emissores por meio da Teoria de Redes e de Cópulas Extremas (**Extreme Copulas**),

para capturar a dependência não-linear de cauda e a topologia de propagação de choques de liquidez no mercado de crédito corporativo.

BIBLIOGRAFIA

- ACERBI, Carlo; TASCHE, Dirk. On the coherence of expected shortfall. **Journal of Banking & Finance**, v. 26, n. 7, p. 1487–1503, 2002.
- ALTMAN, Edward I. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. **The journal of finance**, v. 23, n. 4, p. 589–609, 1968.
- ANBIMA. **Mercado de capitais bate recorde histórico e encerra 2025 com emissão de R\$ 838,8 bilhões**. Disponível em: <<https://data.anbima.com.br/publicacoes/boletim-de-mercado-de-capitais/mercado-de-capitais-bate-recorde-historico-e-encerra-2025-com-emissao-de-8388-bilhoes>>.
- ARDIA, David *et al.* Markov-switching GARCH models in R: The MSGARCH package. **Journal of Statistical Software**, v. 91, n. 4, p. 1–38, 2019.
- ARTZNER, Philippe *et al.* Coherent measures of risk. **Mathematical finance**, v. 9, n. 3, p. 203–228, 1999.
- BAO, Jack; PAN, Jun; WANG, Jiang. The Illiquidity of Corporate Bonds. **The Journal of Finance**, v. 66, n. 3, p. 911–946, 2011.
- BARRA, Anuar de Sousa. **Estudo exploratório sobre a liquidez das debêntures no mercado secundário brasileiro: medidas diretas de liquidez e características dos títulos e emissores**. Dissertação de Mestrado—[S.l.: S.n.].
- BAUM, Leonard E. *et al.* A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. **The annals of mathematical statistics**, v. 41, n. 1, p. 164–171, 1970.
- BISHOP, Christopher M. **Pattern recognition and machine learning**. [S.l.]: Springer, 2006.
- BOLLERSLEV, Tim. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, v. 31, n. 3, p. 307–327, 1986.
- BORDA, Jean-Charles de. Mémoire sur les élections au scrutin. **Histoire de l'Académie Royale des Sciences pour 1781**, 1781.
- CALIŃSKI, Tadeusz; HARABASZ, Jerzy. A dendrite method for cluster analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974.
- CHRISTOFFERSEN, Peter F. Evaluating interval forecasts. **International Economic Review**, v. 39, n. 4, p. 841–862, 1998.

CORRÊA, Paulo Eduardo Gonçalves Camargo; SHENG, Hsia Hua. O apreçamento do spread de liquidez no mercado secundário de debêntures. **Revista de Administração**, v. 45, n. 1, p. 30–42, 2010.

DAVIES, David L. ; BOULDIN, Donald W. A cluster separation measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, n. 2, p. 224–227, 1979.

DUFFIE, Darrell; SINGLETON, Kenneth J. **Credit risk: pricing, measurement, and management**. [S.l.]: Princeton university press, 2003.

ENGLE, Robert F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. **Econometrica**, v. 50, n. 4, p. 987–1007, 1982.

FREITAS, Wilson. **python-bcb: Interface Python para a API de dados abertos do Banco Central do Brasil**. Disponível em: <<https://wilsonfreitas.github.io/python-bcb/>>.

HAAS, Markus; MITTNIK, Stefan; PAOLELLA, Marc S. A new approach to Markov-switching GARCH models. **Journal of financial econometrics**, v. 2, n. 4, p. 493–530, 2004.

HAIR, Joseph F. *et al.* **Multivariate data analysis**. [S.l.]: Pearson Prentice Hall Upper Saddle River, NJ, 2010. v. 7

HAMILTON, James D. **Time series analysis**. [S.l.]: Princeton University Press, 1994.

HO, Tin Kam; HULL, Jonathan J.; SRIHARI, Sargur N. Decision combination in multiple classifier systems. **IEEE transactions on pattern analysis and machine intelligence**, v. 16, n. 1, p. 66–75, 1994.

JORION, Philippe. **Value at Risk: The New Benchmark for Managing Financial Risk**. 3rd. ed. [S.l.]: McGraw-Hill, 2006.

KITTLER, Josef *et al.* On combining classifiers. **IEEE transactions on pattern analysis and machine intelligence**, v. 20, n. 3, p. 226–239, 1998.

KUPIEC, Paul H. Techniques for verifying the accuracy of risk measurement models. **The Journal of Derivatives**, v. 3, n. 2, p. 73–84, 1995.

MERTON, Robert C. On the pricing of corporate debt: The risk structure of interest rates. **The Journal of finance**, v. 29, n. 2, p. 449–470, 1974.

NELSON, Daniel B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, v. 59, n. 2, p. 347–370, 1991.

POLITIS, Dimitris N. ; ROMANO, Joseph P. The stationary bootstrap. **Journal of the American Statistical Association**, v. 89, n. 428, p. 1303–1313, 1994.

RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. **Proceedings of the IEEE**, v. 77, n. 2, p. 257–286, 1989.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987.

SAEYS, Yvan; ABEEL, Thomas; PEER, Yves Van de. Robust feature selection using ensemble feature selection techniques. *Em*: 2008.

SHENG, Hsia Hua; SAITO, Richard. Liquidez das debêntures no mercado brasileiro. **Revista de Administração**, v. 43, n. 2, p. 176–185, 2008.

TSAY, Ruey S. **Analysis of financial time series**. 2. ed. [S.l.]: John Wiley & Sons, 2005.