

Nome da Universidade / Instituição

Guilherme Tolotti Azevedo

Modelagem de Risco de Cauda no Mercado de Crédito Privado: Uma Abordagem via Markov-Switching GARCH (HMM)

Dissertação apresentada como requisito parcial
para obtenção do grau de Mestre.

Orientador: Nome do Orientador

São Paulo, SP

2026

SUMÁRIO

1 Introdução	4
1.1 O Problema de Pesquisa	5
1.2 Objetivos (Geral e Específicos)	6
2 Revisão da Literatura	6
2.1 Value-at-Risk e Modelos da Família GARCH	7
2.2 A Hipótese de Mudança de Regimes (Regime-Switching)	8
2.3 Aprendizado de Máquina Não Supervisionado: K-Means e HMM	9
2.3.1 K-Means	9
2.3.2 Hidden Markov Models (HMM)	10
3 Metodologia e Dados	11
3.1 Coleta e Tratamento de Dados (ANBIMA)	12
3.2 O Pipeline de Risco (EGARCH, K-Means e HMM)	14
3.2.1 Pré-processamento de Dados e Filtros	16
3.2.2 EGARCH	17
3.2.3 Seleção de variáveis	23
3.2.4 K-Means	27
3.2.5 HMM	28
3.2.6 Modelo Misto (Ensemble)	30
3.3 Protocolos de Validação (Kupiec POF e Backtest)	31
4 Resultados e Discussões	33
4.1 Rejeição da Hipótese Nula (Validação de Kupiec)	33
4.2 O Desempenho do HMM vs K-Means na Classificação	33
4.3 Simulação de Portfólio (Backtest Financeiro)	33
5 Conclusão	33
5.1 Principais Descobertas	33
5.2 Implicações Práticas	34

5.3 Limitações e Recomendações para Estudos Futuros	34
Bibliografia	35

1 Introdução

O mercado de crédito privado brasileiro vem crescendo continuamente, e se consolidando como uma ferramenta de captação de recursos para as empresas, como se pode observar em Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais (ANBIMA) (2026). Uma das principais ferramentas de crédito privado utilizadas são as debêntures, que tiveram um crescimento de 307% no volume de emissões quando comparamos o volume observado em 2020 contra o volume observado em 2025. Porém, esse mercado enfrenta problemas de liquidez, e conforme Sheng; Saito (2008), apresenta as seguintes características:

- As transações são dispersas e ocorrem em duas diferentes instituições - Bolsa de Valores de São Paulo (Bovespa Fix) e Sistema Nacional de Debêntures (SND);
- Existe baixa atividade, não havendo registro de transações para períodos longos e, em algumas emissões de debêntures, o volume de transações no mercado secundário é quase nulo e o valor total em reais é baixo;
- Existe um baixo número de negociações diárias;
- Predominância de debêntures de médio prazo (vencimento em torno de quatro anos);
- Demanda significativa por investidores institucionais e fundos de pensão;
- Em geral as emissões não são conversíveis em ações;
- Alguns investidores adquirem debêntures e as mantêm até o vencimento;

Apesar de algumas dessas características estruturais se manterem verdadeiras, como:

- A baixa liquidez (onde mais da metade das marcações diárias do mercado giram volumes inferiores a R\$ 1 milhão);
- A exclusividade de emissões do tipo simples;

e outras características, como:

- A baixa presença de pessoas físicas e investidores estrangeiros;
 - O fato de os intermediários manterem os papéis na carteira até o vencimento;
- serem reforçadas por estudos mais recentes como Barra (2021) e Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais (ANBIMA) (2026), houve algumas mudanças relevantes que sugerem um amadurecimento institucional. A amostra deste estudo indica que as empresas têm conseguido alongar o perfil de suas dívidas, com as debêntures apresentando uma mediana de sete anos de prazo até o vencimento.

1.1 O Problema de Pesquisa

Apesar do crescimento e amadurecimento do mercado de crédito privado brasileiro, a baixa liquidez no mercado secundário representa um desafio para a precificação e acompanhamento de risco do papel. Estudos como Corrêa; Sheng (2010) focam em problemas de apreçamento do spread de crédito, enquanto estudos como Sheng; Saito (2008) analisam os fatores que afetam o prêmio de liquidez em debêntures. Contudo, muitos modelos assumem situações normais de mercado, enquanto outros fazem suposições ainda mais fortes que não condizem com a realidade do mercado brasileiro. Bancos e assets muitas vezes seguem controlando o risco de cauda de debêntures baseado em GARCH e VaR contínuos, que possuem suposições violadas quando ocorrem eventos extremos, e podem estar subestimando o risco observado.

Como demonstrado por BAO; PAN; WANG (2011), o mercado de crédito corporativo apresenta fricções de liquidez que impedem o ajuste contínuo dos preços, eventos recentes envolvendo o Grupo Pão de Açúcar e Americanas são exemplos dos saltos observados nos preços das debêntures desses emissores; No caso das Americanas, houve uma queda de 50% no valor das debentures em um dia, acumulando perdas de cerca de 90% em uma semana; Já no caso do Grupo Pão de Açúcar, foram observados deságios de até cerca de 70%. Nessas situações, modelos GARCH

e VaR tradicionais falham em capturar o risco de cauda, uma vez que segundo Jorion (2006), assumem que a liquidação será instantânea a preço de tela. Para corrigir essas suposições e capturar quebras estruturais, a literatura mais moderna defende a transição para modelos baseados em mudanças de regime (Markov-Switching), conforme proposto por Haas; Mittnik; Paoletta (2004) e Ardia et al. (2019).

1.2 Objetivos (Geral e Específicos)

A proposta desse trabalho é desenvolver e avaliar os resultados de uma modelagem de risco de crédito adotada a realidade do mercado brasileiro de debêntures. Ao invés de tentarmos prever flutuações contínuas, o modelo busca identificar eventos de mudança de regime para disparar alertas de risco antes de que se observem grandes perdas, possibilitando ao detentor das debentures, um tempo hábil para tentar vender o papel antes que as perdas se materializem.

Para isso, serão utilizadas duas abordagens de modelagem de risco, uma baseada em K-Means e outra em HMM, ambas utilizando como features a volatilidade e o spread das debentures, utilizando dados abertos divulgados pela Anbima. Além disso, toda a aplicação, feita em python, será disponibilizada para consulta pública no github, permitindo que qualquer interessado possa replicar os resultados, incluindo o download das informações utilizadas no trabalho, já que os dados são públicos.

2 Revisão da Literatura

A ideia central deste trabalho parte da modelagem de risco de crédito de debêntures. Mas o que é risco? Existem várias definições. Jorion (2006) talvez tenha uma das mais simples e intuitivas: risco é a volatilidade dos resultados inesperados, que podem representar o valor de ativos, patrimônios ou resultados. E esse risco pode ser originado de várias formas, criados pelos humanos como ciclos de negócios,

inflação, mudanças políticas, guerras, etc., ou podem ocorrer devido a fenômenos naturais como terremotos, tsunamis, etc. É na tentativa de combater esses riscos que a economia cresce e as tecnologias se desenvolvem.

Parte significativa do mercado financeiro atual foi desenvolvida na tentativa de lidar ou compartilhar esses riscos. Ao mesmo tempo que o mercado se desenvolveu, se gerou a necessidade de limitar as perdas potenciais sem deixar de tomar risco. Existem controles **ex post**, mas esses não conseguem garantir que as perdas sejam próximas ao limite desejado; ao depender da sorte, podem ser maiores. A solução é o uso de modelos quantitativos **ex ante** que limitam a exposição a determinados ativos ou fatores de risco baseados em distribuições de probabilidade, como por exemplo os modelos de **Value at Risk**.

2.1 Value-at-Risk e Modelos da Família GARCH

O **Value at Risk** (VaR) pode ser definido de forma intuitiva como a maior perda esperada de uma carteira em um determinado período de tempo, com um determinado nível de confiança. Ou, de forma mais formal, é o quantil da distribuição de ganhos e perdas projetadas para um horizonte de tempo. Muitas vezes para séries temporais, essa projeção é feita por meio de modelos como o GARCH, que apesar de ser amplamente utilizado, falha em choques assimétricos, como observamos nos eventos recentes envolvendo o Grupo Pão de Açúcar e Americanas. Para superar essa fraqueza do modelo GARCH, Nelson (1991) propõe o modelo EGARCH, que captura assimetrias na volatilidade dos ativos financeiros.

Matematicamente, a especificação da variância condicional do EGARCH(1,1) de Nelson (1991) é dada por:

$$\ln(\sigma_t^2) = \omega + \alpha \left[|z_{t-1}| - \sqrt{\frac{2}{\pi}} \right] + \gamma z_{t-1} + \beta \ln(\sigma_{t-1}^2) \quad (1)$$

Onde:

- σ_t^2 é a variância condicional no tempo t .
- z_t é o resíduo padronizado ($z_t = \varepsilon_t / \sigma_t$).
- α mensura o “efeito tamanho” (a magnitude do choque).
- γ captura o **efeito assimétrico** (o sinal do choque).
- β mede a persistência da volatilidade.

Se $\gamma < 0$, choques negativos em $t - 1$ aumentam a variância em t mais do que choques positivos da mesma magnitude, diferentemente do modelo GARCH tradicional.

2.2 A Hipótese de Mudança de Regimes (Regime-Switching)

Porém, mesmo o modelo EGARCH que possui o tratamento da assimetria dos retornos possui limitações. A família GARCH, como explicado por Tsay (2005), assume que os parâmetros do modelo (ou seja, os pesos ω , α , γ e β da Equação Equação 1) e a “variância incondicional” não mudam ao longo do tempo. Eles são constantes, baseados em uma única média do comportamento global da série.

Devido a essa constância, esses modelos tem dificuldade em se adaptarem quando existe uma quebra de regime, como os eventos de crédito que foram comentados acima, que uma vez divulgados, alteraram toda a dinâmica de negociação e preço dos papéis, as informações que foram observadas antes do evento não são mais tão relevantes para prever o comportamento futuro dos ativos afetados. Hamilton (1994) mostra que essas quebras estruturais ocorrem na maioria das series macroeconomicas ou financeiras que possuem um período suficientemente longo. Como solução a esse problema, o autor propõe a hipótese de mudanças de regime (**Regime-Switching**). Segundo essa teoria, a economia e os mercados não têm um estado único. Eles transitam entre diferentes estados, onde as equações que regem os preços mudam dependendo do regime atual. Para solucionar esse problema, foi proposto a utilização de Cadeias de Markov para modelar a transição entre diferentes estados da economia.

2.3 Aprendizado de Máquina Não Supervisionado: K-Means e HMM

Enquanto alguns autores na literatura propõem a integração direta (como os modelos MS-GARCH unificados), neste trabalho adotam-se dois modelos tintos para agrupar e classificar os regimes de risco utilizando como variáveis de entrada o **spread** de crédito e a volatilidade extraída pelo modelo EGARCH. Esses modelos são:

2.3.1 K-Means

Um algoritmo popular para problemas de clusterização é o **K-means** que particiona os dados em K grupos distintos, minimizando a variância intra-cluster. Para utilizá-lo no problema em questão, foram criados três clusters de acordo com o nível de risco do papel, de forma que o esperado é que conforme um papel começa apresentar durante o seu período de negociação uma variação mais errática do seu spread ele vá migrando do cluster de baixo ao cluster de alto risco.

Para entender melhor essa aplicação vamos tomar como base Bishop (2006), em nosso problema temos que identificar grupos ou **clusters** de dados em um espaço multidimensional. Suponha que esse espaço seja dado por $\{x_1, x_2, \dots, x_N\}$ onde cada um dos N pontos no espaço multidimensional é um vetor de dimensão D .

O objetivo do algoritmo de K-means é particionar os dados em K grupos distintos, de forma que a soma do quadrado das distancias de cada ponto com o vetor μ_k mais próximo seja minimizada. Ou de forma mais formal:

$$J = \sum_{\{n=1\}}^N \sum_{\{k=1\}}^K r_{nk} \|x_n - \mu_k\|^2 \quad (2)$$

Onde $r_{nk} \in \{0, 1\}$ é uma variável indicadora, onde $r_{nk} = 1$ se o ponto x_n foi alocado ao **cluster** k e $r_{nj} = 0$ para $j \neq k$, enquanto μ_k representa o vetor centroide do **cluster** k . O objetivo é encontrar os valores de r_{nk} e μ_k que minimizam J . Isso pode ser realizado por meio de um algoritmo iterativo, dividido em duas etapas, conhecido como Algoritmo de Lloyd (ou, mais genericamente, algoritmo de maximização de expectativa (EM)).

O modelo, por vezes apresenta um problema conhecido como **Label Switching**, no qual os centróides gerados recebem rótulos arbitrários, isso ocorre porque o algoritmo inicializa os centróides (μ_k) de forma aleatória e busca minimizar a soma das distancias quadráticas (conforme a Equação 2), independentemente dos rótulos atribuídos aos centróides. Porém, existem muitas formas conhecidas de tratar esse problema. A forma adotada nesse trabalho será detalhada em Seção 3.2.4, mas envolve a aplicação de um vetor de polaridade de risco para fixar os rótulos nos regimes Verde (baixo risco), Amarelo (alerta) e Vermelho (crise).

Apesar de sua eficiência em separar os períodos de forma estática, minimizando J , o K-Means é cego para o tempo: ele ignora a probabilidade de transição de um dia para o outro, e como será analisado posteriormente, isso dá maior estabilidade aos resultados, porém, faz com seu tempo de reação seja mais lento, ou em alguns casos seja insensível devido a uma quebra de regime abrupta.

2.3.2 Hidden Markov Models (HMM)

Para corrigir a imperfeição temporal do K-Means, utiliza-se o HMM, um modelo probabilístico ideal para utilização em dados sequenciais. Conforme detalhado por Bishop (2006), o HMM parte do princípio de que os dados que medidos no mercado (como, por exemplo, o **spread** e a volatilidade) são reflexos de um estado que não pode ser observado. Esse estado é a causa do comportamento dos preços, e é chamado de **variável latente** (ou *hidden state*).

Seja z_n a variável latente que representa o estado ou regime oculto do mercado no tempo n . No HMM, assume-se que o comportamento do variável observada é gerado por um processo de Markov onde a probabilidade do estado atual z_n depende diretamente do estado imediatamente anterior $z_{\{n-1\}}$, o que é expresso por meio de uma distribuição condicional $p(z_n | z_{\{n-1\}})$.

Como as variáveis latentes assumem um conjunto finito de K regimes categóricos (neste estudo, 3 níveis de risco), essa distribuição condicional $p(z_n | z_{\{n-1\}})$ corresponde matematicamente a uma tabela de valores que denotaremos pela matriz A . Os elementos dessa matriz A são conhecidos como **probabilidades de transição** e representam a chance do mercado migrar do regime i para o regime j de um instante de tempo para o outro.

Isso é similar ao tratamento que se faz com matrizes de transição de rating, onde assume-se que uma empresa com rating AAA tem uma chance $p_{AAA \rightarrow AA}$ de migrar para o rating AA no próximo dia, independentemente do rating que a empresa tinha ontem. O tempo necessário para a empresa migrar de AAA para AA não importa, apenas o rating atual influencia a chance.

Dessa forma, o HMM não apenas agrupa os dados de forma estática com base nas emissões observadas (volatilidade e **spread**), mas também estima a matriz de transição estocástica A . É justamente o uso das variáveis latentes z_n e $z_{\{n-1\}}$ que permite ao modelo capturar a inércia do mercado de debêntures e modelar a dinâmica de transições entre regimes.

3 Metodologia e Dados

A análise do risco de crédito das debêntures requer uma coleta extensa de dados e análise rigorosa de sua qualidade para que o modelo implementado seja acurado e capaz de capturar as nuances desejadas. Este capítulo detalha os procedimentos que foram adotados para a coleta, tratamento e análise dos dados. Além dos modelos e validações aplicados neste estudo.

Uma vez que o estudo será disponibilizado juntamente dos códigos-fonte utilizados para sua implementação, todos os procedimentos detalhados abaixo podem ser replicados pelo leitor de forma independente. Para facilitar a reprodução, as funções utilizadas em cada etapa serão citadas, a fim de auxiliar a compreensão do leitor. Os

detalhes sobre a utilização de cada função e da ferramenta como um todo poderão ser encontrados na documentação do projeto disponível no repositório do GitHub.

3.1 Coleta e Tratamento de Dados (ANBIMA)

Os dados base de spread por debenture e dia, que alimentam essa pesquisa foram extraídos do site da ANBIMA, mais especificamente na seção de Prévias Públicas de Negociação de Instrumentos Financeiros, que pertence ao sistema REUNE. O período da amostra foi do segundo dia de janeiro de 2018 a 10 de julho de 2026. Os dados extraídos diários possuem as seguintes colunas: Código Cetip, Tipo, Agrupamento, Taxa Mínima, Taxa Média, Taxa Máxima, Preço Mínimo, Preço Médio, Preço Máximo e Faixa de Volume. O leitor pode replicar esse download por meio da classe `data.anbima_scraper.AnbimaScraper`; para maior comodidade também se pode utilizar `data.run_scraper_full.rodar_extracao` e posteriormente `data.unify_csvs.unify_csvs`, uma vez que o download gera um arquivo csv por dia de consulta.

Já as informações cadastrais foram obtidas na página Debentures.com.br (que será substituída pelo ANBIMA Data) por meio de consulta utilizando o pacote `debentures_dot_com`. As informações obtidas são referentes a emissão das debentures e incluem informações como: Ticker, Indexador, Data de Emissão, Data Vencimento, Empresa, CNPJ, Emissão, Situação, Classe, Garantia, Quantidade Emitida, Quantidade Mercado, Taxa Emissão, Motivo de Saída, entre outras; para mais informações sobre os campos citados ou campos disponíveis consultar a página do ANBIMA Data e/ou o pacote `debentures_dot_com`. O leitor pode replicar esse download por meio da função `data.build_cadastro.build_cadastro_mestre`.

As informações macroeconômicas (CDI, Selic, IPCA Mensal e 12M e IGPM Mensal) foram extraídas utilizando o pacote `python-bcb`. O leitor pode replicar esse download por meio da função `data.download_macro.download_macro_data`, que é uma

aplicação direta do pacote de Freitas ([S.d.]) para as variáveis de interesse para a pesquisa.

Na etapa de pré-processamento, mais detalhada em Seção 3.2.1, foi realizada a normalização e tratamento das variáveis. Como a base de dados extraída da ANBIMA abrange múltiplos indexadores (como IPCA+, DI+ e % do CDI), foi necessário separar esse grupos treinar e aplicar o modelo de forma independente, criando uma instância de modelagem por indexador, conforme será detalhado nas sessões seguintes, uma vez que os papéis de diferentes indexadores possuem comportamento de risco distintos, assim como distinta sensibilidade a variação da taxa.

Como citado em Seção 1, um desafio inerente ao mercado secundário de crédito privado brasileiro é a baixa liquidez dos ativos, inclusive com alguns chegando a possuir dias sem negociação. A ANBIMA classifica o volume de negociação em faixas, sendo a faixa mais baixa dada por “Até 1MM”, e portanto, dado as informações possuídas na realização dessa pesquisa, esses são os ativos definidos como ilíquidos. No código implementado, desenvolveu-se uma rotina de tratamento governada pela flag `filter_low_liquidity`. Quando habilitada, essa rotina remove da base de dados para treinamento (que será detalhada posteriormente), os ativos que permaneceram como ilíquidos durante um período igual ou superior a 95% da amostra. O propósito dessa funcionalidade é impedir que, caso sejam observados eventos de variação de spread expurios, devido a baixa liquidez, eles não sejam propagados para o modelo EGARCH, o que poderia corromper a estimação da persistência e dos choques (parâmetros α e β) da variância condicional. É importante notar que esses ativos foram removidos apenas da amostra de teste, com a exceção de RDVT11, que foi removido manualmente da amostra devido aos seguintes fatores:

- O ativo não tinha dados de negociação durante a etapa de treinamento, então seria considerado posteriormente, mesmo ilíquido.

- A série de preços do ativo apresenta grandes variações, com um espaçamento elevado entre os dados, o que pode introduzir vieses na estimação.
 - Em 05/12/2023 o ativo foi negociado com PU de 1001.77, sendo negociado novamente apenas em 20/03/2024 com PU de 1.40 e posterior em 21/03/2024 com PU de 0.000014. Voltando a ser negociado em 26/07/2024 com PU de 38.04 e em 28/02/2025 com PU de 754.31.
 - A empresa passou por eventos de reestruturação e recuperação judicial
- A princípio, a empresa deveria ser um exemplo de evento que o modelo deveria prever, porém, devido ao espaçamento irregular de marcações e a falta de liquidez, ocorrem inconsistências expurias, que serão mais detalhadas posteriormente. Também serão mostrados os resultados obtidos quando o ativo é mantido na amostra, para efeitos de comparação.

3.2 O Pipeline de Risco (EGARCH, K-Means e HMM)

Para a implementação dos modelos, foi criado um **pipeline** de risco, que, através de um fluxo linear estima as variáveis de maior impacto para o modelo, realiza o cálculo da volatilidade, VaR e **Expected Shortfall** (ES) por papel e, por fim, aplica o algoritmo K-Means e o Modelo Oculto de Markov (HMM). Uma vez obtidos os resultados do K-Means e HMM, se gera um modelo **Ensemble**, ponderando os resultados de cada modelo. Para mais detalhes sobre o funcionamento do **pipeline**, consultar a documentação do projeto disponível no repositório do GitHub. Abaixo será detalhada a metodologia aplicada em cada etapa. Para facilitar a compreensão sistêmica, a Figura 1 ilustra a arquitetura global do **pipeline**, desde a coleta de dados e divisão temporal até o processamento nos motores estocásticos e a simulação final (**Backtest**).




Figura 1: Arquitetura do Pipeline de Risco e Backtest

3.2.1 Pré-processamento de Dados e Filtros

Os dados coletados em Seção 3.1 foram divididos em dois períodos **In-Sample** e **Out-of-Sample**, sendo o período **In-Sample**, iniciado em janeiro de 2018 até dezembro de 2022 utilizados para a seleção e estimação dos parâmetros dos modelos e o período **Out-of-Sample**, iniciado em janeiro de 2023 até julho de 2026, utilizado para a implementação, observação e validação dos modelos, incluindo a avaliação do modelo em eventos de crédito realizado como o Grupo Pão de Açúcar, amplamente citado nessa pesquisa, devido a suas proporções e ao fato de ter sido o evento mais recente, dado o momento em que este trabalho foi escrito.

Além disso, as variáveis obtidas na etapa Seção 3.1 foram utilizadas como base para o cálculo de outras métricas. Para papéis indexados a um percentual do CDI (ex: 120% do DI), foi realizada uma conversão explícita baseada na taxa CDI anualizada (extraída via `python-bcb`). A transformação anualiza o fator diário do título e extrai o prêmio absoluto sobre a taxa livre de risco, conforme abaixo:

$$F_{\text{cdi}} = \left(1 + \frac{\text{CDI}_t}{100}\right)^{\frac{1}{252}} \quad (3)$$

$$F_{\text{título}} = (F_{\text{cdi}} - 1) \times \left(\frac{\text{Taxa do Ativo}_t}{100}\right) + 1 \quad (4)$$

$$S_t = ((F_{\text{título}})^{252} - 1) \times 100 - \text{CDI}_t \quad (5)$$

Para os títulos atrelados a índices de inflação (como IPCA, IGPM) ou por um prêmio direto sobre o DI (DI Spread), a própria taxa informada no secundário já reflete o prêmio de risco puro:

$$S_t = \text{Taxa do Ativo}_t \quad (6)$$

A partir dessa informação, foi calculado a variação diária do **spread (Delta Spread)**, que atua como o principal input para o ajuste temporal do modelo EGARCH.

$$\Delta S_t = S_t - S_{t-1} \quad (7)$$

Devido a indisponibilidade de dados suficientes para o cálculo de duration se utilizou como base a quantidade de dias úteis para o vencimento do papel (limitado ao mínimo de dois dias), para calcular a taxa ajustada ao prazo, conforme abaixo:

$$\text{Taxa}_{\text{prazo}} = \frac{S_t}{\ln(\max(DU, 2))}$$

Foi também calculado o z-score do spread, utilizando uma janela móvel de 60 dias, além do **Spread Range Intraday** e **Spread Skew Intraday**, dados respectivamente por:

$$S_{\text{range}} = \text{Taxa do Ativo}_{\text{max}} - \text{Taxa do Ativo}_{\text{min}}$$

$$S_{\text{skew}} = \frac{\text{Taxa do Ativo}_{\text{max}} - \text{Taxa do Ativo}_{\text{min}}}{S_{\text{range}} + \varepsilon}$$

Sendo $\varepsilon = 1e - 6$ para evitar divisão por zero. A implementação desses cálculos é realizada de maneira estruturada na classe `DataPreprocessor`.

3.2.2 EGARCH

Apesar do viés teórico discutido em Seção 2, para se optar pelo modelo EGARCH, foram testados vários modelos da família GARCH em um modelo de torneio de **grid-search**, para diferentes tamanhos de amostra. O torneio avaliou os dados a partir de 2018 até o fim de 2022, que foi o período utilizado para treinamento do modelo, sendo o período a partir de 2023 o período de validação dos resultados, conforme detalhado em Seção 3.2.1. O código listou todos os ativos e filtrou os 30, 50, 100, 500, 1000, 3000, 5000 mais líquidos do período.

Para cada um dos ativos selecionados, o otimizador testou um grid combinatório de 32 especificações da família GARCH (utilizando o pacote `arch`). Os hiperparâmetros iterados foram:

- Média Condicional: Fixada em um modelo Autorregressivo de ordem 1 (AR(1)).
- Famílias de Volatilidade: GARCH tradicional, EGARCH (exponencial), GJR-GARCH (assimétrico) e TARCH.
- Defasagens (Lags) p : 1 e 2 (Impacto da variância passada).

- Defasagens (Lags) q : 1 e 2 (Impacto dos choques correntes).
- Distribuição dos Resíduos: Normal e t-Student.

A variável de entrada, conforme detalhado em Seção 3.2.1 foi o **Delta Spread**. Para cada combinação de modelo e ativo foi calculado o Critério de Informação de Akaike (AIC) e então para cada papel o modelo escolhido foi aquele que apresentou menor valor de AIC, cada vez que o modelo foi eleito foi considerado uma vitória. Ao final foi calculado a taxa média de vitórias de cada modelo e eleito aquele que apresentou um maior percentual de vitórias. Matematicamente, a taxa de vitória W_j de um modelo j é dada por:

$$W_j = \frac{\sum_{i=1}^N I_{i,j}}{N} \times 100 \quad (8)$$

onde N é o número total de ativos avaliados e $I_{i,j}$ é uma função indicadora que assume valor 1 se o modelo j apresentar o menor AIC para o ativo i (ou seja, $AIC_{i,j} = \min_k AIC_{i,k}$), e 0 caso contrário.

Adotou-se o modelo que maximizou W_j , garantindo a escolha empírica do algoritmo que melhor se adapta à maior proporção do mercado de crédito. Para amostras pequenas o destaque foi o modelo EGARCH(2,1,1) utilizando a distribuição t-student, porém, a partir de 100 amostras, o EGARCH(1,1,1) com a distribuição t-student passou a apresentar uma maior taxa de vitórias, como se pode observar nas figuras abaixo:




Figura 2: Torneio GARCH: Ranking Médio para a amostra dos 30 ativos mais líquidos.




Figura 3: Torneio GARCH: Ranking Médio para a amostra dos 100 ativos mais líquidos.




Figura 4: Torneio GARCH: Ranking Médio para a amostra ampla de 5000 ativos.

Além disso, nas Figura 3, Figura 4 podemos observar que apesar do EGARCH(1,1,1) com a distribuição t-student apresentar maior taxa de vitórias, o GARCH(1,0,1) com a distribuição t-student apresentou melhor rank médio no teste. Esse resultado é, de certa forma, esperado, uma vez que para debentures liquidas que não possuem grandes choques, o GARCH, como visto em Seção 2 tem alto poder preditivo em condições de normalidade, enquanto o EGARCH pode ser penalizado pela tentativa de estimar assimetria (e paramentos a mais quando comparamos apenas as versões supra citadas), uma vez que o AIC penaliza modelos que possuem parâmetros extras caso eles não tragam ganhos de aderência significativos. Contudo, nos papéis que passam por mais eventos de estresse, é esperado que o EGARCH performe melhor, por ser capaz de capturar assimetrias, além da heterocedasticidade condicional. O que poderia justificar os resultados observados.

Como o intuito dessa pesquisa é estudar justamente os casos de estresse, e não a dinâmica da normalidade, foi adotado o modelo que apresentou maior **Win Rate**, e não aquele que apresentou o melhor rank médio. Essa escolha é justificada pelo fato de que, desejamos possuir o modelo que possui maior taxa de acertos, em detrimento da otimização de parâmetros, o que também justifica a escolha do AIC como métrica principal em detrimento do BIC, que possui maior penalização por parâmetros extras, favorecendo modelos mais simples. Além disso, o EGARCH modela a variancia em escala logarítmica, o que garante que a variancia seja sempre positiva, diferentemente do GARCH tradicional.

Após a eleição do EGARCH(1,1,1) com distribuição t-Student como o motor principal de volatilidade condicional, foram aplicados testes de diagnóstico aos resíduos gerados por este modelo para atestar sua qualidade estatística:

1. **Ljung-Box (Lag 10)**: Para confirmar a ausência de autocorrelação serial remanescente, atestando que a média condicional AR(1) foi bem especificada.

2. **ARCH-LM (Lag 10)**: O teste do multiplicador de Lagrange (Lagrange Multiplier) para verificar se toda a heterocedasticidade condicional foi devidamente absorvida pela variância EGARCH, impossibilitando a persistência do efeito ARCH nos resíduos. Como a modelagem GARCH é realizada univariadamente (ativo a ativo), ajustou-se o modelo campeão para o universo viável de debêntures do período de teste, totalizando uma amostra de 529 debêntures. Este número representa a quantidade de debentures na amostra utilizada para o período que preencheram simultaneamente os critérios de elegibilidade: alta liquidez (exclusão de dias com volume “Até 1MM”), convergência numérica no otimizador de máxima verossimilhança e um histórico contínuo mínimo de 50 observações válidas. Os testes de hipótese foram aplicados aos resíduos de cada um dos ativos, considerando um nível de significância de 5%.

Os resultados demonstram um excelente grau de aderência do modelo ao mercado de crédito secundário brasileiro. Conforme ilustrado na Figura 5, 86,4% dos papéis modelados passaram no teste de Ljung-Box e 94,9% dos ativos passaram no teste ARCH-LM. A aprovação no teste ARCH-LM evidencia que o modelo EGARCH é adequado para a maioria das debêntures analisadas.




Figura 5: Taxa de aprovação dos testes de diagnóstico nos resíduos padronizados do EGARCH(1,1,1) t-Student para 529 debêntures.

Para mais detalhes a respeito dessa implementação, consultar o script `diagnostico_residuos.py` e a classe `ValidadorEconometrico`.

Uma vez definido e implementado o modelo EGARCH(1,1,1) com distribuição t-Student, a distribuição estimada para cada ativo foi utilizada também para o cálculo do Valor em Risco (VaR) e Expected Shortfall (ES) (com percentil de 99%, que foram atribuídos as variáveis `VaR_99` e `Expected_Shortfall_99`, respectivamente) como forma de precificar o risco das debêntures analisadas baseado na série de volatilidade estimada. Como a distribuição escolhida para os resíduos foi a t-student, se $\nu \leq 2$ então a variância da distribuição se torna infinita, levando a erros numéricos no python quando se tenta calcular o VaR e ES, para evitar tais erros, foi aplicado um limite nos graus de liberdade, de forma que ν sempre será maior que 2.05, matematicamente, temos que o tratamento aplicado foi:

$$\nu = \max(2.05, \nu_{\text{est}}) \quad (9)$$

Onde ν_{est} é o valor estimado pelo modelo EGARCH(1,1,1). Além disso, durante a estimação da volatilidade, foram encontrados alguns problemas de otimização devido a instabilidade de algumas séries, principalmente as que permanecem dias sem negociação e quando são negociadas apresentam “saltos” no spread. Como o intuito do modelo é uma classificação de warning, aplicou-se uma limitação na volatilidade calculada, de forma que caso o EGARCH estime um valor que seja 20 vezes maior que o percentil 99% da volatilidade observada do ativo, estimada pelo desvio padrão, o valor é removido da amostra e replica-se a volatilidade observada no dia anterior, matematicamente, temos que o tratamento aplicado foi:

$$\sigma_{\text{est}}(t) = \sigma_{\text{est}}(t - 1) \quad \text{se} \quad \sigma_{\text{est}}(t) > v_{\text{teto}} \quad (10)$$

onde $\sigma_{\text{est}}(t)$ é a volatilidade estimada pelo modelo EGARCH(1,1,1) no dia t , e v_{teto} é o limite superior definido como 20 vezes o percentil 99 da série in-sample. Para mais detalhes a respeito dessa implementação, consultar o script `volatility.py` e a classe `VolatilityEstimator`.

3.2.3 Seleção de variáveis

Nas seções Seção 3.2.1 e Seção 3.2.2 foram listadas as variáveis calculadas:

- Taxa_ZScore
- Volatilidade_EGARCH
- VaR_99
- Expected_Shortfall_99
- Spread_Equivalente
- Spread_Range_Intraday
- Spread_Skew_Intraday

Estas variáveis foram utilizadas como um input para um processo de seleção de variáveis, que eligiu as mais relevantes para utilização nos modelos propostos. Devido a natureza não supervisionada desses modelos, a determinação da relevância dessas

variáveis não pode ser realizada através dos métodos usuais que são utilizados para os processos de aprendizado supervisionado. Por essa razão, a seleção de variáveis implementada realiza combinações iterativas por meio de um **Grid Search** sobre subconjuntos das variáveis candidatas utilizando os dados de treinamento (**In-Sample**). Com intuito de garantir significado econômico aos clusters, a variável `Taxa_ZScore` foi mantida como obrigatória em todas as combinações. Impedindo que o algoritmo selecione apenas variáveis de risco correlacionadas (como a volatilidade EGARCH e o VaR), o que não agregaria valor discriminatório aos clusters, devido a carencia da proficiência relativa ao spread de crédito.

Para cada subconjunto testado, os dados foram padronizados utilizando **RobustScaler** devido a sua capacidade de lidar com outliers, conforme apresentado em Seção 2. Os subconjuntos foram então submetidos a uma clusterização primária utilizando K-Means com $k = 3$ regimes. A qualidade de separabilidade de cada agrupamento foi mensurada através de três métricas:

1. **Silhouette Score** (Rousseeuw (1987)): Mede a coesão intra-cluster frente à separabilidade inter-cluster, variando no intervalo $[-1, 1]$. Nesta métrica, valores maiores indicam melhor adequação, ou seja, valores próximos a 1 sugerem clusters perfeitamente densos e bem separados, enquanto valores próximos a 0 ou negativos indicam forte sobreposição.
2. **Índice Davies-Bouldin** (Davies; Bouldin (1979)): Avalia a razão média da dispersão interna do cluster pela distância euclidiana entre os centróides, penalizando sobreposições. Diferente do Silhouette, nesta métrica valores menores indicam melhor adequação, pois um índice menor (com limite inferior tendendo a zero) significa que os clusters são compactos internamente e distantes uns dos outros.

3. **Índice Calinski-Harabasz** (Caliński; Harabasz (1974)): Mensura a razão entre a variância inter-cluster e a variância intra-cluster, ponderada pelos graus de liberdade do sistema. Para este índice, valores maiores indicam melhor adequação, denotando que a distância entre os centros dos clusters é expressivamente maior que a dispersão dos pontos dentro de cada regime.

Uma vez que as métricas atuam em ordens de grandeza e domínios matemáticos distintos, o subconjunto vencedor não é escolhido por médias absolutas, mas sim pelo método de agregação de Ranks de Borda (**Borda Count**). O algoritmo computa a posição de cada combinação no ranking individual de cada métrica. O **Borda Score** final é dado pela soma das posições invertidas, garantindo uma eleição ordinal, determinística e robusta às magnitudes isoladas de índices específicos.

Como resultado da otimização, o subconjunto eleito como vencedor combinou as variáveis Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99. A Figura 6 ilustra o Top 10 das combinações avaliadas, ordenadas pelo **Borda Score**, evidenciando o desempenho superior do trio escolhido na capacidade de particionamento latente.




Figura 6: Top 10 Subconjuntos de Variáveis classificados pelo método de Borda Count.

Uma forma mais ludica de observar o desempenho superior dessas variáveis, é realizar a comparação de forma multidimensional, a Figura 7 ilustra o desempenho das quatro principais combinações normalizado nos três eixos de avaliação (Coesão, Dispersão e Separação). O gráfico demonstra graficamente como a combinação vencedora consegue maximizar simultaneamente o **Silhouette Score** e o **Calinski-Harabasz**, enquanto minimiza o índice de **Davies-Bouldin**.

Comparação Multidimensional - Feature Selection




Figura 7: Comparação Multidimensional das métricas de particionamento (Min-Max Scaled).

Na Figura 7, o conjunto dado pelas variáveis Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99 e o conjunto dado pelas variáveis Taxa_ZScore,

Volatilidade_EGARCH e VaR_99 parecem ter um desempenho muito similar, mas quando observamos a Figura 6, o primeiro conjunto possui um score superior. A única diferença entre eles é a substituição do Expected Shortfall pelo VaR, porém, o Expected Shortfall possui um score superior em todas as métricas, apesar de ser visualmente difícil a identificação na Figura 7. Além disso, como foi abordado em Seção 2 o Expected shortfall é uma métrica superior, pois enquanto o VaR responde a pergunta “Qual é a perda máxima que posso esperar com 99% de confiança?”, o Expected Shortfall responde a pergunta “Qual é a perda média que posso esperar quando o VaR for excedido?”. Além disso, diferentemente do VaR, o Expected Shortfall é uma medida de risco coerente, o que o torna uma métrica superior.

3.2.4 K-Means

Eleitas as variáveis de entrada do modelo (Taxa_ZScore, Volatilidade_EGARCH e Expected_Shortfall_99), o algoritmo K-Means atua como uma **baseline** atemporal. O processo é realizado iterativamente para cada grupo de indexador (ex: DI, IPCA), a fim de respeitar as dinâmicas particulares de cada mercado.

O primeiro passo é a separação da amostra de treino e teste (**In-Sample** para treino, **Out-of-Sample** para teste), conforme detalhado em Seção 3.2.1. Para garantir que **outliers** extremos (como casos que discutimos nas seções anteriores, em que ativos passam dias sem negociação e depois quando voltam a ser negociados apresentam saltos no spread), aplica-se uma Winsorização (clipagem) no 1º e 99º percentis utilizando os dados **In-Sample**. Esses limites são posteriormente aplicados aos dados **Out-of-Sample**, prevenindo o viés de antecipação de informação (**look-ahead bias**).

Em seguida, os dados são padronizados através do algoritmo RobustScaler. Para capturar o risco relativo de cada papel, o escalonamento é feito individualmente por ativo, possuindo como limitador inferior 10% da variância (IQR) global do indexa-

dor, evitando que ativos estruturalmente ilíquidos sofram explosões numéricas. Já, que, uma vez o **RobustScaler** é dado por:

$$\text{Scaled}(x) = \frac{x - Q_2(x)}{Q_3(x) - Q_1(x)} \quad (11)$$

Caso o IQR ($Q_3(x) - Q_1(x)$) seja nulo ou próximo de zero, o escalonamento se torna indefinido.

O K-Means é então treinado nos dados padronizados com $k = 3$ agrupamentos. Devido à natureza não-supervisionada do K-Means (o problema do **Label Switching**), os centróides gerados recebem rótulos arbitrários. O modelo resolve este problema através de um vetor de polaridade de risco (onde valores maiores de volatilidade e **Z-Score** implicam maior risco), ordenando as médias dos agrupamentos para classificar deterministicamente os regimes em Verde (baixo risco), Amarelo (alerta) e Vermelho (crise).

Na etapa preditiva, para a construção de um modelo misto ponderado (conforme será abordado em Seção 3.2.6), a probabilidade de crise (Prob_Crise_KMeans) é definida com base na distância euclidiana inversa de cada observação **Out-of-Sample** até o centróide Vermelho.

3.2.5 HMM

O Modelo Oculto de Markov (HMM - **Hidden Markov Model**) acrescenta a dependência temporal que o K-Means ignora. O pré-processamento para o HMM segue as exatas mesmas premissas de divisão, winsorização e padronização geométrica (piso de variância) descritas em Seção 3.2.4, adicionando apenas a restrição de que a massa de dados obedeça estritamente a ordenação sequencial no tempo. Já que para o HMM, essa ordenação é de extrema importância para que o modelo consiga modelar as transições entre os estados latentes.

O treinamento **In-Sample** é realizado através de um HMM Gaussiano (GaussianHMM) de 3 estados latentes com matriz de covariância diagonal, aplicando o algoritmo de otimização de **Baum-Welch**. Da mesma forma, os vetores de médias estimadas para as emissões Gaussianas sofrem a correção heurística de **Label Switching** para rotular os estados como Verde, Amarelo e Vermelho.

Uma alteração fundamental feita no HMM padrão diz respeito à calibração da Matriz de Transição de Estados (A). Em bases de dados com regimes muito duradouros, pode haver a total ausência empírica de transições entre estados extremos (como saltos diretos de Verde para Vermelho) na amostra de treinamento. Isso gera probabilidades de transição iguais a zero, transformando os regimes em “estados absorventes” (uma vez que o modelo entre nesse estado, a probabilidade de sair matematicamente se anula). Para mitigar esse problema, aplicou-se primeiramente a **Suavização de Laplace (Additive Smoothing)** sobre a matriz empírica de contagens de transição:

$$P'_{\{ij\}} = \frac{C_{\{ij\}} + \alpha}{\sum_{\{k=1\}}^K C_{\{ik\}} + K\alpha} \quad (12)$$

onde $C_{\{ij\}}$ é a contagem empírica de transições do estado i para o estado j observadas na sequência latente decodificada do **In-Sample**, $K = 3$ é o número de estados, e $\alpha = 1$ atua como o pseudo-fator aditivo.

Complementarmente à equação Equação 12, para garantir matematicamente que o modelo permaneça reativo aos novos choques de mercado em tempo real e não dependa excessivamente da inércia do estado anterior, impôs-se um limiar (piso) arbitrário de 1% (0.01) sobre a matriz de probabilidade de transição, seguido por uma re-normalização linha a linha (para assegurar que o somatório das probabilidades convirja para 1):

$$P''_{\{ij\}} = \max(P'_{\{ij\}}, 0.01) \quad (13)$$

$$P_{\{ij\}} = \frac{P''_{\{ij\}}}{\sum_{\{k=1\}}^K P''_{\{ik\}}} \quad (14)$$

Esse mecanismo em duas etapas força o modelo a manter vias probabilísticas ativas e o impede de tornar-se inerte, especialmente para a saída do estado de crise (Vermelho).

A inferência nos dados **Out-of-Sample** é rigorosamente desenhada para evitar viés do futuro. Para estimar a probabilidade de um ativo estar em crise no dia t , o modelo recebe apenas a sequência de variáveis observáveis do instante inicial até o instante t (janela expansiva causal). A sequência ótima de estados latentes é decodificada utilizando o **Algoritmo de Viterbi**, e a probabilidade marginal instantânea de crise (Prob_Crise_HMM) é inferida simultaneamente pelo algoritmo **Forward-Backward**.

3.2.6 Modelo Misto (Ensemble)

As previsões individuais do K-Means (detalhada em Seção 3.2.4) e do HMM (detalhada em Seção 3.2.5) são posteriormente combinadas em uma pontuação final, buscando mesclar a estabilidade atemporal do particionamento geométrico (K-Means) com a agilidade e memória temporal do filtro bayesiano (HMM).

A combinação matemática é realizada através de uma média ponderada das probabilidades individuais de cada modelo, sendo os pesos definidos **a priori**. Atribui-se um peso de 70% a probabilidade do modelo HMM devido a premissa de que o mercado e os agentes nele inseridos possuem memória e inércia, ou seja, conseguem reagir de forma mais rápida a choques que tragam informações sobre um possível evento de cauda. Os 30% restantes foram atribuídos ao modelo K-Means, atuando como uma âncora temporal de estabilidade, tentando reduzir as várias oscilações observadas no HMM. A equação do **Ensemble** no instante t é dada por:

$$\text{Probabilidade Sintética}_t = 0.70 \times \text{Prob_Crise_HMM}_t + 0.30 \times \text{Prob_Crise_KMeans}_t \quad (4.5)$$

Por fim, para garantir uma combinação mais suave e menos suscetível a ruídos de alta frequência, aplicou-se um filtro de média móvel exponencial de 3 dias (EMA₃) sobre

a “Probabilidade Sintética”, gerando a pontuação final de risco. A fórmula da Média Móvel Exponencial é calculada recursivamente da seguinte forma:

$$\text{Pontuação Final}_t = \alpha \times \text{Probabilidade Sintética}_t + (1 - \alpha) \times \text{Pontuação Final}_{t-1} \quad (16)$$

onde α é o fator de suavização, definido por $\alpha = \frac{2}{N+1}$. Para uma janela de $N = 3$ dias, o fator resulta em $\alpha = 0.5$. Dessa forma, a “Pontuação Final” de risco absorve os choques recentes rapidamente, mas preserva a memória de curto prazo para evitar que a volatilidade diária acione alarmes falsos de crise.

3.3 Protocolos de Validação (Kupiec POF e Backtest)

Para testar a robustez e a aplicabilidade prática do modelo desenvolvido, a etapa de validação foi estruturada em duas dimensões complementares, aplicadas sobre o período **Out-of-Sample** para garantir a ausência de viés prospectivo (**Look-Ahead Bias**). A primeira dimensão avaliada diz respeito à acurácia estatística do modelo, aplicada sobre as saídas do motor EGARCH-t. Foi utilizado o Teste de Proporção de Falhas (**POF - Proportion of Failures**) desenvolvido por Kupiec (1995), que avalia se a frequência empírica de violações (quantidade de dias em que a perda real do ativo excedeu a perda máxima estimada pelo VaR) é estatisticamente compatível com o nível de confiança estipulado pelo modelo. Rejeitar a hipótese nula do teste indica que o motor de volatilidade subestima ou superestima sistematicamente as caudas pesadas observadas no mercado.

A segunda dimensão avalia a qualidade preditiva do modelo no contexto do mercado de crédito corporativo brasileiro por meio de um **Backtest** financeiro, focado em avaliar a eficácia dos diferentes “Regimes de Risco” sugeridos pelos modelos apresentados. O **backtest** simula o impacto de diferentes estratégias de liquidação de portfólio baseadas nas pontuações de risco dos modelos (Verde, Amarelo ou Vermelho), comparando duas abordagens de liquidação para cada modelo:

- Venda Retardada: Estratégia reativa, onde a liquidação ocorre quando o modelo acusa um Regime de Risco Vermelho. Idealmente, caso o modelo seja capaz de prever o estado vermelho antes do choque, esse modelo deveria gerar rentabilidade superior, uma vez que a venda ocorre antes ou no exato momento do choque, evitando assim perdas substanciais. Todavia, se o modelo não for capaz de prever o estado vermelho antes do choque, essa estratégia tende a gerar perdas operacionais, uma vez que o choque já ocorreu e a venda só será realizada após a materialização dos choques no preço dos ativos.
- Venda Preventiva: Estratégia ofensiva, onde a liquidação ocorre quando o modelo acusa um Regime de Risco Amarelo. Idealmente, deveria ser superada pela venda retardada em caso de um modelo ideal, porém, na prática, em cenários onde o modelo pode demorar a reagir na classificação para o regime vermelho, essa estratégia tende a gerar rentabilidade superior, uma vez que a venda ocorre assim que são observados os primeiros sinais de deterioração do ativo, antes da materialização completa do choque. Todavia, caso haja muitos falsos positivos, essa estratégia tende a gerar rentabilidade inferior à venda retardada, uma vez que gera custos operacionais desnecessários e reduz o ganho em cenários de alta volatilidade.

Para tornar a simulação o mais realista possível e capturar a penalidade financeira do **whipsaw** (falsos rompimentos que geram múltiplos sinais de entrada e saída), o **backtest** incorpora uma taxa de custo de transação de 0,5% (50 **bps**). No mercado secundário de crédito brasileiro, caracterizado por menor liquidez e **spreads** de **bid-ask** mais elásticos do que o mercado de ações, a inclusão desse custo é fundamental. Ele atua como um fator de desconto sobre estratégias excessivamente reativas (com alta rotatividade

4 Resultados e Discussões

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur.

4.1 Rejeição da Hipótese Nula (Validação de Kupiec)

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

4.2 O Desempenho do HMM vs K-Means na Classificação

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

4.3 Simulação de Portfólio (Backtest Financeiro)

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

5 Conclusão

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur.

5.1 Principais Descobertas

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

5.2 Implicações Práticas

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

5.3 Limitações e Recomendações para Estudos Futuros

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

Bibliografia

- ARDIA, David *et al.* Markov-switching GARCH models in R: The MSGARCH package. **Journal of Statistical Software**, v. 91, n. 4, p. 1–38, 2019.
- ASSOCIAÇÃO BRASILEIRA DAS ENTIDADES DOS MERCADOS FINANCEIRO E DE CAPITAIS (ANBIMA). **Mercado de capitais bate recorde histórico e encerra 2025 com emissão de R\$ 838,8 bilhões**. Disponível em: <<https://data.anbima.com.br/publicacoes/boletim-de-mercado-de-capitais/mercado-de-capitais-bate-recorde-historico-e-encerra-2025-com-emissao-de-8388-bilhoes>>.
- BAO, JACK; PAN, JUN; WANG, JIANG. The Illiquidity of Corporate Bonds. **The Journal of Finance**, v. 66, n. 3, p. 911–946, 2011.
- BARRA, Anuar de Sousa. **Estudo exploratório sobre a liquidez das debêntures no mercado secundário brasileiro: medidas diretas de liquidez e características dos títulos e emissores**. Dissertação de Mestrado—[S.l.: S.n.].
- BISHOP, Christopher M. **Pattern recognition and machine learning**. [S.l.]: Springer, 2006.
- CALIŃSKI, Tadeusz; HARABASZ, Jerzy. A dendrite method for cluster analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974.
- CORRÊA, Paulo Eduardo Gonçalves Camargo; SHENG, Hsia Hua. O apreçamento do spread de liquidez no mercado secundário de debêntures. **Revista de Administração**, v. 45, n. 1, p. 30–42, 2010.
- DAVIES, David L. ; BOULDIN, Donald W. A cluster separation measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, n. 2, p. 224–227, 1979.
- FREITAS, Wilson. **python-bcb: Interface Python para a API de dados abertos do Banco Central do Brasil**. Disponível em: <<https://wilsonfreitas.github.io/python-bcb/>>.

HAAS, Markus; MITTNIK, Stefan; PAOLELLA, Marc S. A new approach to Markov-switching GARCH models. **Journal of financial econometrics**, v. 2, n. 4, p. 493–530, 2004.

HAMILTON, James D. **Time series analysis**. [S.l.]: Princeton University Press, 1994.

JORION, Philippe. **Value at Risk: The New Benchmark for Managing Financial Risk**. 3rd. ed. [S.l.]: McGraw-Hill, 2006.

KUPIEC, Paul H. Techniques for verifying the accuracy of risk measurement models. **The J. of Derivatives**, v. 3, n. 2, 1995.

NELSON, Daniel B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, v. 59, n. 2, p. 347–370, 1991.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987.

SHENG, Hsia Hua; SAITO, Richard. Liquidez das debêntures no mercado brasileiro. **Revista de Administração**, v. 43, n. 2, p. 176–185, 2008.

TSAY, Ruey S. **Analysis of financial time series**. 2. ed. [S.l.]: John Wiley & Sons, 2005.